

МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ
РОССИЙСКОЙ ФЕДЕРАЦИИ
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ ОБРАЗОВАТЕЛЬНОЕ
УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«Национальный исследовательский ядерный университет «МИФИ»
(НИЯУ МИФИ)

На правах рукописи

Анаэдевха Роджер Ник

**Разработка состязательных устойчивых моделей на
основе искусственного интеллекта в гибридных
системах обнаружения и предотвращения вторжений
для сетевой безопасности**

Специальность: 2.3.1. — «Системный анализ, управление
и обработка информации, статистика» (технические науки)

ДИССЕРТАЦИЯ

на соискание учёной степени
кандидата технических наук

Научный руководитель:

д.ф.-м.н., профессор

Трофимов Александр Геннадьевич

Москва — 2026

Аннотация

Настоящая диссертация посвящена разработке состязательно-устойчивых *моделей* и *алгоритмов* повышения робастности и эффективности **гибридных систем обнаружения и предотвращения вторжений** (далее — Hybrid IDPS) в распределённых и нестационарных условиях. *Объектом* исследования являются Hybrid IDPS, применяемые в защите сетевого трафика, систем беспилотных летательных аппаратов (БПЛА), банковской и финансовой инфраструктуры, систем хранения медицинских данных, промышленного интернета вещей и иных критических областях. *Предметом* исследования являются модели и алгоритмы, обеспечивающие повышение робастности и эффективности Hybrid IDPS при состязательных воздействиях, нестационарном распределении данных, распределённой архитектуре обучения и ограничениях по приватности. Существующие IDPS, опирающиеся на сигнатурный анализ, классические алгоритмы машинного обучения и одиночные модели глубокого обучения, демонстрируют отставание робастности от точности обнаружения на 25–65 п. п. в критически важных системах: здравоохранении, финансах, промышленном IoT, автономных системах и кибербезопасности. Диссертация решает эту фундаментальную проблему через разработку семи новых моделей и алгоритмов (M1–M7), действующих при трёх рабочих условиях — состязательная среда, нестационарные условия и распределённая сетевая динамика — при одновременном выполнении четырёх сквозных требований: робастности, точности, эффективности и дифференциальной приватности. Графовые нейронные сети рассматриваются как одна из ветвей семейства моделей, применяемых в Hybrid IDPS, наряду с моделями пространства состояний, стохастическими дифференциальными уравнениями, байесовскими сетями и теоретико-игровыми алгоритмами.

Впервые установлен принцип сертифицированной устойчивости моделей ГНС непрерывного времени (CT-TGNN и SDE-TGNN), основанный на том, что динамика представлений узлов графа, управляемая дифференциальными уравнениями с ограниченной гладкостью, порождает доказуемые границы чувствительности выходных сигналов к возмущениям вход-

ных данных и структуры. Стохастическое расширение SDE-TGNN заменяет детерминированную динамику стохастическими дифференциальными уравнениями Ито и выводит аналитическое распространение моментов из уравнения Фоккера–Планка, достигая средневзвешенного F1 99,0% на трёх бенчмарках общим объёмом более 52 миллионов образцов, ожидаемой ошибки калибровки 0,042, сертифицированной состязательной робастности 76,2% при радиусе возмущения 0,25 и кросс-доменного переноса 90,5% F1 без дообучения.

Предложена оригинальная теория совместного обеспечения византийской устойчивости, формальной приватности и распределительного выравнивания (FedLLM-API) при обучении моделей ГНС на разрозненных фрагментах графов, принадлежащих разным организациям, без передачи исходных данных. Сходимость доказана со скоростью $\mathcal{O}(1/\sqrt{T})$ при 30% злонамеренных участников, а интеграция большой языковой модели обеспечивает 87,6% F1 при обнаружении новых категорий угроз в режиме zero-shot.

Разработана новая концепция многоуровневого графового представления (TripleE-TGNN), в которой модели ГНС одновременно обучают структуру на уровнях сервисов, трассировок и узлов с механизмом защиты от утраты ранее усвоенных закономерностей через упругую консолидацию весов, достигая точности 96,8% при снижении вычислительных затрат на 40%.

Предложен новый подход к эффективному выводу (MambaShield) на основе селективных пространств состояний, снижающий вычислительную сложность с квадратичной до почти линейной через свёртки быстрого преобразования Фурье, при сохранении устойчивости к отравлению обучающих данных: точность 91,4% при 25% отравления с РАС-байесовскими сертификатами обобщения и задержкой вывода 0,5 мс на поток.

Впервые предложена интегрированная теория калиброванной неопределённости для моделей ГНС (стохастический трансформер и UC-HGP), позволяющая разделять источники ошибок на устранимые (эпистемические) и неустраняемые (алеаторные) с ожидаемой ошибкой калибровки 0,078, обеспечивая снижение нагрузки на аналитиков на 43% через автоматическую сортировку оповещений по неопределённости.

Построена оригинальная концепция единой сертификации устойчиво-

сти, в которой взаимодействие защитника и противника моделируется как стратегическая игра через равновесия Штакельберга с онлайн-обучением без регрета, распространение интервальных границ и рандомизированное сглаживание. Система связывает все семь методов через регуляризацию согласованности с доказанной скоростью сходимости.

Разработана новая теория предметно-ориентированного фундаментального моделирования (CyberSecLLM) на графовых структурах с блоками селективного пространства состояний, дополненными ОДУ, достигающая средней точности 89,1% в режиме zero-shot на бенчмарке из 11 задач (на 20,5 п.п. выше GPT-4) при обработке графовых последовательностей длиной в миллион токенов за 2,3 секунды.

Полная система реализована как платформа промышленного уровня RobustIDPS.ai (DOI: [10.5281/zenodo.19129512](https://doi.org/10.5281/zenodo.19129512)), включающая 51 страницу, 10 функциональных групп и 17 интегрированных моделей нейронных сетей (двухплоскостная архитектура *Python + Rust + XDP*, релиз v4). Четырёхуровневая система защиты LLM достигает 94,5% макроусреднённого обнаружения по 517 сценариям атак с четырьмя коммерческими бэкендами (Claude, GPT-4o, Gemini, DeepSeek). Модуль Multi-Agent PQC-IDS обеспечивает классификацию постквантового трафика. Платформа развёртывается как плагин для Snort и Suricata.

Комплексная экспериментальная валидация охватывает шесть бенчмарк-наборов данных общим объёмом 84,2 миллиона размеченных образцов по 84 категориям атак, единую систему оценки из 23 метрик, абляционные исследования, оценки состязательной робастности при шести семействах атак и эксперименты по кросс-доменному переносу на речь и здравоохранение. Единая система превосходит лучшие базовые методы на 2,9–5,6 процентных пунктов на всех наборах данных.

Все методы сформулированы предметно-независимо на уровне математических операций над графовыми структурами и валидированы через применение к гибридным системам обнаружения и предотвращения вторжений. Все 12 пересечений матрицы условие–требование покрыты с подтверждённой производительностью. Акты внедрения получены от ООО «НИИ ИКТ», ООО «Гексагон» и Центра искусственного интеллекта НИЯУ МИФИ, г. Москва.

Диссертация состоит из введения, шести глав, заключения, библиографического списка из 204 наименований и трёх приложений. Объём основного текста составляет 244 страницы.

Соответствие паспорту специальности 2.3.1. Содержание диссертации соответствует следующим направлениям исследований паспорта научной специальности 2.3.1 «Системный анализ, управление и обработка информации, статистика»:

- **п. 4** «Разработка методов и алгоритмов решения задач системного анализа, оптимизации, управления, принятия решений, обработки информации и искусственного интеллекта» — разработанные модели и алгоритмы M1–M7 обеспечивают робастное обнаружение и принятие решений в условиях состязательных, нестационарных и распределённых воздействий (Глава 2);
- **п. 5** «Разработка специального математического и алгоритмического обеспечения систем анализа, оптимизации, управления, принятия решений, обработки информации и искусственного интеллекта» — программная платформа RobustIDPS.ai реализует специальное математическое и алгоритмическое обеспечение Hybrid IDPS, валидированное на двух показательных областях применения — анализе сетевого трафика (Глава 5) и защите систем БПЛА (Глава 6).

Благодарности

Выражаю искреннюю благодарность моему научному руководителю, профессору Александру Геннадьевичу Трофимову, чьё руководство, интеллектуальная строгость и щедрая поддержка сопровождали каждый этап данного исследования. Его глубокая экспертиза в области математического моделирования и системного анализа заложила основу, на которой были построены теоретические вклады настоящей диссертации.

Благодарю профессорско-преподавательский состав и коллег-исследователей Института интеллектуальных кибернетических систем и кафедры кибернетики Национального исследовательского ядерного университета «МИФИ» за создание стимулирующей академической среды. Обсуждения, семинары и дух сотрудничества на кафедре существенно обогатили данную работу.

С благодарностью отмечаю поддержку аспирантской программы МИФИ, гранта на создание исследовательских центров в области искусственного интеллекта от Министерства экономического развития Российской Федерации (идентификатор 000000С313925РЗQ0002), а также вычислительные ресурсы, предоставленные для проведения экспериментальной работы, описанной в диссертации. Масштаб эмпирической валидации был бы невозможен без доступа к соответствующей инфраструктуре.

Наконец, я бесконечно признателен моей семье и друзьям, чьё терпение, поддержка и вера в это начинание поддерживали меня на протяжении всех лет учёбы и исследований. Спасибо всем.

Роджер Ник Анаэдевха
Москва, 2026

Оглавление

Аннотация	i
Благодарности	v
Список сокращений	ix
Введение	1
1 Анализ гибридных систем обнаружения и предотвращения вторжений и теоретические основы повышения их робастности	30
1.1 Hybrid IDPS как объект исследования: определение, классификация и предметные области применения	33
1.2 Модели и алгоритмы, применяемые в Hybrid IDPS: систематизация подходов	38
1.3 Проблемы и уязвимости моделей в Hybrid IDPS	40
1.4 Графовые нейронные сети: архитектура, уязвимость и проблема двойного входа	41
1.5 Динамика непрерывного времени на эволюционирующих графах	44
1.6 Распределённое обучение на графах с гарантиями приватности	47
1.7 Вычислительная эффективность для крупномасштабных темпоральных графов	49
1.8 Нестационарная адаптация и оценка неопределённости	51
1.9 Единая сертификация робастности	53
1.10 Состязательное машинное обучение в смежных критических областях: случай нейросетевой навигации беспилотных летательных аппаратов	55
1.11 Сводка выявленных исследовательских пробелов	58
2 Математическая модель Hybrid IDPS и предлагаемые модели и алгоритмы повышения её робастности и эффектив-	

ности	61
2.1 Математическая модель Hybrid IDPS	61
2.2 Единая постановка задачи	66
2.3 Модель M1: CT-TGNN — Динамика темпоральных графовых нейронных сетей непрерывного времени	71
2.4 Модель M2: FedLLM-API — Федеративная оптимизация гра- фов с приватностью	76
2.5 Модель M3: TripleE-TGNN — Многоуровневые темпоральные вложения графов	82
2.6 Модель M4: MambaShield — Вывод на основе пространства состояний с устойчивостью к отравлению	87
2.7 Методы M5 и M6: Вывод с калиброванной неопределён- ностью на графах	91
2.8 Прямо совместимое обнаружение при смене протокольного режима	96
2.9 Модель M7: Теоретико-игровая сертификация и единая система	100
2.10 Систематизация метрик оценки качества Hybrid IDPS	105
2.11 Итоги главы	106
3 Инстанцирование системы Hybrid IDPS для защиты сетево- го трафика и её эталонная валидация	109
3.1 Обнаружение сетевых вторжений: терминологии и контекст	110
3.2 Конвейер преобразования данных в граф	111
3.3 Таксономия классификации	113
3.4 Конвейер инженерии признаков	114
3.5 Предметно-ориентированная реализация методов	115
3.6 Конфигурация гиперпараметров и оптимизация	122
3.7 Интегрированная архитектура системы	124
3.8 Экспериментальная методология	125
3.9 Результаты единого бенчмарка	126
3.10 Результаты по отдельным методам	127
3.10.1 M1: Результаты CT-TGNN (Пробел 1, Подзадача 1) .	127
3.10.2 SDE-TGNN: Стохастическое расширение (Пробел 1, Подзадача 1)	128

3.10.3	M2: Результаты FedLLM-API (Пробел 2, Подзадача 2)	130
3.10.4	M3: Результаты TripleE-TGNN (Пробел 3, Подзадача 3)	130
3.10.5	M4: Результаты MambaShield (Пробел 4, Подзадача 4)	131
3.10.6	M5/M6: Результаты с калиброванной неопределённостью (Пробел 6, Подзадача 6)	131
3.10.7	M7: Результаты теоретико-игровой сертификации (Пробел 7, Подзадача 7)	131
3.10.8	CyberSecLLM: Результаты фундаментальной модели (Пробел 5)	132
3.11	Сравнительный анализ с базовыми линиями	132
3.12	Абляционные исследования	133
3.13	Предварительное расширение системы Hybrid IDPS на сектор БПЛА	134
3.14	Итоги главы	135
4	Кросс-секущая валидация системы Hybrid IDPS: состязательная робастность, кросс-доменный перенос и постквантовая совместимость	137
4.1	Оценка состязательной робастности	137
4.2	Эксперименты по кросс-доменному переносу	138
4.3	Кросс-секущая валидация по свойствам эффективности, приватности и калибровки системы	140
4.4	Результаты мультиагентного обнаружения с учётом PQС	142
4.5	Обсуждение и практические следствия	143
4.6	Итоги главы	144
5	Система анализа сетевого трафика на основе программной платформы RobustIDPS.ai	145
5.1	Постановка задачи: защита сетевого трафика системой Hybrid IDPS	145
5.2	Обзор платформы и целевые пользователи	146
5.3	Архитектура системы	148
5.4	Функциональные группы и реестр страниц	150
5.5	Командный центр ИИ	151

5.6	Модели обнаружения	154
5.7	Пакет SOC-аналитики	156
5.8	Тестирование безопасности LLM	157
5.9	Соответствие стандартам MLSecOps	158
5.10	Модуль Multi-Agent PQC-IDS	159
5.11	Миграция граничного агента на Rust и быстрый путь XDP .	159
5.12	Операционная инфраструктура развёртывания	161
5.13	Развёртывание и интеграция с существующими СОПВ . . .	163
5.14	Сравнение с коммерческими и открытыми платформами . .	165
5.15	Результаты валидации платформы	165
5.16	Вклад в открытый исходный код	167
5.17	Итоги главы	168
6	Система защиты беспилотных летательных аппаратов на основе Hybrid IDPS	170
6.1	Обзор подсистемы и целевые задачи защиты БПЛА	171
6.2	Архитектура системы: трёхуровневая модель <i>борт — дроно- порт — облако</i>	174
6.3	Операционный граф БПЛА как экземпляр единой задачи .	175
6.4	Конвейер преобразования телеметрии БПЛА в граф	176
6.5	Отображение методов M1–M7 на подсистемы БПЛА	177
6.5.1	Зрительное восприятие	178
6.5.2	ГНСС-навигация	178
6.5.3	Автопилотная политика управления	179
6.6	Сертификаты робастности для подсистем БПЛА	179
6.7	Программная реализация Phase A на основе библиотеки robustnn-core	180
6.8	Интеграция с платформой RobustIDPS.ai	182
6.9	Результаты валидации Phase A	183
6.10	Сравнение с существующими промышленными решениями .	187
6.11	Соответствие нормативной базе	188
6.12	Итоги главы	189
	Заключение	191

Список литературы	197
А Математические доказательства и выводы	197
А.1 Доказательство Теоремы 2.1: Сходимость СТ-TGNN	197
А.2 Доказательство Теоремы 2.2: Сертификат робастности по Липшицу	198
А.3 Доказательство Теоремы 2.3: Византийско-устойчивая феде- ративная сходимость	199
А.4 Доказательство Теоремы 2.4: РАС-байесовская граница для моделей пространства состояний	201
А.5 Доказательство Теоремы 2.5: Граница регрета мультиплика- тивных весов	202
А.6 Доказательство Теоремы 2.6: Сходимость единой системы .	203
А.7 Дополнительные выводы	204
В Детали реализации и гиперпараметры	209
В.1 Программная инфраструктура и зависимости	209
В.2 Конфигурации гиперпараметров	210
В.3 Конвейер предобработки данных	214
В.4 Вычислительная инфраструктура	215
В.5 Протоколы оценки	215
В.6 Доступность кода и данных	216
С Дополнительные экспериментальные результаты	217
С.1 Производительность по категориям атак	217
С.2 Детали абляционного исследования	220
С.3 Кросс-облачный и кросс-доменный перенос	223
С.4 Анализ компромисса приватность–качество	224
С.5 Метрики вычислительной производительности	225

Список иллюстраций

- 1 Концептуальная схема системы Hybrid IDPS в трёх аспектах. **Сверху** — ядро архитектуры (Hybrid NIDPS AI-Native Core) с трёхканальным детектированием (сигнатурный, аномалийный, протокольный), AI/ML-движком в качестве усиливающего слоя, блоком принятия решений и реагирования и защищаемыми системами. **В центре** — предметные области применения системы: сетевой трафик, БПЛА, медицинские записи, автономные транспортные средства, банковско-финансовая инфраструктура. **Снизу** — поверхность атак на канонические компоненты: атакующий → векторы атак (спуфинг, джемминг, инъекция, malware, утечка данных, DoS/DDoS) → целевые компоненты (signature, anomaly, protocol framing) → последствия (обход обнаружения, нарушение работы, компрометация данных). . . . 3
- 2 Двойственная природа входов ГНС-моделей, применяемых в качестве одной из ветвей обучаемых детекторов в системах Hybrid IDPS. Модель одновременно получает числовые данные (матрица признаков **X**) и реляционную структуру (матрица смежности **A**). Возмущение любого из входов может нарушить обученное представление, что мотивирует разработку системы повышения робастности и эффективности Hybrid IDPS, являющейся предметом настоящей диссертации. 5
- 3 Расположение семи методов в пространстве условий функционирования (слева) и требований (справа). M4: MambaShield находится на пересечении всех трёх условий; M1: CT-TGNN связывает состязательное и нестационарное условия через сертифицированные непрерывно-временные динамики. . . . 11

4	Архитектурная основа исследовательской программы. Семь методов покрывают все 12 пересечений матрицы условие–требование 3×4 . Каждый сформулирован на уровне математических операций над графами — предметно-независим. Все модели разработаны автором и описаны в 18 рецензируемых публикациях.	11
1.1	Интегрированная схема системы Hybrid IDPS: AI-нативное, адаптивное, контекстно-зависимое, упреждающее защитное решение. Слева — источники данных (сетевой трафик, телеметрия БПЛА, медицинские записи, автономные транспортные средства, банковский/финтех-трафик, системные журналы); по центру — ядро системы с трёхканальным детектированием (сигнатурное, аномалийное, протокольный анализ), AI-нативным интеллектуальным слоем (глубокое обучение, онлайн- обучение, корреляция угроз, оценка риска) и единым менеджером решений и реагирования; справа — блок предотвращения и реагирования (фильтрация трафика, защита команд БПЛА, защита медицинских данных, активная безопасность транспортных средств, предотвращение мошенничества, инцидент-форензика) и системные возможности (обнаружение в реальном времени, многосекторная видимость, адаптивное обучение, низкая доля ложных срабатываний, масштабируемость, объяснимый ИИ). Нижняя панель приводит характерные классы уязвимостей в каждом из пяти показательных секторов.	32

1.2	Иерархическая классификация Hybrid IDPS по пяти ортогональным осям. По методу обнаружения — сигнатурные (детерминированный поиск по базе известных шаблонов), аномалийные (статистическое или обучаемое отклонение от нормального профиля), протокольные (контекстно-зависимый анализ корректности сетевых, прикладных и промышленных протоколов и их состояний) и гибридные (комбинация трёх предыдущих, усиленная обучаемыми моделями M1–M7). По охвату — хостовые (HIDS), сетевые (NIDS) и распределённые (DIDS). По топологии развёртывания — централизованные, распределённые, федеративные. По характеру реагирования — пассивные (только оповещение), активные (вмешательство в поток), IPS (полная блокировка). По уровню стека — прикладной, сетевой и физический.	34
1.3	Предметные области применения Hybrid IDPS. Сектора (а) и (б) рассматриваются в работе как показательные применения и изложены подробно в Главах 5 (анализ сетевого трафика) и 6 (защита БПЛА). Сектора (в)–(ж) приведены обзорно с указанием поверхности атак и режима интеграции защитных моделей.	35
1.4	Систематизация моделей и алгоритмов, применяемых в Hybrid IDPS. Графовые нейронные сети (выделены красной рамкой) являются одним из листов ветви глубокого обучения наряду с свёрточными (CNN), рекуррентными (RNN), моделями пространства состояний (SSM) и стохастическими дифференциальными уравнениями (SDE), а не центральной парадигмой. Разработанные в Главе 2 модели M1–M7 заимствуют конструкции из нескольких ветвей одновременно (см. табл. 1.1).	39
1.5	Систематизация проблем и уязвимостей, рассматриваемых в качестве мотивации для разработки моделей M1–M7. Каждая из пяти осей покрывается одной или несколькими разработанными моделями (прямое отображение приведено в табл. 1.1 после изложения существующих ограничений).	40

2.1	Принципиальная архитектура модели M1: СТ-TGNN — темпоральной графовой нейронной сети непрерывного времени с мультимасштабными ветвями ОДУ и адаптивной пакетной нормализацией. Применение модели к защите сетевого трафика с конкретными значениями постоянных времени и гиперпараметров рассматривается в §3.5 Главы 3.	75
2.2	Принципиальная архитектура модели M2: FedLLM-API — федеративного оптимизатора с византийско-устойчивой агрегацией, дифференциальной приватностью через калиброванный шум и выравниванием распределений по принципу оптимального транспорта Вассерштейна, интегрированного с большой языковой моделью для zero-shot-обнаружения новых категорий угроз.	81
2.3	Принципиальная архитектура модели M3: TripleE-TGNN — тройного вложения для многоуровневого темпорального представления графов с двойным временно-пространственным вниманием и упругой консолидацией весов для предотвращения катастрофического забывания.	86
2.4	Принципиальная архитектура модели M4: MambaShield — селективной модели пространства состояний со сложностью вывода $\mathcal{O}(L \log L)$ через свёртки на основе быстрого преобразования Фурье, дополненной прогрессивной состязательной дистилляцией и РАС-байесовскими сертификатами обобщения.	90
2.5	Принципиальная архитектура моделей M5: Stochastic Transformer и M6: UC-HGP — вариационного байесовского внимания (M5) с иерархическим гауссовским процессом (M6) для декомпозиции эпистемической и алеаторной неопределённости и сортировки оповещений по уровню эпистемической неопределённости.	95
2.6	Принципиальная архитектура <i>мультиагентного PQS-IDS-модуля</i> — прямо-совместимой системы обнаружения вторжений при смене протокольного режима, с протокол-специфичными кодировщиками для решёточных, кодовых и хэш-протоколов и слиянием через кросс-внимание.	99

2.7	Принципиальная архитектура модели M7: теоретико-игровой сертификации — единой системы, моделирующей взаимодействие защитника и противника как стратегическую игру с равновесием Штакельберга, объединяющая модели M1–M6 через регуляризацию согласованности.	105
3.1	Архитектура CT-TGNN, реализованная для динамики сетевого трафика.	116
3.2	Архитектура FedLLM-API для совместной разведки угроз через организационные границы.	117
3.3	Архитектура TripleE-TGNN для многоуровневого мониторинга безопасности в облачных средах.	118
3.4	Архитектура MambaShield для обнаружения вторжений с адаптацией к дрейфу и прогрессивной дистилляцией робастности.	119
3.5	Стохастический трансформер с сортировкой на основе неопределённости для операций безопасности.	120
3.6	Теоретико-игровая система для адаптивных графовых противников в сетевой безопасности.	121
3.7	Прямо совместимая мультипротокольная архитектура обнаружения для постквантового трафика.	122
3.8	Интегрированный конвейер обнаружения, показывающий поток данных от сырого сетевого трафика через все семь методов к оповещениям, ранжированным по серьёзности и оценённым по уверенности. Модуль FedLLM-API синхронизирует модели через границы при дифференциальной приватности.	124
3.9	Улучшение точности на каждом наборе данных (процентные пункты) единой системы над лучшей одиночной базовой линией. Наибольший прирост наблюдается на наборах с высоким топологическим разнообразием (UNSW-NB15: +5,6, Edge-IIoT: +5,5).	127

3.10	Покаатегорийная полнота CT-TGNN на CIC-IoT-2023 по семи основным семействам атак. DDoS достигает наивысшей полноты (99,1%), тогда как спуфинг наиболее сложен (95,2%), что отражает его большую топологическую вариативность. .	128
3.11	Сертифицированная робастность SDE-TGNN как функция радиуса возмущения R . Затенённая полоса показывает сертифицированную точность, полученную рандомизированным сглаживанием; пунктирная линия показывает сертификат Липшица из Теоремы 2.2. При $R = 0.25$, 76,2% тестовых образцов являются доказуемо робастными.	129
3.12	Деградация точности FedLLM-API при увеличении доли византийских участников в сравнении с базовыми линиями FedAvg, FedProx, Krum и Медиана. FedLLM-API плавно деградирует с 94,2% до 79,8% при увеличении повреждения с 0% до 50%, тогда как FedAvg обрушивается до 52,1%. . . .	130
3.13	Абляционное исследование: падение производительности при удалении каждого компонента. Горизонтальные полосы показывают величину деградации; ветвь LLM, византийское усечённое среднее и выравнивание OT — три наиболее критичных компонента. Шум ДП — единственный компонент, удаление которого повышает точность (+3,1%), отражая компромисс приватность–качество.	134
4.1	Робастная точность как функция бюджета возмущений ϵ для FGSM, PGD-20 и сертифицированных (рандомизированное сглаживание) оценок SDE-TGNN. Сертифицированная кривая обеспечивает доказуемую нижнюю границу; FGSM и PGD представляют эмпирические верхние границы при конкретных стратегиях атак.	138

4.2	Кросс-доменный перенос F1 (%) для SDE-TGNN, базовой линии Neural ODE и базовой линии BiLSTM на трёх наборах данных безопасности и двух областях вне безопасности (речь, здравоохранение). SDE-TGNN достигает 90,5% среднего переноса без дообучения, что на 9,4 п. п. выше Neural ODE и на 14,1 п. п. выше BiLSTM.	139
4.3	Кросс-доменное обобщение системы Hybrid IDPS на ROC-кривой: обучение проведено на наборах кибербезопасности (CIC-IoT-2023, CSE-CICIDS-2018, UNSW-NB15), тестирование — без дообучения — на бенчмарках обработки речи (детектирование событий) и клинического мониторинга. Сохранение $AUC > 0,9$ на принципиально иных предметных областях подтверждает предметную независимость семёрки $\mathcal{H} = (\mathcal{V}_t, \mathcal{E}_t, X_t, A_t, f_\theta, g_\psi, \pi)$ и моделей M1–M7 на уровне математических операций над графовыми структурами. . .	140
4.4	Точность при атаке C&W на четырёх этапах миграции PQC (Классический $\rightarrow$ Гибридный $\rightarrow$ Чистый Kyber $\rightarrow$ Полный PQC). MambaShield со структурированной FIM сохраняет точность в пределах 2,5 п. п. на всех этапах, тогда как наивное дообучение обрушивается на 25,5 п. п. из-за катастрофического забывания классических паттернов трафика.	143
5.1	Постановка задачи защиты сетевого трафика системой Hybrid IDPS в реализации платформы RobustIDPS.ai. Слева — входные потоки (сетевые пакеты, NetFlow, оповещения сигнатурных движков); в центре — система с 17 интегрированными моделями M1–M7; справа — выходные артефакты (ранжированные оповещения, развёртываемые правила Snort/Suricata, управляющие действия для SIEM/SOAR-оркестрации).	146

5.2	Высокоуровневая архитектура системы RobustIDPS.ai, показывающая все 10 функциональных групп, поддерживающую инфраструктуру (Docker Compose, PostgreSQL, Redis, WebSocket, Celery, а также Rust-плоскость данных релиза v4) и поток данных от приёма сырого трафика через обнаружение, анализ и реагирование.	149
5.3	Двухплоскостная архитектура RobustIDPS.ai v4: Python-плоскость управления (синяя рамка, верх) и Rust-плоскость данных (оранжевая пунктирная рамка, низ) разделены чёткой границей и связаны тремя gRPC-примитивами. StreamFlows — поток записей о потоках из плоскости данных в плоскость управления; UpdateConfig — проталкивание списков блокировки в обратном направлении; ApplyModelUpdate — атомарная доставка INT8 ONNX-ученика на работающие агенты без перезапуска.	150
5.4	Панель управления RobustIDPS.ai, отображающая статистику обнаружения в реальном времени, распределение категорий атак и метрики производительности моделей. Левая панель показывает активную конфигурацию модели; центр — временную шкалу обнаружений; правая панель — разбивку оповещений по степени серьёзности.	152
5.5	Интерфейс загрузки и анализа: (вверху) панель загрузки файлов с выпадающим списком выбора модели, (центр) таблица результатов обнаружения с попоточной классификацией и оценками уверенности, (внизу) разбивка по категориям атак с метриками производительности по классам.	153
5.6	Страница моделей, отображающая 17 интегрированных моделей обнаружения с настраиваемыми гиперпараметрами, метриками точности по каждой модели и бенчмарками задержки. Пользователи могут выбрать любую модель в качестве активного детектора или запустить ансамблевые сравнения.	155

5.7	Пакет SOC-аналитики: (слева) панель авторасследования с выходом рассуждения LLM и сопоставлением MITRE ATT&CK [?], (центр) интерфейс поиска угроз с запросом на естественном языке, (справа) сгенерированное правило Suricata с SID, приоритетом и ссылками CVE.	157
5.8	Интерфейс тестирования безопасности LLM, показывающий площадку инъекции промптов с оценкой DefensePipeline в реальном времени. Левая панель показывает инъекционный вход; центр отображает санитизированный выход с флагами обнаружения и сопоставленными правилами; правая панель показывает статистику обнаружения по всем 4 бэкендам LLM.	158
5.9	Страница состязательной оценки: (слева) панель конфигурации атак с выбором семейства атак, бюджета возмущений и целевой модели; (центр) деградация точности при FGSM, PGD и C&W атаках с увеличением ε ; (справа) сравнение стандартных и состязательно обученных моделей.	166
5.10	Страница «О платформе», показывающая версию платформы, DOI-цитирование, информацию о разработчиках, технологический стек и ссылки на репозиторий GitHub, архив Zenodo и наборы данных Kaggle.	168
6.1	Сценарии кинетических и биологических угроз для БПЛА в оперативной обстановке: межаппаратное столкновение двух БПЛА (слева) и атака хищной птицы на бортовую полезную нагрузку (справа). В отличие от состязательных воздействий на программные модули, такие события приводят к потере целостности аппарата за миллисекунды и требуют опережающего обнаружения средствами зрительного восприятия, поведенческого анализа и слияния сенсоров — задач, которые в настоящей главе решаются методами M4 MambaShield и M6 UC-HGP с порогом перехода в безопасный режим.	172

6.2	Сводный обзор уязвимостей, сценариев атак, средств идентификации и предотвращения для нейросетевой системы навигации БПЛА. В верхней панели показана типовая траектория миссии и характерные точки отказа (<i>сигнальное подавление, спуфинг, столкновение, перехват канала управления, атака хищной птицы</i>). В средней панели перечислены уязвимые подсистемы. В нижней панели представлены пять основных семейств состязательных атак уровня машинного обучения, поверхности атак, конвейер <i>обнаружение — идентификация — предотвращение</i> и базовая отраслевая метрика завершаемости миссии в функции отношения помеха/сигнал (см. рис. 6.7).	173
6.3	Трёхуровневая архитектура единого защитного фреймворка для нейросетевой системы навигации БПЛА. Методы M1–M7 и фундаментальная модель CyberSecLLM распределены по уровням <i>борт — дронопорт — облако</i> в соответствии с их вычислительной сложностью и сетевыми ограничениями. . .	175
6.4	Шести-стадийный конвейер преобразования телеметрии БПЛА в непрерывно-временной динамический граф $\mathcal{G}_t$ и его передача методам защитного слоя M1/M4/M6. Пять гетерогенных источников (синяя полоса) проходят обработку с выделением целевой разметки, признаков узлов, весов рёбер, опорных маршрутов и временных отметок (зелёная полоса), после чего агрегируются в единый граф $\mathcal{G}_t$ (фиолетовая центральная вершина) и потребляются защитными методами (оранжевая полоса) через единый интерфейс UAVGraphBatch. Многомасштабные временные константы τ_{fast} (IMU/LiDAR) и τ_{slow} (планы миссий) абсорбируют гетерогенность частот датчиков.	177
6.5	Зависимость робастной точности от бюджета PGD-атаки ε для трёх архитектур. Предлагаемая СТ-TGNN сохраняет робастную точность $\geq 0,92$ во всём исследуемом диапазоне. . .	185
6.6	Компромисс между параметром сглаживания σ , сертифицированным ℓ_2 -радиусом и точностью сглаженного классификатора (Cohen-style, $\alpha = 10^{-3}$).	185

6.7	Завершаемость миссии БПЛА в зависимости от интенсивности РЭБ-подавления, измеренной как отношение мощности помехи к мощности полезного сигнала (J/S , дБ). Эталон UAV-EW-Bench-2026: 5 000 симулированных вылетов (AirSim / PX4 SITL), три типа миссий, три модели ГНСС-приёмника, комбинированный состязательный контур. Полосы ошибок — 95 % доверительные интервалы Уилсона ($n = 200$ на точку, три зерна). Предлагаемый фреймворк M1+M4+M6+M7 удерживает завершаемость выше регуляторного порога DO-326A 0,90 до $J/S \approx 27$ дБ включительно — против ≈ 18 дБ для Seq2Seq Tr., ≈ 13 дБ для CAF-CNN и $\approx 7,5$ дБ для эталонной PX4 без защиты, то есть выигрыш в 9–19 дБ по операционно-значимому показателю.	187
-----	--	-----

Список таблиц

2	Три рабочих условия и методы, разработанные для их решения.	9
3	Четыре сквозных требования и методы, их выполняющие.	10
1.1	Отображение проблем Hybrid IDPS, выявленных в §1.3, на разработанные в Главе 2 модели и алгоритмы M1–M7 (соответствие направлению п. 4 паспорта специальности 2.3.1).	59
1.2	Семь выявленных исследовательских пробелов, их покрытие условий и требований, а также методы, предложенные для их решения в настоящей диссертации.	60
2.1	Сводка шести свойств Hybrid IDPS как исследовательских вопросов: каждое свойство формализовано инвариантом и закрывается одной или несколькими моделями M1–M7.	65
2.2	Декомпозиция единой постановки задачи на семь подзадач.	71
2.3	Систематизация двадцати трёх метрик оценки качества Hybrid IDPS по шести свойствам из §2.1.2.	106
3.1	Унифицированная таксономия классификации: 34 класса по 7 категориям атак.	113
3.2	Конвейер инженерии 83 признаков, организованных по категориям.	114
3.3	Сводная конфигурация гиперпараметров всех методов для области кибербезопасности.	123
3.4	Обзор бенчмарк-наборов данных, использованных в экспериментальной оценке.	125
3.5	Производительность единой системы на всех бенчмарк-наборах данных.	127
3.6	Производительность CT-TGNN на бенчмарк-наборах данных.	128
3.7	SDE-TGNN: обнаружение, калибровка, сертифицированная робастность и перенос.	129
3.8	Производительность FedLLM-API при различных долях византийских участников.	129

3.9	Точность MambaShield при увеличении долей отравления.	131
3.10	Производительность CyberSecLLM в режиме zero-shot на CyberSecBench.	132
3.11	Сравнительная производительность относительно базовых линий на CIC-IoT-2023.	132
3.12	Абляционное исследование: влияние удаления отдельных компонентов.	133
3.13	Предварительное расширение системы Hybrid IDPS на сектор БПЛА: ключевые метрики на трёх UAV-задачах в сравнении с результатами на сетевом трафике. Полная экспериментальная программа для сектора БПЛА — Глава 6.	135
4.1	Состязательная робастность платформы при шести методах атак.	138
4.2	Точность прямо совместимого обнаружения по семействам протоколов.	142
5.1	Функциональные группы RobustIDPS.ai (51 страница в 10 группах).	151
5.2	Производительность моделей обнаружения на валидационном бенчмарке CIC-IoT-2023.	154
5.3	Показатели обнаружения атак LLM по модулям.	157
5.4	Производительность плоскости данных на Rust (релиз v4) относительно эталонной Python-реализации релиза v3.	160
5.5	Сравнение трёх форм развёртывания плоскости данных RobustIDPS.ai v4.	163
5.6	Сравнение возможностей с открытыми и коммерческими платформами.	165
6.1	Отображение методов M1–M7 и фундаментальной модели CyberSecLLM на механизмы защиты в подсистемах БПЛА.	178

6.2	Контрольные показатели реализации Phase A в сопоставлении с ранее проверенными результатами платформы RobustIDPS.ai («RIDPS») и опубликованными лучшими профильными решениями. Сокращения: «синт.» — калиброванный TEXBAT-подобный синтетический корпус.	184
6.3	Сравнение единого защитного фреймворка с существующими промышленными решениями (B — базовый уровень, + — частичная поддержка, ✓ — полная поддержка).	188
B.1	Конфигурация гиперпараметров CT-TGNN.	210
B.2	Конфигурация гиперпараметров TripleE-TGNN.	211
B.3	Конфигурация гиперпараметров FedLLM-API.	211
B.4	Конфигурация гиперпараметров прямо совместимого обнаружения.	212
B.5	Конфигурация гиперпараметров MambaShield.	212
B.6	Конфигурация гиперпараметров стохастического трансформера.	213
B.7	Конфигурация гиперпараметров теоретико-игровой системы.	213
C.1	Покатегорийные результаты CT-TGNN на CIC-IoT-2023.	218
C.2	Покатегорийные результаты единой системы на CSE-CICIDS2018.	218
C.3	Покатегорийные результаты единой системы на UNSW-NB15.	219
C.4	Покатегорийная точность обнаружения TripleE-TGNN и доминирующая гранулярность.	219
C.5	Расширенные результаты абляции с 95% доверительными интервалами (пять затравок).	220
C.6	Чувствительность CT-TGNN к относительному допуску решателя ОДУ.	221
C.7	Чувствительность FedLLM-API к бюджету дифференциальной приватности ϵ	221
C.8	Чувствительность FedLLM-API к доле усечения при 30% византийских противников.	222
C.9	Чувствительность MambaShield к температуре дистилляции и размеру ансамбля (25% отравления).	222

C.10 Чувствительность стохастического трансформера к числу прямых проходов МК.	223
C.11 Точность кросс-датасетного переноса СТ-TGNN (%). Строки: обучающий набор; столбцы: тестовый набор.	223
C.12 Результаты кросс-доменного переноса с и без предобучения на сетевой безопасности.	224
C.13 Влияние дифференциальной приватности на точность по на- борам данных ($\epsilon = 0.85$, $\delta = 10^{-5}$).	224
C.14 Кумулятивный расход приватности по федеративным раун- дам ($\delta = 10^{-5}$).	225
C.15 Сравнение вычислительной производительности по методам (P100 GPU).	225
C.16 Задержка вывода (мс) как функция длины последовательно- сти.	226
C.17 Сравнение времени обучения (четыре V100 GPU, CIC-IoT- 2023).	226
C.18 Размер модели и влияние квантования.	227

Список сокращений

AI (ИИ)	Искусственный интеллект
AML	Состязательное машинное обучение
APT	Развитая постоянная угроза (Advanced Persistent Threat)
AUC-ROC	Площадь под кривой рабочей характеристики приёмника
BN	Пакетная нормализация (Batch Normalisation)
BWT	Обратный перенос (метрика непрерывного обучения)
C&W	Атака Карлини–Вагнера (Carlini–Wagner Attack)
Y1, Y2, Y3	Обозначения рабочих условий: Состязательная среда, Распределённая динамика, Нестационарность
CL-RL	Непрерывное обучение – Обучение с подкреплением
CNN	Свёрточная нейронная сеть (Convolutional Neural Network)
CPO	Оптимизация политики с ограничениями (Constrained Policy Optimisation)
CT-GNN	Графовая нейронная сеть непрерывного времени
CT-TGNN	Темпоральная графовая нейронная сеть непрерывного времени (Модель M1)
CVE	Общие уязвимости и экспозиции (Common Vulnerabilities and Exposures)
CyberSecLLM	Предметно-ориентированная фундаментальная модель кибербезопасности

DDoS	Распределённая атака отказа в обслуживании
Dec-CMDP	Децентрализованный марковский процесс принятия решений с ограничениями
DNN	Глубокая нейронная сеть (Deep Neural Network)
DoS	Атака отказа в обслуживании
DP (ДП)	Дифференциальная приватность
ECE	Ожидаемая ошибка калибровки (Expected Calibration Error)
ELBO	Нижняя граница свидетельства (Evidence Lower Bound)
EWC	Упругая консолидация весов (Elastic Weight Consolidation)
FedAvg	Федеративное усреднение (Federated Averaging)
FedGTD	Федеративная теоретико-игровая защита (Federated Game-Theoretic Defence)
FedLLM-API	Федеративная оптимизация графов с большими языковыми моделями и приватностью (Модель M2)
FFT (БПФ)	Быстрое преобразование Фурье (Fast Fourier Transform)
FGSM	Метод быстрого знака градиента (Fast Gradient Sign Method)
FIM	Матрица информации Фишера (Fisher Information Matrix)
FWT	Прямой перенос (метрика непрерывного обучения)
GAN	Генеративно-сопоставительная сеть (Generative Adversarial Network)
GIN	Графовая изоморфная сеть (Graph Isomorphism Network)

GNN (ГНС)	Графовая нейронная сеть (Graph Neural Network)
GPU	Графический процессор (Graphics Processing Unit)
HIDPS (ГСОПВ)	Гибридная система обнаружения и предотвращения вторжений
HiPPO	Оператор полиномиальной проекции высокого порядка (High-order Polynomial Projection Operator)
IAT	Межпакетный интервал (Inter-Arrival Time)
ICS (АСУ ТП)	Промышленная система управления (Industrial Control System)
ICS3D	Intrusion and Counter-measure Simulation in Cloud and Edge Computing Security Dataset
IDPS (СОПВ)	Система обнаружения и предотвращения вторжений
IDS (COB)	Система обнаружения вторжений (Intrusion Detection System)
IIoT	Промышленный Интернет вещей (Industrial Internet of Things)
IoT	Интернет вещей (Internet of Things)
KL	Дивергенция Кульбака–Лейблера (Kullback–Leibler Divergence)
LLM	Большая языковая модель (Large Language Model)
LSTM	Долгая краткосрочная память (Long Short-Term Memory)
LWE	Обучение с ошибками (Learning With Errors)
M1–M7	Обозначения семи разработанных методов (см. Рис. 4)
MA-CPO	Мультиагентная оптимизация политики с ограничениями

MA-PQC-IDS	Мультиагентная постквантовая криптографическая система обнаружения вторжений
MambaShield	Селективная модель пространства состояний с устойчивостью к отравлению (Модель М4)
MC (МК)	Монте-Карло
MC-Dropout	Дропаут Монте-Карло (Monte Carlo Dropout)
MCC	Коэффициент корреляции Мэттьюза (Matthews Correlation Coefficient)
MITRE ATT&CK	Состязательные тактики, техники и общие знания
ML (МО)	Машинное обучение (Machine Learning)
MLP	Многослойный перцептрон (Multi-Layer Perceptron)
MLSecOps	Операции безопасности машинного обучения
NIDPS (ССОПВ)	Сетевая система обнаружения и предотвращения вторжений
NIST	Национальный институт стандартов и технологий (National Institute of Standards and Technology)
NLP	Обработка естественного языка (Natural Language Processing)
NPLR	Нормальное плюс низкоранговое (Normal Plus Low-Rank)
Нейронное ОДУ	Нейронное обыкновенное дифференциальное уравнение (Neural Ordinary Differential Equation)
ОДУ	Обыкновенное дифференциальное уравнение (Ordinary Differential Equation)
ODE-S6	ОДУ-дополненное селективное пространство состояний (блок CyberSecLLM)
OT (ОТ)	Оптимальный транспорт (Optimal Transport)
OWASP	Open Worldwide Application Security Project

PAC	Вероятно приблизительно корректный (Probably Approximately Correct)
PARD	Прогрессивная состязательная дистилляция робастности
PCAP	Захват пакетов (Packet Capture)
PGD	Проецированный градиентный спуск (Projected Gradient Descent)
PQC	Постквантовая криптография (Post-Quantum Cryptography)
PWA	Прогрессивное веб-приложение (Progressive Web Application)
T1–T4	Обозначения требований: Робастность, Точ- ность, Эффективность, Приватность
RAG	Генерация с дополненным извлечением (Retrieval-Augmented Generation)
RL	Обучение с подкреплением (Reinforcement Learning)
RMF	Система управления рисками (NIST AI RMF)
RNN (PHC)	Рекуррентная нейронная сеть (Recurrent Neural Network)
SCADA	Диспетчерское управление и сбор данных (Supervisory Control and Data Acquisition)
SDE (СДУ)	Стохастическое дифференциальное уравне- ние (Stochastic Differential Equation)
SDE-TGNN	Темпоральная графовая нейронная сеть на стохастических дифференциальных уравне- ниях
SOC	Центр операций безопасности (Security Operations Centre)
SSM	Модель пространства состояний (State-Space Model)
Стох. трансф.	Стохастический трансформер (Модель M5)

SVM	Метод опорных векторов (Support Vector Machine)
TABN	Темпоральная адаптивная пакетная нормализация (Temporal Adaptive Batch Normalisation)
TGNN	Темпоральная графовая нейронная сеть (Temporal Graph Neural Network)
TLS	Протокол безопасности транспортного уровня (Transport Layer Security)
TripleE-TGNN	Темпоральная графовая нейронная сеть с тройным вложением для многоуровневых представлений (Модель M3)
UC-HGP	Иерархический гауссовский процесс с калиброванной неопределённостью (Модель M6)

ВВЕДЕНИЕ

Актуальность темы исследования

Гибридные системы обнаружения и предотвращения вторжений (далее — Hybrid IDPS) являются основным защитным контуром информационных систем в критически важных предметных областях: анализе сетевого трафика, защите беспилотных летательных аппаратов (БПЛА), банковско-финансовой инфраструктуре, медицинских информационных системах, промышленном интернете вещей и автоматизированных системах управления технологическими процессами (АСУ ТП), автономных транспортных средствах, а также облачных и SaaS-инфраструктурах. Hybrid IDPS объединяет в едином защитном контуре сигнатурные, аномалийные, статистические и обучаемые компоненты, средства автоматического реагирования и интерфейсы интеграции с внешними системами регистрации событий и реагирования (SIEM/SOAR), и составляет основной объект исследования настоящей диссертации. Однако робастность существующих IDPS-систем — их способность сохранять качество обнаружения при состязательных воздействиях, в распределённых средах и в нестационарных условиях эксплуатации — отстаёт от точности обнаружения на 25–65 процентных пунктов в каждой из перечисленных областей [? ? ? ?], что делает разработку моделей и алгоритмов повышения робастности и эффективности систем Hybrid IDPS *актуальной* научной задачей. Настоящая работа посвящена *разработке состязательных устойчивых моделей на основе искусственного интеллекта в гибридных системах обнаружения и предотвращения вторжений для сетевой безопасности*, рассматриваемой в первую очередь на инстанции защиты сетевого трафика (NIDPS) и подтверждаемой переносом в смежный сектор защиты бортовых систем БПЛА; при этом все шесть сквозных свойств P1–P6, включая распределённые и нестационарные условия эксплуатации, сохраняются в полном объёме как обязательные требования к разрабатываемым AI-моделям.

Под *гибридной системой обнаружения и предотвращения вторже-*

ный (Hybrid IDPS) в настоящей диссертации понимается специфический класс *ИИ/МО-усиленных* защитных контуров, объединяющих три канонических типа детектирования информационной безопасности — *сигнатурный* (детерминированное сопоставление с базой известных шаблонов атак), *аномалийный* (статистическое или обучаемое отклонение от нормального профиля поведения) и *протокольный* (контекстно-зависимый анализ корректности сетевых, прикладных и промышленных протоколов и состояний) — дополнительно *усиленных моделями искусственного интеллекта и машинного обучения на каждом из трёх каналов*. Этот класс систематически отличается от *конвенциональных* IDPS-продуктов отрасли (типа Snort 3, Suricata, Zeek, Cisco IPS, Palo Alto Networks Threat Prevention, McAfee Network Security Platform), которые либо реализуют один из трёх каналов в чистом виде, либо объединяют все три без обучаемого слоя. Конвенциональные IDPS демонстрируют три систематические неэффективности: (а) *неспособность обнаруживать атаки нулевого дня* — сигнатурный канал слеп к новым шаблонам атак до момента включения соответствующих сигнатур в базу, что в коммерческой практике даёт временную задержку 30–90 дней между появлением атаки и её включением в защитный контур [?]; (б) *высокий уровень ложных срабатываний* — аномалийный канал в чисто статистической реализации генерирует ложные оповещения с частотой 10^{-2} – 10^{-1} на нормальный поток, что приводит к перегрузке аналитиков (alert fatigue) и в ряде задокументированных случаев — к пропуску критических инцидентов [?]; (в) *ограниченность семантического контекста* — протокольный канал в чистом виде масштабируется как $\mathcal{O}(P \cdot S)$ по числу проверяемых протоколов P и числу состояний S и требует ручного обновления правил при появлении новых версий протоколов и постквантовых протокольных режимов. Дополнение всех трёх каналов обучаемыми моделями М1–М7, разработанными в Главе 2, систематически преодолевает каждую из трёх неэффективностей одновременно: сертифицированную робастность к состязательным возмущениям обеспечивают модели М1, М4, М7 (направление П1 из §2.1.2); калиброванную неопределённость для управления уровнем ложных срабатываний — модели М5–М6 (направление П5); предметно-независимую адаптацию к новым протоколам без переобучения ядра системы — модели М3 и фундамен-

тальная модель CyberSecLLM (направление П6). Таким образом, термин *Hybrid IDPS* в настоящей работе обозначает не конвенциональную инженерную сборку трёх классов детекторов, а *единую ИИ-нативную систему*, в которой обучаемые модели систематически интегрированы во все три канала детектирования. Концептуальная схема системы Hybrid IDPS, охватывающая три аспекта — (а) ядро трёхканальной архитектуры обнаружения с AI/ML-движком, (б) предметные области применения и (в) поверхности атак на канонические компоненты системы, — приведена на рис. 1.




Рис. 1 – Концептуальная схема системы Hybrid IDPS в трёх аспектах. **Сверху** — ядро архитектуры (Hybrid NIDPS AI-Native Core) с трёхканальным детектированием (сигнатурный, аномалийный, протокольный), AI/ML-движком в качестве усиливающего слоя, блоком принятия решений и реагирования и защищаемыми системами. **В центре** — предметные области применения системы: сетевой трафик, БПЛА, медицинские записи, автономные транспортные средства, банковско-финансовая инфраструктура. **Снизу** — поверхность атак на канонические компоненты: атакующий → векторы атак (спуфинг, джемминг, инъекция, malware, утечка данных, DoS/DDoS) → целевые компоненты (signature, anomaly, protocol framing) → последствия (обход обнаружения, нарушение работы, компрометация данных).

Систематический анализ существующих систем Hybrid IDPS, проведён-

ный в Главе 1, выявляет четыре взаимосвязанные группы проблем, ограничивающих надёжность их применения: (1) уязвимость обучаемых детекторов системы к малым целенаправленным возмущениям входных данных и графовых связей; (2) неспособность системы обрабатывать новые или эволюционирующие паттерны угроз без полного переобучения; (3) чрезмерная вычислительная стоимость аналитического ядра системы, исключающая её применение в реальном времени на крупных объёмах телеметрии и сетевого трафика; (4) отсутствие формальных гарантий приватности при федеративном обучении системы по фрагментам данных, принадлежащим разным организациям. Эти четыре проблемы динамичны по своей природе и взаимосвязаны архитектурным корнем — использованием обучаемых моделей с двойственным входом (числовые признаки и реляционная структура), в качестве которых в современных Hybrid IDPS применяются графовые нейронные сети (ГНС), модели пространства состояний, стохастические дифференциальные модели, байесовские сети и теоретико-игровые алгоритмы.

Поскольку графовые нейронные сети [? ? ? ? ?] являются одной из наиболее распространённых ветвей семейства обучаемых моделей, применяемых в современных Hybrid IDPS, а сами проблемы (1)–(4) наиболее наглядно проявляются именно в моделях с двойственным входом, дальнейший анализ актуальности в настоящем введении опирается на конкретные документально подтверждённые отказы ГНС-моделей в системах Hybrid IDPS как репрезентативный пример более широкой проблематики. В отличие от обычных нейронных сетей, принимающих единый тензор данных, ГНС-модель одновременно получает два входа: числовые *входные данные* ($\mathbf{X} \in \mathbb{R}^{n \times d}$, матрица признаков, кодирующая атрибуты сущностей) и реляционную *входную структуру* ($\mathbf{A}$, матрица смежности, кодирующая попарные связи). Сеть формирует свой выход путём распространения данных вдоль структуры через итеративную агрегацию окрестностей. Возмущение любого из входов — данных или структуры — может нарушить предсказания. Именно эта двойственная природа входов отличает ГНС-модели от обычных нейронных сетей и образует один из источников проблем робастности систем Hybrid IDPS, решаемых в настоящей диссертации одновременно для нескольких ветвей семейства обучаемых моделей (ГНС, моделей простран-

ства состояний, стохастических дифференциальных моделей).




Рис. 2 – Двойственная природа входов ГНС-моделей, применяемых в качестве одной из ветвей обучаемых детекторов в системах Hybrid IDPS. Модель одновременно получает числовые данные (матрица признаков $\mathbf{X}$) и реляционную структуру (матрица смежности $\mathbf{A}$). Возмущение любого из входов может нарушить обученное представление, что мотивирует разработку системы повышения робастности и эффективности Hybrid IDPS, являющейся предметом настоящей диссертации.

Большинство моделей ГНС работают в дискретном времени, что усугубляет эти уязвимости. Модели дискретного времени принудительно привязывают нерегулярные события графа к фиксированной тактовой сетке, теряя информацию и гарантии робастности. Формулировки непрерывного времени — например, через нейронные обыкновенные дифференциальные уравнения [? ? ?] — гладко следуют за временем событий, захватывают множественные временные масштабы в одной модели и обнаруживают границу Липшица, дающую сертифицированную робастность — преимущество, которое ни одна дискретная модель не может обеспечить. Поскольку представления эволюционируют согласно дифференциальному уравнению с ограниченной константой Липшица, малые возмущения входа могут вызвать лишь ограниченные, гладкие изменения выхода — гладкость управляющего потока математически ограничивает степень изменения предсказания злоумышленником. Неравенство Грёнуолла формализует это: расстояние между двумя траекториями ОДУ растёт не более чем экспоненциально

по $L_g T$, давая замкнутый сертификат робастности:

$$\|\mathbf{h}_1(T) - \mathbf{h}_2(T)\| \leq e^{L_g T} \|\mathbf{x}_1 - \mathbf{x}_2\|, \quad (1)$$

где $\mathbf{h}_i(T)$ — скрытое состояние траектории i в момент T , $\mathbf{x}_i$ — начальный вход (признаки и структура), L_g — константа Липшица векторного поля ОДУ, T — горизонт интегрирования, $e^{L_g T}$ — максимальный коэффициент усиления, а $\|\cdot\|$ обозначает евклидову норму. Модели ГНС дискретного времени не имеют такого непрерывного механизма, поэтому возмущения непредсказуемо накапливаются от слоя к слою. Однако модели непрерывного времени получают ограниченное внимание в литературе и текущей практике, поэтому настоящая диссертация сосредоточена на их разработке через модели на основе СТ-GNN.

Актуальность этих уязвимостей систем Hybrid IDPS подтверждается тремя сходящимися трендами. *Во-первых*, масштаб проблемы: глобальный ущерб от кибератак достигает \$10,5 трлн в год к 2025 году, и ИИ-инструменты центров управления безопасностью (SOC) необходимы, но сами по себе уязвимы. Эволюция ландшафта киберугроз от случайных атак к целенаправленным кампаниям с применением искусственного интеллекта проанализирована, в частности, в работе И. К. Сачкова [?]. *Во-вторых*, регулирование: NIST AI RMF, EU AI Act и сроки перехода на постквантовую криптографию требуют от Hybrid IDPS сертифицированной устойчивости, а не только эмпирического тестирования. *В-третьих*, теоретический пробел: нет единой математической основы для Hybrid IDPS, одновременно обеспечивающей робастность, приватность, эффективность и точность системы на динамических графовых представлениях данных. Настоящая диссертация восполняет этот пробел: *7 моделей и алгоритмов* с формальными гарантиями по 3 рабочим условиям и 4 требованиям, систематически интегрированных в единую систему Hybrid IDPS.

Документальным подтверждением служат недавние рецензируемые исследования, фиксирующие систематические отказы существующих Hybrid IDPS-систем в четырёх критически важных областях. В *медицинских информационных системах* градиентная атака на чувствительность

рёбер ГНС-детекторов вызвала падение AUC приблизительно на 25% на бенчмарках MoleculeNet (Tox21, ClinTox, SIDER), при этом токсичные соединения были классифицированы как безопасные [?]. В *банковско-финансовой инфраструктуре* атака MonTi с внедрением группы почти утроила ошибку классификации ГНС-детекторов мошенничества (CARE-GNN, PC-GNN, GAGA) с 25,7% до 68,6% [?]. В *промышленном IoT* отравление обучающих данных федеративных детекторов вторжений вызвало коллапс точности системы на 64 процентных пункта с 94,2% до 30,0% при не-i.i.d. условиях [?]. В *сетевой кибербезопасности* атака PROVNINJA снизила обнаружение систем-Hybrid IDPS на основе провананса до 59%, сделав APT-атакующих фактически невидимыми [?]. Эти задокументированные отказы систематически подтверждают, что робастность существующих Hybrid IDPS отстаёт от точности обнаружения на 25–65 процентных пунктов во всех критически важных предметных областях, и этот разрыв мотивирует разработку моделей и алгоритмов M1–M7, составляющих основной результат настоящей диссертации.

Распределённая среда — это среда, в которой несколько организаций (например, больницы, банки, центры обработки данных) владеют частью одних и тех же графовых данных и не могут ими делиться, поэтому общая модель должна обучаться на каждой части через федеративное обучение [? ? ? ? ?] — без доступа какой-либо стороны к сырым данным другой. Модели ГНС в распределённых средах должны быть более устойчивыми, эффективными, робастными и точными, поскольку они внедряются в критически важные системы быстрее, чем могут быть установлены их гарантии: злоумышленники могут обманывать их малыми возмущениями; распределения смещаются после развёртывания; законы о приватности ограничивают обмен данными [? ? ? ?]; при этом периферийные устройства требуют вывода в реальном времени. Ни один существующий подход не решает все четыре проблемы одновременно — этот разрыв мотивирует диссертацию.

Реальные графовые данные дрейфуют после развёртывания — топологии эволюционируют, паттерны атак меняются, появляются новые протоколы [? ?] — и статические модели ГНС незаметно теряют точность без предупреждения. Это недопустимо в критически важных системах, где

устаревшая модель является опасной моделью. Цель состоит в создании динамических моделей ГНС, которые обнаруживают сдвиг распределения онлайн, адаптируют параметры без забывания ранее изученных паттернов и оценивают неопределённость через байесовские апостериорные обновления [? ? ?] для маркировки новых входов для экспертного анализа.

Существующие модели ГНС и модели на основе трансформеров [? ?] масштабируются квадратично ($\mathcal{O}(L^2)$) с длиной последовательности, поскольку каждый узел должен обращать внимание на каждый другой узел, что делает их слишком медленными и ресурсоёмкими для вывода в реальном времени на больших темпоральных графах с миллионами событий. Литература показывает, что структурированные модели пространства состояний [? ? ? ?] более эффективны, снижая стоимость до $\mathcal{O}(L \log L)$ через свёртки быстрого преобразования Фурье и обеспечивая развёртывание на периферийных устройствах, где модели масштаба трансформеров неприменимы. Поэтому в настоящей диссертации предлагается перенос фокуса внимания и практик с трансформеров на селективные модели пространства состояний для графовых данных.

Описанные выше четыре проблемы не являются независимыми; они образуют логическую цепочку, звенья которой определяют поэтапный охват настоящей диссертации. Динамика графов непрерывного времени обеспечивает основу представлений; федеративные алгоритмы обеспечивают распределённое развёртывание; эффективный вывод на основе пространства состояний позволяет работу в реальном времени; а онлайн-байесовская адаптация гарантирует долгосрочную надёжность. Выход каждой задачи является входом для следующей, и ни один существующий подход не решает все четыре задачи совместно при трёх рабочих условиях и четырёх требованиях, определённых ниже.

Три рабочих условия и четыре сквозных требования независимы — они определяют пространство, в котором любая графовая ИИ-система должна функционировать надёжно. В диссертации предлагаются методы, удовлетворяющие всем условиям одновременно.

Три рабочих условия: (1) состязательная среда, в которой целенаправленный противник возмущает топологию графа, признаки узлов или временной порядок событий; (2) распределённая среда, в которой графовые

данные фрагментированы между организациями, не имеющими возможности централизовать свои данные, и где некоторые участники могут быть ненадёжными или злонамеренными; и (3) нестационарность, при которой статистические свойства графа эволюционируют во времени.

Четыре сквозных требования: (T1) робастность — предсказания должны оставаться устойчивыми при возмущениях; (T2) точность — должна поддерживаться высокая производительность классификации; (T3) эффективность — события графа должны обрабатываться достаточно быстро для работы в реальном времени; и (T4) дифференциальная приватность — процесс обучения не должен раскрывать конфиденциальные данные.

Таблица 2 – Три рабочих условия и методы, разработанные для их решения.

Условие	Методы	Обоснование
У1: Состязательная среда	M1: CT-TGNN M5: Стох. трансф. M7: Сертификация	Нейронные ОДУ непрерывного времени обеспечивают гладкость траектории представления с ограниченной константой Липшица, предоставляя детерминированные сертификаты робастности, которые альтернативы дискретного времени обеспечить не могут. Стохастическое состязательное обучение и теоретико-игровые стратегии равновесия дополняют архитектурную гарантию адаптивной защитой.
У2: Нестационарные условия	M1: CT-TGNN M3: TripleE-TGNN M4: MambaShield M6: UC-HGP	CT-TGNN захватывает темпоральную эволюцию через нейронные дифференциальные уравнения; TripleE-TGNN предотвращает катастрофическое забывание через упругую консолидацию весов; MambaShield обеспечивает близкую к линейной эффективность; а UC-HGP предоставляет неопределённость на иерархических гауссовских процессах для обнаружения дрейфа.
У3: Распределённая сетевая динамика	M2: FedLLM-API M7: Сертификация	Оптимальный транспорт через итерации Синкхорна корректирует гетерогенность между фрагментами графов, а покоординатная агрегация усечённым средним устойчива к повреждённым участникам, при этом калиброванный гауссовский шум обеспечивает формальный бюджет приватности.

Таблица 3 – Четыре сквозных требования и методы, их выполняющие.

Требование	Методы	Обоснование
T1: Робастность	M1: CT-TGNN M4: MambaShield M7: Сертификация	CT-TGNN обеспечивает непрерывную динамику с ограниченной константой Липшица; MambaShield устойчив к отравлению на этапе обучения через прогрессивную дистилляцию; система сертификации связывает гарантии через рандомизированное сглаживание и распространение интервальных границ.
T2: Точность	M3: TripleE-TGNN M5: Стох. трансф. M6: UC-HGP	Многоуровневые вложения графов захватывают структуру на уровнях сервисов, трассировок и узлов; вариационное байесовское внимание декомпозирует неопределённость; иерархические гауссовские процессы обеспечивают калиброванные доверительные интервалы.
T3: Эффективность	M4: MambaShield M2: FedLLM-API M3: TripleE-TGNN	MambaShield снижает стоимость вывода с квадратичной до близкой к линейной; FedLLM-API сокращает число раундов коммуникации; TripleE-TGNN достигает экономии через структурированную разреженность и обучение с учётом квантования.
T4: Приватность	M2: FedLLM-API M1: CT-TGNN M7: Сертификация	FedLLM-API обеспечивает (ϵ, δ) -дифференциальную приватность; CT-TGNN поддерживает дифференциально приватное извлечение признаков; система сертификации отслеживает кумулятивный бюджет приватности.

Три условия не являются взаимоисключающими: реальные графовые системы, как правило, сталкиваются с двумя или всеми тремя одновременно. На Рис. 3 показано, как семь методов расположены в пространстве, определённом пересекающимися условиями.

Система обеспечивает предметную независимость. Каждый метод сформулирован на уровне математических операций над графовыми структурами без привязки к какой-либо конкретной прикладной области. Лишь в последующих главах эти методы отображаются на сущности и ограничения конкретных сред развёртывания, в частности гибридных систем обнаружения и предотвращения вторжений. После определения пространства




Рис. 3 – Расположение семи методов в пространстве условий функционирования (слева) и требований (справа). М4: MambaShield находится на пересечении всех трёх условий; М1: CT-TGNN связывает состязательное и нестационарное условия через сертифицированные непрерывно-временные динамики.




Рис. 4 – Архитектурная основа исследовательской программы. Семь методов покрывают все 12 пересечений матрицы условие–требование 3×4 . Каждый сформулирован на уровне математических операций над графами — предметно-независим. Все модели разработаны автором и описаны в 18 рецензируемых публикациях.

задач, рабочих условий и архитектурной основы в следующем разделе формулируется точная цель исследования и последовательные задачи для её

достижения.

Цель исследования

Основной целью настоящей диссертации является *повышение робастности и эффективности гибридных систем обнаружения и предотвращения вторжений* (Hybrid IDPS), функционирующих в распределённых и нестационарных условиях, путём разработки ИИ/МО-усиленных моделей и алгоритмов, систематически обеспечивающих шесть сквозных свойств системы (П1–П6 из §2.1.2): состязательную устойчивость, робастность, эффективность, совместимость с распределённой средой, человеческий фактор через калиброванную неопределённость и нестационарную адаптацию.

Достижение этой цели требует выполнения семи исследовательских задач, расположенных в последовательную цепочку, так что выход каждой задачи обеспечивает вход, необходимый для следующей. Математические конструкции, реализующие эти задачи (модели и алгоритмы M1–M7), разрабатываются в Главе 2 и в настоящем введении не вводятся.

1. Провести систематический обзор и классификацию существующих Hybrid IDPS, выявить ограничения конвенциональных отраслевых продуктов в трёх канонических каналах детектирования (сигнатурный, аномалийный, протокольный анализ) и сформулировать открытые исследовательские пробелы, мотивирующие ИИ/МО-расширение системы (Глава 1).
2. Формализовать Hybrid IDPS как единый математический объект и поставить шесть сквозных свойств П1–П6 системы в виде исследовательских вопросов с соответствующими количественными инвариантами (§2.1).
3. Разработать модели и алгоритмы для обучаемых детекторов Hybrid IDPS, систематически закрывающие каждое из шести свойств, с доказательствами сходимости, сертификатами робастности и анализом вычислительной сложности (Глава 2).
4. Инстанцировать Hybrid IDPS для сектора защиты сетевого трафика и систематически валидировать её на шести эталонных наборах данных общим объёмом 84,2 миллиона размеченных образцов (Глава 3).
5. Провести кросс-секущую валидацию системы Hybrid IDPS на уровне

состязательной робастности по шести семействам атак, кросс-доменного переноса в принципиально иные предметные области и прямой совместимости с постквантовыми протокольными режимами (Глава 4).

6. Реализовать инстанцирование Hybrid IDPS для защиты сетевого трафика как программную платформу промышленного уровня (RobustIDPS.ai) с двухплоскостной архитектурой и продемонстрировать её внедрение в профильных организациях (Глава 5).

7. Расширить систему Hybrid IDPS на сектор защиты беспилотных летательных аппаратов, продемонстрировать предметную независимость разработанных моделей и предоставить референсную реализацию Phase A с валидацией в условиях радиоэлектронной борьбы (Глава 6).

Объект исследования

Объектом исследования являются *гибридные системы обнаружения и предотвращения вторжений* (Hybrid IDPS), функционирующие в состязательных, нестационарных и распределённых средах и адаптируемые к различным предметным областям — защите сетевого трафика, систем БПЛА, банковской и финансовой инфраструктуры, систем хранения медицинских данных, промышленного интернета вещей, систем управления критическими инфраструктурами и других. Hybrid IDPS объединяет сигнатурные, поведенческие, статистические и обучаемые компоненты в единый защитный контур с многоуровневой архитектурой и интегрированными средствами реагирования. Свойства Hybrid IDPS, рассматриваемые в работе, определяют, может ли система надёжно функционировать при состязательном возмущении входных данных, нестационарной эволюции распределения трафика, распределённой архитектуре обучения, ограничениях приватности и ограниченных вычислительных бюджетах целевых платформ. В качестве математического представления внутренних структур данных IDPS используется аппарат темпоральных графов, что обеспечивает единое формальное описание разнородных предметных областей.

Предмет исследования

Предметом исследования являются *модели и алгоритмы* повышения робастности и эффективности Hybrid IDPS, обеспечивающие сквозное удовлетворение требований робастности, точности, эффективности и дифференциальной приватности в состязательных, нестационарных и распределённых условиях. Предмет исследования охватывает: модели на основе нейронных обыкновенных и стохастических дифференциальных уравнений для сертифицированной динамики непрерывного времени (M1, расширение SDE-TGNN); алгоритмы федеративной оптимизации с византийско-устойчивой агрегацией и выравниванием по принципу оптимального транспорта (M2); многоуровневые темпорально-графовые модели с упругой консолидацией весов (M3); модели селективного пространства состояний для эффективного последовательного вывода (M4); вероятностные модели на основе байесовских апостериорных обновлений и иерархических гауссовских процессов для онлайн-калибровки и адаптации к дрейфу (M5, M6); теоретико-игровые алгоритмы сертификации устойчивости при адаптивном противнике (M7); а также фундаментальную модель CyberSecLLM. Графовые нейронные сети рассматриваются в работе как одна из ветвей классификации моделей, применяемых в Hybrid IDPS, наряду с моделями пространства состояний, стохастическими дифференциальными моделями и теоретико-игровыми алгоритмами. Все формулировки сконструированы предметно-независимо и пригодны к переносу на любую область, где Hybrid IDPS сталкивается с состязательными или нестационарными условиями.

Методы исследования

Методологическая программа настоящей диссертации организована вокруг восьми формальных методов, каждый из которых выбран потому, что он решает конкретный и измеримый аспект проблемы робастности гибридных моделей IDPS.

Нейронные обыкновенные дифференциальные уравнения моделируют непрерывную эволюцию представлений узлов через параметризованное

векторное поле,

$$\frac{d\mathbf{h}(t)}{dt} = f_{\theta}(\mathbf{h}(t), t), \quad (2)$$

решаемое численными интеграторами с адаптивным шагом. Их роль — обеспечить динамику на графовых структурах, чувствительность выхода которой, измеряемая константой Липшица обученного отображения, может быть оценена и представлена как сертификат робастности (центральный элемент моделей M1: CT-TGNN и M3: TripleE-TGNN).

Графовые нейронные сети расширяют обученные представления на реляционные данные через агрегацию окрестностей,

$$\mathbf{h}_v^{(k+1)} = \phi\left(\mathbf{h}_v^{(k)}, \bigoplus_{u \in \mathcal{N}(v)} \psi(\mathbf{h}_u^{(k)}, \mathbf{e}_{uv})\right), \quad (3)$$

и их сочетание с нейронным ОДУ на изменяющейся во времени структуре смежности порождает темпоральные графовые модели, захватывающие как топологические, так и временные зависимости (используется в методах M1, M3 и M5).

Оптимальный транспорт обеспечивает геометрию на распределениях вероятностей через расстояние Вассерштейна,

$$W_p(\mu, \nu) = \left(\inf_{\gamma \in \Pi(\mu, \nu)} \int c(\mathbf{x}, \mathbf{y}) d\gamma(\mathbf{x}, \mathbf{y}) \right)^{1/p}, \quad (4)$$

чья энтропийная регуляризация через итерации Синкхорна снижает вычислительную стоимость. В данной работе метод применяется для выравнивания гетерогенных распределений фрагментов графов в рамках цикла федеративной оптимизации при сохранении измеримого бюджета дифференциальной приватности (центральный элемент метода M2: FedLLM-API).

Дифференциальная приватность формализует конфиденциальность на уровне записей данных через условие

$$\mathbf{P}[\mathcal{M}(\mathcal{D}) \in S] \leq e^{\epsilon} \mathbf{P}[\mathcal{M}(\mathcal{D}') \in S] + \delta, \quad (5)$$

а её композиция через моменты-бухгалтер позволяет точно отслеживать кумулятивный расход приватности ϵ по раундам обучения (используется в

методах М2 и М7).

Модели пространства состояний переформулируют последовательную обработку графовых событий как линейную динамическую систему,

$$\mathbf{h}_{t+1} = \mathbf{A} \mathbf{h}_t + \mathbf{B} \mathbf{x}_t, \quad \mathbf{y}_t = \mathbf{C} \mathbf{h}_t + \mathbf{D} \mathbf{x}_t, \quad (6)$$

чьё свёрточное ядро вычисляется за близкое к линейному время через быстрое преобразование Фурье (центральный элемент моделей М4: MambaShield и М5: Стохастический трансформер).

Робастная оптимизация встраивает наихудшие возмущения графа непосредственно в оценку параметров через мин-макс целевую функцию

$$\min_{\theta} \mathbb{E}_{(\mathbf{x}, y) \sim \mathcal{D}} \left[\max_{\|\boldsymbol{\delta}\| \leq \epsilon} \mathcal{L}(f_{\theta}(\mathbf{x} + \boldsymbol{\delta}), y) \right], \quad (7)$$

чья структура двойственности связывает бюджет возмущений ϵ с чувствительностью выхода обученного отображения на графе (используется в методах М1 и М7).

Байесовский вывод формирует апостериорные предсказательные распределения, декомпозирующие полную предсказательную неопределённость на эпистемическую неопределённость (обусловленную ограниченностью обучающих данных) и алеаторную неопределённость (возникающую из-за присущего шума). В данной работе вариационное байесовское внимание и иерархические гауссовские процессы обеспечивают эту декомпозицию для графовых данных (центральный элемент моделей М5 и М6).

Теоретико-игровое моделирование формализует состязательную обстановку как стратегическое взаимодействие между защитником (графовым классификатором) и атакующим. Анализ равновесия Штакельберга и алгоритмы онлайн-обучения без регрета определяют оптимальные стратегии защиты при модели наихудших возмущений (центральный элемент метода М7).

Византийско-устойчивая агрегация использует покоординатные усечённые средние для фильтрации повреждённых обновлений градиентов в условиях федеративного обучения на графах (центральный элемент метода М2:

FedLLM-API).

В дополнение к этим математическим методам в исследовании применяются стандартные практики программной инженерии, проектирования распределённых систем и высокопроизводительных вычислений для обеспечения возможности обработки крупномасштабных темпоральных графовых потоков в рамках ограничений задержки операционных сред реального времени.

Научная новизна

Научная новизна настоящей работы состоит из семи вкладов в теорию и практику построения *систем Hybrid IDPS*, каждый из которых сформулирован как принцип, концепция или теория, установленные автором, и систематически отвечает за один или несколько инвариантов П1–П6 из §2.1.2.

1. *Впервые* установлен принцип сертифицированной устойчивости *обучаемого детектора системы Hybrid IDPS* на основе моделей непрерывного времени (M1: CT-TGNN, SDE-TGNN): динамика представлений узлов графа, управляемая дифференциальными уравнениями с ограниченной гладкостью, порождает доказуемые границы чувствительности выходных сигналов к возмущениям входных данных и структуры (инвариант П1, ур. (2.2)). Ни одна предшествующая работа не выводит сертифицированную робастность системы из гладкости управляющего дифференциального уравнения на темпорально эволюционирующих топологиях графов.

2. *Оригинальная* теория совместного обеспечения византийской устойчивости, формальной приватности и распределительного выравнивания при обучении *системы Hybrid IDPS* на разрозненных фрагментах данных, принадлежащих разным организациям, без передачи исходных данных (M2: FedLLM-API, инвариант П4). Ни один предшествующий алгоритм не гарантирует совместно устойчивость системы к повреждениям, защиту приватности и выравнивание распределений для гетерогенных фрагментов.

3. *Новая* концепция многоуровневого представления данных в *системе Hybrid IDPS* (M3: TripleE-TGNN), в которой обучаемые модели одновременно обучают структуру на нескольких семантических уровнях (сервис/трассировка/узел) с механизмом защиты от утраты ранее усвоенных законо-

мерностей при поступлении новых данных (инвариант П6). Ни одна предшествующая архитектура не обучает многоуровневые темпоральные представления с одновременным предотвращением забывания.

4. *Новый* подход к эффективному выводу *детектора системы Hybrid IDPS* на основе селективных пространств состояний (М4: MambaShield), позволяющий снизить вычислительную сложность с квадратичной до почти линейной при сохранении устойчивости к отравлению обучающих данных (инвариант П3, ур. (2.4)). Предшествующие структурированные модели пространства состояний не были адаптированы для графовых данных Hybrid IDPS с формальными гарантиями робастности.

5. *Впервые* предложена интегрированная теория калиброванной неопределённости для *системы Hybrid IDPS* (М5–М6: стохастический трансформер + UC-HGP), позволяющая разделять источники ошибок системы на устранимые (эпистемические) и неустранимые (алеаторные) и систематически выявлять момент, когда детектор системы перестаёт быть надёжным (инвариант П5, ур. (2.6)). Ни одна предшествующая работа не интегрирует эти два механизма неопределённости для онлайн-адаптации системы Hybrid IDPS.

6. *Оригинальная* концепция единой сертификации устойчивости *системы Hybrid IDPS* (М7), в которой взаимодействие защитника и противника моделируется как стратегическая игра с доказуемо оптимальной стратегией выбора, связывающая все разработанные модели М1–М6 в целостную систему через регуляризацию согласованности. Ни одна предшествующая единая система Hybrid IDPS не обеспечивает доказуемые гарантии против всех четырёх типов возмущений (П1–П4) одновременно.

7. *Новая* теория предметно-ориентированного фундаментального моделирования (CyberSecLLM) на графовых структурах, обеспечивающая распознавание системой Hybrid IDPS ранее невиданных категорий угроз без дополнительного обучения и совместимость с эволюционирующими протоколами, в том числе постквантовыми. Эти вклады сведены к следующим основным научным результатам, выносимым на защиту.

Основные научные результаты, выносимые на защиту

Результаты, выносимые на защиту, перечислены в порядке, отражающем их логические зависимости; каждый результат опирается на гарантии, установленные предшествующими, и систематически реализован в составе *единой системы Hybrid IDPS* — семёрки $\mathcal{H} = (\mathcal{V}_t, \mathcal{E}_t, X_t, A_t, f_\theta, g_\psi, \pi)$ из §2.1.

(1) **Модели M1 (CT-TGNN, SDE-TGNN) для сертифицированной динамики обучаемого детектора системы Hybrid IDPS** — оригинальные архитектуры непрерывного времени, в которых нейронные ОДУ и стохастические дифференциальные уравнения управляют эволюцией представлений на динамических топологиях, обеспечивая системе сертифицированные границы робастности через анализ Липшица обученного векторного поля (инвариант П1).

(2) **Алгоритм M2 (FedLLM-API) для распределённого обучения системы Hybrid IDPS с сохранением приватности** — федеративный оптимизатор с доказанной сходимостью, сочетающий византийско-устойчивую агрегацию усечённым средним с $(\varepsilon=0,85, \delta=10^{-5})$ дифференциальной приватностью и выравниванием оптимального транспорта Васерштейна для гетерогенных фрагментов данных (инвариант П4).

(3) **Архитектура M3 (TripleE-TGNN) для многоуровневого представления данных в системе Hybrid IDPS** — система тройного вложения, обучающая структуру на уровнях сервисов, трассировок и узлов с помощью двойного внимания и упругой консолидации весов, снижающая вычислительные затраты системы через структурированную разреженность и предотвращающая катастрофическое забывание (инвариант П6).

(4) **Архитектура M4 (MambaShield) для эффективного вывода системы Hybrid IDPS** — селективная модель пространства состояний, снижающая сложность вывода детектора системы с $\mathcal{O}(L^2)$ до $\mathcal{O}(L \log L)$ через свёртки БПФ, с прогрессивной состязательной дистилляцией и РАС-байесовскими сертификатами обобщения (инвариант П3).

(5) **Модели M5–M6 (стохастический трансформер и UC-HGP) для адаптации системы Hybrid IDPS к дрейфу с учётом неопределённости** — вариационное байесовское внимание с выводом на иерархических гауссовских процессах, обеспечивающее декомпозицию эпистемической и алеаторной неопределённости системы, онлайнное обнаружение дрейфа и гарантии сублинейного регрета при нестационарных распределениях данных (инварианты П5, П6).

(6) **Единая система сертификации Hybrid IDPS (M7), интегрирующая модели (1)–(5)** — единая методология оценки, связывающая все разработанные модели через теоретико-игровые равновесия Штакельберга и регуляризацию согласованности, валидированная на 6 бенчмарк-наборах данных общим объёмом 84,2 миллиона размеченных образцов и подтверждённая в двух показательных приложениях системы — защите сетевого трафика (Глава 5) и защите беспилотных летательных аппаратов (Глава 6).

Теоретическая значимость

Теоретическая значимость работы состоит в создании единой математической основы для робастного обучения на динамических графовых структурах, интегрирующей пять областей математики, ранее не объединявшихся для задач на графах:

1. **Нейронные ОДУ** — для сертифицированной динамики непрерывного времени на графах, при которой Липшицевость обученного отображения порождает доказуемые границы чувствительности.
2. **Оптимальный транспорт** — для выравнивания распределений между организациями с одновременным обеспечением формальных гарантий дифференциальной приватности.
3. **Селективные модели пространства состояний** — для снижения вычислительной сложности темпорального вывода с квадратичной до почти линейной, что делает обработку в реальном времени осуществимой.
4. **Байесовский вывод** — для декомпозиции предсказательной неопределённости на устранимую (эпистемическую) и неустранимую (алеаторную) компоненты, позволяющей системе определять, когда её решения ненадёжны.

5. Теоретико-игровой выбор стратегий — для моделирования взаимодействия защитника и противника как стратегической игры с доказуемо оптимальной стратегией защиты.

Эта основа устанавливает шесть формальных гарантий — скорости сходимости ($\mathcal{O}(1/\sqrt{T})$), сертификаты робастности по Липшицу, границы (ε, δ) -дифференциальной приватности, РАС-байесовские границы обобщения, сублинейный регрет ($R(T) \leq 2\sqrt{T \log |\mathcal{C}|}$) и единую сходимость (Теорема 6) — которые являются предметно-независимыми и подтверждены как теоретически (через доказательства), так и эмпирически (через эксперименты на 84,2 миллионах образцов).

Практическая значимость

Разработанные модели и алгоритмы M1–M7 в составе единой *системы Hybrid IDPS* применимы в шести предметных секторах из §1.1.2 и могут быть реализованы следующим образом.

1. **Защита сетевого трафика (NIDS).** SOC-аналитики, инженеры кибербезопасности, исследователи MLSecOps и разработчики ИИ используют программную платформу с открытым исходным кодом RobustIDPS.ai (DOI: [10.5281/zenodo.19129512](https://doi.org/10.5281/zenodo.19129512), Глава 5), интегрирующую 17 моделей системы M1–M7, четырёхуровневую систему защиты LLM с обнаружением 94,5% по 517 сценариям атак, и работающую как плагин для Snort, Suricata и аналогичных систем СОПСВ. Эта область — основное показательное применение разработанной системы.

2. **Защита беспилотных летательных аппаратов (БПЛА).** Инженеры по защите БПЛА развёртывают трёхуровневую архитектуру *борт-дронпорт-облако* системы Hybrid IDPS (Глава 6), сохраняющую долю успешного завершения миссии $MCR \geq 0,80$ при отношении помеха/сигнал $J/S \leq 20$ дБ в условиях радиоэлектронной борьбы и состязательных атак на бортовые нейросетевые модули зрительного восприятия.

3. **Защита банковской и финансово-технологической инфраструктуры.** Банки и финансовые регуляторы используют систему Hybrid IDPS с моделью M2 (FedLLM-API) для совместного обучения детекторов мошенничества на графах транзакций без обмена данными

клиентов, сохраняя приватность через гарантии (ε, δ) -дифференциальной приватности и устойчивость к группе византийских участников $\beta < 1/3$.

4. Защита медицинских информационных систем. Команды биомедицинского ИИ интегрируют систему Hybrid IDPS с моделями M1 и M6 в платформы поддержки клинических решений для обеспечения сертифицированно безопасных предсказаний на молекулярных графах и графах взаимодействия пациент–врач–лаборатория с калиброванной оценкой эпистемической неопределённости.

5. Защита промышленного интернета вещей и АСУ ТП (IIoT/SCADA). Инженеры ОТ-безопасности развёртывают систему Hybrid IDPS с моделью M4 (MambaShield) на периферийных шлюзах и контроллерах SCADA для обнаружения аномалий в реальном времени с детерминированной задержкой в десятки миллисекунд благодаря $\mathcal{O}(L \log L)$ сложности вывода.

6. Защита автономных транспортных средств. Инженеры безопасности АТС используют систему Hybrid IDPS с моделями M1, M4 и M6 для получения калиброванных эпистемических оценок уверенности для решений на графах слияния сенсоров (камера, ЛидАР, радар, ИНС), что позволяет системе маркировать ненадёжные предсказания до того, как они приведут к опасным действиям и переводить транспортное средство в безопасный режим.

Практическая применимость подтверждена актами внедрения от трёх организаций: ООО «НИИ ИКТ» (защита сетевой безопасности критической инфраструктуры, точность 95,7%), ООО «Гексагон» (федеративное обучение для коммерческих Hybrid IDPS и безопасность периферийных вычислений, точность 96,8%, снижение затрат на 40%) и Центр искусственного интеллекта НИЯУ МИФИ, г. Москва (применение разработанных AI-моделей Hybrid IDPS к защите бортовых систем БПЛА).

Личный вклад

Все результаты получены автором лично под научным руководством проф. А. Г. Трофимова. Автор лично разработал архитектуры ST-TGNN и SDE-TGNN, создал алгоритм FedLLM-API, спроектировал архитектуру

TripleE-TGNN, разработал модель MambaShield, интегрировал стохастический трансформер с UC-HGP, построил единую систему сертификации и реализовал платформу RobustIDPS.ai. Вклад автора составляет 100% в постановке задач, разработке методов, проведении экспериментов, создании программного обеспечения и подготовке публикаций.

Достоверность научных результатов

Уверенность в представленных результатах обеспечивается несколькими независимыми линиями валидации.

Каждый предложенный алгоритм сопровождается формальным математическим анализом: теоремами сходимости с явными выражениями скорости, сертификатами робастности, выведенными из анализа чувствительности выхода графовой нейронной динамики и рандомизированного сглаживания, адаптированного к дискретным графовым структурам, гарантиями приватности, полученными через композицию моментов-бухгалтера гауссовского механизма, и границами вычислительной сложности, подтверждёнными как асимптотическим анализом, так и эмпирическим профилированием.

Эмпирическая оценка охватывает шесть бенчмарк-наборов данных, предоставляющих в совокупности более 84,2 миллиона размеченных образцов по 84 категориям возмущений. Используются три набора данных общего сетевого трафика: CIC-IoT-2023 (46,6 млн записей, 33 категории), CSE-CICIDS2018 (16,2 млн записей, 7 категорий) и UNSW-NB15 (2,5 млн записей, 9 категорий). Три специализированных набора данных облачных и периферийных сред из коллекции ICS3D дополняют их: Microsoft GUIDE (13,7 млн записей), Container Security (3,2 млн записей) и Edge-IIoT (2,0 млн записей).

Абляционные эксперименты систематически удаляют отдельные компоненты для количественной оценки маргинального вклада каждого. Состязательная робастность оценивается при шести семействах атак (FGSM, PGD, C&W, DeepFool, гауссовский шум, отравление масок меток). Все эксперименты документированы таблицами гиперпараметров, спецификациями случайных затравок и описаниями оборудования, достаточными для

независимого воспроизведения.

Апробация работы

Основные результаты настоящего исследования были представлены и прошли рецензирование на международных и национальных научных площадках:

1. Конференция IEEE молодых исследователей в области электротехники и электроники (ElCon-2024), ЭТУ-ЛЭТИ, Санкт-Петербург, IEEE Xplore.
2. Конференция IEEE молодых исследователей в области электротехники и электроники (ElCon-2025), ЭТУ-ЛЭТИ, Санкт-Петербург, IEEE Xplore.
3. Международная конференция NEUROINFORMATICS-2025, Springer.
4. III Всероссийская научно-техническая конференция «Кибернетика и информационная безопасность» (КИБ-2025), НИЯУ МИФИ, Москва.
5. 27-я Международная конференция IEEE молодых специалистов в области электронных устройств и материалов (EDM-2026), Республика Алтай.
6. 11-я конференция IEEE по технологиям интеграции электронных систем (IEEE ESTC 2026), Хельсинки, Финляндия.
7. Конференция IEEE «Исследования и технологии для общества и промышленности» (RTSI 2026), Эспоо, Финляндия.
8. NeurIPS 2026: 40-я ежегодная конференция по системам обработки нейронной информации, Сидней, Австралия.

Акты внедрения получены от трёх организаций: ООО «НИИ ИКТ», ООО «Гексагон» и Центра искусственного интеллекта Национального исследовательского ядерного университета «МИФИ», г. Москва.

Публикации

Результаты настоящей диссертации изложены в рецензируемых публикациях в международных журналах и трудах конференций.

Опубликованные журнальные статьи

1. Anaedevha, R. N., Trofimov, A. G., Borodachev, Y. V. (2026). MambaShield: Selective State-Space Models for Poisoning-Resilient Sequential Modeling.

- Expert Systems with Applications*, Elsevier. DOI: 10.1016/j.eswa.2026.131175
2. Anaedevha, R. N., Trofimov, A. G., Borodachev, Y. V. (2026). Uncertainty-calibrated hierarchical Gaussian processes for intrusion detection with multi-scale temporal modeling. *Neurocomputing*, p.133105, Elsevier. DOI: 10.1016/j.neucom.2026.133105
3. Anaedevha, R. N., Trofimov, A. G., Borodachev, Y. V. (2026). Temporal Adaptive Neural Ordinary Differential Equations with Deep Spatio-Temporal Point Processes for Real-Time Network Intrusion Detection. *Complex and Intelligent Systems*, Springer. DOI: 10.1007/s40747-026-02291-7
4. Anaedevha, R. N., Trofimov, A. G. (2024). Improved Robust Adversarial Model against Evasion Attacks on Intrusion Detection Systems. *Optical Memory and Neural Networks (Information Optics)*, 33(Suppl. 3), S414–S423. Springer. DOI: 10.3103/S1060992X24700681

Опубликованные труды конференций

5. Anaedevha, R. N., Trofimov, A. G. (2025). Stochastic Multimodal Transformer with Uncertainty Quantification for Robust Network Intrusion Detection. In: *Advances in Neural Computation, Machine Learning, and Cognitive Research IX. NEUROINFORMATICS 2025*. Studies in Computational Intelligence, vol.1241. Springer, Cham. DOI: 10.1007/978-3-032-07690-8_35
6. Anaedevha, R. N. *et al.* (2025). Integrated Deep Q-Networks and Actor-Critic Models for Enhanced Poisoning Attack Detection in Network Intrusion Detection Systems. In: *2025 Conf. of Young Researchers in Electrical and Electronic Engineering (ElCon)*, ETU-LETI, Saint Petersburg. IEEE Xplore, Vol. 33, pp. 556–567.
7. Anaedevha, R. N. *et al.* (2024). Application of Machine Learning Models for Device Identification in Wireless Network Traffic. In: *2024 Conf. of Young Researchers in Electrical and Electronic Engineering (ElCon)*, Saint Petersburg. IEEE Xplore, pp. 104–110. DOI: 10.1109/ElCon61730.2024.10468413

Принятые к публикации

8. Anaedevha, R. N., Trofimov, A. G., Borodachev, Y. V. (2025). Stochastic PAC-Bayesian Transformers for Network Intrusion Detection and Natural Language Processing Applications. *Knowledge and Information Systems*, Springer. Принята.
9. Anaedevha, R. N., Trofimov, A. G., Borodachev, Y. V. (2025). Byzantine-Resilient Stochastic Games for Federated Multi-Cloud Intrusion Detection. *Complex and Intelligent Systems*, Springer. Принята.

Статьи на рецензировании

10. Anaedevha, R. N. *et al.* (2026). TripleE-TGNN: Triple-Embedding Temporal Graph Neural Networks for Multi-Granularity Microservices Security. *IEEE Trans. Dependable and Secure Computing*.
11. Anaedevha, R. N. *et al.* (2026). PQ-IDPS: Adversarially Robust Intrusion Detection for Post-Quantum Encrypted Traffic. *IEEE Trans. Neural Networks and Learning Systems*.
12. Anaedevha, R. N. *et al.* (2026). FedLLM-API: Privacy-Preserving Large Language Model Federation for Zero-Day API Threat Detection. *IEEE Trans. Information Forensics and Security*.
13. Anaedevha, R. N. *et al.* (2026). CT-TGNN: Continuous-Time Temporal Graph Neural Networks for Real-Time Threat Propagation Analysis. *IEEE Trans. Services Computing*.

Сводка публикаций

Общий объём составляет 18 статей: 4 опубликованы в журналах, 3 в трудах конференций, 2 приняты и находятся в печати, 9 на рецензировании. Шестнадцать статей (89%) написаны в качестве первого автора. Публикации индексируются в Scopus, Web of Science и IEEE Xplore. Препринты доступны на TechRxiv и Research Square, записи цитирования поддерживаются в Google Scholar (h-индекс: 4) и ORCID (0000-0003-3649-1561).

Соответствие паспорту специальности

Диссертация соответствует специальности 2.3.1 «Системный анализ, управление и обработка информации, статистика»:

П.4 «Разработка методов и алгоритмов решения задач системного анализа, оптимизации, управления, принятия решений, обработки информации и искусственного интеллекта.» — Единая матрица 3×4 «условия–требования» декомпозирует проблему устойчивости динамических моделей ГНС на 7 подзадач; разработаны алгоритмы адьюнктного обучения СТ-TGNN, FFT-свёртки MambaShield и византийски устойчивая оптимизация FedLLM-API; теоретико-игровые равновесия Штакельберга обеспечивают принятие решений с гарантиями; конвейер извлечения 83 признаков обрабатывает 84,2 млн образцов; 7 новых архитектур нейронных сетей с 6 доказанными теоремами.

П.5 «Разработка специального математического и алгоритмического обеспечения систем анализа, оптимизации, управления, принятия решений, обработки информации и искусственного интеллекта.» — Сертификаты Липшица на основе неравенства Грёнуолла, пропаганда моментов Фоккера–Планка, РАС-байесовские оценки и вассерштейновское OT-выравнивание составляют математическое обеспечение; 8 алгоритмов обеспечивают полный цикл от обучения до развёртывания; платформа RobustIDPS.ai (DOI: 10.5281/zenodo.19129512) с 51 страницами и 17 моделями реализует программное обеспечение.

Структура и объём работы

Диссертация состоит из Введения, шести глав, Заключение, библиографического списка и трёх приложений. Основной текст составляет 230 страниц. Библиография содержит 204 наименования.

Во Введении обосновывается актуальность робастного и эффективно-го обучения на динамических графовых структурах как фундаментальной исследовательской задачи, представлены задокументированные свидетельства отказов моделей ГНС в четырёх критически важных областях, сформулирована цель исследования с семью последовательными задачами, опре-

делены объект и предмет исследования, описаны методы исследования с их формальными уравнениями, изложена научная новизна семи разработанных концепций и теорий, определены теоретическая и практическая значимость, представлен личный вклад автора, сформулированы шесть основных научных результатов, выносимых на защиту, подтверждена достоверность результатов, документированы мероприятия по апробации, публикации и соответствие паспорту специальности.

Глава 1, «Анализ существующей литературы и выявление пробелов», представляет обзор литературы, следующий поэтапному охвату исследования: динамика непрерывного времени на эволюционирующих графах, распределённое федеративное обучение с приватностью, вычислительная эффективность для крупномасштабных графов и нестационарная адаптация с оценкой неопределённости. Каждый раздел завершается связующим утверждением, соединяющим выявленный пробел с решением, разработанным в следующей главе. Выявлено семь исследовательских пробелов из 128 цитируемых работ.

Глава 2, «Методы, алгоритмы и математические основы», представляет полные математические выводы, доказательства сходимости и робастности, алгоритмический псевдокод, архитектурные схемы и анализ сложности для всех семи методов (M1–M7) и их расширений (SDE-TGNN, CyberSecLLM). Единая постановка задачи последовательно выводится в 7 этапах и декомпозируется на 7 подзадач. 62 уравнения, 6 теорем, 8 алгоритмов.

Глава 3, «Адаптация и согласование с гибридными системами обнаружения и предотвращения вторжений», является предметно-ориентированной главой, в которой математические методы Главы 2 отображаются на сущности и ограничения кибербезопасности. Определена таксономия из 34 классов, описан конвейер 83 инженерных признаков, представлены гиперпараметры и обоснование их выбора для каждой модели.

Глава 4, «Экспериментальные результаты и валидация», представляет полную экспериментальную программу на 6 наборах данных (84,2 млн образцов, 84 категории, 23 метрики), включая результаты по отдельным методам, абляцию, состязательную робастность при 6 семействах атак, кросс-доменный перенос и федеративное обучение при византийских повреждениях.

Глава 5, «RobustIDPS.ai: Программная платформа для промышленного развёртывания», описывает платформу с открытым исходным кодом (DOI: 10.5281/zenodo.19129512): 51 страницу, 10 функциональных групп, 17 моделей, 4-уровневая защита LLM (94,5%), модуль Multi-Agent PQC-IDS и интеграция со Snort/Suricata. Пользовательское исследование подтвердило 34% снижение времени сортировки оповещений.

Глава 6, «Применение единого защитного фреймворка к нейросетевой системе навигации беспилотных летательных аппаратов», демонстрирует предметно-независимость разработанных в Главах 2–4 моделей и методов через их перенос на новую критически важную область — противодействие радиоэлектронной борьбе и состязательному машинному обучению в системе навигации БПЛА. Описана трёхуровневая архитектура *борт — дронопорт — облако*, операционный граф БПЛА как экземпляр единой задачи (§2.1), отображение методов M1–M7 на конкретные подсистемы (зрительное восприятие, ГНСС-навигация, автопилотная политика), референсная реализация Phase A с интеграцией в платформу RobustIDPS.ai и соответствие нормативной базе (Постановление Правительства № 1701, ГОСТ Р 72118-2025, NIST AI RMF, DO-326A/ED-202A).

В Заключение перечислены все научные результаты, подтверждено покрытие всех 12 ячеек матрицы условие–требование, указаны акты внедрения и намечены направления дальнейших исследований.

Приложение А содержит полные доказательства всех теорем. Приложение Б предоставляет таблицы гиперпараметров и спецификации инфраструктуры. Приложение В документирует дополнительные экспериментальные результаты.

Глава 1

Анализ гибридных систем обнаружения и предотвращения вторжений и теоретические основы повышения их робастности

В настоящей главе представлен системный обзор гибридных систем обнаружения и предотвращения вторжений (Hybrid IDPS) как объекта исследования: даны определение и классификация Hybrid IDPS (§1.1), систематизированы предметные области применения — защита сетевого трафика, систем БПЛА, финансово-технологической инфраструктуры, медицинских данных, промышленного интернета вещей, автономных транспортных средств и облачных сред, — проведена таксономия моделей и алгоритмов, применяемых в Hybrid IDPS (§1.2), и систематизированы проблемы и уязвимости моделей в Hybrid IDPS (§1.3). Графовые нейронные сети рассматриваются в работе как одна из ветвей семейства моделей, применяемых в Hybrid IDPS, наряду со статистическими, классическими ML-, гибридными и теоретико-игровыми подходами. После систематизации предметной области разделы 1.4–1.9 углубляются в техническую базу разработки моделей M1–M7 по поэтапному охвату: от динамики непрерывного времени на эволюционирующих графах, через распределённое федеративное обучение с приватностью, к вычислительной эффективности для крупномасштабных графов и, наконец, к нестационарной адаптации с оценкой неопределённости. Каждый раздел адресует одно или несколько пересечений трёх рабочих условий (состязательная среда, распределённая динамика, нестационарность) и четырёх сквозных требований (робастность, точность, эффективность, приватность), выстраивая систематическое перечисление семи исследовательских пробелов, мотивирующих модели и алгоритмы, разработанные в Главе 2.

Высокоуровневая интегрированная схема системы Hybrid IDPS, си-

стематически охватывающая источники данных, конвейер нормализации, трёхканальное ядро детектирования (сигнатурное, аномалийное, протокольный анализ) с AI-нативным интеллектуальным слоем, единый менеджер решений и реагирования, перечень защищаемых секторов с их характерными уязвимостями и обобщённые свойства и выгоды развёртывания системы, приведена на рис. [1.1](#).




Рис. 1.1 – Интегрированная схема системы Hybrid IDPS: AI-нативное, адаптивное, контекстно-зависимое, упреждающее защитное решение. Слева — источники данных (сетевой трафик, телеметрия БПЛА, медицинские записи, автономные транспортные средства, банковский/финтех-трафик, системные журналы); по центру — ядро системы с трёхканальным детектированием (сигнатурное, аномалийное, протокольный анализ), AI-нативным интеллектуальным слоем (глубокое обучение, онлайн-обучение, корреляция угроз, оценка риска) и единым менеджером решений и реагирования; справа — блок предотвращения и реагирования (фильтрация трафика, защита команд БПЛА, защита медицинских данных, активная безопасность транспортных средств, предотвращение мошенничества, инцидент-форензика) и системные возможности (обнаружение в реальном времени, многосекторная видимость, адаптивное обучение, низкая доля ложных срабатываний, масштабируемость, объяснимый ИИ). Нижняя панель приводит характерные классы уязвимостей в каждом из пяти показательных секторов.

1.1 Hybrid IDPS как объект исследования: определение, классификация и предметные области применения

Гибридной системой обнаружения и предотвращения вторжений (Hybrid IDPS) в настоящей диссертации называется ИИ/МО-нативный программно-аппаратный комплекс защиты информационных систем, объединяющий в едином защитном контуре три канонических типа детектирования информационной безопасности — сигнатурный (детерминированное сопоставление с базой известных шаблонов атак), аномалийный (статистическое или обучаемое отклонение от нормального профиля поведения) и протокольный анализ (контекстно-зависимый разбор корректности сетевых, прикладных и промышленных протоколов с учётом их состояний), — усиленных обучаемыми моделями на каждом из трёх каналов и дополненных средствами автоматического реагирования и интерфейсами интеграции с внешними системами регистрации событий и реагирования (SIEM/SOAR). В отличие от конвенциональных IDPS-продуктов отрасли (Snort, Suricata, Zeek, Cisco IPS, Palo Alto Threat Prevention) Hybrid IDPS в смысле настоящей диссертации систематически отличается от классических IDS четырьмя свойствами: (i) гибридностью обнаружения — решение о наличии вторжения принимается комбинацией нескольких независимых детекторов, статистических признаков и обучаемых моделей с разной степенью объяснимости; (ii) адаптируемостью к предметной области — одна и та же базовая архитектура может быть инстанцирована в защиту сетевого трафика, систем БПЛА, банковско-финансовой инфраструктуры, медицинских данных, промышленного интернета вещей и иных областей за счёт смены формального представления входных данных; (iii) обратной связью реагирования — наряду с обнаружением Hybrid IDPS способен инициировать активное противодействие угрозе через изменение правил межсетевого экрана, изоляцию узлов, переключение сенсорных конвейеров или передачу события в SOAR-оркестратор; (iv) ИИ-нативностью — обучаемые модели M1–M7, разработанные в Главе 2, интегрированы во все три канала детектирования (сигнатурный,

аномалийный, протокольный) для систематического преодоления трёх неэффективностей конвенциональных IDPS (см. Введение): задержки сигнатурных баз в 30–90 дней, частоты ложных срабатываний 10^{-2} – 10^{-1} на нормальный поток и квадратичной стоимости протокольного анализа по числу протоколов и состояний.

1.1.1 Классификация Hybrid IDPS

Известные в литературе системы IDPS поддаются классификации по пяти ортогональным осям: по применяемому методу обнаружения, по охвату наблюдаемой среды, по сетевой топологии развёртывания, по характеру реагирования и по уровню стека протоколов. Структура классификации приведена на рис. 1.2.




Рис. 1.2 – Иерархическая классификация Hybrid IDPS по пяти ортогональным осям. По методу обнаружения — сигнатурные (детерминированный поиск по базе известных шаблонов), аномалийные (статистическое или обучаемое отклонение от нормального профиля), протокольные (контекстно-зависимый анализ корректности сетевых, прикладных и промышленных протоколов и их состояний) и гибридные (комбинация трёх предыдущих, усиленная обучаемыми моделями M1–M7). По охвату — хостовые (HIDS), сетевые (NIDS) и распределённые (DIDS). По топологии развёртывания — централизованные, распределённые, федеративные. По характеру реагирования — пассивные (только оповещение), активные (вмешательство в поток), IPS (полная блокировка). По уровню стека — прикладной, сетевой и физический.

В рамках настоящей диссертации центральное внимание уделяется гибридным системам распределённой топологии, действующим на сетевом и прикладном уровнях, с активным реагированием.

1.1.2 Предметные области применения Hybrid IDPS

Hybrid IDPS как универсальный защитный контур применим в широком спектре предметных областей. На рис. 1.3 приведена систематизация

семи практически значимых секторов, для каждого из которых ниже даны краткие постановочные сведения о поверхности атак и специфике интеграции защитных моделей. Полные системные реализации для двух показательных секторов — защиты сетевого трафика и защиты беспилотных летательных аппаратов — изложены в Главах 5 и 6 соответственно.




Рис. 1.3 – Предметные области применения Hybrid IDPS. Сектора (а) и (б) рассматриваются в работе как показательные применения и изложены подробно в Главах 5 (анализ сетевого трафика) и 6 (защита БПЛА). Сектора (в)–(ж) приведены обзорно с указанием поверхности атак и режима интеграции защитных моделей.

(а) Защита сетевого трафика (NIDS) Защита сетевого трафика исторически является первой и наиболее изученной областью применения IDPS. Объектом наблюдения служит последовательность сетевых пакетов и потоков, агрегированных в многомерные признаковые векторы (для бенчмарков CIC-IoT-2023, CSE-CICIDS-2018, UNSW-NB15 — 46–83-мерные векторы). Поверхность атак включает сканирование портов, эксплуатацию уязвимостей служб, отказ в обслуживании (DoS/DDoS), горизонтальное распространение, управляющие каналы (C2), эксфильтрацию данных и постквантовые протокольные переходы. Hybrid IDPS интегрируется в стек защиты как дополнение к классическим сигнатурным движкам (Snort, Suricata) и получает на вход агрегированные признаки потоков, событийные графы взаимодействия узлов и потоки SIEM-оповещений. Полное системное описание данного сектора — Глава 5.

(б) Защита беспилотных летательных аппаратов (UAV) Защита БПЛА является показательным расширением Hybrid IDPS за пределы традиционного сетевого периметра. Объектом наблюдения служит гетерогенный поток телеметрии бортовых сенсоров (ИНС/ГНСС, ЛидАР, оптический поток, состояние двигателей и полезной нагрузки) в сочетании с командно-телеметрическим каналом борт-дропоорт-облако. Поверхность

атак включает спуфинг и подавление сигналов ГНСС, радиоэлектронную борьбу (РЭБ), состязательные атаки на бортовые нейросетевые модули зрительного восприятия, отравление политик автопилота, перехват командного канала, а также кинетические и биологические угрозы (столкновения, атаки хищных птиц). Hybrid IDPS адаптируется к данной среде через переход от граф-представления сетевого трафика к граф-представлению операционной обстановки БПЛА с сохранением неизменности математического аппарата M1–M7. Полное системное описание — Глава 6.

(в) Защита банковской и финансово-технологической инфраструктуры Объектом защиты выступают графы транзакций между счетами, платёжными картами, торговыми точками и интерфейсами быстрых платежей. Поверхность атак включает кардинг, отмывание денежных средств, рейдовые транзакционные атаки на детекторы мошенничества (MonTi-атака [?] утраивает ошибку классификации CARE-GNN/PC-GNN/GAGA с 25,7% до 68,6%), спуфинг учётных данных, фишинг и атаки на системы оценки кредитоспособности. Hybrid IDPS в финтех-секторе действует в условиях *сильного дисбаланса классов* (доля мошеннических транзакций < 1%) и *регуляторных ограничений* на использование персональных данных, что требует одновременной византийской устойчивости византийско-устойчивого федеративного обучения между банками и сертифицированной устойчивости детектора к состязательным переоформлениям транзакционных подграфов — методы для обоих требований разрабатываются в Главе 2.

(г) Защита медицинских информационных систем Объектом защиты служат графы электронных медицинских карт, графы взаимодействия пациент–врач–лаборатория, а также графы молекулярных представлений в задачах фармакологии. Поверхность атак включает атаки на чувствительность связей в графовых изоморфных сетях (падение AUC до 25% на бенчмарках MoleculeNet, при котором токсичные соединения классифицируются как безопасные [?]), атаки на конфиденциальность обучающих данных (модельная инверсия, атаки на принадлежность к обучающей выборке) и отравление графов клинических исследований. Hybrid IDPS в ме-

дицинском секторе должен обеспечивать строгое (ϵ, δ) -дифференциально-приватное обучение и калиброванную оценку эпистемической неопределённости для отделения недостоверных предсказаний от достоверных.

(д) Защита промышленного интернета вещей и АСУ ТП (IIoT/SCADA) Промышленный интернет вещей и системы автоматизированного управления технологическими процессами (АСУ ТП) технически отличаются от традиционных NIDS-сред тремя обстоятельствами, что делает IIoT/SCADA отдельной предметной областью применения Hybrid IDPS, а не частным случаем сектора (а): *(i)* стек протоколов передачи данных опирается на специализированные промышленные протоколы (Modbus, DNP3, IEC 61850, OPC-UA, S7) с семантикой управляющих регистров, отсутствующей в стеке TCP/IP; *(ii)* операционные ограничения требуют детерминированной задержки реакции в пределах десятков миллисекунд, что исключает применение тяжёлых неэффективных моделей; *(iii)* модель угроз включает специфические для индустрии классы — манипуляцию состоянием программируемых логических контроллеров (ПЛК), повтор сигналов с датчиков и атаки на временные метки синхронизации. Отравление обучающих данных федеративных детекторов вторжений в IIoT-сетях зафиксировано как причина коллапса точности с 94,2% до 30,0% при не-i.i.d. условиях обучения [?]. Hybrid IDPS в IIoT-секторе реализуется на основе моделей, разработанных в Главе 2.

(е) Защита автономных транспортных средств Объектом защиты в автономных транспортных средствах является граф слияния сенсоров (камера, ЛидАР, радар, ИНС), граф взаимодействия с другими участниками движения через каналы V2X/V2I и граф программных компонентов автопилота. Поверхность атак включает состязательные физические заплатки на дорожные знаки, спуфинг ГНСС, инъекцию ложных V2X-сообщений и отравление траекторного планировщика. Сектор отличается от сектора (б) тем, что действующие лица находятся в наземной среде с другими законодательными ограничениями и иной топологией информационного обмена. Hybrid IDPS в данном секторе использует калиброванную оценки эпистемической неопределённости как триггера перехода в безопасный режим.

(ж) Защита облачных и SaaS-инфраструктур Защита облачных и SaaS-инфраструктур также технически отличается от традиционных NIDS-сред и не сводится к сектору (а) по следующим причинам: (i) основным наблюдаемым потоком является не поток сетевых пакетов, а поток вызовов прикладных программных интерфейсов (API) между микросервисами (так называемый east-west-трафик), наблюдаемый через инфраструктуру сервисного меша (Istio, Linkerd); (ii) требуется обязательная многоарендная (*multi-tenant*) изоляция между арендаторами облака, отсутствующая в традиционных сетевых средах; (iii) модель угроз включает специфические для облака классы — побег из контейнера, злоупотребление учётными записями систем управления идентификацией и доступом (IAM), атаки на цепочку поставок программного обеспечения и подмену образов контейнеров. Атака PROVNINJA [?], снижающая обнаружение ГНС-систем на основе провенанса до 59%, документально подтверждает необходимость защиты данного сектора. Hybrid IDPS в облачном секторе реализуется через модели, разработанные в Главе 2.

1.2 Модели и алгоритмы, применяемые в Hybrid IDPS: систематизация подходов

Совокупность моделей и алгоритмов, применяемых в Hybrid IDPS, систематизирована на рис. 1.4 по пяти семействам: статистические модели, классические алгоритмы машинного обучения, модели глубокого обучения, гибридные подходы и теоретико-игровые алгоритмы. Графовые нейронные сети (ГНС) рассматриваются как один из листов ветви глубокого обучения — наряду с свёрточными, рекуррентными, трансформерными моделями и моделями пространства состояний — а не как центральная парадигма.



Рис. 1.4 – Систематизация моделей и алгоритмов, применяемых в Hybrid IDPS. Графовые нейронные сети (выделены красной рамкой) являются одним из листов ветви глубокого обучения наряду с свёрточными (CNN), рекуррентными (RNN), моделями пространства состояний (SSM) и стохастическими дифференциальными уравнениями (SDE), а не центральной парадигмой. Разработанные в Главе 2 модели M1–M7 заимствуют конструкции из нескольких ветвей одновременно (см. табл. 1.1).

Каждое семейство моделей имеет характерные сильные и слабые стороны, определяющие область его применимости в задачах Hybrid IDPS. Статистические модели и классические алгоритмы машинного обучения эффективны на низкоразмерных табличных признаках и предоставляют интерпретируемые границы принятия решений, однако не способны автоматически извлекать абстрактные представления из необработанных сенсорных потоков и не масштабируются до миллионных размеров графов. Модели глубокого обучения — CNN, RNN, трансформеры, GNN, SSM, SDE — обеспечивают сквозное обучение признаков, однако страдают от чувствительности к состязательным возмущениям и требуют значительных вычислительных ресурсов на этапе вывода. Гибридные подходы (стекинг, ансамбли, конвейерные архитектуры) комбинируют сильные стороны разных семейств. Теоретико-игровые алгоритмы (многоруких бандитов, равновесия Штакельберга, обучение с подкреплением) применяются для онлайн-выбора стратегий реагирования при адаптивном противнике. Соответствие разработанных в работе моделей M1–M7 ветвям приведённой таксономии задаёт область ответственности каждой модели и допускает прямое отображение на направление п. 4 паспорта специальности 2.3.1.

1.3 Проблемы и уязвимости моделей в Hybrid IDPS

Множество проблем, рассматриваемых в работе как мотивирующих разработку моделей и алгоритмов М1–М7, систематизировано на рис. 1.5. Проблемы разнесены по пяти кросс-секущим осям: робастность к состязательным воздействиям, точность в условиях нестационарности и дисбаланса классов, эффективность вывода в условиях ограниченных бюджетов, дифференциальная приватность в распределённых средах и нестационарная адаптация при дрейфе распределения.




Рис. 1.5 – Систематизация проблем и уязвимостей, рассматриваемых в качестве мотивации для разработки моделей М1–М7. Каждая из пяти осей покрывается одной или несколькими разработанными моделями (прямое отображение приведено в табл. 1.1 после изложения существующих ограничений).

Соответствие осей рис. 1.5 разработанным моделям задаёт прямое отображение направлений исследований паспорта специальности 2.3.1 (п. 4 и п. 5) на содержательные результаты диссертации: ось *робастность* покрывается моделями М1, М4 и М5–М6; ось *точность* — М1, М3 и М5–М6; ось *эффективность* — М4 и М7; ось *приватность* — М2; ось *нестационарность* — М1, М3 и М6.

1.4 Графовые нейронные сети: архитектура, уязвимость и проблема двойного входа

1.4.1 Архитектура передачи сообщений и агрегация окрестностей

Графовые нейронные сети [???] расширяют глубокое обучение на неевклидовы реляционные данные путём итеративной агрегации информации от соседей узла. Каноническая формулировка передачи сообщений обновляет представление узла v на слое $k + 1$ как

$$\mathbf{h}_v^{(k+1)} = \phi\left(\mathbf{h}_v^{(k)}, \bigoplus_{u \in \mathcal{N}(v)} \psi(\mathbf{h}_u^{(k)}, \mathbf{e}_{uv})\right), \quad (1.1)$$

где ϕ и ψ — обучаемые функции, $\bigoplus$ — перестановочно-инвариантный агрегатор (сумма, среднее или максимум), а $\mathcal{N}(v)$ обозначает окрестность v . Данная схема охватывает GCN [?], GAT [?], GraphSAGE [?] и их темпоральные расширения [?????]. Выразительность парадигмы передачи сообщений формально охарактеризована через иерархию изоморфизмов Вейсфейлера–Лемана [?], устанавливающую фундаментальные ограничения на то, какие свойства уровня графа эти архитектуры могут различать.

Графовые нейронные сети применяются в здравоохранении (предсказание свойств молекул на графах атомов и связей, графы взаимодействия пациентов для рекомендаций по лечению), финансах (анализ графов транзакций для обнаружения мошенничества и противодействия отмыванию денег), кибербезопасности (графы сетевого трафика для обнаружения вторжений), промышленных системах (графы слияния датчиков для мониторинга SCADA и АСУ ТП) и автономных системах (графы слияния датчиков для восприятия) [?????]. Широта этих применений подчёркивает актуальность анализа робастности.

1.4.2 Уязвимость двойного входа

В отличие от обычных нейронных сетей, принимающих единый тензор данных, графовая нейронная сеть одновременно получает два входа: число-

вые *входные данные* $\mathbf{X} \in \mathbb{R}^{n \times d}$ (матрица признаков, кодирующая атрибуты сущностей) и реляционную *входную структуру* $\mathbf{A} \in \{0, 1\}^{n \times n}$ (матрица смежности, кодирующая попарные связи). Сеть формирует выход путём распространения данных вдоль структуры через итеративную агрегацию окрестностей, и возмущение *любого* из входов — данных или структуры — может нарушить выход [? ? ?].

Zügner и др. [?] продемонстрировали, что изменение всего пяти рёбер в графе цитирования может переключить предсказанную метку целевого узла, в то время как Wojcchewski и Günnemann [?] показали, что глобальные атаки отравления снижают точность классификации узлов до 20% на бенчмарк-наборах данных. Dai и др. [?] расширили эти результаты на возмущение графов на основе обучения с подкреплением, а последующие работы [?] подтвердили, что как признаковые, так и топологические возмущения переносятся между архитектурами ГНС. Biggio и Roli [?] предоставили исчерпывающую таксономию состязательных атак на машинное обучение, а Carlini и Wagner [?] установили эталонные методологии оценки. Kurakin и др. [?] продемонстрировали, что состязательные возмущения сохраняются в условиях реального мира, а Papernot и др. [?] показали осуществимость атак чёрного ящика через переносимость. Athalye и др. [?] впоследствии показали, что обфусцированные градиенты создают ложное чувство безопасности, мотивируя необходимость сертифицированных, а не эмпирических защит. Bhagoji и др. [?] проанализировали состязательные атаки в распределённых условиях, Jia и Liang [?] исследовали отравление данных для рекомендательных систем, а Bose и Hamilton [?] разработали состязательные атаки на графовые вложения. Sun и др. [?] обзрели методы робастности, специфичные для графов, а Jin и др. [?] разработали системы состязательного обучения графов. Компромисс между состязательной робастностью и точностью был формально охарактеризован Tsipras и др. [?], а Tramèr и др. [?] продемонстрировали ансамблевые атаки, преодолевающие маскировку градиентов.

Gama, Bruna и Ribeiro [?] предложили систему устойчивости, ограничивающую чувствительность выхода графовых фильтров через константу Липшица их частотной характеристики. Однако эти границы быстро растут с глубиной сети и не распространяются на темпоральные, распределённые

тельные или состязательные условия, с которыми сталкиваются реальные графовые системы.

1.4.3 Задокументированные отказы в критически важных областях

Уязвимость графовых нейронных сетей не является теоретической проблемой — она задокументирована в рецензируемых исследованиях в четырёх критически важных областях. В здравоохранении градиентные атаки на чувствительность рёбер на графовые изоморфные сети вызвали падение AUC приблизительно на 25% на бенчмарках MoleculeNet (Tox21, ClinTox, SIDER), при этом токсичные соединения были классифицированы как безопасные [?]. В финансах атака MonTi с внедрением группы почти утроила ошибку классификации ГНС-детекторов мошенничества с 25,7% до 68,6% [?]. В промышленном IoT отравление данных федеративных детекторов вторжений вызвало коллапс точности на 64 процентных пункта с 94,2% до 30,0% при не-IID условиях [?]. В кибербезопасности атака PROVNINJA снизила обнаружение ГНС-систем на основе провенанса до 59%, сделав АРТ-атакующих невидимыми [?]. Эти задокументированные отказы подтверждают, что робастность ГНС отстаёт от точности предсказаний на 25–65 процентных пунктов во всех критически важных областях.

Итоги раздела. Механизм передачи сообщений, придающий графовым нейронным сетям выразительную способность, также создаёт поверхность атаки двойного входа, эксплуатируемую как через признаковые, так и через топологические возмущения. Существующие границы устойчивости не распространяются на темпоральные, распределительные или состязательные условия. В следующем разделе рассматривается, могут ли формулировки непрерывного времени обеспечить недостающие сертифицированные гарантии робастности.

1.5 Динамика непрерывного времени на эволюционирующих графах

1.5.1 Нейронные обыкновенные дифференциальные уравнения для представления графов

Chen и др. [?] предложили нейронные обыкновенные дифференциальные уравнения (нейронные ОДУ), заменяющие дискретные послойные обновления обычных сетей параметризацией непрерывной глубины:

$$\frac{d\mathbf{h}(t)}{dt} = f_{\theta}(\mathbf{h}(t), t), \quad (1.2)$$

где f_{θ} — нейронная сеть, параметризующая векторное поле. Выход в любой момент времени T получается численным интегрированием уравнения (1.2) от $t = 0$ до $t = T$ с помощью решателей с адаптивным шагом, а градиенты вычисляются с эффективным использованием памяти через метод сопряжённых чувствительностей [?]. Данная формулировка была расширена на графовые данные: Chamberlain и др. [?] сформулировали графовую нейронную диффузию как непрерывное УЧП на графе, а Rusch и др. [?] разработали связанные осцилляторные графовые нейронные ОДУ, предотвращающие чрезмерное сглаживание. Rubanova и др. [?] расширили нейронные ОДУ на нерегулярно дискретизированные временные ряды, Dupont и др. [?] предложили расширенные нейронные ОДУ с пространствами состояний повышенной размерности, а Kidger и др. [?] разработали нейронные управляемые дифференциальные уравнения для нерегулярных временных рядов. Grathwohl и др. [?] связали нейронные ОДУ с непрерывными нормализующими потоками, а Finlay и др. [?] предложили методы регуляризации для стабильного обучения. Hasani и др. [?] разработали нейронные ОДУ с жидкими постоянными времени для адаптивных вычислений, а Li и др. [?] применили нейронные ОДУ к непрерывным графовым нейронным сетям на статических топологиях.

Темпоральные графовые сети, такие как TGAT [?] и TGN [?], моделируют взаимодействия с временными метками на эволюционирующих гра-

фах, но работают в дискретном времени — каждое событие вызывает один шаг обновления. Это принудительно привязывает нерегулярные события графа к фиксированной вычислительной тактовой сетке, теряя информацию о точном времени и порядке взаимодействий между шагами.

1.5.2 Устойчивость по Липшицу и граница Грёнуолла

Ключевое преимущество формулировок непрерывного времени — их присущая гладкость. Поскольку представления эволюционируют согласно дифференциальному уравнению с ограниченной константой Липшица L_g , неравенство Грёнуолла обеспечивает замкнутый сертификат робастности:

$$\|\mathbf{h}_1(T) - \mathbf{h}_2(T)\| \leq e^{L_g T} \|\mathbf{x}_1 - \mathbf{x}_2\|, \quad (1.3)$$

где $\mathbf{h}_i(T)$ — скрытое состояние траектории i в момент T , а $\mathbf{x}_i$ — начальный вход. Эта граница утверждает, что малые возмущения входа могут вызвать лишь ограниченные, гладкие изменения выхода — гладкость управляющего потока математически ограничивает степень изменения предсказания злоумышленником. Графовые нейронные сети дискретного времени не имеют такого непрерывного механизма, поэтому возмущения непредсказуемо накапливаются от слоя к слою [?].

Рандомизированное сглаживание [?] и распространение интервальных границ [?] обеспечивают альтернативные пути сертификации, но они были разработаны для классификаторов изображений и не учитывают комбинаторную структуру матриц смежности графов или интегрирование нейронных ОДУ в непрерывном времени. Лесцуег и др. [?] связали дифференциальную приватность с сертифицированной робастностью, а Salman и др. [?] объединили рандомизированное сглаживание с состязательным обучением. Shafahi и др. [?] разработали свободное состязательное обучение для повышения эффективности, а Wong и Kolter [?] предоставили масштабируемое верифицированное обучение через выпуклую релаксацию.

1.5.3 Ограничения существующих подходов непрерывного времени

Несмотря на теоретическую перспективность, ни одна существующая работа не выводит сертифицированные границы робастности из гладкости управляющего дифференциального уравнения на темпорально эволюционирующих топологиях графов. Существующие модели графов непрерывного времени либо работают на статических графах [?], либо обрабатывают темпоральные рёбра без анализа Липшица [? ? ? ? ?]. Многомасштабная темпоральная динамика (захватывающая как субсекундные переходные процессы, так и часовые структурные тенденции) не была решена в рамках сертифицированной системы. Более того, обучение с $O(1)$ -памятью через сопряжённый метод не было сочетано с темпоральной адаптивной нормализацией для эволюционирующих топологий графов.

Пробел 1: *Отсутствие сертифицированной робастности при динамике графов непрерывного времени.* Ни одна существующая архитектура не обеспечивает формально сертифицированные границы робастности для графовых нейронных сетей, работающих в непрерывном времени на темпорально эволюционирующих топологиях, сочетая анализ Липшица управляющего векторного поля с обучением через сопряжённый метод с эффективным использованием памяти и многомасштабной темпоральной динамикой.

Итоги раздела. Формулировки непрерывного времени предлагают принципиальный путь к сертифицированной робастности через динамику с ограниченной константой Липшица, но существующие подходы не распространяются на эволюционирующие графы с темпоральными потоками событий. В следующем разделе рассматривается, как эти модели должны быть адаптированы для распределённых сред, в которых данные не могут быть централизованы.

1.6 Распределённое обучение на графах с гарантиями приватности

1.6.1 Основы федеративного обучения

McMahan и др. [?] предложили федеративное усреднение (FedAvg), позволяющее проводить распределённое обучение на множестве участников без централизации сырых данных. Каждый участник вычисляет локальные обновления градиентов на своём фрагменте данных, а центральный сервер агрегирует эти обновления в глобальную модель. Данная парадигма необходима для графовых данных в здравоохранении (графы взаимодействия пациентов между больницами), финансах (графы транзакций между банками) и кибербезопасности (графы трафика между центрами обработки данных), где регуляции приватности запрещают обмен данными [? ? ?]. Dwork [?] заложил основы алгоритмической приватности, а McMahan и др. [?] объединили федеративное обучение с дифференциальной приватностью в масштабе. Li и др. [?] решили проблему гетерогенного федеративного обучения через проксимальную регуляризацию, а Zhao и др. [?] охарактеризовали проблему не-IID в федеративных условиях. Wang и др. [?] предложили федеративное согласованное усреднение для гетерогенных архитектур. Sun и Lyu [?] продемонстрировали атаки отравления на федеративное обучение, Fang и др. [?] разработали атаки отравления локальных моделей, а El-Mhamdi и др. [?] установили информационно-теоретические пределы византийско-устойчивой агрегации. Geyer и др. [?] предложили дифференциальную приватность на уровне клиентов для федеративного обучения, а Agarwal и др. [? ? ?] разработали коммуникационно-эффективный распределённый SGD с гарантиями приватности. Wei и др. [?] проанализировали сходимость дифференциально приватного федеративного обучения. Применение подходов глубокого обучения к обнаружению сетевых вторжений в гетерогенных средах систематически рассмотрено В. И. Васильевым, А. М. Вульфеныным и М. Б. Гузаировым [?]; обнаружение сетевых атак на основе графовых нейронных сетей в распределённых системах исследовано И. В. Котенко, И. Б. Саенко и А. А. Браницким [?].

1.6.2 Византийско-устойчивая агрегация

Стандартное федеративное усреднение уязвимо к византийским участникам, отправляющим повреждённые обновления градиентов. Blanchard и др. [?] предложили Krum, который выбирает обновление, наиболее близкое к его соседям, в то время как Yin и др. [?] показали, что по координатным усечённые средние достигают минимаксно-оптимальных скоростей при византийском повреждении. Для графовых данных сама топология может быть частично контролируема противником, добавляя комбинаторную поверхность атаки, отсутствующую в стандартных федеративных условиях.

1.6.3 Дифференциальная приватность и оптимальный транспорт

Дифференциальная приватность [?] формализует конфиденциальность на уровне записей данных через условие

$$\mathbb{P}[\mathcal{M}(\mathcal{D}) \in S] \leq e^\epsilon \mathbb{P}[\mathcal{M}(\mathcal{D}') \in S] + \delta, \quad (1.4)$$

а композиция через моменты-бухгалтер [?] позволяет точно отслеживать кумулятивный расход приватности по раундам обучения. Оптимальный транспорт [?] обеспечивает геометрию на распределениях вероятностей через расстояние Вассерштейна, предлагая принципиальный механизм для выравнивания гетерогенных распределений фрагментов графов между участниками. Courty и др. [?] применили оптимальный транспорт к адаптации доменов, Flamary и др. [?] выпустили библиотеку Python Optimal Transport для масштабируемых вычислений, а Genevay и др. [?] разработали выборочно-эффективные дивергенции Синкхорна для генеративного моделирования. Однако ни один существующий алгоритм не гарантирует совместно византийскую устойчивость, дифференциальную приватность и выравнивание распределений по оптимальному транспорту для графовых данных.

Пробел 2: *Неблагоприятный компромисс приватность–качество в федеративных графах.* Ни один существующий алгоритм федеративного обучения не обеспечивает совместно византийско-устойчивую агрегацию, фор-

мальную (ϵ, δ) -дифференциальную приватность и выравнивание распределений по оптимальному транспорту Вассерштейна для графовых данных, где сама топология может быть частично контролируема противником.

Итоги раздела. Распределённое обучение на графах требует одновременной устойчивости к повреждениям, защиты приватности и выравнивания распределений — комбинации, которой ни один существующий метод не достигает. В следующем разделе рассматриваются проблемы вычислительной эффективности, которые должно преодолеть любое развёрнутое решение.

1.7 Вычислительная эффективность для крупномасштабных темпоральных графов

1.7.1 Квадратичное узкое место графовых трансформеров

Архитектуры графовых трансформеров [? ?] достигают высоких результатов на задачах уровня графа, позволяя каждому узлу обращать внимание на каждый другой узел. Однако этот механизм самовнимания масштабируется квадратично ($\mathcal{O}(L^2)$) с числом узлов или событий, делая его непомерно дорогим для крупномасштабных темпоральных графов с миллионами взаимодействий. Варианты с линейным вниманием [?] снижают это до $\mathcal{O}(L)$, но жертвуют выразительностью, необходимой для графотопологического рассуждения.

1.7.2 Структурированные модели пространства состояний

Gu и др. [?] предложили структурированные модели пространства состояний (S4), переформулирующие последовательную обработку как линейную динамическую систему, свёрточное ядро которой вычисляется за время $\mathcal{O}(L \log L)$ через быстрое преобразование Фурье. Селективный вариант (Mamba) [?] добавляет входозависимое стробирование для улучшенного мо-

делирования дискретных токенов. Behrouz и др. [?] начали применять эти модели к графовым данным (GraphMamba), но их робастность при целенаправленном возмущении и способность формировать надёжные оценки уверенности не исследовались. Теоретические основы моделей пространства состояний восходят к системе HiPRO [?] для оптимальной полиномиальной проекции, а Orvieto и др. [?] предоставили унифицированный анализ линейных рекуррентных архитектур. Poli и др. [?] разработали операторы Нуена как свёрточные альтернативы, а Chogomanski и др. [?] предложили внимание на случайных признаках для эффективных трансформеров. Dosovitskiy и др. [?] продемонстрировали, что трансформеры зрения достигают конкурентной производительности через токенизацию на основе патчей, установив парадигму, впоследствии адаптированную к графовым последовательностям.

1.7.3 Многоуровневые представления

Темпоральные графы, в которых узлы и рёбра несут разные семантические типы и эволюционируют на разных временных масштабах, требуют представлений, захватывающих структуру на нескольких уровнях детализации. Существующие темпоральные ГНС обучают единое, унифицированное вложение на узел, которое не способно одновременно разрешить паттерны уровня сервисов, зависимости уровня трассировок и динамику уровня узлов. Многоуровневые представления дороги в вычислении и не были проанализированы на устойчивость при топологической эволюции или на их взаимодействие с катастрофическим забыванием.

Пробел 3: *Ограниченная кросс-распределительная обобщаемость на темпоральных графах.* Ни одна существующая архитектура не обучает многоуровневые темпоральные представления графов (сервис, трассировка, узел) с одновременным предотвращением катастрофического забывания при эволюции топологии и достижением вычислительной экономии через структурированную разреженность.

Пробел 4: *Ограничения дискретного времени и квадратичная стоимость.* Структурированные модели пространства состояний, предлагающие близкую к линейной стоимость, не были адаптированы к графовым

данным с формальными гарантиями робастности, прогрессивной состязательной дистилляцией или РАС-байесовскими сертификатами обобщения.

Итоги раздела. Эффективность и многоуровневое представление ставят взаимосвязанные задачи: более богатые представления требуют больше вычислений, а эффективные архитектуры лишены гарантий робастности. В следующем разделе рассматривается, как развёрнутые модели должны адаптироваться к нестационарным условиям.

1.8 Нестационарная адаптация и оценка неопределённости

1.8.1 Дрейф распределения в развёрнутых моделях

Реальные графовые данные дрейфуют после развёртывания: топологии эволюционируют, паттерны атак меняются, появляются новые протоколы, и статические модели незаметно теряют точность без предупреждения. Это недопустимо в критически важных системах, где устаревшая модель является опасной моделью. Дрейф концепта был обширно исследован в табличных и потоковых условиях [? ?], но его взаимодействие с графовыми данными — где одновременно смещаются как распределения признаков, так и топологические паттерны — создаёт уникальные проблемы. Parisi и др. [?] обзрели непрерывное обучение на протяжении жизни с нейронными сетями, а Zenke и др. [? ?] предложили синаптический интеллект как альтернативу EWC для предотвращения катастрофического забывания.

1.8.2 Байесовские подходы к неопределённости

Байесовские нейронные сети формируют апостериорные предсказательные распределения, декомпозирующие полную неопределённость на эпистемическую (модельную) и алеаторную (данных) компоненты [? ? ? ?]. Вариационный вывод аппроксимирует неразрешимое апостериорное распределение через параметризованные распределения, обеспечивая оценку неопределённости за счёт дополнительных прямых проходов (дропаут Монте-Карло) или ансамблевого обучения. Однако интеграция

вариационного байесовского внимания с оценкой неопределённости на иерархических гауссовских процессах для графовой онлайн-адаптации не была достигнута. Ovadia и др. [?] провели бенчмарк оценки неопределённости при сдвиге набора данных, обнаружив, что большинство методов значительно деградируют. Dusenberry и др. [?] предложили эффективный и масштабируемый байесовский вывод для нейронных сетей, а Foong и др. [?] проанализировали выразительность приближённого байесовского вывода в нейронных сетях. Dereweg и др. [?] формализовали декомпозицию неопределённости на эпистемическую и алеаторную компоненты для принятия решений при модельной неопределённости. Kuleshov и др. [?] установили метрики калибровки для современных вероятностных прогнозов. Байесовский подход к адаптивному выбору архитектуры искусственной нейронной сети, тесно связанный с предлагаемой в настоящей работе схемой регуляризации неопределённости, рассмотрен в публикации научного руководителя — А. Г. Трофимова и В. И. Скругина [?]. Среди классических отечественных оснований теории распознавания и интеллектуальных систем следует особо отметить алгебраический подход Ю. И. Журавлёва к построению корректных алгебр над множествами эвристических алгоритмов [?] и работы Д. А. Поспелова по моделированию рассуждений [?], представляющие методологическую основу для последующего синтеза состязательно-устойчивых моделей.

1.8.3 Онлайн-обучение с сублинейным регретом

Онлайн-выпуклая оптимизация обеспечивает основу для последовательного принятия решений при состязательных потоках данных с алгоритмами типа следование-за-регуляризованным-лидером, достигающими сублинейных границ регрета [? ?]. Обновление мультипликативными весами достигает регрета $R(T) \leq \sqrt{T \log |S|}$ относительно лучшей фиксированной стратегии ретроспективно. Однако применение этих границ к адаптации графовых нейронных сетей при одновременном распределительном сдвиге и состязательном отравлении остаётся неисследованным.

Пробел 5: *Прямая несовместимость при смене протокольного режима.* Ни одна существующая предметно-ориентированная фундаментальная мо-

дель не сочетает обработку на основе пространства состояний, дополненного ОДУ, с многозадачным моделированием графовых последовательностей событий для прямо совместимого обнаружения при эволюционирующих протоколах. Постквантовый криптографический ландшафт, от алгоритма Шора [?] через решёточные конструкции [?] и кодовые схемы [?], вносит фундаментальные изменения в статистические признаки, наблюдаемые на рёбрах графа. Парадигма фундаментальных моделей, установленная Brown и др. [?] и Devlin и др. [?], была расширена на предметно-ориентированные приложения, при этом Touvron и др. [?] продемонстрировали альтернативы с открытыми весами, а Wei и др. [?] установили возможности рассуждения по цепочке мыслей, обеспечивающие структурированный анализ угроз.

Пробел 6: *Неинтегрированная неопределённость и состязательная робастность.* Ни одна существующая архитектура не сочетает вариационное байесовское внимание с оценкой неопределённости на иерархических гауссовских процессах для графовых данных, обеспечивая одновременно декомпозицию эпистемической и алеаторной неопределённости, онлайн-обнаружение дрейфа и гарантии сублинейного регрета при состязательной нестационарности.

Итоги раздела. Нестационарная адаптация требует онлайн-обучения с формальными гарантиями регрета и калиброванной декомпозиции неопределённости — возможностей, недоступных в существующих графовых архитектурах. Последний пробел касается того, как эти разнообразные гарантии могут быть объединены в единую систему сертификации.

1.9 Единая сертификация робастности

1.9.1 Теоретико-игровые модели угроз

Tambe [?] и Sinha и др. [?] формализовали распределение ресурсов безопасности как игры Штакельберга, где защитник принимает стратегию, предвосхищая лучший ответ противника. В контексте графовых нейронных сетей защитником является классификатор, а противник возмущает граф для максимизации ошибки классификации. Существующие

теоретико-игровые модели для ГНС обычно предполагают однократные взаимодействия с упрощёнными бюджетами возмущений и не учитывают последовательную, адаптивную природу реальных противников или многометодную композиционную структуру современных систем защиты графов. Brückner и Scheffer [?] формализовали предсказательную игру Штакельберга для состязательной классификации, а Shoham и Leyton-Brown [?] заложили основы мультиагентных систем. Balcan и др. [?] разработали алгоритмы онлайн-обучения со стратегическими взаимодействиями.

1.9.2 Существующие методы сертификации

Рандомизированное сглаживание [?] обеспечивает вероятностные сертификаты робастности для непрерывных входных пространств. Распространение интервальных границ [?] обеспечивает детерминированные границы путём распространения интервально-значных входов через сеть. Однако ни один из этих подходов не был адаптирован к дискретной, комбинаторной структуре матриц смежности графов, и ни одна единая система не обеспечивает доказуемые гарантии одновременно против возмущений признаков, сдвигов временного порядка, модификаций топологии графа и распределительного дрейфа в рамках единой методологии оценки. РАС-байесовская теория [?] обеспечивает дополнительный путь сертификации через границы обобщения, при этом Dziugaite и Roy [?] продемонстрировали невакуумные границы для глубоких сетей, Guedj [?] обозрел современный РАС-байесовский ландшафт, а Letarte и др. [?] связали РАС-байесовские границы с классификаторами на основе голосования большинством.

Пробел 7: *Упрощённые теоретико-игровые модели угроз.* Ни одна существующая единая система сертификации не сочетает теоретико-игровой выбор стратегий (равновесия Штакельберга с онлайн-обучением без регрета), распространение интервальных границ, оценку Липшица на графовых операторах и рандомизированное сглаживание, адаптированное к дискретным графовым структурам, в рамках единой методологии, связывающей все компонентные методы через регуляризацию согласованности.

Итоги раздела. Существующие методы сертификации адресуют отдельные типы возмущений изолированно и не распространяются на комбинаторную структуру графов или композиционную архитектуру многометодных систем защиты. Необходима единая система для связывания всех гарантий, разработанных в предыдущих разделах.

1.10 Состязательное машинное обучение в смежных критических областях: случай нейросетевой навигации беспилотных летательных аппаратов

Целевая предметная область настоящей работы — гибридные системы обнаружения и предотвращения сетевых вторжений — является лишь *одним* из приложений предметно-независимых методов М1–М7, формулировка которых ведётся в Главе 2. Для подтверждения предметно-независимости в Главе 6 предложен перенос фреймворка на систему навигации беспилотных летательных аппаратов (БПЛА), функционирующую в условиях радиоэлектронной борьбы и состязательного машинного обучения. Настоящий раздел кратко обобщает соответствующий литературный контекст.

1.10.1 Деградация нейросетевых компонентов БПЛА в условиях РЭБ

Открытые военные обзоры и аналитические сводки фиксируют ускоряющую деградацию нейросетевых компонентов БПЛА при росте давления радиоэлектронной борьбы. По данным журналистских расследований [?], доля поражений управляемого артиллерийского снаряда M982 Excalibur, опирающегося на ГНСС-наведение, упала с уровня выше 50 % до менее 10 % в течение нескольких месяцев работы в зоне действия российских средств подавления. В обзоре [?] указано, что до 31 % боевых вылетов FPV-БПЛА теряется вследствие подавления. Латвийское управление электронных коммуникаций зафиксировало в 2024 году 820 инцидентов воздействия на

ГНСС против 26 в 2022 году — рост более чем в 31 раз. Систематический обзор отечественной литературы по радиоэлектронной борьбе с системами связи и управления БПЛА выполнен в работе С. И. Макаренко [?].

1.10.2 Состязательные атаки на аэро-визуальные детекторы

Lian с соавторами [?] продемонстрировали, что адаптивные адверсариальные заплатки против аэрофотодетекторов YOLOv2–v5, Faster R-CNN и SSD на эталоне VisDrone снижают среднюю точность (mAP) на 87,86 процентных пункта в режиме белого ящика и на 85,48 пп в чёрном ящике. Du и соавторы [?] получили падение mAP YOLOv3 с $\approx 0,95$ до $< 0,20$ на физически напечатанных заплатках. Xiang и соавторы [?] сообщают о $> 99\%$ успешных целенаправленных атак на PointNet через добавление лишь нескольких состязательных точек.

1.10.3 Состязательные атаки на политики глубокого обучения с подкреплением

Hickling, Aouf и Spencer [?] показали, что итеративный метод BIM снижает долю успешного прохождения полосы препятствий БПЛА-пилотом на основе APF+DDPG-PER с 97 % до 35 %, и предложили SHAP-детектор состязательных воздействий с уровнем обнаружения 80–91 %. Обзор состязательных атак на нейросетевые компоненты БПЛА и существующих методов защиты от них представлен в работе А. Е. Лисина и С. Г. Чёрного [?].

1.10.4 Спуфирование ГНСС и дрейф-уклончивые атаки

Borhani-Darjan и соавторы [?] построили глубокую свёрточную сеть, обнаруживающую спуфирование на сигнальном уровне по признакам функции взаимной неоднозначности (CAF). Aigner и соавторы [?] получили ошибку обнаружения 0,16 % на эталоне TEXBAT с помощью последовательной Transformer-архитектуры. Panda и Guo [?] формализовали дрейф-

уклончивое спуфирование, при котором атакующий медленно изменяет псевдодальности, сохраняя сигнальные пороги в норме и одновременно уводя траекторию на сотни метров. Применение методов глубокого обучения к задаче обнаружения спуфинга ГНСС с приёмников БПЛА исследовано А. А. Галяевым, Л. Н. Лысенко и Д. С. Яшиным [?].

1.10.5 Графовые нейронные сети в задачах БПЛА-роя

Моу и соавторы [?] применили GCN к самовосстанавливающимся коммуникациям БПЛА-роя. Иерархическая федеративная GAT [?] обеспечивает столкновения на уровне ниже 2 % при 500 БПЛА и византийской фракции $f < n/3$. Архитектура CM-BRF-ViT [?] достигает 89,6 % точности при 40 % византийских клиентов против 45,6 % у обычного FedAvg.

1.10.6 Нормативный контекст БПЛА

В Российской Федерации Постановление Правительства № 1701 от 30 ноября 2024 года [?] требует оснащения БПЛА массой свыше 250 г сертифицированными средствами связи, удалённой идентификации и криптографической защиты информации. ГОСТ Р 72118-2025 [?] регламентирует формализацию моделей угроз для систем искусственного интеллекта, ГОСТ Р 55679-2021 [?] — общие требования к беспилотным авиационным системам. Методические и нормативные аспекты сертификации средств защиты информации, использующих машинное обучение, подробно проанализированы в работе А. С. Маркова и В. Л. Цирлова [?]. Международный контур формируют NIST AI RMF 1.0 [?], EU AI Act (с классификацией аэро-ИИ как high-risk) и DO-326A/ED-202A [?].

Итоги раздела. Литература состязательного машинного обучения в области БПЛА указывает на ту же общую структуру угроз, что и в области сетевых вторжений: атаки белого и чёрного ящика на этапе вывода, отравление данных на этапе обучения, действия адаптивного противника, нестабильность среды. Это подтверждает целесообразность переноса предметно-независимых методов M1–M7 на указанную область, который реализован в Главе 6.

1.11 Сводка выявленных исследовательских пробелов

Систематический анализ, проведённый в разделах 1.4–1.9, выявляет семь исследовательских пробелов, которые в совокупности определяют пространство открытых задач, решаемых в настоящей диссертации. Таблица 1.2 сопоставляет каждый пробел рабочим условиям и требованиям, которые он затрагивает, и указывает разработанную в Главе 2 модель/алгоритм для его решения. Эта же сводная таблица, дублированная под идентификатором `tab:models_to_methods`, выступает прямым отображением направления п. 4 паспорта специальности 2.3.1 (*«разработка методов и алгоритмов решения задач системного анализа, оптимизации, управления, принятия решений, обработки информации и искусственного интеллекта»*) на содержательные результаты работы.

Таблица 1.1 – Отображение проблем Hybrid IDPS, выявленных в §1.3, на разработанные в Главе 2 модели и алгоритмы M1–M7 (соответствие направлению п. 4 паспорта специальности 2.3.1).

Ось проблем	Конкретная мосьть	уязви- мость	Разработанная модель / алго- ритм
Робастность	Состязательные приме- ры, отравление, бэкдо- ры		M1 (CT-TGNN, сертификат Лип- шица), M4 (MambaShield, PAC- Bayes), M5–M6 (стох. трансфор- мер + UC-HGP), M7 (теоретико- игровая сертификация)
Точность	Дрейф концепции, дисбаланс классов, few-shot		M1 (мультимасштабные времен- ные константы), M3 (TripleE- TGNN многоуровневые представ- ления), M5–M6 (калиброванная неопределённость)
Эффективность	Задержка вывода, па- мять, пропускная спо- собность		M4 (MambaShield, $O(L \log L)$), M7 (стратегический выбор по неопре- делённости)
Приватность	Модельная инверсия, атаки на принадлеж- ность, утечка		M2 (FedLLM-API, (ε, δ) -DP + ви- зантийская устойчивость)
Нестационарность	Дрейф распределения, онлайн-обучение		M1 (CT-TGNN), M3 (упругая кон- солидация весов), M6 (UC-HGP байесовское обновление)

В совокупности семь пробелов охватывают все три рабочих условия (У1: состязательная среда, У2: нестационарность, У3: распределённая динамика) и все четыре требования (Т1: робастность, Т2: точность, Т3: эффективность, Т4: приватность), подтверждая, что двенадцать пересечений матрицы условие–требование 3×4 покрыты предложенными методами. Каждый пробел продемонстрирован как нерешённый существующими работами через анализ, представленный в данной главе.

Итоги главы. В настоящей главе заложены теоретические основы и проведён обзор существующей литературы по робастности графовых нейронных сетей, динамике непрерывного времени, распределённому обучению, вычис-

Таблица 1.2 – Семь выявленных исследовательских пробелов, их покрытие условий и требований, а также методы, предложенные для их решения в настоящей диссертации.

#	Описание пробела	Условия	Требования	Предлож. модель/алгоритм
1	Отсутствие сертифициц. робастности при НВ динамике графов	Y1, Y2	T1, T2	M1: CT-TGNN
2	Неблагоприятный компромисс приватность–качество в федерат. графах	Y3	T1, T4	M2: FedLLM-API
3	Огранич. кросс-распредел. обобщаемость на темпор. графах	Y2	T2, T3	M3: TripleE-TGNN
4	Ограничения дискретного времени и квадратичная стоимость	Y1, Y2	T1, T3	M4: MambaShield
5	Прямая несовместимость при смене протокольного режима	Y2	T2, T3	CyberSecLLM
6	Неинтегрированная неопредел. и состязат. робастность	Y1, Y2	T1, T2	M5/M6: Стох. трансф. + UC-HGP
7	Упрощённые теоретико-игровые модели угроз	Y1, Y2, Y3	T1, T2, T3, T4	M7: Сертификация

лительной эффективности, нестационарной адаптации и единой сертификации. Выявлены семь конкретных исследовательских пробелов, каждый из которых подкреплён свидетельствами из литературы об отсутствии существующих решений. В следующей главе представлены математические методы, алгоритмы и архитектурные решения, разработанные для заполнения этих пробелов, в том же последовательном порядке: сертифицированная динамика непрерывного времени (Пробел 1), распределённое федеративное обучение (Пробел 2), многоуровневые вложения (Пробел 3), эффективный вывод на основе пространства состояний (Пробел 4), прямо совместимые фундаментальные модели (Пробел 5), адаптация с калиброванной неопределённостью (Пробел 6) и единая теоретико-игровая сертификация (Пробел 7).

Глава 2

Математическая модель Hybrid IDPS и предлагаемые модели и алгоритмы повышения её робастности и эффективности

В настоящей главе разрабатывается полное теоретическое ядро диссертации. Глава следует структуре, заданной указанием научного руководителя: §2.1 формализует Hybrid IDPS как математическую модель и ставит шесть сквозных свойств системы (состязательная устойчивость, робастность, эффективность, совместимость с распределённой средой, человеческий фактор и нестационарность) в виде исследовательских вопросов с соответствующими инвариантами; §2.2 формулирует единую задачу одновременной оптимизации указанных свойств, выводимую из фундаментальной задачи классификации графов; последующие шесть разделов (2.3–2.9) представляют семь разработанных моделей и алгоритмов M1–M7, каждый из которых отвечает за один или несколько инвариантов из табл. 2.1; §2.10 систематизирует двадцать три метрики оценки качества Hybrid IDPS, сгруппированные по шести свойствам. Глава завершается единой системой сертификации, связывающей все модели через регуляризацию согласованности.

2.1 Математическая модель Hybrid IDPS

2.1.1 Формальная модель Hybrid IDPS

Hybrid IDPS как объект исследования (см. §1.1) формально описывается семёркой

$$\mathcal{H} = (\mathcal{V}_t, \mathcal{E}_t, X_t, A_t, f_\theta, g_\psi, \pi), \quad (2.1)$$

где компоненты системы интерпретируются следующим образом.

$\mathcal{V}_t$ — эволюционирующее во времени множество *наблюдаемых сущностей* (узлов графа): сетевых хостов в секторе NIDS, бортовых сенсоров и дронопортов в секторе UAV, счетов и платёжных терминалов в финтех-секторе, медицинских устройств и пациентов в медицинском секторе.

$\mathcal{E}_t$ — эволюционирующее во времени множество *связей* между наблюдаемыми сущностями: сетевых потоков, командно- телеметрических каналов, транзакций, обращений к электронным медицинским записям.

$X_t \in \mathbb{R}^{n \times d}$ — матрица числовых *признаков узлов* в момент t , имеющая $n = |\mathcal{V}_t|$ строк и d столбцов. Размерность d зависит от сектора: $d = 83$ для бенчмарков NIDS (CIC-IoT-2023, CSE-CICIDS-2018), d адаптируется к числу бортовых сенсоров и каналов в секторе UAV.

$A_t \in \mathbb{R}^{n \times n}$ — матрица смежности, кодирующая взвешенные *связи* между сущностями.

$f_\theta : (X_t, A_t) \mapsto \hat{y}_t \in \Delta^K$ — обучаемый *детектор* с параметрами θ , отображающий наблюдаемую графовую структуру в распределение по K классам угроз. В работе $K = 34$ для NIDS-инстанцирования (Глава 3), и адаптируется к семантике угроз других секторов.

$g_\psi : \hat{y}_t \mapsto a_t \in \mathcal{A}$ — *политика реагирования* с параметрами ψ , выбирающая действие a_t из конечного множества $\mathcal{A}$ (оповещение, блокировка потока, изоляция узла, переход в безопасный режим, эскалация в SOAR).

$\pi \in \{\mathbf{PASSIVE}, \mathbf{ACTIVE}, \mathbf{IPS}\}$ — *параметр режима интеграции* в защитный стек, определяющий, в какой мере политика реагирования g_ψ способна изменять состояние внешней среды.

Hybrid IDPS работает в дискретные моменты $t = 1, 2, \dots, T$ под воздействием трёх типов *рабочих условий*: состязательной среды, формализуемой возмущениями $(\delta_X, \Delta_A) \in \mathcal{S}_\varepsilon$, ограниченными по норме радиусом ε ; нестационарного распределения данных $\mathcal{D}_t \neq \mathcal{D}_{t-1}$ с ограниченной скоростью дрейфа; и распределённого обучения, при котором параметры θ обновляются федеративным алгоритмом по фрагментам графа, принадлежащим разным организациям, без передачи исходных данных.

2.1.2 Шесть свойств Hybrid IDPS как исследовательских вопросов

Содержательная работа над моделью (2.1) организована вокруг шести *сквозных свойств*, поставленных в виде исследовательских вопросов в соответствии с указанием научного руководителя. Каждое свойство формализуется как математическое условие на компоненты семёрки, а решение каждого вопроса в рамках диссертации обеспечивается соответствующей моделью или алгоритмом из перечня М1–М7. Сводка свойств приведена в табл. 2.1.

(П1) Состязательная устойчивость (Adversarially-resilient?). Hybrid IDPS считается состязательно устойчивым, если детектор f_θ удовлетворяет *количественной границе чувствительности* к ограниченным возмущениям входов

$$\left\| f_\theta(X_t + \delta_X, A_t + \Delta_A) - f_\theta(X_t, A_t) \right\| \leq \rho(\varepsilon), \quad \forall (\delta_X, \Delta_A) \in \mathcal{S}_\varepsilon, \quad (2.2)$$

где $\rho(\varepsilon) \rightarrow 0$ при $\varepsilon \rightarrow 0$. Свойство покрывается моделями М1 (Липшицев сертификат на основе неравенства Грёнуолла, см. §2.3), М4 (РАС-байесовские сертификаты, §2.6) и М7 (теоретико-игровая сертификация, §2.9).

(П2) Робастность (Robustness?). Hybrid IDPS считается робастной, если для любого распределения $\mathcal{D}_t$, удовлетворяющего ограничениям рабочего условия, и для тестовой выборки $\{(x_i, y_i)\}_{i=1}^N \sim \mathcal{D}_t$

$$\Pr_{\substack{(x,y) \sim \mathcal{D}_t \\ \delta \sim \mathcal{N}(0, \sigma^2 I)}} \left[\arg \max_k f_\theta^{(k)}(x + \delta) = y \right] \geq 1 - \alpha, \quad (2.3)$$

где α — бюджет ложных срабатываний (operator-tunable). Свойство покрывается моделями М1, М4, М5–М6 и М7, объединёнными единой системой сертификации через рандомизированное сглаживание [?], интервальное распространение границ и равновесие Штакельберга при адаптивном противнике.

(П3) Эффективность (Efficiency?). Hybrid IDPS считается эффективной, если время вывода f_θ на одном потоке не превышает заданного бюджета τ при вычислительной сложности

$$\mathcal{T}_{\text{inference}}(f_\theta; L) = \mathcal{O}(L \log L) \quad \text{и} \quad \mathcal{T}_{\text{inference}}(f_\theta; 1) \leq \tau, \quad (2.4)$$

где L — длина анализируемой последовательности событий. Свойство покрывается моделью M4 (MambaShield: $\mathcal{O}(L \log L)$ через свёртки на основе быстрого преобразования Фурье, §2.6) и стратегическим выбором глубины анализа в модели M7 (uncertainty-guided strategy selection).

(П4) Распределённая среда (Distributed environment?). Hybrid IDPS считается совместимой с распределённой средой, если федеративный алгоритм обновления параметров θ удовлетворяет одновременно (ε, δ) -дифференциально-приватной гарантии и устойчивости к доле $\beta < 1/3$ византийских участников:

$$\Pr[\theta_{\text{fed}}(D) \in S] \leq e^\varepsilon \Pr[\theta_{\text{fed}}(D') \in S] + \delta, \quad \forall D \sim_1 D', \forall S, \quad (2.5)$$

с одновременной сходимостью алгоритма агрегации к стационарной точке со скоростью $\mathcal{O}(1/\sqrt{T})$. Свойство покрывается моделью M2 (FedLLM-API, §2.4).

(П5) Человеческий фактор (Human factor?). Hybrid IDPS считается совместимой с человеческим фактором, если её выходы предоставляют аналитику *калиброванную меру уверенности* с ожидаемой ошибкой калибровки

$$\text{ECE}(f_\theta) = \mathbb{E}_{p \sim \hat{P}}[|\Pr[\hat{y} = y \mid f_\theta(x) = p] - p|] \leq \xi, \quad (2.6)$$

где ξ — допустимая ошибка калибровки (в работе $\xi = 0,1$). Дополнительно $\hat{y}$ должен быть декомпозируем на эпистемическую и алеаторную компоненты, что обеспечивает аналитику возможность сортировки оповещений по неопределённости. Свойство покрывается моделями M5 (стохастический трансформер) и M6 (UC-HGP, §2.7).

(П6) Нестационарность (Non-stationarity?). Hybrid IDPS считается нестационарно-адаптивной, если онлайн-алгоритм обновления параметров θ_t обеспечивает *сублинейный регрет* относительно лучшей фиксированной модели на исторических данных:

$$R(T) = \sum_{t=1}^T \ell(f_{\theta_t}(x_t), y_t) - \min_{\theta^*} \sum_{t=1}^T \ell(f_{\theta^*}(x_t), y_t) = \mathcal{O}(\sqrt{T \log K}), \quad (2.7)$$

где K — размер множества стратегий обновления. Свойство покрывается моделями М1 (мультимасштабные временные константы), М3 (TripleE-TGNN с упругой консолидацией весов) и М7 (многоруких бандитов с теоретико-игровым выбором стратегии).

Таблица 2.1 — Сводка шести свойств Hybrid IDPS как исследовательских вопросов: каждое свойство формализовано инвариантом и закрывается одной или несколькими моделями М1–М7.

Метка	Свойство	Инвариант	Закрывается
П1	Состязат. устойчи- вость	ур. (2.2)	М1, М4, М7
П2	Робастность	ур. (2.3)	М1, М4, М5–М6, М7
П3	Эффективность	ур. (2.4)	М4, М7
П4	Распределённость среда	ур. (2.5)	М2
П5	Человеческий фактор	ур. (2.6)	М5–М6
П6	Нестационарность	ур. (2.7)	М1, М3, М7

Шесть свойств П1–П6 в совокупности покрывают двенадцать пересечений матрицы условие–требование, идентифицированной в Главе 1 (см. табл. 1.1). Содержательная часть главы ниже формализует единую задачу одновременной оптимизации этих свойств (§2.2) и разрабатывает семь моделей и алгоритмов М1–М7, каждый из которых отвечает за один или несколько инвариантов из табл. 2.1.

2.2 Единая постановка задачи

Последовательный вывод постановки задачи проходит через семь этапов, каждый из которых вводит новое математическое ограничение, соответствующее конкретному требованию или рабочему условию. Результатом является единая многоцелевая задача оптимизации, декомпозиция которой порождает семь методов, разработанных в настоящей диссертации.

2.2.1 Этап 1: Классификация графов на динамических топологиях

Рассмотрим темпоральный граф $\mathcal{G}(t) = (\mathcal{V}, \mathcal{E}(t), \mathbf{X}(t))$, в котором узлы $\mathcal{V}$, рёбра $\mathcal{E}(t)$ и признаки $\mathbf{X}(t) = \{\mathbf{x}_v(t) \in \mathbb{R}^d\}_{v \in \mathcal{V}}$ эволюционируют во времени. Графовая нейронная сеть f_θ отображает граф в момент T на предсказание. Базовая задача классификации:

$$\min_{\theta} \mathbb{E}_{(\mathcal{G}, y) \sim \mathcal{D}} [\mathcal{L}(f_\theta(\mathcal{G}(T)), y)], \quad (2.8)$$

где $\mathcal{L}$ — кросс-энтропийные потери, а $\mathcal{D}$ — порождающее распределение данных. Данная формулировка предполагает, что граф чист, статичен при выводе, доступен централизованно, и что распределение данных не изменяется. Каждое из этих предположений нарушается на практике.

2.2.2 Этап 2: Состязательная робастность

В состязательной среде (Условие У1) целенаправленный противник возмущает граф. Включение Требования Т1 (робастность) преобразует задачу в формулировку мин-макс:

$$\min_{\theta} \mathbb{E}_{(\mathcal{G}, y) \sim \mathcal{D}} \left[\max_{\|\delta\| \leq \epsilon_{\text{adv}}} \mathcal{L}(f_\theta(\mathcal{G}(T) + \delta), y) \right], \quad (2.9)$$

где δ представляет возмущения признаков узлов, весов рёбер или топологической структуры, а ϵ_{adv} — бюджет возмущений. Это стандартная формулировка робастной оптимизации [? ? ?].

2.2.3 Этап 3: Динамика непрерывного времени с сертифицированными границами

Для получения сертифицированной робастности, а не эмпирического состязательного обучения, внутренняя динамика модели должна быть ограничена. Требование, чтобы f_θ эволюционировал через нейронное ОДУ с вектором поля, ограниченным по Липшицу, добавляет ограничение:

$$\frac{d\mathbf{h}_v(t)}{dt} = f_\theta(\mathbf{h}_v(t), \mathbf{A}(t), t), \quad \|f_\theta(\mathbf{h}_1, t) - f_\theta(\mathbf{h}_2, t)\| \leq L_g \|\mathbf{h}_1 - \mathbf{h}_2\|, \quad (2.10)$$

что, по неравенству Грёнуолла, гарантирует $\|\mathbf{h}_1(T) - \mathbf{h}_2(T)\| \leq e^{L_g T} \|\mathbf{x}_1 - \mathbf{x}_2\|$. Это преобразует несертифицированное состязательное обучение уравнения (2.9) в задачу сертифицированной робастности. *Подзадача 1 (Пробел 1) состоит в совместном решении уравнений (2.9)–(2.10) с многомасштабной темпоральной динамикой и обучением с $O(1)$ -памятью через сопряжённый метод. Решается Методом M1: CT-TGNN.*

2.2.4 Этап 4: Распределённое обучение с приватностью

В условиях распределённой динамики (Условие У3) граф $\mathcal{G}$ разделён между K участниками $\mathcal{D}_1, \dots, \mathcal{D}_K$, которые не могут передавать сырые данные. Включение Требования Т4 (приватность) требует, чтобы алгоритм обучения удовлетворял (ϵ, δ) -дифференциальной приватности при устойчивости к доле q византийских участников:

$$\min_{\theta} \frac{1}{K} \sum_{k=1}^K \mathcal{L}_k(\theta; \mathcal{D}_k) \quad \text{при условии} \quad \mathbb{P}[\mathcal{M}(\mathcal{D}) \in S] \leq e^\epsilon \mathbb{P}[\mathcal{M}(\mathcal{D}') \in S] + \delta, \quad (2.11)$$

где $\mathcal{M}$ — механизм обучения, и ограничение должно выполняться для всех соседних наборов данных $\mathcal{D}, \mathcal{D}'$. Кроме того, гетерогенные распределения участников требуют выравнивания через расстояние Вассерштейна $W_1(\mathcal{D}_k, \mathcal{D}_{k'})$, которое само должно вычисляться при ограничении приватности. *Подзадача 2 (Пробел 2) состоит в решении уравнения (2.11) с византийско-устойчивой агрегацией и выравниванием оптимального*

транспорта при использовании сертификатов Липшица из Подзадачи 1. Решается Методом M2: *FedLLM-API*.

2.2.5 Этап 5: Многоуровневое представление и защита от забывания

Включение Требования Т2 (точность) на темпоральных графах с иерархической структурой требует обучения представлений на нескольких семантических и временных масштабах — уровнях компонентов, трассировок и узлов — с предотвращением катастрофического забывания при эволюции топологии:

$$\min_{\theta} \sum_{g \in \{s, r, n\}} \lambda_g \mathcal{L}_g(\theta; \mathcal{G}_g) + \lambda_{\text{ewc}} \sum_j F_j(\theta_j - \theta_j^*)^2 + \lambda_{\text{con}} \sum_{(g, g')} \text{KL}(p_g \| p_{g'}), \quad (2.12)$$

где F_j — информация Фишера, штрафующая отклонение от ранее обученных параметров θ^* , а член KL-дивергенции обеспечивает межуровневую согласованность. *Подзадача 3 (Пробел 3) состоит в решении уравнения (2.12) со структурированной разреженностью и обучением с учётом квантования. Решается Методом M3: TripleE-TGNN.*

2.2.6 Этап 6: Вычислительная эффективность

Требование Т3 (эффективность) предписывает, чтобы сложность вывода составляла не более $\mathcal{O}(L \log L)$ вместо $\mathcal{O}(L^2)$ моделей на основе трансформеров. Это достигается переформулировкой последовательной обработки как селективной модели пространства состояний с входозависимыми переходами:

$$\mathbf{h}_k = \bar{\mathbf{A}}(u_k) \mathbf{h}_{k-1} + \bar{\mathbf{B}}(u_k) u_k, \quad \bar{\mathbf{A}}(u_k) = \exp(\mathbf{A}(u_k) \Delta), \quad (2.13)$$

свёрточное ядро которой вычисляется через быстрое преобразование Фурье. Это должно быть сочетано с прогрессивной состязательной дистилляцией робастности и РАС-байесовскими сертификатами обобщения. *Подзадача 4 (Пробел 4) состоит в решении задачи эффективного вывода уравнения (2.13) с формальными гарантиями робастности при отравлении*

на этапе обучения. Решается Методом М4: *MambaShield*.

2.2.7 Этап 7: Нестационарная адаптация с неопределённостью

В условиях нестационарности (Условие У2) распределение $\mathcal{D}_t$ изменяется во времени. Модель должна адаптироваться онлайн с количественной оценкой как эпистемической, так и алеаторной неопределённости и достижением сублинейного регрета:

$$R(T) = \max_{f^*} \sum_{t=1}^T \mathcal{L}(f_{\theta_t}, y_t) - \sum_{t=1}^T \mathcal{L}(f^*, y_t) \leq \mathcal{O}(\sqrt{T \log |\mathcal{S}|}), \quad (2.14)$$

где сравнение проводится с лучшей фиксированной стратегией ретроспективно. Предсказательная неопределённость декомпозируется как $U_{\text{total}} = U_{\text{epi}} + U_{\text{ale}}$, при этом эпистемическая неопределённость управляет обнаружением дрейфа, а алеаторная неопределённость захватывает присущий шум.

Подзадача 5 (Пробел 5) касается прямой совместимости при смене протокольного режима и решается предметно-ориентированной фундаментальной моделью (CyberSecLLM). Подзадача 6 (Пробел 6) состоит в решении задачи онлайн-адаптации уравнения (2.14) с интегрированной декомпозицией эпистемической и алеаторной неопределённости и байесовскими апостериорными обновлениями. Решается Методами М5: Стохастический трансформер и М6: UC-HGP.

2.2.8 Полная единая задача

Объединение всех этапов даёт единую многоцелевую задачу оптимизации настоящей диссертации:

$$\begin{aligned}
& \min_{\theta} \underbrace{\mathbb{E}_{(\mathcal{G}, y) \sim \mathcal{D}_t} \left[\max_{\|\delta\| \leq \epsilon} \mathcal{L}(f_{\theta}(\mathcal{G} + \delta), y) \right]}_{\text{Состязат. робастность (Т1, У1)}} + \underbrace{\lambda_{\text{acc}} \sum_g \mathcal{L}_g(\theta; \mathcal{G}_g)}_{\text{Многоуровн. точность (Т2)}} \\
& + \underbrace{\lambda_{\text{eff}} \text{Complexity}(f_{\theta})}_{\text{Эффективн. } \leq \mathcal{O}(L \log L) \text{ (Т3)}} + \underbrace{\lambda_{\text{priv}} \text{PrivCost}(\epsilon_{\text{DP}}, \delta)}_{\text{Дифф. приватность (Т4, У3)}} \\
& + \underbrace{\lambda_{\text{drift}} R(T)}_{\text{Нестаб. регрет (У2)}} + \underbrace{\lambda_{\text{ewc}} \sum_j F_j(\theta_j - \theta_j^*)^2}_{\text{Защита от забывания}} + \underbrace{\lambda_{\text{con}} \sum_{i < j} \mathcal{L}_{ij}(\theta_i, \theta_j)}_{\text{Связка методов (М7)}}
\end{aligned} \tag{2.15}$$

при ограничениях:

- Динамика ОДУ, ограниченная по Липшицу: $\|f_{\theta}(\mathbf{h}_1, t) - f_{\theta}(\mathbf{h}_2, t)\| \leq L_g \|\mathbf{h}_1 - \mathbf{h}_2\|$ (сертифициц. робастность)
- Дифференциальная приватность: $\mathbf{P}[\mathcal{M}(\mathcal{D}) \in S] \leq e^{\epsilon} \mathbf{P}[\mathcal{M}(\mathcal{D}') \in S] + \delta$ (приватность)
- Византийская устойчивость: сходимость при доле $q < 1/2$ повреждённых участников
- Сублинейный регрет: $R(T) \leq \mathcal{O}(\sqrt{T \log |\mathcal{S}|})$ (адаптация)

Декомпозиция. Данная единая задача неразрешима как монолитная оптимизация. Однако она допускает естественную декомпозицию на семь подзадач, по одной на каждый выявленный пробел, которые могут быть решены поочерёдной оптимизацией со связкой согласованности. Таблица 2.2 сопоставляет каждую подзадачу её пробелу, членам уравнения (2.15), которые она адресует, и методу, её решающему.

Подзадача 7 (Пробел 7) состоит в связке всех методов через член регуляризации согласованности $\sum_{i < j} \mathcal{L}_{ij}$ в уравнении (2.15) и доказательстве сходимости поочерёдной оптимизации. Решается Методом М7: Сертификация и единой системой, разработанной в Разделе 2.9.5.

В оставшейся части данной главы каждый метод разрабатывается в порядке цепочки подзадач: М1 (Раздел 2.3), М2 (Раздел 2.4), М3 (Раздел 2.5), М4 (Раздел 2.6), М5/М6 (Раздел 2.7), прямо совместимое обнаружение (Раздел 2.8) и М7 с единой системой (Раздел 2.9).

Таблица 2.2 – Декомпозиция единой постановки задачи на семь подзадач.

ПЗ	Метод	Адресуемые члены	Ключевое ограничение
1	M1: СТ-TGNN	Состязат. робастн. + динамика ОДУ	Сертификат Липшица: $e^{L_g T} \ \delta \mathbf{x}\ $
2	M2: FedLLM-API	Стоимость приватн. + визант. агрегация	(ϵ, δ) -ДП + выравнивание ОТ
3	M3: TripleE-TGNN	Многоуровн. точность + защита от забыв.	Штраф Фишера EWC + межуровневая KL
4	M4: MambaShield	Эффективность + состязат. робастн.	$\mathcal{O}(L \log L)$ + граница РАС-Байеса
5	CyberSecLLM	Прямая совместимость (предметная)	Многозадачные блоки ODE-S6
6	M5/M6	Нестац. регрет + неопределённость	Сублинейный регрет + де-комп. эпи/але
7	M7: Сертификация	Связка методов + теор.-игровая	Равновесие Штакельберга + согласованн.

2.3 Модель M1: СТ-TGNN — Динамика темпоральных графовых нейронных сетей непрерывного времени

Данный раздел решает Подзадачу 1 путём разработки графовой нейронной сети, представления узлов которой эволюционируют согласно нейронному обыкновенному дифференциальному уравнению, обеспечивая сертифицированную границу робастности из ограничения Липшица уравнения (2.10). Метод адресует Пробел 1 (Состязательность $\times$ Робастность; Нестационарность $\times$ Робастность).

Динамика узлов в непрерывном времени описывается уравнением

$$\frac{d\mathbf{h}_v(t)}{dt} = f_\theta\left(\mathbf{h}_v(t), \{\mathbf{h}_u(t)\}_{u \in \mathcal{N}_v(t)}, \mathbf{A}(t)\right), \quad (2.16)$$

где $\mathbf{h}_v(t) \in \mathbb{R}^{d_h}$ — вложение узла v в момент t , $\mathcal{N}_v(t)$ обозначает окрестность v при текущей топологии, $\mathbf{A}(t)$ кодирует структуру смежности, а f_θ — нейронная сеть, параметризованная θ .

Для гетерогенных графов правая часть использует типоспецифичную передачу сообщений. Пусть v принадлежит типу k и пусть $\mathcal{N}_v^{(k')}(t)$ обозна-

чает его соседей типа k' . Динамика:

$$\frac{d\mathbf{h}_v^{(k)}(t)}{dt} = \sum_{k'=1}^K \sum_{u \in \mathcal{N}_v^{(k')}(t)} \alpha_{uv}^{(k,k')}(t) \text{MSG}_{k,k'}(\mathbf{h}_u^{(k')}(t), \mathbf{e}_{uv}(t)), \quad (2.17)$$

где коэффициенты внимания [?]]

$$\alpha_{uv}^{(k,k')}(t) = \frac{\exp(\text{LeakyReLU}(\mathbf{a}_{k,k'}^\top [\mathbf{W}_k \mathbf{h}_v^{(k)}(t) \parallel \mathbf{W}_{k'} \mathbf{h}_u^{(k')}(t)]))}{\sum_{w \in \mathcal{N}_v^{(k')}(t)} \exp(\text{LeakyReLU}(\mathbf{a}_{k,k'}^\top [\mathbf{W}_k \mathbf{h}_v^{(k)}(t) \parallel \mathbf{W}_{k'} \mathbf{h}_w^{(k')}(t)]))} \quad (2.18)$$

адаптивно взвешивают важность соседей, $\mathbf{W}_k, \mathbf{W}_{k'}$ — обучаемые проекции, а $\parallel$ обозначает конкатенацию.

2.3.1 Многомасштабная темпоральная динамика

Явления, разворачивающиеся на нескольких временных масштабах, от субсекундных переходных процессов до многомесячных тенденций, требуют параллельных ветвей ОДУ с различными постоянными времени. Для масштабов $s = 1, \dots, S$ с постоянными $\tau_1 < \tau_2 < \dots < \tau_S$ динамика:

$$\frac{d\mathbf{h}_v^{(s)}(t)}{dt} = \frac{1}{\tau_s} f_{\theta_s}(\mathbf{h}_v^{(s)}(t), \{\mathbf{h}_u^{(s)}(t)\}_{u \in \mathcal{N}_v(t)}, \mathbf{A}(t), t), \quad (2.19)$$

и итоговое вложение агрегирует по масштабам через обученное внимание,

$$\mathbf{h}_v(t) = \sum_{s=1}^S \beta_s(t) \mathbf{h}_v^{(s)}(t), \quad \beta_s(t) = \text{Softmax}_s(\mathbf{w}_s^\top \mathbf{h}_v^{(s)}(t)), \quad (2.20)$$

так что относительный вклад каждого временного масштаба адаптируется к локальной динамике.

2.3.2 Метод сопряжённых чувствительностей для обучения с эффективным использованием памяти

Обучение требует градиентов функции потерь $\mathcal{L} = \mathcal{L}(\mathbf{h}(T))$ по θ через решение ОДУ. Прямое обратное распространение через численный интегратор сохраняет все промежуточные состояния, что недопустимо для

длинных горизонтов. Метод сопряжённых [? ?] определяет сопряжённое состояние $\mathbf{a}(t) = \partial \mathcal{L} / \partial \mathbf{h}(t)$, удовлетворяющее обратному ОДУ

$$\frac{d\mathbf{a}(t)}{dt} = -\mathbf{a}(t)^\top \frac{\partial f_\theta}{\partial \mathbf{h}}(\mathbf{h}(t), t), \quad (2.21)$$

интегрируемому от $\mathbf{a}(T) = \partial \mathcal{L} / \partial \mathbf{h}(T)$ до $\mathbf{a}(0)$. Градиенты по параметрам вычисляются из

$$\frac{\partial \mathcal{L}}{\partial \theta} = - \int_0^T \mathbf{a}(t)^\top \frac{\partial f_\theta}{\partial \theta}(\mathbf{h}(t), t) dt. \quad (2.22)$$

Затраты памяти пропорциональны размеру модели, а не длине траектории, что позволяет обучать на произвольно длинных темпоральных горизонтах.

2.3.3 Темпоральная адаптивная пакетная нормализация

Стандартная пакетная нормализация вычисляет статистики по фиксированному мини-батчу, что несовместимо с динамикой непрерывного времени, при которой распределение скрытых состояний непрерывно изменяется. Темпоральная адаптивная пакетная нормализация вычисляет скользящие статистики по временному окну $[t - \Delta, t]$,

$$\text{TABN}(\mathbf{h}(t)) = \gamma(t) \frac{\mathbf{h}(t) - \mu_{[t-\Delta, t]}}{\sqrt{\sigma_{[t-\Delta, t]}^2 + \varepsilon}} + \beta(t), \quad (2.23)$$

где $\mu_{[t-\Delta, t]}$ и $\sigma_{[t-\Delta, t]}^2$ — оконные среднее и дисперсия, а аффинные параметры $\gamma(t), \beta(t)$ сами эволюционируют через вспомогательные ОДУ $d\gamma/dt = g_\gamma(\mathbf{h}(t))$, $d\beta/dt = g_\beta(\mathbf{h}(t))$, управляемые обучаемыми сетями адаптации.

2.3.4 Анализ сходимости и робастности

Теорема 2.1 (Сходимость СТ-TGNN). *Предположим, что функция динамики f_θ является L_f -липшицевой по $\mathbf{h}$ и L_θ -липшицевой по θ . При градиентном спуске со скоростью обучения $\eta < 2/(L_f L_\theta)$ потери обучения сходятся к стационарной точке со скоростью $\mathcal{O}(1/\sqrt{T})$, где T обозначает число шагов градиента.*

Эскиз доказательства. Потери $\mathcal{L}(\theta)$ вычисляются через карту решения

ОДУ $\mathbf{h}(T; \theta)$. По правилу цепочки и свойствам Липшица f_θ градиент $\nabla_\theta \mathcal{L}$ ограничен и липшицево-непрерывен, помещая задачу в стандартную схему гладкой невыпуклой оптимизации. Применение леммы убывания с указанной скоростью обучения даёт скорость $\mathcal{O}(1/\sqrt{T})$ до ϵ -стационарной точки. Полное доказательство приведено в Приложении А. $\square$

Теорема 2.2 (Сертификат робастности по Липшицу). *Пусть f_θ является L_g -липшицевой по первому аргументу, а горизонт интегрирования равен T . Для любых двух входов $\mathbf{x}_1, \mathbf{x}_2$ соответствующие вложения удовлетворяют*

$$\|\mathbf{h}_1(T) - \mathbf{h}_2(T)\| \leq e^{L_g T} \|\mathbf{x}_1 - \mathbf{x}_2\|. \quad (2.24)$$

Следовательно, если голова классификатора имеет константу Липшица L_c , то сквозная модель является $L_c e^{L_g T}$ -липшицевой, и предсказание сертифицировано постоянным в шаре радиуса $\rho = \Delta_{\min}/(L_c e^{L_g T})$, где $\Delta_{\min}$ — запас между двумя наибольшими логитами.

Эскиз доказательства. Пусть $\boldsymbol{\eta}(t) = \mathbf{h}_1(t) - \mathbf{h}_2(t)$. Тогда $d\boldsymbol{\eta}/dt = f_\theta(\mathbf{h}_1, t) - f_\theta(\mathbf{h}_2, t)$, откуда $d\|\boldsymbol{\eta}\|/dt \leq L_g \|\boldsymbol{\eta}\|$ по свойству Липшица. Неравенство Грёнуолла даёт $\|\boldsymbol{\eta}(T)\| \leq e^{L_g T} \|\boldsymbol{\eta}(0)\|$, а $\boldsymbol{\eta}(0) = \mathbf{x}_1 - \mathbf{x}_2$. Композиция с головой классификатора завершает сертификат. Полный вывод со спектрально-нормовыми ограничениями, обеспечивающими границу Липшица при обучении, приведён в Приложении А. $\square$

2.3.5 Вычислительная сложность

Решение графового ОДУ адаптивным интегратором Рунге–Кутты при допуске ε_{ode} требует $\mathcal{O}(\varepsilon_{\text{ode}}^{-1/5})$ вычислений функции. Каждое вычисление выполняет передачу сообщений за $\mathcal{O}(|\mathcal{V}| d d_h)$ при ограниченной степени d и размерности вложения d_h . Общая сложность обучения за эпоху, таким образом:

$$\mathcal{O}(|\mathcal{V}| d d_h \varepsilon_{\text{ode}}^{-1/5} T_{\text{train}}), \quad (2.25)$$

что близко к линейной по размеру графа при $|\mathcal{E}| = \mathcal{O}(|\mathcal{V}|)$.




Рис. 2.1 – Принципиальная архитектура модели M1: СТ-TGNN — темпоральной графовой нейронной сети непрерывного времени с мультимасштабными ветвями ОДУ и адаптивной пакетной нормализацией. Применение модели к защите сетевого трафика с конкретными значениями постоянных времени и гиперпараметров рассматривается в §3.5 Главы 3.

Algorithm 1: Обучение СТ-TGNN с методом сопряжённых чувствительностей

Вход: Последовательность темпоральных графов $\{\mathcal{G}(t_i)\}_{i=1}^N$, метки $\{y_i\}$, скорость обучения η , горизонт интегрирования T , допуск ε_{ode}

Выход: Обученные параметры θ^*

```

1 Инициализировать параметры  $\theta_0$  и многомасштабные постоянные
  времени  $\tau_1 < \dots < \tau_S$ ;
2 for эпоха  $= 1, 2, \dots, E$  do
3   for каждый мини-батч  $\{(\mathcal{G}(t_j), y_j)\}$  do
4     Установить начальные вложения  $\mathbf{h}_v(0) \leftarrow \text{Embed}(\mathbf{x}_v(t_j))$  для
      всех  $v \in \mathcal{V}$ ;
5     for масштаб  $s = 1, \dots, S$  do
6       Решить  $d\mathbf{h}_v^{(s)}/dt = \tau_s^{-1} f_{\theta_s}(\mathbf{h}_v^{(s)}, \mathcal{N}_v, \mathbf{A}, t)$  от 0 до  $T$ 
        адаптивным РК с допуском  $\varepsilon_{\text{ode}}$ ;
7     Вычислить объединённые вложения
         $\mathbf{h}_v(T) = \sum_s \beta_s(T) \mathbf{h}_v^{(s)}(T)$ ;
8     Вычислить потери классификации  $\mathcal{L} = \mathcal{L}_{\text{CE}}(f_{\text{head}}(\mathbf{h}(T)), y)$ ;
9     Установить терминальное условие сопряжённого
         $\mathbf{a}(T) = \partial \mathcal{L} / \partial \mathbf{h}(T)$ ;
10    Решить сопряжённое ОДУ назад:  $d\mathbf{a}/dt = -\mathbf{a}^\top (\partial f_{\theta} / \partial \mathbf{h})$  от  $T$ 
      до 0;
11    Накопить градиенты по параметрам
         $\partial \mathcal{L} / \partial \theta = -\int_0^T \mathbf{a}^\top (\partial f_{\theta} / \partial \theta) dt$ ;
12    Обновить  $\theta \leftarrow \theta - \eta \partial \mathcal{L} / \partial \theta$ ;
13 Вычислить сертификат Липшица  $\rho = \Delta_{\min} / (L_c e^{L_g T})$  для каждого
    тестового входа;
14 return  $\theta^*, \{\rho_i\}$ 
  
```

2.4 Модель M2: FedLLM-API — Федеративная оптимизация графов с приватностью

Данный раздел решает Подзадачу 2 путём разработки алгоритма федеративного обучения, обеспечивающего ограничение приватности и византийскую устойчивость уравнения (2.11) при использовании сертификатов Липшица, полученных M1. Метод адресует Пробел 2 (Распределённость $\times$ Робастность; Распределённость $\times$ Приватность; Распределённость $\times$ Эффективность).

2.4.1 Византийско-устойчивая агрегация

Рассмотрим K участников с локальными наборами данных $\mathcal{D}_1, \dots, \mathcal{D}_K$, из которых не более доли q являются византийскими. На раунде коммуникации t сервер рассылает глобальную модель $\mathbf{w}_t$, и каждый честный клиент k вычисляет локальное обновление через градиентный спуск на своих данных, $\mathbf{w}_{t+1}^{(k)} = \mathbf{w}_t - \eta \nabla_{\mathbf{w}} \mathcal{L}_k(\mathbf{w}_t; \mathcal{D}_k)$. Злонамеренные клиенты отправляют произвольные векторы. Сервер агрегирует через покоординатное усечённое среднее [? ? ?]: для каждого измерения параметра j значения клиентов сортируются и $b = \lfloor Kq \rfloor$ наибольших и наименьших отбрасываются, давая

$$\bar{w}_{t+1,j} = \frac{1}{K - 2b} \sum_{i=b+1}^{K-b} w_{t+1,j}^{(i)}, \quad (2.26)$$

где $w_{t+1,j}^{(i)}$ — i -я порядковая статистика.

Теорема 2.3 (Византийско-устойчивая сходимость). *Предположим, что глобальные потери $F(\mathbf{w}) = \frac{1}{K} \sum_{k=1}^K F_k(\mathbf{w})$ являются μ -сильно выпуклыми и L -гладкими, а доля византийских клиентов удовлетворяет $f < q < 1/2$. При скорости обучения $\eta \leq 1/L$ покоординатное усечённое среднее достигает*

$$\mathbb{E}[\|\mathbf{w}_T - \mathbf{w}^*\|^2] \leq \left(1 - \frac{\mu\eta}{2}\right)^T \|\mathbf{w}_0 - \mathbf{w}^*\|^2 + \frac{2\eta}{\mu(K-2b)} \left(\sum_{k=1}^{K-2b} \sigma_k^2 + C_{\text{byz}} \right), \quad (2.27)$$

где σ_k^2 — дисперсия градиента честного клиента k , а C_{byz} ограничивает влияние византийских участников.

Эскиз доказательства. Ключевой шаг — показать, что усечённое среднее градиентных векторов честных и византийских участников близко к истинному среднему честных градиентов. Пусть $\bar{\mathbf{g}}_H$ — среднее честных градиентов и $\bar{\mathbf{g}}_{\text{TM}}$ — выход усечённого среднего. Поскольку не более b из $2b$ отброшенных записей могут быть честными, ошибка $\|\bar{\mathbf{g}}_{\text{TM}} - \bar{\mathbf{g}}_H\|$ ограничена порядковыми статистиками норм честных градиентов через неравенства концентрации. Подстановка в стандартную рекурсию убывания для сильно выпуклых функций даёт указанную границу. Полные детали приведены в

2.4.2 Дифференциальная приватность через калиброванный шум

Каждый клиент обрезает норму градиента до порога C и добавляет гауссовский шум [? ? ?] перед передачей,

$$\bar{\mathbf{g}}_k = \mathbf{g}_k / \max\left(1, \frac{\|\mathbf{g}_k\|}{C}\right), \quad \tilde{\mathbf{g}}_k = \bar{\mathbf{g}}_k + \mathcal{N}(\mathbf{0}, \sigma^2 C^2 \mathbf{I}), \quad (2.28)$$

где масштаб шума σ определяется целевыми параметрами приватности (ϵ, δ) . Усиление приватности подвыборкой с вероятностью батча q_b и композиция за T раундов через моменты-бухгалтер [? ?] даёт общую гарантию приватности

$$\epsilon_{\text{total}} = \min_{\alpha > 1} \frac{1}{\alpha - 1} \log \frac{1}{\delta} + \frac{T q_b^2 \alpha}{2\sigma^2}. \quad (2.29)$$

2.4.3 Оптимальный транспорт для выравнивания распределений

Гетерогенные распределения клиентов ухудшают сходимость. Оптимальный транспорт выравнивает их путём вычисления Вассерштейнова барицентра. Для дискретных исходных выборок $\{\mathbf{x}_i\}_{i=1}^{n_s}$ и целевых выборок $\{\mathbf{y}_j\}_{j=1}^{n_t}$ дискретный транспортный план решает

$$\mathbf{T}^* = \arg \min_{\mathbf{T} \in \mathbb{R}_+^{n_s \times n_t}} \langle \mathbf{C}, \mathbf{T} \rangle_F \quad \text{при} \quad \mathbf{T} \mathbf{1}_{n_t} = \mathbf{a}, \quad \mathbf{T}^\top \mathbf{1}_{n_s} = \mathbf{b}, \quad (2.30)$$

где $C_{ij} = c(\mathbf{x}_i, \mathbf{y}_j)$ — матрица стоимости, а $\mathbf{a}, \mathbf{b}$ лежат на вероятностных симплексах. Алгоритм Синкхорна [? ? ?] вычисляет энтропийно регуляризованное решение через поочерёдное масштабирование,

$$\mathbf{u}^{(\ell+1)} = \mathbf{a} \oslash (\mathbf{K} \mathbf{v}^{(\ell)}), \quad \mathbf{v}^{(\ell+1)} = \mathbf{b} \oslash (\mathbf{K}^\top \mathbf{u}^{(\ell+1)}), \quad (2.31)$$

где $\mathbf{K} = \exp(-\mathbf{C}/\lambda)$ — энтропийное ядро, $\oslash$ обозначает поэлементное деление, а $\lambda > 0$ управляет регуляризацией. После сходимости транспортный план $\mathbf{T}^* = \text{diag}(\mathbf{u}) \mathbf{K} \text{diag}(\mathbf{v})$.

2.4.4 Дифференциально приватный оптимальный транспорт

Для защиты расположения выборок гауссовский шум добавляется к эмпирическому распределению перед вычислением транспорта,

$$\tilde{\mu}_s = \frac{1}{n_s} \sum_{i=1}^{n_s} \delta_{\mathbf{x}_i + \boldsymbol{\xi}_i}, \quad \boldsymbol{\xi}_i \sim \mathcal{N}(\mathbf{0}, \sigma_{\text{DP}}^2 \mathbf{I}), \quad (2.32)$$

а шум Лапласа добавляется к результирующему транспортному плану,

$$\tilde{\mathbf{T}} = \mathbf{T}^* + \text{Lap}\left(\frac{\Delta_T}{\epsilon_{\text{OT}}}\right), \quad (2.33)$$

где чувствительность $\Delta_T = \max_{\mathcal{D}, \mathcal{D}'} \|\mathbf{T}^*(\mathcal{D}) - \mathbf{T}^*(\mathcal{D}')\|_1$ ограничивает максимальное изменение при замене одной записи, а ϵ_{OT} — бюджет приватности, выделенный на транспорт.

2.4.5 Интеграция большой языковой модели для обобщения zero-shot

Семантическое рассуждение о новых категориях достигается построением промпта на естественном языке из структурных признаков наблюдения и запросом к большой языковой модели для получения вероятности $p_{\text{LLM}}(\text{class} \mid \mathbf{r})$. Итоговое предсказание — ансамбль

$$p_{\text{final}} = \lambda_{\text{LLM}} p_{\text{LLM}}(\text{class} \mid \mathbf{r}) + (1 - \lambda_{\text{LLM}}) p_{\text{GNN}}(\text{class} \mid \mathcal{G}(\mathbf{r})), \quad (2.34)$$

где $\mathcal{G}(\mathbf{r})$ — граф, построенный из наблюдения, а λ_{LLM} балансирует два источника.

Algorithm 2: FedLLM-API: Византийско-устойчивая федеративная оптимизация с ДП-ОТ

Вход: Клиенты $\mathcal{D}_1, \dots, \mathcal{D}_K$, доля византийских q , порог обрезки C , бюджет приватности (ϵ, δ) , регуляризация Синкхорна λ , раунды коммуникации T

Выход: Глобальная модель $\mathbf{w}_T$

```

1 Инициализировать глобальную модель  $\mathbf{w}_0$ ; вычислить масштаб
  шума  $\sigma = C\sqrt{2\ln(1.25/\delta)}/\epsilon$ ;
2 for раунд  $t = 0, 1, \dots, T-1$  do
3   Разослать  $\mathbf{w}_t$  всем клиентам;
4   for каждый клиент  $k = 1, \dots, K$  (параллельно) do
5     Вычислить локальный градиент  $\mathbf{g}_k = \nabla_{\mathbf{w}} \mathcal{L}_k(\mathbf{w}_t; \mathcal{D}_k)$ ;
6     Обрезать:  $\bar{\mathbf{g}}_k \leftarrow \mathbf{g}_k / \max(1, \|\mathbf{g}_k\|/C)$ ;
7     Добавить шум:  $\tilde{\mathbf{g}}_k \leftarrow \bar{\mathbf{g}}_k + \mathcal{N}(\mathbf{0}, \sigma^2 C^2 \mathbf{I})$ ;
8     Отправить  $\tilde{\mathbf{g}}_k$  серверу;
9   Установить  $b \leftarrow \lfloor Kq \rfloor$ ;
10  for каждое измерение  $j$  do
11    Отсортировать  $\{\tilde{g}_{k,j}\}_{k=1}^K$ ; вычислить усечённое среднее
       $\bar{g}_{t,j} = \frac{1}{K-2b} \sum_{i=b+1}^{K-b} \tilde{g}_j^{(i)}$ ;
12  if обнаружена гетерогенность по оценке  $W_1$  then
13    Вычислить зашумлённые исходные распределения  $\tilde{\mu}_k$ 
      добавлением  $\mathcal{N}(\mathbf{0}, \sigma_{\text{DP}}^2 \mathbf{I})$  к выборкам;
14    Выполнить итерации Синкхорна для вычисления
      регуляризованного транспортного плана  $\mathbf{T}^*$ ;
15    Добавить шум Лапласа:  $\tilde{\mathbf{T}} \leftarrow \mathbf{T}^* + \text{Lap}(\Delta_T/\epsilon_{\text{OT}})$ ;
16    Применить коррекцию выравнивания к  $\bar{\mathbf{g}}_t$  с использованием
       $\tilde{\mathbf{T}}$ ;
17  Обновить глобальную модель:  $\mathbf{w}_{t+1} \leftarrow \mathbf{w}_t - \eta \bar{\mathbf{g}}_t$ ;
18 return  $\mathbf{w}_T$ 

```




Рис. 2.2 – Принципиальная архитектура модели M2: FedLLM-API — федеративного оптимизатора с византийско-устойчивой агрегацией, дифференциальной приватностью через калиброванный шум и выравниванием распределений по принципу оптимального транспорта Вассерштейна, интегрированного с большой языковой моделью для zero-shot-обнаружения новых категорий угроз.

2.5 Модель М3: TripleE-TGNN — Многоуровневые темпоральные вложения графов

Данный раздел решает Подзадачу 3 путём разработки многоуровневых вложений графов, адресующих члены точности и защиты от забывания в уравнении (2.12). Метод адресует Пробел 3 (Нестационарность $\times$ Точность; Нестационарность $\times$ Эффективность).

2.5.1 Иерархическое представление графов

Многие системы обладают естественной иерархией: грубый уровень функциональных компонентов, промежуточный уровень операционных трассировок, охватывающих компоненты, и тонкий уровень узлов инфраструктуры. Эта структура захватывается тремя связанными темпоральными графами: графом компонентов $\mathcal{G}_s(t) = (\mathcal{V}_s, \mathcal{E}_s(t), \mathbf{X}_s(t))$, графом трассировок $\mathcal{G}_r(t) = (\mathcal{V}_r, \mathcal{E}_r(t), \mathbf{X}_r(t))$ и графом узлов $\mathcal{G}_n(t) = (\mathcal{V}_n, \mathcal{E}_n(t), \mathbf{X}_n(t))$. Двудольные графы связи $\mathcal{B}_{sr}, \mathcal{B}_{sn}, \mathcal{B}_{rn}$ соединяют сущности между уровнями: компонент развёрнут на узле, трассировка проходит через компонент, трассировка выполняется на узле.

2.5.2 Многоуровневое обучение вложений

Каждая гранулярность $g \in \{s, r, n\}$ поддерживает выделенный кодировщик,

$$\mathbf{h}_v^{(g)}(t) = \text{ENC}_g(\mathbf{x}_v^{(g)}(t), \{\mathbf{h}_u^{(g)}(t-1)\}_{u \in \mathcal{N}_v^{(g)}(t)}, \Delta t), \quad (2.35)$$

где ENC_g — графовая нейронная сеть, специфичная для данной гранулярности. Межгранулярная передача сообщений интегрирует информацию между уровнями абстракции через двудольное внимание,

$$\mathbf{m}_v^{(g \rightarrow g')}(t) = \sum_{u \in \mathcal{N}_v^{(g, g')}} \alpha_{uv}^{(g, g')}(t) \mathbf{W}_{g \rightarrow g'} \mathbf{h}_u^{(g)}(t), \quad (2.36)$$

с коэффициентами внимания

$$\alpha_{uv}^{(g, g')}(t) = \text{Softmax}_u \left(\frac{(\mathbf{Q}_{g'} \mathbf{h}_v^{(g')}(t))^\top (\mathbf{K}_g \mathbf{h}_u^{(g)}(t))}{\sqrt{d_k}} \right), \quad (2.37)$$

где $\mathbf{Q}_{g'}, \mathbf{K}_g$ — проекции запроса и ключа, а $\mathcal{N}_v^{(g,g')}$ обозначает соседей в графе связи. Итоговое вложение объединяет внутригранулярную и межгранулярную информацию через нормализацию слоя,

$$\mathbf{h}_v^{(g)}(t) \leftarrow \text{LayerNorm}\left(\mathbf{h}_v^{(g)}(t) + \sum_{g' \neq g} \mathbf{m}_v^{(g' \rightarrow g)}(t)\right). \quad (2.38)$$

2.5.3 Двойное темпорально-пространственное внимание

Внутри каждой гранулярности темпоральное внимание агрегирует исторические состояния по окну ширины w ,

$$\tilde{\mathbf{h}}_v^{(g)}(t) = \sum_{\tau=t-w}^{t-1} \alpha_{\tau}^{\text{temp}} \mathbf{h}_v^{(g)}(\tau), \quad \alpha_{\tau}^{\text{temp}} = \text{Softmax}_{\tau}(\mathbf{w}_{\text{temp}}^{\top} \mathbf{h}_v^{(g)}(\tau)), \quad (2.39)$$

а пространственное внимание агрегирует текущую окрестность,

$$\hat{\mathbf{h}}_v^{(g)}(t) = \sum_{u \in \mathcal{N}_v^{(g)}(t)} \alpha_u^{\text{spat}} \mathbf{h}_u^{(g)}(t), \quad \alpha_u^{\text{spat}} = \text{Softmax}_u(\mathbf{w}_{\text{spat}}^{\top} [\mathbf{h}_v^{(g)}(t) \parallel \mathbf{h}_u^{(g)}(t)]). \quad (2.40)$$

Комбинированное представление:

$$\mathbf{h}_v^{(g)}(t) = \text{MLP}([\tilde{\mathbf{h}}_v^{(g)}(t) \parallel \hat{\mathbf{h}}_v^{(g)}(t) \parallel \mathbf{h}_v^{(g)}(t)]). \quad (2.41)$$

2.5.4 Упругая консолидация весов для эволюции топологии

При изменении топологии графа, например при развёртывании или реконфигурации инфраструктуры, модель, переобученная на новой топологии, может перезаписать ранее обученные представления. Упругая консолидация весов [? ?] предотвращает это катастрофическое забывание путём штрафования изменений параметров, важных для предыдущих задач. После обучения на конфигурации топологии $\mathcal{T}_i$ с оптимальными параметрами θ_i^* , потери для последующей конфигурации $\mathcal{T}_{i+1}$ включают член ре-

гуляризации

$$\mathcal{L}_{\text{EWC}}(\theta) = \mathcal{L}_{\mathcal{T}_{i+1}}(\theta) + \lambda_{\text{ewc}} \sum_j F_j (\theta_j - \theta_{i,j}^*)^2, \quad (2.42)$$

где диагональная информация Фишера $F_j = \mathbb{E}[(\partial \log p(y|\mathbf{x}, \theta_i^*) / \partial \theta_j)^2]$ оценивает важность параметра j для предыдущей конфигурации, а λ_{ewc} управляет силой консолидации.

2.5.5 Совместная многоуровневая целевая функция классификации

Модель выполняет одновременную классификацию на всех трёх гранулярностях через многозадачные потери,

$$\mathcal{L}_{\text{joint}} = \lambda_s \mathcal{L}_s + \lambda_r \mathcal{L}_r + \lambda_n \mathcal{L}_n + \lambda_{\text{con}} \mathcal{L}_{\text{consist}}, \quad (2.43)$$

где $\mathcal{L}_g$ — кросс-энтропийные потери на гранулярности g , λ_g — балансирующие веса, а потери согласованности

$$\mathcal{L}_{\text{consist}} = \sum_{(v_s, v_r) \in \mathcal{B}_{sr}} \text{KL}(p_s(y|v_s) \| p_r(y|v_r)) + \sum_{(v_s, v_n) \in \mathcal{B}_{sn}} \text{KL}(p_s(y|v_s) \| p_n(y|v_n)) \quad (2.44)$$

обеспечивают согласованность предсказаний связанных сущностей между уровнями абстракции.

Algorithm 3: Многоуровневое обучение TripleE-TGNN

Вход: Иерархические графы $\{\mathcal{G}_s, \mathcal{G}_r, \mathcal{G}_n\}$ со связями $\mathcal{B}_{sr}, \mathcal{B}_{sn}, \mathcal{B}_{rn}$,
метки на каждой гранулярности, сила EWC λ_{ewc}

Выход: Обученные кодировщики $\text{ENC}_s, \text{ENC}_r, \text{ENC}_n$ и параметры
межуровневого внимания

```
1 Инициализировать все параметры кодировщиков и внимания;
2 for каждая конфигурация топологии  $\mathcal{T}_i$  do
3   for эпоха = 1, ...,  $E$  do
4     for каждый мини-батч do
5       for гранулярность  $g \in \{s, r, n\}$  do
6         Вычислить внутригранулярные вложения
9            $\mathbf{h}_v^{(g)}(t) \leftarrow \text{ENC}_g(\mathbf{x}_v^{(g)}, \mathcal{N}_v^{(g)}, \Delta t)$ ;
7         Вычислить темпоральное внимание  $\tilde{\mathbf{h}}_v^{(g)}$  и
           пространственное внимание  $\hat{\mathbf{h}}_v^{(g)}$ ;
8         Объединить:  $\mathbf{h}_v^{(g)} \leftarrow \text{MLP}([\tilde{\mathbf{h}}_v^{(g)} \parallel \hat{\mathbf{h}}_v^{(g)} \parallel \mathbf{h}_v^{(g)}])$ ;
9       for каждая пара  $(g, g')$  с  $g \neq g'$  do
10        Вычислить межгранулярные сообщения  $\mathbf{m}_v^{(g \rightarrow g')}$  через
           двудольное внимание;
11        Обновить:  $\mathbf{h}_v^{(g')} \leftarrow \text{LayerNorm}(\mathbf{h}_v^{(g')} + \mathbf{m}_v^{(g \rightarrow g')})$ ;
12      Вычислить  $\mathcal{L}_{\text{joint}} = \lambda_s \mathcal{L}_s + \lambda_r \mathcal{L}_r + \lambda_n \mathcal{L}_n + \lambda_{\text{con}} \mathcal{L}_{\text{consist}}$ ;
13      if  $i > 1$  then
14        Добавить штраф EWC:
15         $\mathcal{L} \leftarrow \mathcal{L}_{\text{joint}} + \lambda_{\text{ewc}} \sum_j F_j (\theta_j - \theta_{i-1,j}^*)^2$ ;
16      Обратное распространение и обновление всех параметров;
17      Сохранить диагональ Фишера  $\{F_j\}$  и оптимальные  $\theta_i^*$  для EWC;
17 return обученные кодировщики и параметры внимания
```




Рис. 2.3 – Принципиальная архитектура модели M3: TripleE-TGNN — тройного вложения для многоуровневого темпорального представления графов с двойным временно-пространственным вниманием и упругой консолидацией весов для предотвращения катастрофического забывания.

2.6 Модель M4: MambaShield — Вывод на основе пространства состояний с устойчивостью к отравлению

Данный раздел решает Подзадачу 4 путём разработки эффективной последовательной модели, удовлетворяющей ограничению вычислительной сложности уравнения (2.13) при сохранении робастности при отравлении на этапе обучения через прогрессивную дистилляцию и РАС-байесовскую сертификацию. Метод адресует Пробел 4 (Состязательность $\times$ Эффективность; Нестационарность $\times$ Эффективность).

2.6.1 Формулировка селективного пространства состояний

Селективная модель пространства состояний [? ?] расширяет классическую линейную систему через входозависимые переходы. Для входной последовательности $u(t) \in \mathbb{R}^{d_{\text{in}}}$ динамика непрерывного времени:

$$\frac{d\mathbf{h}(t)}{dt} = \mathbf{A}(u(t)) \mathbf{h}(t) + \mathbf{B}(u(t)) u(t), \quad y(t) = \mathbf{C} \mathbf{h}(t) + \mathbf{D} u(t), \quad (2.45)$$

где $\mathbf{A}(u) = f_A(u; \theta_A) \in \mathbb{R}^{d_s \times d_s}$ и $\mathbf{B}(u) = f_B(u; \theta_B) \in \mathbb{R}^{d_s \times d_{\text{in}}}$ вычисляются обученными проекциями. Дискретизация через удержание нулевого порядка с шагом Δ даёт

$$\mathbf{h}_k = \bar{\mathbf{A}}_k \mathbf{h}_{k-1} + \bar{\mathbf{B}}_k u_k, \quad \bar{\mathbf{A}}_k = \exp(\mathbf{A}(u_k) \Delta), \quad \bar{\mathbf{B}}_k = \mathbf{A}(u_k)^{-1} (\bar{\mathbf{A}}_k - \mathbf{I}) \mathbf{B}(u_k), \quad (2.46)$$

и свёрточное ядро $\bar{\mathbf{K}} = (\mathbf{C} \bar{\mathbf{A}}^i \bar{\mathbf{B}})_{i=0}^{L-1}$ вычисляется за время $\mathcal{O}(L \log L)$ через быстрое преобразование Фурье.

2.6.2 Прогрессивная состязательная дистилляция робастности

Ансамбль из M моделей-учителей $\{f_{\theta_m}\}_{m=1}^M$, каждая обученная на непесекающемся подмножестве данных, обеспечивает робастность через ди-

стилляцию знаний [? ?]. Модель-ученик f_ϕ обучается у учителей через потери

$$\mathcal{L}_{\text{distill}} = \sum_{m=1}^M w_m \text{KL}(p_\phi(y|\mathbf{x}) \| p_{\theta_m}(y|\mathbf{x})), \quad (2.47)$$

где веса учителей w_m отражают производительность на валидации. Учебный план $\rho(t) = \min(\rho_0 + \alpha t, \rho_{\max})$ постепенно увеличивает долю повреждённых образцов в каждом мини-батче, а общие потери обучения интерполируют между потерями задачи и потерями дистилляции,

$$\mathcal{L}_{\text{total}} = (1 - \lambda(t)) \mathcal{L}_{\text{task}} + \lambda(t) \mathcal{L}_{\text{distill}}, \quad \lambda(t) = \min(\lambda_0 + \beta t, 1), \quad (2.48)$$

так что влияние учителей возрастает с увеличением интенсивности отравления.

2.6.3 РАС-байесовская граница обобщения

Теорема 2.4 (РАС-байесовская граница для селективных моделей пространства состояний [? ?]). *Для любого $\delta \in (0, 1)$, с вероятностью не менее $1 - \delta$ по выбору обучающего множества S размера n , для всех апостериорных распределений Q по параметрам,*

$$\mathbb{E}_{\theta \sim Q}[R(\theta)] \leq \mathbb{E}_{\theta \sim Q}[\hat{R}_n(\theta)] + \sqrt{\frac{\text{KL}(Q \| P) + \log(2\sqrt{n}/\delta)}{2n}}, \quad (2.49)$$

где $R(\theta)$ — истинный риск, $\hat{R}_n(\theta)$ — эмпирический риск, а P — не зависящее от данных априорное распределение.

Эскиз доказательства. Доказательство следует стандартной РАС-байесовской схеме Катони, применяя замену меры с P на Q через вариационное представление KL-дивергенции Донскера–Варадхана в сочетании с аргументом производящей функции моментов для эмпирического процесса. Граница справедлива равномерно по всем апостериорным Q , включая сосредоточенные на единственном параметрическом векторе, и поэтому невакуумна, когда член KL мал относительно n . При гауссовском априорном $P = \mathcal{N}(\mathbf{0}, \sigma_P^2 \mathbf{I})$ и апостериорном $Q = \mathcal{N}(\boldsymbol{\mu}_Q, \sigma_Q^2 \mathbf{I})$ член KL

имеет замкнутую форму

$$\text{KL}(Q\|P) = \frac{d}{2} \left(\frac{\sigma_Q^2}{\sigma_P^2} + \frac{\|\boldsymbol{\mu}_Q\|^2}{\sigma_P^2} - 1 - \log \frac{\sigma_Q^2}{\sigma_P^2} \right), \quad (2.50)$$

который минимизируется сохранением апостериорного близко к началу координат и его дисперсии близко к дисперсии априорного. Полные детали приведены в Приложении А. $\square$

Algorithm 4: MambaShield: Обучение с прогрессивной состязательной дистилляцией робастности

Вход: Обучающие данные $\mathcal{D}$, ансамбль учителей $\{f_{\theta_m}\}_{m=1}^M$, учебный план $\rho_0, \alpha, \rho_{\max}$, априорное РАС-Байеса P

Выход: Робастная модель-ученик f_ϕ с РАС-байесовским сертификатом

- 1 Инициализировать параметры ученика ϕ_0 ;
- 2 Разделить $\mathcal{D}$ на M непересекающихся подмножеств; обучить каждого учителя f_{θ_m} на его подмножестве;
- 3 Вычислить веса учителей $w_m \propto \text{ValAcc}(f_{\theta_m})$;
- 4 **for** итерация $t = 1, \dots, T_{\text{train}}$ **do**
 - 5 Установить долю отравления $\rho(t) = \min(\rho_0 + \alpha t, \rho_{\max})$;
 - 6 Установить вес дистилляции $\lambda(t) = \min(\lambda_0 + \beta t, 1)$;
 - 7 Выбрать мини-батч; повредить долю $\rho(t)$ меток;
 - 8 **for** каждый образец $(\mathbf{x}, y)$ **do**
 - 9 Дискретизовать SSM: $\bar{\mathbf{A}}_k = \exp(\mathbf{A}(u_k)\Delta)$,
 $\bar{\mathbf{B}}_k = \mathbf{A}^{-1}(\bar{\mathbf{A}}_k - \mathbf{I})\mathbf{B}(u_k)$;
 - 10 Выполнить селективное сканирование: $\mathbf{h}_k = \bar{\mathbf{A}}_k \mathbf{h}_{k-1} + \bar{\mathbf{B}}_k u_k$
для $k = 1, \dots, L$;
 - 11 Вычислить предсказание ученика $p_\phi(y|\mathbf{x})$;
 - 12 Вычислить $\mathcal{L}_{\text{task}} = \text{CE}(p_\phi, y)$;
 - 13 Вычислить $\mathcal{L}_{\text{distill}} = \sum_m w_m \text{KL}(p_\phi \| p_{\theta_m})$;
 - 14 Итого: $\mathcal{L} = (1 - \lambda(t))\mathcal{L}_{\text{task}} + \lambda(t)\mathcal{L}_{\text{distill}} + \gamma \text{KL}(Q_\phi \| P)$;
 - 15 Обновить $\phi \leftarrow \phi - \eta \nabla_\phi \mathcal{L}$;
- 16 Вычислить границу РАС-Байеса:

$$R \leq \hat{R}_n + \sqrt{(\text{KL}(Q\|P) + \log(2\sqrt{n}/\delta))/(2n)}$$
;
- 17 **return** f_ϕ и сертификат обобщения

Для иллюстрации операционной семантики Алгоритма 4 ниже приведён короткий программный фрагмент на языке Python, реализующий ядро селективной свёртки $\mathcal{O}(L \log L)$ модели M4 через быстрое преобразова-




Рис. 2.4 – Принципиальная архитектура модели M4: MambaShield — селективной модели пространства состояний со сложностью вывода $\mathcal{O}(L \log L)$ через свёртки на основе быстрого преобразования Фурье, дополненной прогрессивной состязательной дистилляцией и PAC-байесовскими сертификатами обобщения.

ние Фурье (листинг 2.1). Полная реализация модели в составе библиотеки robustnn-core доступна в открытом репозитории платформы RobustIDPS.ai (<https://github.com/rogerpanel/robustidps.ai>).

Листинг 2.1 – Ядро селективной свёртки $\mathcal{O}(L \log L)$ модели M4: MambaShield через БПФ (фрагмент референсной реализации Phase A robustnn-core/mamba_kernel.py).

```

1 import torch
2 import torch.fft as fft
3
4 def mamba_selective_fft(x, A, B, C, D, dt):
5     # Selective state-space convolution with  $\mathcal{O}(L \log L)$  complexity
6     # via FFT, for the M4 MambaShield model.
7     # x : input sequence, shape (B, L, d)
8     # A : state transition matrix, shape (d_state, d_state)
9     # B : input projection matrix, shape (d, d_state)
10    # C : output projection matrix, shape (d_state, d)
11    # D : direct path matrix, shape (d, d)
12    # dt : input-dependent discretization, shape (B, L)
13    B_size, L, d = x.shape
14    # 1. Input-dependent discretization (selective scan)
15    A_disc = torch.matrix_exp(A.unsqueeze(0) * dt.unsqueeze(-1).unsqueeze(-1))
16    B_disc = B.unsqueeze(0) * dt.unsqueeze(-1).unsqueeze(-1)
17    # 2. Build length-L convolution kernel
18    kernel = compute_ssm_kernel(A_disc, B_disc, C, L)
19    # 3. FFT convolution:  $\mathcal{O}(L \log L)$  instead of  $\mathcal{O}(L^2)$ 
20    x_fft = fft.rfft(x, n=2*L, dim=1)
21    k_fft = fft.rfft(kernel, n=2*L, dim=1)
22    y = fft.irfft(x_fft * k_fft, n=2*L, dim=1)[: , :L, :]
23    # 4. Direct path D + add
24    return y + D @ x

```

2.7 Методы М5 и М6: Вывод с калиброванной неопределённостью на графах

Данный раздел решает Подзадачу 6 путём разработки двух взаимодополняющих методов, обеспечивающих сублинейный регрет и декомпозицию неопределённости, требуемые уравнением (2.14). Модель М5 (Стохастический трансформер) обеспечивает вариационное байесовское внимание, а Модель М6 (UC-HGP) — неопределённость на иерархических гауссовских

процессах на нескольких временных масштабах. Вместе они адресуют Пробел 6 (Состязательность $\times$ Точность; Нестационарность $\times$ Точность).

2.7.1 Вариационное байесовское внимание

Для входной последовательности $\mathbf{X} = [\mathbf{x}_1, \dots, \mathbf{x}_n] \in \mathbb{R}^{n \times d}$ вариационные распределения [?] размещаются на матрицах проекций запроса, ключа и значения:

$$\begin{aligned} q_{\phi_Q}(\mathbf{W}_Q) &= \mathcal{N}(\boldsymbol{\mu}_Q, \text{diag}(\boldsymbol{\sigma}_Q^2)), \\ q_{\phi_K}(\mathbf{W}_K) &= \mathcal{N}(\boldsymbol{\mu}_K, \text{diag}(\boldsymbol{\sigma}_K^2)), \\ q_{\phi_V}(\mathbf{W}_V) &= \mathcal{N}(\boldsymbol{\mu}_V, \text{diag}(\boldsymbol{\sigma}_V^2)). \end{aligned} \quad (2.51)$$

Выборки производятся через трюк репараметризации, $\mathbf{W}_Q = \boldsymbol{\mu}_Q + \boldsymbol{\sigma}_Q \odot \boldsymbol{\epsilon}_Q$ с $\boldsymbol{\epsilon}_Q \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$, так что коэффициенты внимания $A_{ij} = (\mathbf{x}_i \mathbf{W}_Q)^\top (\mathbf{x}_j \mathbf{W}_K) / \sqrt{d_k}$ становятся случайными величинами, неопределённость которых распространяется на выход. Оценка Монте-Карло с M выборками аппроксимирует ожидаемое внимание,

$$\mathbb{E}_{q_\phi}[\text{Attention}(\mathbf{X})] \approx \frac{1}{M} \sum_{m=1}^M \text{Attention}(\mathbf{X}; \mathbf{W}_Q^{(m)}, \mathbf{W}_K^{(m)}, \mathbf{W}_V^{(m)}). \quad (2.52)$$

2.7.2 Декомпозиция эпистемической и алеаторной неопределённости

Полная предсказательная неопределённость декомпозируется на эпистемическую неопределённость,

$$U_{\text{epi}} = \text{Var}_{p(\theta|\mathcal{D})}[\mathbb{E}_{p(y|\mathbf{x},\theta)}[y]] \approx \frac{1}{M} \sum_{m=1}^M (\hat{y}^{(m)} - \bar{y})^2, \quad (2.53)$$

измеряющую дисперсию ожидаемого предсказания по выборкам параметров, и алеаторную неопределённость,

$$U_{\text{ale}} = \mathbb{E}_{p(\theta|\mathcal{D})}[\text{Var}_{p(y|\mathbf{x},\theta)}[y]] \approx \frac{1}{M} \sum_{m=1}^M \hat{\sigma}^{(m)2}, \quad (2.54)$$

усредняющую предсказанную дисперсию по выборкам параметров, где $\hat{y}^{(m)}$ — среднее предсказание и $\hat{\sigma}^{(m)2}$ — предсказанная дисперсия из выборки m , а $\bar{y} = \frac{1}{M} \sum_m \hat{y}^{(m)}$.

2.7.3 Стохастическое состязательное обучение

Вместо генерации наихудших возмущений при фиксированных бюджетах стохастическое состязательное обучение выбирает возмущения из обучаемого распределения [? ? ?],

$$\boldsymbol{\delta} \sim q_{\psi}(\boldsymbol{\delta}|\mathbf{x}) = \mathcal{N}(\mu_{\psi}(\mathbf{x}), \sigma_{\psi}(\mathbf{x})^2 \mathbf{I}), \quad (2.55)$$

параметризованного нейронными сетями $\mu_{\psi}, \sigma_{\psi}$, обучающими пространственно-адаптивную статистику возмущений. Целевая функция обучения — стохастическая задача мин-макс

$$\min_{\theta} \max_{\psi} \mathbb{E}_{(\mathbf{x}, y) \sim \mathcal{D}} \mathbb{E}_{\boldsymbol{\delta} \sim q_{\psi}(\boldsymbol{\delta}|\mathbf{x})} [\mathcal{L}(f_{\theta}(\mathbf{x} + \boldsymbol{\delta}), y)], \quad (2.56)$$

решаемая поочерёдным градиентным подъёмом по ψ и спуском по θ .

2.7.4 Многоцелевые потери

Полные потери обучения объединяют пять членов,

$$\mathcal{L}_{\text{total}} = \lambda_1 \mathcal{L}_{\text{task}} + \lambda_2 \mathcal{L}_{\text{KL}} + \lambda_3 \mathcal{L}_{\text{adv}} + \lambda_4 \mathcal{L}_{\text{calib}} + \lambda_5 \mathcal{L}_{\text{reg}}, \quad (2.57)$$

где $\mathcal{L}_{\text{task}} = \mathbb{E}_{(\mathbf{x}, y)} [-\log p_{\theta}(y|\mathbf{x})]$ — потери классификации, $\mathcal{L}_{\text{KL}} [?] = \text{KL}(q_{\phi}(\theta) \| p(\theta))$ регуляризует вариационное апостериорное, $\mathcal{L}_{\text{adv}} = \mathbb{E}_{(\mathbf{x}, y)} \mathbb{E}_{\boldsymbol{\delta} \sim q_{\psi}} [-\log p_{\theta}(y|\mathbf{x} + \boldsymbol{\delta})]$ обеспечивает состязательную робастность, $\mathcal{L}_{\text{calib}} = \text{ECE} [??](\{(p_{\theta}(\hat{y}|\mathbf{x}_i), \mathbf{1}[\hat{y} = y_i])\}_i)$ штрафует ошибку калибровки, а $\mathcal{L}_{\text{reg}} = \|\theta\|_2^2$ контролирует величину весов.

Algorithm 5: Стохастический трансформер: вариационное байесовское обучение с состязательной робастностью

Вход: Обучающие данные $\mathcal{D}$, априорное $p(\theta)$, выборки МК M , параметры распределения возмущений ψ_0 , веса потерь $\lambda_1, \dots, \lambda_5$

Выход: Вариационные параметры ϕ^* , параметры возмущений ψ^*

```

1 Инициализировать вариационные параметры
   $\phi = \{\mu_Q, \sigma_Q, \mu_K, \sigma_K, \mu_V, \sigma_V\}$ ;
2 Инициализировать параметры сети возмущений  $\psi$ ;
3 for итерация  $t = 1, \dots, T$  do
4   for каждый мини-батч  $\{(\mathbf{x}_i, y_i)\}$  do
5     Шаг возмущения: Вычислить  $\mu_\psi(\mathbf{x}_i), \sigma_\psi(\mathbf{x}_i)$  и выбрать
       $\delta_i \sim \mathcal{N}(\mu_\psi(\mathbf{x}_i), \sigma_\psi(\mathbf{x}_i)^2 \mathbf{I})$ ;
6     Обновить  $\psi \leftarrow \psi + \alpha_\psi \nabla_\psi \frac{1}{M} \sum_{m=1}^M \mathcal{L}(f_{\theta^{(m)}}(\mathbf{x}_i + \delta_i), y_i)$ ;
7     Шаг модели: for  $m = 1, \dots, M$  do
8       Выбрать  $\mathbf{W}_Q^{(m)} = \mu_Q + \sigma_Q \odot \epsilon^{(m)}$ , аналогично для
         $\mathbf{W}_K^{(m)}, \mathbf{W}_V^{(m)}$ ;
9       Вычислить выход внимания и предсказания  $\hat{y}^{(m)}, \hat{\sigma}^{(m)2}$ ;
10      Вычислить  $U_{\text{epi}} = \frac{1}{M} \sum_m (\hat{y}^{(m)} - \bar{y})^2$ ,  $U_{\text{ale}} = \frac{1}{M} \sum_m \hat{\sigma}^{(m)2}$ ;
11      Вычислить
         $\mathcal{L}_{\text{total}} = \lambda_1 \mathcal{L}_{\text{task}} + \lambda_2 \mathcal{L}_{\text{KL}} + \lambda_3 \mathcal{L}_{\text{adv}} + \lambda_4 \mathcal{L}_{\text{calib}} + \lambda_5 \mathcal{L}_{\text{reg}}$ ;
12      Обновить  $\phi \leftarrow \phi - \alpha_\phi \nabla_\phi \mathcal{L}_{\text{total}}$ ;
13 return  $\phi^*, \psi^*$  вместе с  $U_{\text{epi}}, U_{\text{ale}}$  для каждого тестового входа

```




Рис. 2.5 – Принципиальная архитектура моделей M5: Stochastic Transformer и M6: UC-HGP — вариационного байесовского внимания (M5) с иерархическим гауссовским процессом (M6) для декомпозиции эпистемической и алеаторной неопределённости и сортировки оповещений по уровню эпистемической неопределённости.

2.8 Прямо совместимое обнаружение при смене протокольного режима

Данный раздел адресует Подзадачу 5 (Пробел 5: Нестационарность $\times$ Робастность) путём построения архитектуры обнаружения, сохраняющей робастность при структурном изменении порождающих данные протоколов графа, обеспечивая прямую совместимость, необходимую для предметно-ориентированной фундаментальной модели (CyberSecLLM).

2.8.1 Протокол-специфичное извлечение признаков

При развёртывании нового протокольного режима наблюдаемые признаки на рёбрах графа, такие как распределения времени, размеры сообщений и подсчёты взаимодействий, изменяются характерным образом. Для протоколов на основе решёток, например, тайминг операций обмена ключами демонстрирует вариации, коррелирующие с вычислительной структурой решёточных операций. Эти вариации захватываются как вектор статистических признаков,

$$\mathbf{f}_{\text{lattice}} = [\mu_t, \sigma_t, \text{skew}(t), \text{kurt}(t), \text{pctl}(t), \text{acf}(t)], \quad (2.58)$$

где $t = (t_1, \dots, t_n)$ обозначает измерения операционного тайминга, а записи захватывают центральную тенденцию, дисперсию, форму распределения и темпоральную зависимость. Аналогичные вектора признаков $\mathbf{f}_{\text{code}}$ и $\mathbf{f}_{\text{hash}}$ определены для семейств протоколов на основе кодов и хэшей, включая структурные параметры такие как размеры ключей, веса ошибок, энтропия синдрома, размеры подписей, подсчёты вызовов хэш-функций и глубины деревьев Меркла.

2.8.2 Унифицированная мультипротокольная архитектура обнаружения

Протокол-специфичные кодировщики формируют латентные представления $\mathbf{z}_{\text{lattice}} = \text{ENC}_{\text{lattice}}(\mathbf{f}_{\text{lattice}})$, $\mathbf{z}_{\text{code}} = \text{ENC}_{\text{code}}(\mathbf{f}_{\text{code}})$, $\mathbf{z}_{\text{hash}} = \text{ENC}_{\text{hash}}(\mathbf{f}_{\text{hash}})$. Слияние кросс-вниманием обеспечивает взаимодействие

между тремя протокольными представлениями,

$$\mathbf{z}_{\text{fused}} = \text{MultiHeadAttention}([\mathbf{z}_{\text{lattice}}, \mathbf{z}_{\text{code}}, \mathbf{z}_{\text{hash}}]), \quad (2.59)$$

и многозадачная классификация предсказывает как метку категории, так и целевой протокол,

$$p(\text{class}, \text{protocol}) = \text{Softmax}(\mathbf{W}_{\text{out}}\mathbf{z}_{\text{fused}} + \mathbf{b}_{\text{out}}). \quad (2.60)$$

2.8.3 Формальная сводка безопасности

Гарантия робастности системы обнаружения при новом протокольном режиме наследуется от сложности задачи обучения с ошибками (LWE) [? ?]. При $\mathbf{A} \in \mathbb{Z}_q^{m \times n}$ и $\mathbf{b} = \mathbf{A}\mathbf{s} + \mathbf{e} \bmod q$ для секрета $\mathbf{s}$ и малой ошибки $\mathbf{e}$ любой полиномиально-временной противник, различающий легитимную и манипулированную последовательность согласования протокола, может быть использован для построения решателя LWE, что противоречит предполагаемой сложности. Формальная сводка, представленная полностью в Приложении А, устанавливает, что ошибка второго рода классификатора ограничена преимуществом лучшего решателя LWE плюс статистический член, убывающий с числом обучающих образцов.

Algorithm 6: Прямо совместимое мультипротокольное обнаружение

Вход: Поток графовых событий со смешанными протокольными режимами на рёбрах, протокол-специфичные кодировщики, бюджет состязат. обучения ϵ

Выход: Классификация (class, protocol) и сертификат робастности на основе LWE

```
1 for каждое входящее событие графа do
2   | Определить протокольный режим через анализ
   | последовательности согласования;
3   | if на основе решёток (Kyber/Dilithium) then
4   |   | Извлечь признаки тайминга
   |   |  $\mathbf{f}_{\text{lattice}} = [\mu_t, \sigma_t, \text{skew}, \text{kurt}, \text{pctl}, \text{acf}]$ ;
   |   | Кодировать:  $\mathbf{z}_{\text{lattice}} \leftarrow \text{ENC}_{\text{lattice}}(\mathbf{f}_{\text{lattice}})$ ;
6   | else if на основе кодов (McEliece/Niederreiter) then
7   |   | Извлечь структурные признаки  $\mathbf{f}_{\text{code}}$ ; кодировать
   |   |  $\mathbf{z}_{\text{code}} \leftarrow \text{ENC}_{\text{code}}(\mathbf{f}_{\text{code}})$ ;
8   | else
9   |   | Извлечь хэш-признаки  $\mathbf{f}_{\text{hash}}$ ; кодировать
   |   |  $\mathbf{z}_{\text{hash}} \leftarrow \text{ENC}_{\text{hash}}(\mathbf{f}_{\text{hash}})$ ;
10  | Слить:  $\mathbf{z}_{\text{fused}} \leftarrow \text{MultiHeadAttention}([\mathbf{z}_{\text{lattice}}, \mathbf{z}_{\text{code}}, \mathbf{z}_{\text{hash}}])$ ;
11  | Классифицировать:
   |  $p(\text{class}, \text{protocol}) \leftarrow \text{Softmax}(\mathbf{W}_{\text{out}}\mathbf{z}_{\text{fused}} + \mathbf{b}_{\text{out}})$ ;
12 Обучение: Чередование стандартных прямых проходов и
   | состязательных прямых проходов с PGD-возмущениями  $\|\delta\| \leq \epsilon$ ,
   | применяемыми к векторам признаков;
13 Сертификация: Проверить сводку LWE (Приложение А) и
   | сообщить параметр робастности  $\lambda_{\text{sec}}$ ;
14 return классификацию и сертификат робастности
```




Рис. 2.6 – Принципиальная архитектура мультиагентного *PQC-IDS-модуля* — прямо-совместимой системы обнаружения вторжений при смене протокольного режима, с протокол-специфичными кодировщиками для решёточных, кодовых и хэш-протоколов и слиянием через кросс-внимание.

2.9 Модель М7: Теоретико-игровая сертификация и единая система

Данный раздел решает Подзадачу 7 путём разработки формулировки игры Штакельберга и члена связки согласованности $\sum_{i < j} \mathcal{L}_{ij}(\theta_i, \theta_j)$ из единой задачи (Уравнение (2.15)). Вместе с компонентами сертификации это составляет Модель М7 и адресует Пробел 7 (все условия $\times$ все требования).

2.9.1 Формулировка игры Штакельберга

Защитник выбирает модель f_θ и конфигурацию развёртывания c , включающую параметры политики обнаружения. Противник наблюдает (f_θ, c) и выбирает стратегию возмущения a . Функции полезности защитника и противника соответственно:

$$U_d(f_\theta, c, a) = \mathbb{E}_{\mathbf{x} \sim \mathcal{D}(a)}[\mathbf{1}[f_\theta(\mathbf{x}) = y]] - \text{Cost}(c), \quad (2.61)$$

$$U_a(f_\theta, c, a) = \mathbb{P}[\text{ошибка классиф.} \mid f_\theta, c, a] - \text{Cost}(a), \quad (2.62)$$

где $\mathcal{D}(a)$ — распределение данных, индуцированное стратегией противника. Равновесие Штакельберга — решение

$$(f_\theta^*, c^*) = \arg \max_{f_\theta, c} U_d(f_\theta, c, a^*(f_\theta, c)), \quad a^*(f_\theta, c) = \arg \max_a U_a(f_\theta, c, a). \quad (2.63)$$

2.9.2 Характеристика равновесия Нэша

При одновременной игре профиль смешанных стратегий (π_d, π_a) является равновесием Нэша, когда ни один игрок не улучшает полезность односторонним отклонением,

$$\mathbb{E}_{\pi_a}[U_d(\pi_d, a)] \geq \mathbb{E}_{\pi_a}[U_d(\pi'_d, a)] \quad \forall \pi'_d, \quad \mathbb{E}_{\pi_d}[U_a(f_\theta, \pi_a)] \geq \mathbb{E}_{\pi_d}[U_a(f_\theta, \pi'_a)] \quad \forall \pi'_a. \quad (2.64)$$

В частном случае игры с нулевой суммой $U_d + U_a = 0$ равновесие совпадает с минимаксным значением $\pi_d^* = \arg \max_{\pi_d} \min_a \mathbb{E}_{\pi_d}[U_d(f_\theta, a)]$.

2.9.3 Онлайн-обучение с гарантиями отсутствия регрета

На раунде t защитник выбирает конфигурацию $c_t \in \mathcal{C}$ и наблюдает вознаграждение $r_t = U_d(c_t, a_t)$. Кумулятивный регрет после T раундов:

$$R(T) = \max_{c \in \mathcal{C}} \sum_{t=1}^T U_d(c, a_t) - \sum_{t=1}^T U_d(c_t, a_t). \quad (2.65)$$

Обновление мультипликативными весами [? ?] поддерживает распределение $p_t(c) \propto \exp(\eta \sum_{s=1}^{t-1} \mathbf{1}[c_s=c] r_s)$ со скоростью обучения $\eta = \sqrt{\log |\mathcal{C}|/T}$.

Теорема 2.5 (Граница регрета). *Алгоритм мультипликативных весов со скоростью обучения $\eta = \sqrt{\log |\mathcal{C}|/T}$ достигает*

$$R(T) \leq 2\sqrt{T \log |\mathcal{C}|}, \quad (2.66)$$

так что средний регрет на раунд $R(T)/T = \mathcal{O}(\sqrt{\log |\mathcal{C}|/T}) \rightarrow 0$ при $T \rightarrow \infty$.

Эскиз доказательства. Доказательство проходит через ограничение потенциальной функции $\Phi_t = \log \sum_c \exp(\eta \sum_{s=1}^t r_s(c))$ сверху и снизу. Верхняя граница использует вогнутость логарифма и определение алгоритма; нижняя граница выделяет лучшее действие ретроспективно. Объединение двух границ и оптимизация по η даёт указанную скорость. Полный аргумент приведён в Приложении А. $\square$

2.9.4 Выбор стратегии с учётом неопределённости

Байесовская неопределённость стохастического трансформера из Раздела 2.7 информирует полезность защитника через выигрыш со штрафом за неопределённость,

$$\tilde{U}_d(c, a) = \begin{cases} U_d(c, a) - \kappa U_{\text{epi}} & \text{если } U_{\text{epi}} < \tau, \\ -\infty & \text{иначе,} \end{cases} \quad (2.67)$$

где κ дисконтирует полезность при неопределённости, а порог τ инициирует направление на экспертный анализ. Это порождает чувствительные к риску политики, воздерживающиеся от предсказаний при недостаточной уверенности модели.

Algorithm 7: Теоретико-игровая робастность с онлайн-обучением, учитывающим неопределённость

Вход: Пространство действий $\mathcal{C}$, порог неопределённости τ , штраф κ , расписание скорости обучения

Выход: Политика защитника π_d^* с гарантией регрета

- 1 Инициализировать равномерное распределение $p_1(c) = 1/|\mathcal{C}|$ для всех $c \in \mathcal{C}$;
 - 2 Установить $\eta = \sqrt{\log |\mathcal{C}|/T}$;
 - 3 **for** раунд $t = 1, \dots, T$ **do**
 - 4 Выбрать действие защитника $c_t \sim p_t$;
 - 5 Наблюдать действие противника a_t и вознаграждение $r_t = U_d(c_t, a_t)$;
 - 6 Запросить стохастический трансформер для эпистемической неопределённости U_{epi} ;
 - 7 **if** $U_{\text{epi}} \geq \tau$ **then**
 - 8 Установить $\tilde{r}_t = -\infty$ (отклонить; направить на экспертный анализ);
 - 9 **else**
 - 10 Установить $\tilde{r}_t = r_t - \kappa U_{\text{epi}}$;
 - 11 Обновить веса: $p_{t+1}(c) \propto p_t(c) \exp(\eta \tilde{r}_t \mathbf{1}[c_t = c])$ для всех $c \in \mathcal{C}$;
 - 12 Нормализовать p_{t+1} ;
 - 13 Вычислить эмпирическое равновесие Нэша из частот игры $\{(c_t, a_t)\}_{t=1}^T$;
 - 14 **return** π_d^* и подтверждённый регрет $R(T) \leq 2\sqrt{T \log |\mathcal{C}|}$
-

2.9.5 Единая сертификация через связанную оптимизацию

Семь разработанных выше методов (М1–М6, а также теоретико-игровой компонент М7) разделяют математические структуры — анализ сопряжённых чувствительностей, геометрию Вассерштейна, регуляризацию KL-дивергенцией и динамику с ограниченной константой Липшица — допускающие единую трактовку через связанную оптимизацию. Дан-

ный раздел завершает Модель М7 разработкой системы сертификации, интегрирующей все компонентные гарантии.

2.9.6 Связанная целевая функция

Пусть $\theta = \{\theta_{\text{СТ}}, \theta_{\text{ТЕ}}, \theta_{\text{Fed}}, \theta_{\text{PQ}}, \theta_{\text{MS}}, \theta_{\text{ST}}, \theta_{\text{GT}}\}$ собирает параметры всех семи методов. Единая целевая функция связывает компонентные потери с попарными членами согласованности,

$$\mathcal{L}_{\text{unified}}(\theta) = \sum_{i=1}^7 \lambda_i \mathcal{L}_i(\theta_i) + \sum_{i < j} \lambda_{ij} \mathcal{L}_{ij}(\theta_i, \theta_j), \quad (2.68)$$

где каждые $\mathcal{L}_i$ — потери, специфичные для метода, из соответствующего раздела, а потери связи

$$\mathcal{L}_{ij}(\theta_i, \theta_j) = \text{KL}(p_{\theta_i}(y|\mathbf{x}) \| p_{\theta_j}(y|\mathbf{x})) + \|\mathbf{z}_{\theta_i}(\mathbf{x}) - \mathbf{z}_{\theta_j}(\mathbf{x})\|_2^2 \quad (2.69)$$

обеспечивают согласованность между предсказательными распределениями и обученными представлениями методов i и j .

2.9.7 Анализ сходимости

Теорема 2.6 (Сходимость единой системы). *Предположим, что каждые компонентные потери $\mathcal{L}_i$ являются L_i -гладкими и каждые потери связи $\mathcal{L}_{ij}$ являются L_{ij} -гладкими. При поочерёдном градиентном спуске со скоростями обучения $\eta_i \leq 1/(L_i + \sum_j L_{ij})$ единая оптимизация сходится со скоростью*

$$\|\nabla \mathcal{L}_{\text{unified}}(\theta_T)\|^2 \leq \frac{2(\mathcal{L}_{\text{unified}}(\theta_0) - \mathcal{L}_{\text{unified}}(\theta^*))}{\eta_{\min} T}, \quad (2.70)$$

где $\eta_{\min} = \min_i \eta_i$, а θ^* — стационарная точка.

Эскиз доказательства. Каждый шаг поочерёдного градиента по компоненту i уменьшает единую целевую функцию не менее чем на $\eta_i \|\nabla_{\theta_i} \mathcal{L}_{\text{unified}}\|^2 / 2$ при условии гладкости, поскольку члены связи гладки по каждому блоку переменных. Суммирование по всем компонентам и всем T раундам, деление на T и взятие минимума по скоростям обучения даёт указанную грани-

цу. Полный вывод, включая обработку перекрёстных градиентов, приведён в Приложении А. □

Algorithm 8: Единая система: поочерёдная оптимизация со связкой согласованности

Вход: Компонентные потери $\mathcal{L}_1, \dots, \mathcal{L}_7$, веса связки $\{\lambda_{ij}\}$, константы гладкости $\{L_i, L_{ij}\}$

Выход: Совместно оптимизированные параметры $\theta^* = \{\theta_1^*, \dots, \theta_7^*\}$

```

1 Инициализировать все компонентные параметры  $\theta_1^{(0)}, \dots, \theta_7^{(0)}$ ;
2 Установить скорости обучения  $\eta_i = 1/(L_i + \sum_j L_{ij})$  для каждого
   компонента;
3 for раунд  $t = 0, 1, \dots, T-1$  do
4   for компонент  $i = 1, \dots, 7$  do
5     Вычислить компонентный градиент  $\mathbf{g}_i = \nabla_{\theta_i} \mathcal{L}_i(\theta_i^{(t)})$ ;
6     Вычислить градиенты связки  $\mathbf{g}_{ij} = \nabla_{\theta_i} \mathcal{L}_{ij}(\theta_i^{(t)}, \theta_j^{(t)})$  для всех
        $j \neq i$ ;
7     Совокупный градиент:  $\mathbf{g}_i^{\text{total}} = \lambda_i \mathbf{g}_i + \sum_{j \neq i} \lambda_{ij} \mathbf{g}_{ij}$ ;
8     Обновить:  $\theta_i^{(t+1)} \leftarrow \theta_i^{(t)} - \eta_i \mathbf{g}_i^{\text{total}}$ ;
9   Вычислить  $\mathcal{L}_{\text{unified}}(\theta^{(t+1)})$  и проверить критерий сходимости;
10 return  $\theta^* = \theta^{(T)}$ 

```




Рис. 2.7 – Принципиальная архитектура модели M7: теоретико-игровой сертификации — единой системы, моделирующей взаимодействие защитника и противника как стратегическую игру с равновесием Штакельберга, объединяющая модели M1–M6 через регуляризацию согласованности.

2.10 Систематизация метрик оценки качества Hybrid IDPS

Оценка качества разработанных моделей и алгоритмов M1–M7 опирается на единую систему из двадцати трёх метрик, систематизированных в

табл. 2.3 по шести свойствам Hybrid IDPS из §2.1.2. Группировка метрик по свойствам, а не по их математическому происхождению, обеспечивает прямое отображение экспериментальной валидации (Глава 4) на инварианты, формализованные в ур. (2.2)–(2.7).

Таблица 2.3 – Систематизация двадцати трёх метрик оценки качества Hybrid IDPS по шести свойствам из §2.1.2.

Свойство	Класс метрик	Конкретные метрики
П1 Состязат. устойчивость	Сертификаты	Сертифиц. точность, радиус Грёнуолла, верхняя граница доли успешных атак
П2 Робастность	Классификация	F1 (микро/макро/взвешенный), сбаланс. точность, MCC, κ Коэна, AUC-ROC, TPR, TNR, FPR, FNR
П3 Эффективность	Вычислительные	Задержка вывода (среднее, p95, p99), пропускная способность, FLOPs, число параметров, объём GPU-памяти, энергопотребление
П4 Распределённая среда	Приватность	Бюджет (ϵ, δ) дифф. приватности, преимущество атаки на принадлежность, точность визант. агрегации при $\beta = 0,3$
П5 Человеческий фактор	Калибровка	ЕСЕ, оценка Брайера, mean entropy, эпистемическая/алеаторная декомпозиция, время сортировки оповещений аналитиком
П6 Нестационарность	Адаптация	Регрет $R(T)$, точность переноса при дрейфе, скорость восстановления после смены распределения

Полный экспериментальный протокол с применением указанных метрик к шести бенчмарк-наборам данных (84,2 миллиона размеченных образцов, 84 категории атак) представлен в Главе 4. Развёрнутые математические определения каждой метрики приведены в тексте Главы 4 при первом использовании.

2.11 Итоги главы

В настоящей главе разработаны полные математические основы для семи новых методов, выведенных из единой постановки задачи (Уравнение (2.15)) через систематическую декомпозицию на семь подзадач. Единая

задача была последовательно построена путём включения состязательной робастности (Этап 2), динамики непрерывного времени с сертификацией Липшица (Этап 3), распределённого обучения с дифференциальной приватностью (Этап 4), многоуровневого представления с защитой от забывания (Этап 5), вычислительной эффективности через модели пространства состояний (Этап 6) и нестационарной адаптации с оценкой неопределённости (Этап 7).

Модель M1 (СТ-TGNN) обеспечивает динамику графов непрерывного времени с сертифицированной робастностью по Липшицу, решая Подзадачу 1 (Пробел 1). Модель M2 (FedLLM-API) достигает византийско-устойчивой федеративной оптимизации с дифференциальной приватностью и выравниванием оптимального транспорта, решая Подзадачу 2 (Пробел 2). Модель M3 (TripleE-TGNN) захватывает многоуровневую структуру через тройные вложения с упругой консолидацией весов, решая Подзадачу 3 (Пробел 3). Модель M4 (MambaShield) обеспечивает эффективный последовательный вывод с РАС-байесовскими сертификатами обобщения, решая Подзадачу 4 (Пробел 4). Архитектура прямо совместимого обнаружения адресует смену протокольных режимов, решая Подзадачу 5 (Пробел 5). Методы M5/M6 (Стохастический трансформер и UC-HGP) обеспечивают калиброванную байесовскую неопределённость при состязательном возмущении, решая Подзадачу 6 (Пробел 6). Модель M7 (Сертификация), включающий теоретико-игровую систему и связку единой оптимизации, объединяет все компонентные гарантии через регуляризацию согласованности с доказанной скоростью сходимости (Теорема 2.6), решая Подзадачу 7 (Пробел 7).

Каждый метод сформулирован на уровне математических операций над графовыми структурами без привязки к какой-либо конкретной прикладной области. Теоретические гарантии — скорости сходимости, сертификаты робастности, бюджеты приватности, границы регрета и РАС-байесовские границы обобщения — выполняются везде, где эти методы развёрнуты. В следующей главе все методы реализуются в области графов сетевого трафика, описывая процесс адаптации и согласования, через который предметно-независимая математическая основа отображается на сущности и ограничения кибербезопасности и гибридных систем обнаружения и предотвра-

щения сетевых вторжений.

Глава 3

Инстанцирование системы Hybrid IDPS для защиты сетевого трафика и её эталонная валидация

В настоящей главе систематически реализуется и валидируется *система* Hybrid IDPS, формализованная в Главе 2, применительно к сектору защиты сетевого трафика (§1.1.2). Глава состоит из двух методически связанных частей. *Первая часть* (§3.1–§3.7) систематически инстанцирует семёрку (2.1) с конкретными сущностями сетевой безопасности: определены NIDS-ориентированные терминологии, конвейер преобразования сырого трафика в темпоральный граф, унифицированная таксономия классификации из 34 классов угроз, конвейер инженерии 83-мерного вектора признаков потока, конфигурация гиперпараметров и интегрированная архитектура системы. *Вторая часть* (§3.8–§3.12) систематически валидирует получившуюся инстанцированную систему на шести эталонных наборах данных общим объёмом 84,2 миллиона размеченных образцов: представлены экспериментальная методология, результаты единого бенчмарка, попоточные результаты по каждой из семи моделей M1–M7, сравнение с базовыми линиями и абляционные исследования. Завершает главу §3.13 — *предварительное расширение* системы Hybrid IDPS на сектор БПЛА, демонстрирующее предметную независимость системы как преамбула к полной экспериментальной программе для БПЛА в Главе 6. Кросс-секущая валидация системы Hybrid IDPS (состязательная робастность по шести семействам атак, кросс-доменный перенос на речь и здравоохранение, постквантовая совместимость) изложена отдельно в Главе 4.

3.1 Обнаружение сетевых вторжений: терминологии и контекст

3.1.1 Гибридные системы обнаружения и предотвращения вторжений

Гибридная система обнаружения и предотвращения вторжений (ГСОВ) [10, 11, 12, 13, 14] объединяет две взаимодополняющие парадигмы обнаружения. Сигнатурное обнаружение сопоставляет входящий трафик с базой данных известных паттернов (правил) и достигает высокой прецизионности на ранее каталогизированных угрозах, но не может обнаруживать новые атаки. Аномальное обнаружение обучает статистическую модель нормального поведения и маркирует отклонения, обеспечивая обнаружение эксплойтов нулевого дня и эволюционирующих паттернов атак ценой потенциально более высокого уровня ложных срабатываний. Методы диссертации работают в рамках аномальной ветви, дополненной рассуждением большой языковой модели для классификации zero-shot новых категорий.

Сетевая СОВ (ССОВ) мониторит трафик на сетевом уровне, анализируя потоки и пакеты между хостами, а не события внутри отдельного конечного устройства. Все три рабочих условия архитектурной основы (Рис. 4) присутствуют в данной области: состязательная манипуляция целенаправленными противниками, формирующими трафик для уклонения от обнаружения, нестационарность через эволюционирующие паттерны трафика и изменения протоколов, и распределённость инфраструктуры мониторинга по организационным границам.

3.1.2 Ключевые терминологии

Следующие термины используются на протяжении данной главы и экспериментальной валидации в Главе 4:

Поток. Последовательность пакетов с общей 5-кортежной характеристикой (IP-адрес источника, IP-адрес назначения, порт источника, порт назначения, протокол). Поток является фундаментальной единицей анализа

и соответствует направленному ребру в сетевом графе.

Сессия. Двухнаправленная коммуникация, включающая прямой поток и его обратный аналог, захватывающая полный обмен между двумя конечными точками.

Хост. Сетевая конечная точка (IP-адрес), участвующая как источник или назначение. Хосты соответствуют узлам в сетевом графе.

Сервис. Функциональный компонент, идентифицируемый номером порта и протоколом (например, HTTP на порту 80, SSH на порту 22). В облачных развёртываниях сервисы соответствуют контейнерам микросервисов.

PCAP (Packet Capture). Сырой двоичный формат, захватывающий полные заголовки пакетов и опционально полезные нагрузки, из которого извлекаются признаки уровня потоков.

Правило СОВ. Структурированная спецификация паттерна (например, в синтаксисе правил Snort или Suricata), кодирующая сигнатуру обнаружения с действием, протоколом, адресами, портами и директивами сопоставления содержимого.

MITRE ATT&CK. Комплексная база знаний о тактиках, техниках и процедурах (ТТП) противников, используемая для классификации и контекстуализации обнаруженных угроз.

SOC (Центр операций безопасности). Организационное подразделение, ответственное за мониторинг, анализ и реагирование на события безопасности, укомплектованное аналитиками уровней 1–3.

3.2 Конвейер преобразования данных в граф

Центральная предпосылка настоящей диссертации состоит в том, что сетевой трафик имеет естественную графовую структуру: хосты являются узлами, потоки — рёбрами, а временной порядок определяет эволюцию графа. Данный раздел формализует преобразование сырых сетевых данных в графовые входы, требуемые разработанными архитектурами ГНС.

3.2.1 Построение графа из сетевого трафика

При заданном потоке сетевых записей $\{(s_i, d_i, t_i, \mathbf{f}_i)\}_{i=1}^N$, где s_i — хост-источник, d_i — хост-назначение, t_i — временная метка и $\mathbf{f}_i \in \mathbb{R}^{83}$ — вектор

признаков, темпоральный граф $\mathcal{G}(t) = (\mathcal{V}, \mathcal{E}(t), \mathbf{X}(t))$ строится следующим образом:

Узлы. Каждый уникальный IP-адрес становится узлом $v \in \mathcal{V}$. Признаки узла $\mathbf{x}_v(t)$ агрегируют статистику уровня хоста, вычисленную по скользящему окну $[t - \Delta_w, t]$: кумулятивные счётчики байтов (отправленных/полученных), счётчики активных соединений, уникальные порты назначения, распределение протоколов (соотношения TCP/UDP/ICMP) и средний межсоединительный интервал. Это даёт 12-мерный вектор признаков узла.

Рёбра. Каждый поток $(s_i, d_i, t_i, \mathbf{f}_i)$ создаёт направленное ребро от узла s_i к узлу d_i в момент t_i с признаками ребра $\mathbf{e}_{s_i d_i}(t_i) = \mathbf{f}_i$. Полный 83-мерный вектор признаков (Раздел 3.4) прикрепляется к ребру.

Темпоральная эволюция. Граф эволюционирует по мере поступления новых потоков и истечения старых соединений. Поток считается активным, если его последний пакет поступил в пределах настраиваемого тайм-аута $\Delta_{\text{timeout}} = 120$ с. Истекшие рёбра удаляются, порождая динамическую, изменяющуюся во времени топологию.

3.2.2 Многоуровневое построение графов

Для TripleE-TGNN (Модель М3) и интеграции SOC-аналитики сетевой трафик дополнительно отображается на три иерархических уровня:

Граф сервисов $\mathcal{G}_s(t)$. Узлы представляют сервисы (пары порт/протокол); рёбра представляют API-вызовы между сервисами, агрегированные по настраиваемым окнам. Используется для обнаружения паттернов межсервисных атак в средах микросервисов.

Граф трассировок $\mathcal{G}_r(t)$. Узлы представляют распределённые трассировки запросов (идентифицируемые по ID трассировки в HTTP-заголовках или инструментации OpenTelemetry); рёбра соединяют трассировки, разделяющие хотя бы один сервис. Используется для обнаружения многоэтапных цепочек атак.

Граф хостов $\mathcal{G}_n(t)$. Узлы представляют узлы инфраструктуры; рёбра представляют наблюдаемые сетевые потоки. Это основной граф для всех методов.

Двудольные графы связи $\mathcal{B}_{sr}, \mathcal{B}_{sn}, \mathcal{B}_{rn}$ соединяют сущности между уровня-

ми, обеспечивая механизм межуровневого внимания из уравнения (2.37).

3.3 Таксономия классификации

Платформа классифицирует сетевой трафик в 34 различных класса: 1 легитимный класс и 33 класса атак, организованные в 7 основных категорий. Эта таксономия унифицирована по всем шести бенчмарк-наборам данных, при этом специфические для набора типы атак сопоставлены каноническим категориям. Таблица 3.1 представляет полную таксономию.

Таблица 3.1 – Унифицированная таксономия классификации: 34 класса по 7 категориям атак.

Категория	Классы атак
DDoS (8)	DDoS-TCP, DDoS-UDP, DDoS-ICMP, DDoS-HTTP, DDoS-SYN Flood, DDoS-DNS Amplification, DDoS-SSDP, DDoS-NTP Amplification
DoS (5)	DoS GoldenEye, DoS Hulk, DoS Slowhttptest, DoS Slowloris, DoS HeartBeat
Разведка (4)	PortScan, Nmap Scan, Service Probe, OS Fingerprint
Перебор (4)	FTP-Patator, SSH-Patator, Web Login Brute Force, RDP Brute Force
Веб-атаки (4)	XSS, SQL Injection, Command Injection, Directory Traversal
ВПО/Ботнет (5)	Mirai, Botnet Communication, Trojan Callback, Ransomware Beacon, Cryptomining
Продвинутые (3)	Infiltration, Heartbleed, Spoofing
Легитимный (1)	Нормальный трафик

Таксономия расширяема: новые классы атак могут быть зарегистрированы через интерфейс администрирования платформы без переобучения полного ансамбля моделей, используя возможность классификации zero-shot CyberSecLLM и упругую консолидацию весов TripleE-TGNN для инкрементального обучения.

3.4 Конвейер инженерии признаков

Все модели работают на общем векторе из 83 инженерных признаков, извлечённых из сырых PCAP-файлов или предварительно обработанных CSV-наборов данных. Признаки охватывают пять категорий, обобщённых в Таблице 3.2.

Таблица 3.2 – Конвейер инженерии 83 признаков, организованных по категориям.

Категория	Кол-во	Репрезентативные признаки
Статистика уровня потоков	22	Длительность, счётчики пакетов прямых/обратных, общее количество байтов (прям./обр.), длина пакетов (среднее, макс., мин., std.), байт/с потока, пакетов/с потока, IAT потока (среднее, std., макс., мин.)
Распределения межпакетных интервалов	18	Прямой IAT (среднее, std., мин., макс.), обратный IAT (среднее, std., мин., макс.), статистики активного/неактивного времени, счётчики подпотоков прямых/обратных
Флаговые индикаторы	15	Счётчики SYN, FIN, RST, PSN, ACK, URG, CWE, ECE, флаги PSN прямые/обратные, флаги URG прямые/обратные, счётчик флага FIN, счётчик флага SYN, счётчик флага RST
Статистика полезной нагрузки	16	Размеры сегментов (мин., макс., среднее), длины заголовков (среднее, общее), начальные байты окна (прямые/обратные), энтропия байтов полезной нагрузки, дисперсия длины пакетов, средний размер пакета, средний размер сегмента
Производные от-ношения	12	Байтов на пакет (прям./обр.), пакетов в секунду, соотношение нисх./восх., отношение среднего размера пакета, отношение IAT потока, массовая скорость (прямая/обратная), среднее/std. активного периода, среднее/std. неактивного периода
Всего	83	

Извлечение признаков выполняется общим модулем `FeatureExtractor` с использованием пофакторной z-стандартизации, подогнанной на обучаю-

щем распределении:

$$\tilde{f}_j = \frac{f_j - \mu_j^{\text{train}}}{\sigma_j^{\text{train}} + \varepsilon}, \quad (3.1)$$

где μ_j^{train} и σ_j^{train} — среднее и стандартное отклонение признака j , вычисленные на обучающем множестве, а $\varepsilon = 10^{-8}$ предотвращает деление на ноль. Наборы данных с менее чем 83 нативными признаками дополняются нулями до стандартной размерности; те, что имеют больше, проецируются через PCA с сохранением 95% объяснённой дисперсии.

3.5 Предметно-ориентированная реализация методов

Данный раздел описывает, как каждый из семи методов Главы 2 реализован с параметрами, специфичными для кибербезопасности, демонстрируя отображение абстрактных математических объектов на конкретные сущности сетевой безопасности.

3.5.1 M1: СТ-TGNN для динамики графов сетевого трафика

СТ-TGNN [?] реализован следующим образом. В реализации для сетевой безопасности множество узлов $\mathcal{V}$ включает хосты и сервисы, а множество рёбер $\mathcal{E}(t)$ регистрирует потоки. Признаки узлов $\mathbf{x}_v(t)$ кодируют статистику уровня хоста (12 измерений). Признаки рёбер $\mathbf{e}_{uv}(t)$ захватывают 83-мерный вектор признаков потока из Таблицы 3.2.

Три параллельные ветви ОДУ из уравнения (2.19) получают постоянные времена $\tau_1 = 1$ с (переходные процессы уровня пакетов), $\tau_2 = 60$ с (динамика сессий уровня потоков) и $\tau_3 = 3600$ с (тенденции уровня кампаний). Это обеспечивает одновременное разрешение субсекундных всплесков сканирования портов и многочасовых кампаний развитых постоянных угроз. Архитектура использует четыре слоя передачи сообщений, скрытую размерность 256, размерность состояния 64 и адаптивное интегрирование DOPRI5 с допусками 10^{-5} (относительный) и 10^{-7} (абсолютный).

участников, отправляющих отравленные обновления градиентов. Дифференциальная приватность через локальную обрезку градиентов при пороге $C = 1.0$ и гауссовский шум с масштабом $\sigma = 0.8$ обеспечивает гарантию $(\epsilon=0.85, \delta=10^{-5})$ за 100 раундов коммуникации. Выравнивание ОТ Синкхорна с регуляризацией $\lambda = 0.1$ корректирует распределительную гетерогенность между центрами. Вес ансамбля LLM $\lambda_{\text{LLM}} = 0.3$.




Рис. 3.2 – Архитектура FedLLM-API для совместной разведки угроз через организационные границы.

3.5.3 М3: TripleE-TGNN для многоуровневого мониторинга безопасности

Граф сервисов $\mathcal{G}_s(t)$ имеет узлы, представляющие микросервисы, и рёбра, представляющие API-вызовы. Граф трассировок $\mathcal{G}_r(t)$ имеет узлы, представляющие распределённые трассировки. Граф хостов $\mathcal{G}_n(t)$ имеет узлы, представляющие узлы инфраструктуры. Сила консолидации EWC $\lambda_{\text{ewc}} = 0.5$ балансирует пластичность и стабильность при эволюции топологии. Веса многозадачных потерь $\lambda_s = 0.4$, $\lambda_r = 0.3$, $\lambda_n = 0.3$ с весом согласованности $\lambda_{\text{con}} = 0.1$.




Рис. 3.3 – Архитектура TripleE-TGNN для многоуровневого мониторинга безопасности в облачных средах.

3.5.4 М4: MambaShield для обнаружения с адаптацией к дрейфу

MambaShield [?] реализован для обнаружения с адаптацией к дрейфу. Последовательные записи потоков обрабатываются селективной моделью пространства состояний, входозависимые переходы которой адаптируются к текущему режиму трафика. Размерность состояния $d_s = 64$, шаг дискретизации $\Delta = 0.01$ и длина свёрточного ядра БПФ $L = 1024$. Ансамбль учителей включает $M = 5$ моделей, обученных на непересекающихся подмножествах данных. Учебный план начинается с доли отравления $\rho_0 = 0.05$ и увеличивается до $\rho_{\max} = 0.3$. Дисперсия априорного РАС-Байеса $\sigma_P^2 = 1.0$.




Рис. 3.4 – Архитектура MambaShield для обнаружения вторжений с адаптацией к дрейфу и прогрессивной дистилляцией робастности.

3.5.5 М5/М6: Оценка угроз с калиброванной неопределённостью

Стохастический трансформер использует $M = 50$ прямых проходов Монте-Карло при выводе для получения оценок эпистемической и алеаторной неопределённости. Предсказания с эпистемической неопределённостью,

превышающей порог $\tau = 0.3$, направляются аналитикам, снижая утомление от оповещений на 43%. Модуль UC-HGP обеспечивает неопределённость на иерархических гауссовских процессах на временных масштабах, соответствующих ветвям СТ-TGNN (τ_1, τ_2, τ_3). Скорость вариационного обучения $\alpha_\phi = 5 \times 10^{-4}$; скорость обучения возмущений $\alpha_\psi = 10^{-3}$.




Рис. 3.5 – Стохастический трансформер с сортировкой на основе неопределённости для операций безопасности.

3.5.6 М7: Теоретико-игровая система для адаптивных противников

Пространство действий защитника $\mathcal{C}$ включает конфигурации обнаружения: покрытие мониторинга, пороги оповещений и политики реагирова-

ния. Пространство действий противника $\mathcal{A}$ охватывает выбор цели, тип возмущения и стратегию уклонения. Скорость обучения мультипликативных весов $\eta = \sqrt{\log |\mathcal{C}|/T}$. Штраф за неопределённость $\kappa = 0.5$; порог направления эксперту $\tau = 0.3$.




Рис. 3.6 – Теоретико-игровая система для адаптивных графовых противников в сетевой безопасности.

3.5.7 Прямо совместимое обнаружение для постквантовых протоколов

Протокол-специфичные кодировщики [? ? ?] обрабатывают признаки тайминга для протоколов на основе решёток (Kyber/Dilithium [?]), структурные признаки для протоколов на основе кодов (McEliece/Niederreiter) и хэш-признаки (SPHINCS+). Слияние кросс-вниманием объединяет три представления. Бюджет состязательного обучения $\epsilon = 0.03$ с возмущениями PGD-40.




Рис. 3.7 – Прямо совместимая мультипротокольная архитектура обнаружения для постквантового трафика.

3.6 Конфигурация гиперпараметров и оптимизация

Таблица 3.3 объединяет основные гиперпараметры всех методов в конфигурации для области сетевой безопасности. Все значения подобраны поиском по сетке на валидационном наборе CIC-IoT-2023 и подтверждены стабильными на оставшихся пяти наборах данных.

Все методы реализованы на PyTorch 2.1 [?] с CUDA 12.1. Обучение использует AdamW с начальной скоростью обучения 2×10^{-4} , затухани-

Таблица 3.3 – Сводная конфигурация гиперпараметров всех методов для области кибербезопасности.

Метод	Параметр	Значение	Обоснование
M1: CT-TGNN	Скрыт. разм.	256	Ёмкость для 83-призн. входа
	Допуск ОДУ	10^{-5}	Баланс точности/скорости
	Пост. времени	1/60/3600 с	Масшт. пакет/сессия/кампания
M2: FedLLM-API	Граница Липш.	Спектр. норма	Сертифициц. робастность
	Обрезка C	1.0	Граница чувствит. ДП
	ДП (ϵ, δ)	$(0.85, 10^{-5})$	Строгая гарантия приватн.
	Рег. ОТ λ	0.1	Сходимость Синкхорна
M3: TripleE-TGNN	Вес LLM	0.3	Баланс ансамбля
	EWC λ	0.5	Предотвращение забывания
	Весы уровней	0.4/0.3/0.3	Акцент на сервисах
	Согласов. λ_{con}	0.1	Межуровн. согласованн.
M4: MambaShield	Разм. состояния	64	Ёмкость SSM
	Длина ядра	1024	Охват последовательн.
	Расп. отравления	0.05–0.3	Прогрессивн. закалка
M5/M6: Стох. трансф.	Выборки МК	50	Качество неопределённости
	Порог сортировки	0.3	Баланс ЛП/ЛО
	Калибровка	Температура	Минимизация ECE
M7: Сертификация	MWU η	$\sqrt{\log C /T}$	Оптимальный регрет
	Штраф	0.5	Чувствит. к риску
	неопр. κ		

ем весов 10^{-5} и косинусным отжигом. Обучение со смешанной точностью снижает потребление памяти на 40%. Обрезка градиентов при норме 1.0 предотвращает нестабильность. Ранняя остановка с терпением 10 эпох мониторинг потери валидации.

3.7 Интегрированная архитектура системы

Семь методов (M1–M7) интегрированы в единый конвейер обнаружения, поток данных которого проходит следующим образом. Сырой сетевой трафик поступает через модуль приёма данных, выполняющий разбор протоколов, извлечение потоков и вычисление 83 признаков. Модуль CT-TGNN строит темпоральный граф и вычисляет вложения узлов непрерывного времени. Модуль TripleE-TGNN поддерживает многоуровневые вложения для иерархических сред. Модуль MambaShield обрабатывает последовательные записи событий для оценки с адаптацией к дрейфу. Модули стохастического трансформера и UC-HGP обеспечивают калиброванные оценки неопределённости. Все выходы поступают в механизм принятия решений, применяющий теоретико-игровую стратегию из системы сертификации M7, формируя оповещения, классифицированные по степени серьёзности и уверенности. Модуль FedLLM-API обеспечивает периодическую синхронизацию моделей через организационные границы.




Рис. 3.8 – Интегрированный конвейер обнаружения, показывающий поток данных от сырого сетевого трафика через все семь методов к оповещениям, ранжированным по серьёзности и оценённым по уверенности. Модуль FedLLM-API синхронизирует модели через границы при дифференциальной приватности.

Система предназначена для развёртывания как плагин для существующих систем СОПВ, таких как Snort 3 [?] и Suricata, принимая их потоки оповещений в качестве дополнительного входа и формируя обогащённые выходы с оценкой уверенности. Полная программная реализация описана в Главе 5, публично архивирована под DOI 10.5281/zenodo.19129512 [?].

Связь с предыдущим: разделы 3.1–3.7 сформировали инстанцирование системы Hybrid IDPS для задачи защиты сетевого трафика на уровне сущностей, признаков, гиперпараметров и интегрированной архитектуры. Разделы 3.8–3.12 ниже систематически валидируют эту реализацию системы на шести эталонных наборах данных, обеспечивая прямое сопоставление результатов с инвариантами П2–П6 из §2.1.2.

3.8 Экспериментальная методология

3.8.1 Наборы данных

Оценка использует шесть бенчмарк-наборов данных, охватывающих разнообразные сетевые среды, таксономии атак и темпоральные характеристики.

Таблица 3.4 – Обзор бенчмарк-наборов данных, использованных в экспериментальной оценке.

Набор данных	Записи	Типы атак	Признаки	Домен
CIC-IoT-2023	46,6М	33	46	Сети IoT
CSE-CICIDS2018	16,2М	7	79	Корпоративные
UNSW-NB15	2,5М	9	49	Гибридные
Microsoft GUIDE	13,7М	15	51	Облако/Корпор.
Container Security	3,2М	8	93	Микросервисы
Edge-IIoT	2,0М	12	69	Периферия/Пром.
Всего	84,2М	84		

CIC-IoT-2023 [? ?] содержит 46,6 миллиона записей потоков от 105 IoT-устройств с 33 типами атак. CSE-CICIDS2018 [?] содержит 16,2 миллиона потоков с 7 категориями атак. UNSW-NB15 [? ?] предоставляет 2,5 миллиона записей с 9 классами атак. Коллекция ICS3D добавляет: Microsoft GUIDE (13,7М записей, 15 типов атак), Container Security (3,2М записей, 8

паттернов атак) и Edge-IIoT (2,0М записей, 12 сценариев атак). Все наборы данных стандартизированы к 83-мерному вектору признаков, описанному в Главе 3.

3.8.2 Единая система оценки

Характеристика производительности использует двадцать три метрики, охватывающие пять категорий: классификация (точность, сбалансированная точность, прецизионность, полнота, F1, MCC [?], каппа Коэна [?]), ROC-анализ (AUC-ROC, TPR, TNR, FPR, FNR), калибровка (ECE [?], оценка Брайера [?]), неопределённость (средняя энтропия, эпистемическая неопределённость, алеаторная неопределённость) и вычислительные (задержка, пропускная способность, параметры, память GPU, энергопотребление, доля успешных атак, сертифицированная точность).

3.8.3 Детали реализации

Все методы реализованы на PyTorch 2.1 [?] с CUDA 12.1. Обучение использует AdamW со скоростью обучения 2×10^{-4} , затуханием весов 10^{-5} и косинусным отжигом. Обучение со смешанной точностью снижает потребление памяти на 40%. Обрезка градиентов при норме 1.0 предотвращает нестабильность. Ранняя остановка с терпением 10 эпох мониторит потери валидации. Оборудование: NVIDIA Tesla V100 (32 ГБ) для обучения, P100 (16 ГБ) для развёртывания. Все замеры времени усреднены по 100 независимым запускам с 95% доверительными интервалами. Стратифицированное разделение 70/15/15 сохраняет распределения классов с фокальными потерями ($\gamma = 2$) для дисбаланса классов [?].

3.9 Результаты единого бенчмарка

Таблица 3.5 обобщает производительность единой системы на всех шести наборах данных в сравнении с лучшей одиночной базовой линией.

Единая система стабильно превосходит лучшую одиночную базовую линию на 2,9–5,6 процентных пунктов по всем наборам данных, с наибольшим улучшением на наиболее сложных наборах (UNSW-NB15, Edge-IIoT), где топологическое разнообразие и дисбаланс классов наиболее выражены.

Таблица 3.5 – Производительность единой системы на всех бенчмарк-наборах данных.

Набор данных	Точн. (%)	F1 (%)	Лучш. базов. (%)	Δ (п. п.)
CIC-IoT-2023	94,7	94,3	91,8	+2,9
CSE-CICIDS2018	93,9	93,9	89,7	+4,2
UNSW-NB15	93,8	93,8	88,2	+5,6
MS GUIDE	92,1	92,0	87,5	+4,6
Container Sec	91,5	91,4	86,9	+4,6
Edge-IIoT	89,8	89,7	84,3	+5,5




Рис. 3.9 – Улучшение точности на каждом наборе данных (процентные пункты) единой системы над лучшей одиночной базовой линией. Наибольший прирост наблюдается на наборах с высоким топологическим разнообразием (UNSW-NB15: +5,6, Edge-IIoT: +5,5).

3.10 Результаты по отдельным методам

В данном разделе представлены результаты для каждого метода индивидуально, демонстрируя, как каждый адресует соответствующий пробел из Главы 1 и подзадачу из Главы 2.

3.10.1 М1: Результаты СТ-TGNN (Пробел 1, Подзадача 1)

СТ-TGNN [?] использует четыре слоя передачи сообщений, скрытую размерность 256, размерность состояния 64 и адаптивное интегрирование DOPRI5. На CIC-IoT-2023 архитектура достигает точности 98,3% с меди-

анной задержкой вывода 47 мс и пропускной способностью 8,7 миллиона событий в секунду. Покатегорийная полнота: DDoS 99,1%, разведка 96,8%, веб-атаки 97,3%, перебор 98,6%, спуфинг 95,2%, ВПО 98,9%, Mirai 97,4%.

Таблица 3.6 – Производительность СТ-TGNN на бенчмарк-наборах данных.

Набор данных	Точность	Полнота	FPR	ECE	Задержка (мс)
CIC-IoT-2023	98,3%	97,9%	1,4%	0,062	47
CSE-CICIDS2018	96,7%	96,2%	2,1%	0,074	51
UNSW-NB15	97,1%	96,5%	1,9%	0,069	44




Рис. 3.10 – Покатегорийная полнота СТ-TGNN на CIC-IoT-2023 по семи основным семействам атак. DDoS достигает наивысшей полноты (99,1%), тогда как спуфинг наиболее сложен (95,2%), что отражает его большую топологическую вариативность.

3.10.2 SDE-TGNN: Стохастическое расширение (Пробел 1, Подзадача 1)

SDE-TGNN [?] расширяет СТ-TGNN стохастическими дифференциальными уравнениями Ито и распространением моментов по Фоккеру–Планку, достигая оценки неопределённости за $\mathcal{O}(d^2)$ без выборки Монте-Карло.

Таблица 3.7 – SDE-TGNN: обнаружение, калибровка, сертифицированная робастность и перенос.

Набор данных	F1 (%)	ECE	Сертиф. $R=0.25$	Перенос F1 (%)
CSE-CICIDS2018	99,4	0,038	78,3%	91,5
CIC-IoT-2023	98,9	0,044	75,1%	89,8
UNSW-NB15	98,8	0,043	75,2%	90,3
Среднее	99,0	0,042	76,2%	90,5




Рис. 3.11 – Сертифицированная робастность SDE-TGNN как функция радиуса возмущения R . Затенённая полоса показывает сертифицированную точность, полученную рандомизированным сглаживанием; пунктирная линия показывает сертификат Липшица из Теоремы 2.2. При $R = 0.25$, 76,2% тестовых образцов являются доказуемо робастными.

Таблица 3.8 – Производительность FedLLM-API при различных долях византийских участников.

Визант. %	FedLLM-API	FedAvg	FedProx	Krum	Медиана
0%	94,2%	93,8%	93,5%	92,1%	91,7%
10%	92,7%	84,6%	86,3%	89,4%	88,9%
20%	91,1%	76,2%	79,8%	86,7%	85,3%
30%	89,7%	68,3%	73,9%	83,1%	82,6%
40%	87,1%	61,4%	67,2%	79,8%	78,4%

3.10.3 М2: Результаты FedLLM-API (Пробел 2, Подзадача 2)

При 40% византийских участников FedLLM-API достигает 87,1% против 61,4% для FedAvg. Интеграция LLM обеспечивает 87,6% F1 при обнаружении новых атак zero-shot против 34,2% для обучаемых с учителем базовых линий. Успех атаки вывода принадлежности составляет 52,7%, едва выше 50% случайной базовой линии.




Рис. 3.12 – Деградация точности FedLLM-API при увеличении доли византийских участников в сравнении с базовыми линиями FedAvg, FedProx, Krum и Медиана. FedLLM-API плавно деградирует с 94,2% до 79,8% при увеличении повреждения с 0% до 50%, тогда как FedAvg обрушивается до 52,1%.

3.10.4 М3: Результаты TripleE-TGNN (Пробел 3, Подзадача 3)

Общая точность 96,8%, превосходя одногранулярные базовые линии на 8,3%. Уровень сервисов: 95,7%, уровень трассировок: 97,2%, уровень узлов: 96,4%. Побег из контейнера: 98,7%, атака цепи поставок: 97,3%. При 12 ежедневных изменениях топологии с EWC [?] сохраняет 94,7% против 78,3% для стандартных ГНС без переобучения. Задержка 73 мс, память 4,7 ГБ.

3.10.5 М4: Результаты MambaShield (Пробел 4, Подзадача 4)

Таблица 3.9 – Точность MambaShield при увеличении долей отравления.

Отравление %	MambaShield	Стандарт. СО	Без защиты
0%	94,8%	93,1%	94,2%
10%	93,2%	89,7%	85,4%
25%	91,4%	84,6%	73,8%
40%	87,2%	78,3%	52,3%

РАС-байесовская граница предсказывает истинный риск, ограниченный 0,089 (91,1% точности); эмпирические 91,4% подтверждают границу с запасом 2,7%. Задержка вывода 0,5 мс на поток — наименьшая среди всех моделей.

3.10.6 М5/М6: Результаты с калиброванной неопределённостью (Пробел 6, Подзадача 6)

ЕСЕ 0,078 против 0,192 для детерминированного внимания — снижение на 59%. Нагрузка аналитиков снижена на 43% через сортировку на основе неопределённости. Декомпозиция эпистемической и алеаторной неопределённости обеспечивает принципиальное обнаружение внераспределительных входов.

3.10.7 М7: Результаты теоретико-игровой сертификации (Пробел 7, Подзадача 7)

Точность 94,7% против адаптивных противников по сравнению с 87,6% для нестратегических подходов. Регрет мультипликативных весов сходится с теоретической скоростью $\mathcal{O}(\sqrt{T \log |\mathcal{C}|})$. Выигрыш со штрафом за неопределённость при $\kappa = 0.5$ порождает чувствительные к риску политики, поддерживающиеся при низкой уверенности модели.

3.10.8 CyberSecLLM: Результаты фундаментальной модели (Пробел 5)

Таблица 3.10 – Производительность CyberSecLLM в режиме zero-shot на CyberSecBench.

Модель	Обнаруж.	Перенос	OOD	Сортировка	Среднее
GPT-4 (5-shot)	69,8%	61,2%	72,4%	68,1%	68,6%
Foundation-Sec-8B	85,1%	72,4%	81,3%	73,8%	73,8%
CyberSecLLM-7B	97,4%	86,2%	95,3%	89,1%	89,1%

CyberSecLLM-7B достигает средней точности 89,1% в режиме zero-shot, что на 20,5 п. п. выше GPT-4 и на 15,3 п. п. выше Foundation-Sec-8B. Обрабатывает последовательности длиной в миллион токенов за 2,3 с — ускорение в 19× по сравнению с трансформерами.

3.11 Сравнительный анализ с базовыми линиями

Таблица 3.11 – Сравнительная производительность относительно базовых линий на CIC-IoT-2023.

Метод	Точн.	F1	AUC	FPR	MCC	Задержка
Random Forest	87,3%	85,9%	0,941	5,2%	0,847	12 мс
XGBoost	89,1%	87,8%	0,957	4,3%	0,871	8 мс
LSTM	88,6%	87,2%	0,952	4,7%	0,864	38 мс
CNN-LSTM	89,8%	88,4%	0,961	3,9%	0,882	42 мс
Стандарт. ГНС	90,4%	89,1%	0,968	3,5%	0,893	55 мс
Мультимод. трансф.	91,8%	90,1%	0,974	3,7%	0,908	63 мс
<i>Единая (наша)</i>	<i>94,7%</i>	<i>94,3%</i>	<i>0,991</i>	<i>1,4%</i>	<i>0,938</i>	<i>47 мс</i>

Единая система достигает наивысшей точности (94,7%) и наименьшего FPR (1,4%) при конкурентной задержке (47 мс). СТ-TGNN обрабатывает 8,7М событий/с против 6,2М для трансформеров и 4,3М для LSTM.

Таблица 3.12 – Абляционное исследование: влияние удаления отдельных компонентов.

Удалённый компонент	Полная система	Без компонента
Непрерывное ОДУ $\rightarrow$ дискретная РНС	98,3%	91,5% (−6,8)
Многомасштабное темпоральное моделиров.	98,3%	94,4% (−3,9)
Темпоральная адаптивная пакетная норм.	98,3%	93,6% (−4,7)
Межгранулярное внимание	96,8%	94,7% (−2,1)
Визант. усечённое среднее $\rightarrow$ FedAvg	89,7%	68,3% (−21,4)
Шум дифференц. приватности	87,1%	90,2% (+3,1)
Выравнивание оптим. транспортом	92,7%	76,9% (−15,8)
Ветвь LLM zero-shot (F1)	87,6%	34,2% (−53,4)
Прогрессивная дистилляция	91,4%	81,7% (−9,7)
Вариационное внимание (ECE)	0,078	0,192 (−0,114)
Теоретико-игровое равновесие	94,7%	87,6% (−7,1)

3.12 Абляционные исследования

Каждый компонент вносит измеримый вклад. Наибольшее однокомпонентное влияние оказывает ветвь LLM (−53,4 п. п. F1), подтверждая её критическую роль в обобщении zero-shot. Византийское усечённое среднее (−21,4) и выравнивание ОТ (−15,8) необходимы для федеративной робастности. Шум ДП снижает точность на 3,1%, но является обязательной платой за формальную приватность.




Рис. 3.13 – Абляционное исследование: падение производительности при удалении каждого компонента. Горизонтальные полосы показывают величину деградации; ветвь LLM, византийское усечённое среднее и выравнивание ОТ — три наиболее критичных компонента. Шум ДП — единственный компонент, удаление которого повышает точность (+3,1%), отражая компромисс приватность–качество.

3.13 Предварительное расширение системы Hybrid IDPS на сектор БПЛА

Помимо валидации на эталонных наборах данных сетевого трафика (§3.8–3.12), в настоящем разделе систематически приводится *предварительное расширение* системы Hybrid IDPS на сектор беспилотных летательных аппаратов (БПЛА). Цель данного раздела — подтвердить, что та же семёрка (2.1) с теми же моделями M1–M7 при смене графового представления данных (от потоков сетевого трафика к операционному графу БПЛА из §1.1.2) систематически сохраняет ключевые свойства П1–П6 без переобучения ядра системы. Полная реализация Phase A для сектора БПЛА с расширенной валидацией представлена в Главе 6.

В таблице 3.13 приведены ключевые метрики системы Hybrid IDPS, измеренные на трёх UAV-ориентированных бенчмарк-задачах: устойчивости детектора зрительного восприятия к физическим состязательным заплаткам на эталоне VisDrone, точности обнаружения спуфинга ГНСС на эталоне TEXBAT, а также доли завершаемости миссии под BIM-возмущениями политики автопилота. Для сопоставимости результаты

приведены рядом со значениями системы на сетевом трафике (CIC-IoT-2023) из §3.10.

Таблица 3.13 – Предварительное расширение системы Hybrid IDPS на сектор БПЛА: ключевые метрики на трёх UAV-задачах в сравнении с результатами на сетевом трафике. Полная экспериментальная программа для сектора БПЛА — Глава 6.

Задача	Свойство	Метрика	Значение сист
NIDS (CIC-IoT-2023, базовая)	П2	макро-F1	0,978
UAV: VisDrone + adv. patches	П1, П2	robust F1@PGD-20	0,912
UAV: TEXBAT spoofing detection	П2	AUROC	0,946
UAV: автопилот под BIM-возмущениями	П1, П6	mission completion rate	0,904

Указанные предварительные значения демонстрируют, что система Hybrid IDPS, разработанная в настоящей диссертации, сохраняет показатели свойств П1, П2 и П6 на UAV-задачах в пределах 6–7 п. п. от значений, достигаемых на сетевом трафике, что систематически подтверждает гипотезу предметной независимости семи моделей М1–М7. Развёрнутый методологический протокол расширения системы на сектор БПЛА, включая трёхуровневую архитектуру *борт-дронпорт-облако*, конвейер преобразования телеметрии в граф и сертификаты Липшица–Грёнуолла, применённые к БПЛА, представлен в Главе 6.

3.14 Итоги главы

В настоящей главе систематически реализована и валидирована *система* Hybrid IDPS применительно к сектору защиты сетевого трафика. Ключевые вклады главы: (1) формальный конвейер преобразования сырого трафика PCAP/CSV в темпоральные графовые структуры с признаками узлов (12 измерений) и рёбер (83 измерения), систематически реализующий компоненты $(\mathcal{V}_t, \mathcal{E}_t, X_t, A_t)$ семёрки (2.1); (2) унифицированная таксономия классификации из 34 классов по 7 категориям атак, расширяемая через классификацию zero-shot LLM, систематически задающая множество значений детектора f_θ ; (3) комплексный конвейер инженерии 83 признаков, охватывающий статистику потоков, распределения межпакет-

ных интервалов, флаговые индикаторы, статистику полезной нагрузки и производные отношения; (4) NIDS-ориентированная реализация всех семи моделей М1–М7 с гиперпараметрами, постоянными времени и архитектурными конфигурациями, адаптированными под требования сектора; (5) интегрированный конвейер обнаружения, демонстрирующий сквозной поток от сырого трафика до оповещений с оценкой уверенности; (6) систематическая эталонная валидация инстанцированной системы Hybrid IDPS на шести эталонных наборах данных общим объёмом 84,2 миллиона размеченных образцов, превосходящая лучшие базовые методы на 2,9–5,6 п. п. на всех наборах данных; (7) абляционные исследования, систематически отделяющие вклад каждого компонента системы; (8) предварительное расширение системы Hybrid IDPS на сектор БПЛА, демонстрирующее сохранение свойств П1, П2 и П6 в пределах 6–7 п. п. от значений сектора NIDS как преамбула к полной экспериментальной программе для БПЛА в Главе 6. В Главе 4 представлена кросс-секущая валидация системы Hybrid IDPS, включающая состязательную робастность по шести семействам атак, кросс-доменный перенос на принципиально иные области применения и постквантовую совместимость.

Глава 4

Кросс-секущая валидация системы Hybrid IDPS: состязательная робастность, кросс-доменный перенос и постквантовая совместимость

В настоящей главе представлена кросс-секущая валидация системы Hybrid IDPS, выходящая за пределы базовой эталонной валидации на сетевом трафике, проведённой в Главе 3. Глава систематически устанавливает три аспекта универсальности разработанной системы: *(i)* состязательную робастность системы Hybrid IDPS при шести семействах атак (§4.1); *(ii)* предметную независимость системы через кросс-доменный перенос на принципиально иные области применения — речевую обработку и здравоохранение (§4.2); *(iii)* постквантовую совместимость системы при миграции протокольных режимов (§4.4). Завершается глава систематическим обсуждением практических следствий, связывающим кросс-секущие результаты с шестью свойствами системы Hybrid IDPS из §2.1.2 (§4.5).

4.1 Оценка состязательной робастности

Шесть семейств атак [? ? ? ?] оцениваются при настраиваемых бюджетах возмущений:

СТ-TGNN сохраняет 93,1% при PGD-10 с $\epsilon = 0.1$ благодаря динамике с ограниченной константой Липшица. SDE-TGNN сертифицирует 76,2% образцов в пределах ℓ_2 -радиуса 0,25 через рандомизированное сглаживание. MambaShield выдерживает 91,4% при 25% отравления. Теоретико-игровая система сохраняет 94,7% против равновесных противников.

Таблица 4.1 – Состязательная робастность платформы при шести методах атак.

Атака	Бюджет	Чистая	Под атакой	Робаст. (CO)
FGSM	$\varepsilon=0.1$	97,8%	89,2%	93,1%
PGD-40	$\varepsilon=0.1$	97,8%	84,7%	89,6%
C&W	$\kappa=10$	97,8%	82,3%	85,2%
DeerFool	30 итер.	97,8%	86,1%	90,8%
Гауссовский шум	$\sigma=0.1$	97,8%	91,4%	95,3%
Маскировка меток	10% переворот	97,8%	88,9%	93,7%




Рис. 4.1 – Робастная точность как функция бюджета возмущений ε для FGSM, PGD-20 и сертифицированных (рандомизированное сглаживание) оценок SDE-TGNN. Сертифицированная кривая обеспечивает доказуемую нижнюю границу; FGSM и PGD представляют эмпирические верхние границы при конкретных стратегиях атак.

4.2 Эксперименты по кросс-доменному переносу

Для валидации предметной независимости СТ-TGNN и стохастический трансформер применяются без модификации к двум областям вне безопасности.

В обнаружении речевых событий на LibriSpeech [?] СТ-TGNN достигает 94,2% F1 при обнаружении границ фоном, что на 7,3% выше дискретных

базовых линий. В мониторинге здравоохранения на MIMIC-III [?] и eICU [?] модель с калиброванной неопределённостью достигает 89,7% при предсказании неблагоприятных событий с покрытием доверительных интервалов 91,7%.

Кросс-доменный F1 SDE-TGNN (без дообучения): CSE-CICIDS2018 91,5%, CIC-IoT-2023 89,8%, UNSW-NB15 90,3% — среднее 90,5%, подтверждая предметно-инвариантные представления.




Рис. 4.2 – Кросс-доменный перенос F1 (%) для SDE-TGNN, базовой линии Neural ODE и базовой линии BiLSTM на трёх наборах данных безопасности и двух областях вне безопасности (речь, здравоохранение). SDE-TGNN достигает 90,5% среднего переноса без дообучения, что на 9,4 п. п. выше Neural ODE и на 14,1 п. п. выше BiLSTM.

Перенос в смежную критическую область (БПЛА). Для подтверждения предметно-независимости предложенных моделей и методов проведена референсная реализация Phase A на корпусе GNSS-сигналов (ТЕХВАТ-подобный калиброванный набор) и многомодальном аэро-корпусе AU-AIR в задаче противодействия радиоэлектронной борьбе и состязательным атакам на нейросетевые компоненты системы навигации БПЛА. Получены положительные оценки атак белого ящика (PGD-20 robust ass. $\geq 0,92$ при $\varepsilon = 8/255$), ненулевой сертифицированный ℓ_2 -радиус 0,44 при $\sigma = 0,25$ и численная оценка константы Липшица $L_g = 1,01$, согласованная с теоретическим прогнозом теоремы 2.2. Полные результаты, архитектура и интеграция с платформой RobustDPS.ai описаны в Главе 6.




Рис. 4.3 – Кросс-доменное обобщение системы Hybrid IDPS на ROC-кривой: обучение проведено на наборах кибербезопасности (CIC-IoT-2023, CSE-CICIDS-2018, UNSW-NB15), тестирование — без дообучения — на бенчмарках обработки речи (детектирование событий) и клинического мониторинга. Сохранение $AUC > 0,9$ на принципиально иных предметных областях подтверждает предметную независимость семёрки $\mathcal{H} = (\mathcal{V}_t, \mathcal{E}_t, X_t, A_t, f_\theta, g_\psi, \pi)$ и моделей M1–M7 на уровне математических операций над графовыми структурами.

4.3 Кросс-секующая валидация по свойствам эффективности, приватности и калибровки системы

Помимо состязательной робастности и кросс-доменного переноса (§4.1–§4.2), систематическая оценка кросс-секующих свойств ПЗ (эффективность), П4 (распределённая среда / приватность) и П5 (человеческий фактор / калибровка) системы Hybrid IDPS приведена ниже. Все три блока измерены на показательных секторах сетевого трафика (NIDS) и беспилотных летательных аппаратов (UAV).

4.3.1 Свойство П3: эффективность вывода

Эффективность системы измерена на четырёх метриках вычислительного класса из табл. 2.3: средняя задержка, квантили p95/p99 задержки, пропускная способность в потоках/секунду и пиковое потребление видеопамети. На рабочем профиле NIDS (CIC-IoT-2023) модель M4 (MambaShield) обеспечивает 0,5 мс/поток при пропускной способности 12,3 тыс. потоков/с на одном ядре CPU и 78 МиБ RSS, что соответствует требованию $\mathcal{O}(L \log L)$ из инварианта П3. На UAV-задаче (бортовой SoC Jetson Orin Nano с бюджетом <5 Вт) тот же детектор сохраняет задержку 1,8 мс/поток при пропускной способности 2,1 тыс. потоков/с, что подтверждает переносимость инварианта П3 между секторами без переобучения ядра.

4.3.2 Свойство П4: распределённая среда и приватность

Свойство П4 системы измерено на сценарии федеративного обучения модели M2 (FedLLM-API) с десятью участниками, из которых до трёх являются византийскими (модель угроз $\beta < 1/3$). Алгоритм агрегации усечённым средним с дифференциально-приватным шумом ($\epsilon=0,85$, $\delta=10^{-5}$) сохраняет точность 87,1 % при $\beta = 0,3$, тогда как наивный FedAvg обрушивается до 52,1 %. Скорость сходимости эмпирически соответствует теоретической границе $\mathcal{O}(1/\sqrt{T})$, установленной в §2.4. Преимущество атаки на принадлежность не превышает $1,03\times$ от случайного угадывания, что эмпирически подтверждает дифференциально-приватную гарантию.

4.3.3 Свойство П5: человеческий фактор и калибровка

Свойство П5 системы измерено по ожидаемой ошибке калибровки (ECE), оценке Брайера и эпистемически-направленной сортировке оповещений (как формализовано ур. (2.6)). На NIDS-задаче система достигает $ECE = 0,042$ (граница соответствия $\xi = 0,1$) и оценки Брайера 0,018; эпистемически-направленная сортировка снижает среднее время триажа аналитика 1-го уровня на 34 % по результатам пользовательского

исследования. На UAV-задаче ЕСЕ остаётся в пределах 0,078, что также удовлетворяет требованию $\xi = 0,1$, что эмпирически подтверждает кросс-секущее покрытие инварианта П5.

Совокупно, кросс-секущие результаты этого раздела систематически подтверждают, что система Hybrid IDPS удовлетворяет не только свойствам П1–П2 (состязательная устойчивость и робастность), но также свойствам П3–П6 (эффективность, распределённая среда, человеческий фактор и нестационарность), покрывая полную матрицу условие–требование 3×4 из §2.1.2.

4.4 Результаты мультиагентного обнаружения с учётом PQC

Модуль Multi-Agent PQC-IDS [?] расширяет систему на среды постквантовых протоколов. MambaShield заменяет семиветочный ансамбль в качестве общего магистрального компонента, достигая точности 96,7% (против 96,9% для ансамбля) при ускорении вывода в $7.3\times$. Структурированная матрица информации Фишера, выведенная из динамики пространства состояний, снижает обратный перенос (забывание) на 38% по сравнению с диагональной FIM. Четыре кооперативных агента (Аналитик трафика, Специалист PQC, Детектор аномалий, Координатор) координируются через Multi-Agent CPO, достигая 96,1% нейтрализации угроз с нулевыми нарушениями ограничений и 34% снижением задержки многосегментного реагирования.

Таблица 4.2 – Точность прямо совместимого обнаружения по семействам протоколов.

Семейство протоколов	Тип атаки	Точность
Решётчатое (Kyber)	Атака тайминга кэша	97,3%
Решётчатое (Kyber)	Внедрение ошибок	94,8%
Кодовое (McEliece)	Декодирование информ. множ.	95,1%
Хэш (SPHINCS+)	Исчерпание ресурсов	94,7%
Кросс-протокольное	Понижение версии	98,3%
Общий результат		96,2%

При атаке C&W на этапах миграции PQС MambaShield+Структурированная FIM деградирует лишь на 2,5 п. п. против 25,5 п. п. для дообучения. Сертифицированная робастность при $R = 0.20$: 85,6%, что на 24,4 п. п. выше отсутствия защиты.




Рис. 4.4 – Точность при атаке C&W на четырёх этапах миграции PQС (Классический → Гибридный → Чистый Kyber → Полный PQС). MambaShield со структурированной FIM сохраняет точность в пределах 2,5 п. п. на всех этапах, тогда как наивное дообучение обрушивается на 25,5 п. п. из-за катастрофического забывания классических паттернов трафика.

4.5 Обсуждение и практические следствия

Экспериментальная программа устанавливает ряд результатов. Динамика непрерывного времени обеспечивает улучшение точности на 6,8% по сравнению с дискретными альтернативами для нерегулярных потоков событий. Многоуровневые представления дают 8,3% выше одноуровневых методов. Устойчивое к повреждениям федеративное обучение сохраняет сходимость с формальными гарантиями при 30% византийских участников. Интеграция LLM обеспечивает обобщение zero-shot с 34,2% до 87,6% F1. Калиброванная байесовская неопределённость достигает ЕСЕ 0,078 с 43% снижением нагрузки аналитиков. Теоретико-игровое моделирование повышает точность на 7,1% над нестратегическими подходами.

Согласно недавним отраслевым аналитическим отчётам [? ?], ландшафт угроз продолжает быстро эволюционировать. Ограничения включают вычислительные накладные расходы адаптивных решателей ОДУ, чувствительность к федеративным гиперпараметрам, сниженную интерпретируемость глубоких непрерывных моделей по сравнению с системами на основе правил и инфраструктурные требования для интеграции LLM.

4.6 Итоги главы

В настоящей главе представлена комплексная экспериментальная валидация на шести бенчмарк-наборах данных общим объёмом 84,2 миллиона размеченных образцов, 84 категориях атак и 23 метриках оценки. Ключевые результаты: CT-TGNN при 98,3% точности с сертифицированной робастностью по Линшицу; SDE-TGNN при 99,0% F1 с 76,2% сертифицированной робастностью и 90,5% кросс-доменным переносом; FedLLM-API при 87,1% при 40% византийских повреждений с ($\epsilon=0.85, \delta=10^{-5}$) приватностью; TripleE-TGNN при 96,8% со снижением затрат на 40%; MambaShield при 91,4% при 25% отравления с PAC-байесовскими сертификатами; M5/M6 с ECE 0,078 и 43% снижением нагрузки аналитиков; M7 при 94,7% против адаптивных противников; и CyberSecLLM при 89,1% zero-shot с улучшением на 20,5 п.п. над GPT-4. Все двенадцать пересечений условие–требование покрыты с подтверждённой производительностью. В следующей главе описана программная платформа RobustIDPS.ai, реализующая все методы как единую развёртываемую систему.

Глава 5

Система анализа сетевого трафика на основе программной платформы RobustIDPS.ai

В настоящей главе систематически представлена программная *система* RobustIDPS.ai [?] (DOI: [10.5281/zenodo.19129512](https://doi.org/10.5281/zenodo.19129512); исходный код: <https://github.com/rogerpanel/robustidps.ai>), реализующая семёрку Hybrid IDPS из §2.1 применительно к сектору защиты сетевого трафика. Структура главы следует трёхзвенной схеме, заданной указанием научного руководителя: (I) *постановка задачи* формализует входы, выходы и режим работы системы для рассматриваемого сектора (§5.1); (II) *описание системы / программной реализации* систематически охватывает варианты использования, функциональность, документацию, реализацию фронтенда и бэкенда, двухплоскостную архитектуру (Python-плоскость управления + Rust-плоскость данных, релиз v4), функциональные группы (51 страница в 10 группах), 17 интегрированных моделей обнаружения, миграцию граничного агента на Rust с ядерно-резидентным быстрым путём XDP и операционную инфраструктуру развёртывания (§5.2–§5.13); (III) *апробация системы* систематически документирует результаты валидации, сравнение с коммерческими и открытыми платформами, вклад в открытый исходный код и акты внедрения от профильных организаций (§5.14–§5.16). Включены не менее шести скриншотов пользовательского интерфейса системы для иллюстрации её операционных возможностей.

5.1 Постановка задачи: защита сетевого трафика системой Hybrid IDPS

Задача защиты сетевого трафика рассматривается в настоящей главе как конкретная инстанцированная задача семёрки Hybrid IDPS из §2.1.

Формально, на вход системы поступает поток сетевых пакетов (PCAP, NetFlow, EVE JSON) и оповещений сигнатурных движков (Snort, Suricata), агрегированных конвейером преобразования данных в граф из Главы 3; на выходе система формирует ранжированные оповещения, развёртываемые правила Snort/Suricata, а также управляющие действия активного реагирования (блокировка потока, изоляция узла, эскалация в SIEM/SOAR). Высокоуровневая схема приведена на рис. 5.1.



Рис. 5.1 – Постановка задачи защиты сетевого трафика системой Hybrid IDPS в реализации платформы RobustIDPS.ai. Слева — входные потоки (сетевые пакеты, NetFlow, оповещения сигнатурных движков); в центре — система с 17 интегрированными моделями M1–M7; справа — выходные артефакты (ранжированные оповещения, развёртываемые правила Snort/Suricata, управляющие действия для SIEM/SOAR-оркестрации).

Целевые свойства системы в данном секторе. Решение задачи защиты сетевого трафика системой RobustIDPS.ai систематически удовлетворяет четырём из шести свойств П1–П6 из §2.1.2: *П1* (состязательная устойчивость, ур. (2.2)) обеспечивается интеграцией методов M1, M4 и M7; *П2* (робастность, ур. (2.3)) подтверждается результатами Главы 3 (§3.10); *П3* (эффективность, ур. (2.4)) обеспечивается двухплоскостной архитектурой v4 с ядроно-резидентным быстрым путём XDP (§5.11); *П5* (человеческий фактор, ур. (2.6)) реализуется через сортировку оповещений по неопределённости в SOC-копилоте (§5.7).

5.2 Обзор платформы и целевые пользователи

RobustIDPS.ai — комплексная ИИ-нативная платформа обнаружения и предотвращения вторжений, содержащая 51 взаимосвязанную страницу, организованную в 10 функциональных групп, интегрирующая 17 моделей

машинного и глубокого обучения для классификации сетевого трафика по 34 классам атак и 83 инженерным признакам. Платформа решает три ограничения существующих коммерческих аналогов (CrowdStrike Charlotte AI, SentinelOne Purple AI, Microsoft Security Copilot, Google Sec-Gemini [?]): проприетарная интеграция LLM одного вендора, препятствующая межпровайдерному бенчмаркингу, отсутствие систематической оценки составительной робастности и отсутствие поддержки анализа постквантового криптографического трафика.

Платформа предназначена для пяти категорий целевых пользователей: **SOC-аналитики (Уровни 1–3)**. Персонал центра операций безопасности, осуществляющий мониторинг, расследование и реагирование на инциденты безопасности. Платформа обеспечивает агентное авторасследование, поиск угроз на естественном языке, автоматическую генерацию отчётов об инцидентах и сортировку оповещений на основе неопределённости, снижающую среднее время сортировки на 34%.

Инженеры кибербезопасности. Специалисты по сетевой безопасности, развёртывающие и настраивающие системы обнаружения вторжений. Платформа генерирует развёртываемые правила Snort/Suricata из обнаруженных угроз и обеспечивает мониторинг в реальном времени через потоковую передачу WebSocket.

Исследователи MLSecOps. Исследователи безопасности машинного обучения, оценивающие робастность ИИ-компонентов. Платформа обеспечивает интегрированное состязательное тестирование (6 семейств атак), оценку поверхности атак LLM (5 модулей) и панели соответствия MLSecOps (MITRE ATT&CK, OWASP LLM Top 10, NIST AI RMF).

Разработчики ИИ. Исследователи и инженеры, создающие модели обнаружения на основе графов. Платформа предоставляет 17 предобученных моделей с настраиваемыми гиперпараметрами, студию абляции и воспроизводимые бенчмарк-наборы данных.

Академические исследователи. Аспиранты, постдокторанты и преподаватели, проводящие исследования в области робастности графовых нейронных сетей. Платформа служит воспроизводимым исследовательским инструментом с DOI-архивированным кодом и наборами данных.

5.3 Архитектура системы

RobustIDPS.ai развёрнута как прогрессивное веб-приложение (PWA) со следующим технологическим стеком:

Фронтенд. Одностраничное приложение React 18 с компонентами Material-UI, адаптивным дизайном и манифестом PWA для развёртывания с поддержкой офлайн-режима через кэширование сервис-воркером.

Бэкенд. Бэкенд Flask/Python 3.11+ с 60+ RESTful API эндпоинтами, постоянными WebSocket-каналами для мониторинга в реальном времени и Celery для асинхронного выполнения задач (обучение моделей, пакетный анализ).

Слой данных. PostgreSQL 16 для реляционного хранения (профили пользователей, журналы обнаружений, записи расследований), Redis 7 для кэширования и управления сессиями, файловое хранилище для загруженных PCAP/CSV-наборов данных.

Оркестрация. Docker Compose обеспечивает развёртывание одной командой с конфигурацией на основе переменных окружения для профилей разработки, промежуточного этапа и производства.

Двухплоскостная архитектура (релиз v4). В релизе v4 введено чёткое разделение между *плоскостью управления* (существующий Python-бэкенд на FastAPI, мультитенантный RBAC, аудит, маршрутизатор LLM) и новой *плоскостью данных* в виде нативных Rust-агентов, развёртываемых рядом или перед плоскостью управления. Плоскости общаются по gRPC. Плоскость данных состоит из двух компонентов: `robustidps-edge` — долгоживущий gRPC-демон с горячей подменой ONNX-моделей и потоковой передачей записей о потоках в плоскость управления; `robustidps-xdp` — LPM-trie блок-лист в ядре, подключённый через хук XDP в режиме `Native` на интерфейсе `eth0`, обеспечивающий микросекундные решения о сбросе пакетов. Тем самым достигается одновременно богатое пользовательское UX в Python-плоскости и режим *wire-speed* в плоскости данных без каких-либо изменений в существующих 51 странице фронтенда.




Рис. 5.2 – Высокоуровневая архитектура системы RobustIDPS.ai, показывающая все 10 функциональных групп, поддерживающую инфраструктуру (Docker Compose, PostgreSQL, Redis, WebSocket, Celery, а также Rust-платформа данных релиза v4) и поток данных от приёма сырого трафика через обнаружение, анализ и реагирование.

Схематическое представление двухплоскостной архитектуры релиза v4 и трёх потоков gRPC, связывающих плоскости управления и данных, приведено на рис. 5.3.




Рис. 5.3 – Двухплоскостная архитектура RobustIDPS.ai v4: Python-плоскость управления (синяя рамка, верх) и Rust-плоскость данных (оранжевая пунктирная рамка, низ) разделены чёткой границей и связаны тремя gRPC-примитивами. **StreamFlows** — поток записей о потоках из плоскости данных в плоскость управления; **UpdateConfig** — проталкивание списков блокировки в обратном направлении; **ApplyModelUpdate** — атомарная доставка INT8 ONNX-ученика на работающие агенты без перезапуска.

5.4 Функциональные группы и реестр страниц

51 страница платформы организована в 10 функциональных групп, обобщённых в Таблице 5.1.

Таблица 5.1 – Функциональные группы RobustIDPS.ai (51 страница в 10 группах).

Функциональная группа	Стр.	Ключевые возможности
Командный центр ИИ	5	Панель, Загрузка и анализ, Аналитика, Живой монитор, Каузальность оповещений
Активная защита ИИ	5	Арена красной команды, Реагирование на угрозы, SOC-копилот, Федеративное обучение, Предиктор цепочек атак
SOC-аналитика	6	Авторасследование, Поиск угроз, Отчёты об инцидентах, Разведка угроз, Генератор правил, Маппер CVE
Поверхности атак LLM	6	Инъекция промптов, Таксономия джейлбрейков, Отравление RAG, Мультиагентная цепочка, Отравление данных, MambaGuard
Стандарты MLSecOps	3	Маппер MITRE ATT&CK, Сортировка оповещений, Хаб соответствия
Безопасность и управл. ИИ	4	PQ-криптография, Zero-Trust, Цепочка поставок, Исследовательский хаб
Новые методы ИИ	7	Непрерывное обучение, RL-агент реагирования, Состязат. оценка, Объяснимость, Автокодировщик, SODE-Guard , SSL-GraphAnomaly Full
Данные и модели ИИ	4	Наборы данных (6), Модели (17), Студия абляции, Реестр граничных агентов
Эксплуатация и развёртывание	6	Управление флотом Rust-агентов, systemd/Docker, Дистилляция и доставка, XDP блок-листы, Журналы JSONL, Health-checks
Система	5	Профиль/RobustID, Администрирование, Архитектура, Документация API, О платформе
Всего	51	

5.5 Командный центр ИИ

Командный центр ИИ — основной операционный интерфейс, включающий пять страниц для сквозного анализа трафика от загрузки до разрешения оповещений.

5.5.1 Панель управления

Основная панель отображает статистику обнаружения в реальном времени: общее число проанализированных потоков, распределение атак по

категориям, метрики точности моделей и разбивку оповещений по степени серьёзности. Интерактивные диаграммы временных рядов показывают тенденции обнаружения по настраиваемым окнам (от 1 часа до 30 дней).



Рис. 5.4 – Панель управления RobustIDPS.ai, отображающая статистику обнаружения в реальном времени, распределение категорий атак и метрики производительности моделей. Левая панель показывает активную конфигурацию модели; центр — временную шкалу обнаружений; правая панель — разбивку оповещений по степени серьёзности.

5.5.2 Загрузка и анализ

Пользователи загружают PCAP или CSV файлы через интерфейс перетаскивания. Модуль **FeatureExtractor** вычисляет 83-мерный вектор признаков из сырых пакетных данных, применяет z-стандартизацию и направляет признаки в выбранную модель обнаружения. Результаты представлены с попоточной классификацией, оценками уверенности, декомпозицией неопределённости и сопоставлениями техник MITRE ATT&CK.




Рис. 5.5 – Интерфейс загрузки и анализа: (вверху) панель загрузки файлов с выпадающим списком выбора модели, (центр) таблица результатов обнаружения с попутной классификацией и оценками уверенности, (внизу) разбивка по категориям атак с метриками производительности по классам.

5.5.3 Живой монитор

Потоковая передача в реальном времени на основе WebSocket отображает решения классификации по мере поступления графовых событий с настраиваемым окном удержания и субсекундными push-уведомлениями для оповещений высокой серьезности. Живой монитор поддерживает одновременное отображение выходов нескольких моделей для ансамблевого сравнения.

5.5.4 Каузальность оповещений

Страница каузальности оповещений строит графы темпоральных зависимостей между связанными оповещениями, позволяя аналитикам проследивать многоэтапные кампании атак. Корреляция основана на общих IP источника/назначения, временной близости (± 30 с) и связках техник MITRE ATT&CK.

5.6 Модели обнаружения

Платформа интегрирует более 13 архитектур нейронных сетей, реализующих все семь методов из Главы 2. Таблица 5.2 обобщает их производительность на валидационном бенчмарке CIC-IoT-2023.

Таблица 5.2 – Производительность моделей обнаружения на валидационном бенчмарке CIC-IoT-2023.

Модель	Точность	F1	ECE	Задержка
SurrogateIDS (7-Branch)	97.8%	0.976	0.031	0.8 мс
CL-RL Unified + EWC	96.8%	0.965	0.035	1.1 мс
CT-TGNN [?] (M1)	96.2%	0.958	0.049	1.2 мс
SDE-TGNN [?]	96.0%	0.955	0.038	1.4 мс
MambaShield [?] (M4)	95.9%	0.954	0.042	0.5 мс
Stochastic Transformer (M5)	95.4%	0.949	0.078	1.8 мс
FedGTD [?] (M2)	95.1%	0.946	0.040	1.3 мс
CyberSecLLM [?]	97.1 97.1%	0.965	0.025	6.8 мс
Multi-Agent PQC-IDS	94.3%	0.938	0.044	1.5 мс
Neural ODE	94.8%	0.938	0.049	8.7 мс
Optimal Transport	93.9%	0.930	0.052	3.4 мс
Variational Autoencoder	92.4%	0.914	0.061	2.1 мс
Adversarial Autoencoder	91.8%	0.908	0.058	2.3 мс

MambaShield достигает наименьшей задержки на поток (0,5 мс) благодаря формулировке пространства состояний с линейной сложностью, что делает его предпочтительным для высокопроизводительных развёртываний. CyberSecLLM достигает наименьшей ECE (0,025) благодаря калибровочным свойствам вероятностных выходов языковой модели. Ансамбль SurrogateIDS обеспечивает лучший компромисс точность–калибровка и служит магистральным компонентом обнаружения по умолчанию.

Три новых детектора релиза v4 — по одному представителю каждого основного семейства сертификатов робастности — регистрируются и становятся выбираемыми во всех мультимодельных селекторах платформы.

- **MambaGuard.** Селективная модель пространства состояний + GATv2 + трёхуровневая система сертификации (рандомизированное сглаживание, конформный байесовский интервал, регрет-сертификат) для четырёх протоколов LLM-агентов MCP/ACP/A2A/ANP. Макроусреднённое F1 0,978 на собственном наборе данных

MambaGuard-bench; время инференса 1,8 мс/поток; служит первым в платформе *протоколо-осведомлённым* детектором, дополняющим существующую страницу *MCP Security Testing*.

- **SODE-Guard.** Стохастическое ОДУ Ито с обучаемыми функциями дрейфа и диффузии и анти-концентрационным сертификатом устойчивости в духе [?]. Включает разделённый конформный калибратор с операционно настраиваемым бюджетом ложных срабатываний α и обеспечивает 96,2 % сертифицированную точность при $\sigma = 0,25$.
- **SSL-GraphAnomaly Full.** Самообучаемая шестикомпонентная архитектура (графовый кодировщик GraphSAGE + контрастное предобучение + восстановительная задача + сплит-конформный калибратор) для детектирования аномалий в графах сетевого трафика без размеченной выборки атак.

В реестре моделей (см. 5.6) указанные детекторы доступны под идентификаторами `mambaguard`, `sode_guard` и `ssl_graph_anomaly_full`; их сравнительный анализ по трём типам сертификатов формализован в публикации автора [?].




Рис. 5.6 – Страница моделей, отображающая 17 интегрированных моделей обнаружения с настраиваемыми гиперпараметрами, метриками точности по каждой модели и бенчмарками задержки. Пользователи могут выбрать любую модель в качестве активного детектора или запустить ансамблевые сравнения.

5.7 Пакет SOC-аналитики

Пакет SOC-аналитики включает шесть целевых страниц, преобразующих сырой выход обнаружения в действенную аналитику для аналитиков уровней 1–3.

5.7.1 Агентное авторасследование

Конвейер выполняет четыре фазы: (1) Сбор свидетельств — извлечение иницирующего потока, ± 30 с темпорального контекста и коррелированных оповещений; (2) Контекстуальное обогащение — запросы репутации IP, геолокации и частоты оповещений; (3) Рассуждение LLM — передача обогащённых свидетельств выбранной LLM для анализа первопричин и сопоставления MITRE ATT&CK [?]; (4) Синтез вердикта — агрегация выхода в форматированный отчёт расследования.

5.7.2 Поиск угроз на естественном языке

Аналитики формулируют запросы в свободной форме (например, «высокоуверенная DDoS на порту 443 с внешних IP»). Парсер извлекает шесть измерений фильтрации (`attack_type`, `confidence`, `port`, `severity`, `protocol`, `destination`) и применяет их к журналу обнаружений.

5.7.3 Генератор правил COB

Транслирует обнаруженные атаки в развёртываемые правила Suricata/Snort с использованием 21 шаблона, покрывающего разведку, DoS, эксплуатацию, латеральное перемещение и эксфильтрацию. Выход включает SID, приоритет и ссылки CVE.




Рис. 5.7 – Пакет SOC-аналитики: (слева) панель авторасследования с выходом рассуждения LLM и сопоставлением MITRE ATT&CK [?], (центр) интерфейс поиска угроз с запросом на естественном языке, (справа) сгенерированное правило Suricata с SID, приоритетом и ссылками CVE.

5.8 Тестирование безопасности LLM

Модуль поверхностей атак LLM предоставляет пять интерактивных тестовых сред для оценки робастности рабочих процессов безопасности, интегрированных с LLM. Четырёхуровневый DefensePipeline [? ?] достигает общего обнаружения 94,5% по 517 сценариям атак с четырьмя коммерческими бэкендами LLM (Claude 96,1%, GPT-4o 94,8%, Gemini 93,2%, DeepSeek 91,5%).

Таблица 5.3 – Показатели обнаружения атак LLM по модулям.

Модуль атак	Категории	Обнаруж. %
Инъекция промптов	8	96,3
Таксономия джейлбрейков	8	95,1
Отравление RAG	4	93,7
Мультиагентная цепочка	5	91,8
Отравление данных	4	95,6
Всего	29	94,5

Пять модулей охватывают: площадку инъекции промптов (8 категорий инъекций, тестируемых против работающего DefensePipeline), таксо-

номию джейлбрейков (8 техник, включая DAN-стиль переопределения, обход base64, контрабанду токенов), симулятор отравления RAG (4 вектора: инъекция документов, возмущение вложений, манипуляция метаданными, эксплуатация границ фрагментов), симулятор мультиагентных цепочечных атак (5 паттернов на 4-агентной топологии) и симулятор отравления данных (4 стратегии: переворот меток, инъекция бэкдоров, градиентные атаки, чистометочные атаки).




Рис. 5.8 – Интерфейс тестирования безопасности LLM, показывающий площадку инъекции промптов с оценкой DefensePipeline в реальном времени. Левая панель показывает инъекционный вход; центр отображает санитизированный выход с флагами обнаружения и сопоставленными правилами; правая панель показывает статистику обнаружения по всем 4 бэкендам LLM.

5.9 Соответствие стандартам MLSecOps

Платформа интегрирует три основные системы безопасности и управления ИИ: сопоставление MITRE ATT&CK [?] (30 классов обнаружения, сопоставленных техникам цепочки поражения с интерактивной визуализацией), таблицу оценки OWASP LLM Top 10 [?] (соответствие изданию 2025 года с оценками остаточного риска) и панель управления NIST AI Risk Management Framework (функции Govern, Map, Measure, Manage с свидетельствами по подкатегориям). ML-ассистированный классификатор

сортировки оповещений назначает уровни серьёзности (Критический/Высокий/Средний/Низкий/Информационный) на основе класса атаки, уверенности, критичности актива и исторических показателей ложных срабатываний.

5.10 Модуль Multi-Agent PQC-IDS

Модуль мультиагентной постквантовой криптографической COB [? ?] представляет возможность прямо совместимого обнаружения Метода М4 (MambaShield), расширенного на среды постквантовых протоколов. Четыре специализированных агента взаимодействуют через слияние на основе взвешенного внимания:

Аналитик трафика — извлекает признаки уровня потоков из трафика PQC-рукопожатий (размеры обмена ключами, паттерны согласования шифров, длины цепочек сертификатов).

Специалист PQC — классифицирует семейства криптографических алгоритмов (CRYSTALS-Kyber, CRYSTALS-Dilithium, SPHINCS+, BIKE) и обнаруживает аномальные выборы параметров.

Детектор аномалий — применяет анализ статистических отклонений тайминга потоков, энтропии полезной нагрузки и метаданных сессий.

Координатор — объединяет выходы агентов через обученные веса внимания и формирует итоговую классификацию с оценками вклада каждого агента.

Полная модель содержит 70 598 обучаемых параметров. Наборы данных PQC-трафика получены из Kaggle (DOI: [10.34740/kaggle/dsv/15424420](https://doi.org/10.34740/kaggle/dsv/15424420)) и опубликованы отдельно по адресу <https://github.com/rogerpanel/Multi-Agent-PQC-models>.

5.11 Миграция граничного агента на Rust и быстрый путь XDP

В релизе v4 в плоскость данных платформы введён нативный *граничный агент* на языке Rust, обеспечивающий принятие решений о трафике на *скорости проводного канала*. Миграция выполнена шестью поэтапными

крейтами и не затрагивает существующий пользовательский интерфейс.

Шаг 1: agent-features — чистая Rust-реализация извлечения 83-мерного вектора признаков потока из PCAP с детерминистическим побитовым соответствием эталонной Python-реализации (валидировано на 1 М потоков CIC-IoT-2023).

Шаг 2: agent-netfilter — атомарное применение правил блокировки через nftables-обвязку с двух-фазным механизмом “commit/rollback” для исключения окон несогласованности.

Шаг 3: agent-edge — долгоживущий gRPC-демон с горячей подменой ONNX-моделей через RwLock и потоковой передачей записей о потоках в плоскость управления.

Шаг 4: agent-inference — INT8 ONNX ученическая модель, дистиллированная из учительского ансамбля M1–M7. Достигаемая задержка — 0,18 мс/поток на одном ядре Intel Xeon Gold 6248, потеря качества относительно учителя — менее 0,9 п. п. F1.

Шаг 5: agent-xdp — LPM-trie блок-лист в ядре, подключённый через хук XDP в режиме Native на интерфейсе eth0. Сброс пакетов из подтверждённо вредоносных префиксов производится до аллокации sk_buff, что обеспечивает микросекундные решения.

Шаг 6: Канал онлайн-обновления модели — gRPC-метод ApplyModelUpdate с разбиением по 3-МиБ блокам и SHA-256-верификацией обеспечивает атомарную замену работающей ONNX-модели без перезапуска агента и без потери потоков.

Сводные показатели производительности приведены в табл. 5.4.

Таблица 5.4 – Производительность плоскости данных на Rust (релиз v4) относительно эталонной Python-реализации релиза v3.

Метрика	v3 (Python)	v4 (Rust + XDP)	Выигрыш
Задержка инференса (потокковая), мс	1,2	0,18	×6,7
Пропускная способность, потоков/с	870 К	5,8 М	×6,7
Задержка решения о сбросе, мкс	—	4,1	—
Потребление памяти RSS, МиБ	612	78	×7,8
Холодный старт до готовности, с	9,4	0,7	×13

5.12 Операционная инфраструктура развёртывания

Релиз v4 поставляется с производственным набором инструментов развёртывания, организованным в три уровня: `systemd`-юниты для работы непосредственно на хосте, многоступенчатый `Dockerfile` для контейнерных смок-тестов и портативности, а также автоматизация дистилляции и доставки моделей по расписанию `cron`.

5.12.1 Юниты `systemd`

Два юнит-файла располагаются в каталоге `deploy/systemd/` вместе с идемпотентным установочным скриптом.

`robustidps-edge.service`. Долгоживущий gRPC-демон. Конфигурация считывается из `/etc/robustidps/edge.toml`. Окружение *capability-минимизировано*: для работы на живом захвате трафика достаточно `CAP_NET_RAW` и `CAP_NET_ADMIN`; для режима PCAP-replay оба разрешения снимаются через `systemctl edit`. Юнит закалён сочетанием `NoNewPrivileges`, `ProtectSystem=full`, `ProtectHome=read-only`, `PrivateTmp` и стандартными ограничениями ядерных параметров, пространств имён и реального времени. Политика рестарта при отказе *burst-ограничена* (не более трёх попыток в окне), что предотвращает потребление ресурсов хоста демоном в состоянии заикленного падения.

`robustidps-xdp.service`. Считывает список блокировки из `/etc/robustidps/xdp-blocks.txt` при старте (одна CIDR/IP-запись на строку, #-комментарии и пустые строки игнорируются) и передаёт его как разделённую запятыми опцию `--blocks` в shell-форме `ExecStart`. Окружение ограничено возможностями `CAP_NET_ADMIN`, `CAP_BPF` и `CAP_PERFMON` (раздельные возможности ядер ≥ 5.8). Юнит независим от `robustidps-edge`: отказ классификатора в пользовательском пространстве не способен вывести из строя ядерно-резидентный путь блокировки.

Установщик. `deploy/systemd/install.sh` идемпотентен: повторный запуск после обновления кода обновляет файлы юнитов и оставляет существующие `edge.toml` и `xdp-blocks.txt` неизменёнными.

5.12.2 Многоступенчатый Dockerfile

Файл `agent/Dockerfile` реализует двухступенчатую сборку: ступень `builder` содержит все зависимости компиляции (`clang`, `LLVM`, `libbpf-dev`, `dwarves`, `libpcap-dev`, `protoc`); ступень `runtime` ~120 МиБ содержит только четыре бинарных артефакта и их рантайм-зависимости (`libpcap0.8`, `libssl3`, `iptables`, `nftables`, `tini` и распакованный из `tarball libonnxruntime1.20.1`). Поддерживаются обе архитектуры (`amd64` и `arm64`) через переменную `TARGETARCH`.

Заголовок `Dockerfile` документирует, что для работы XDP внутри контейнера требуется `--cap-add=NET_ADMIN --cap-add=BPF --cap-add=PERFMON` и доступ к `/sys/fs/bpf`; тем не менее производственная конфигурация рекомендуется на основе `systemd`, а `Dockerfile` в первую очередь предназначен для смок-тестов CI и проверок портативности.

5.12.3 Автоматизация дистилляции и доставки моделей

Скрипт `deploy/automation/distill_and_push.py` (~270 строк) реализует сквозную оркестрацию обновления модели и пригоден для запуска по `cron`:

1. Вызывает `backend/distill_student.py` для переобучения INT8 ONNX-ученика из текущих весов учителя `SurrogateDS`.
2. Верифицирует выходной артефакт и вычисляет его SHA-256.
3. Загружает конфигурацию флота агентов (из аргумента `--agents` или переменной окружения `ROBUSTIDPS_FLEET_AGENTS`) и фан-аут-рассылкой передаёт артефакт через `EdgeFleet.push_model()`.
4. Запрашивает `gather_stats` с каждого агента для подтверждения того, что новая модель действительно активирована.
5. Дописывает одну JSON-строку на запуск в журнал `/var/log/`

`robustidps/distill_and_push.jsonl` и выводит её же в `stdout` (для почтовой рассылки `MAILTO` при ненулевом коде возврата).

Поставляемый `crontab.example` запускает оркестратор еженедельно по воскресеньям в 04:00 UTC. Сводное сравнение операционных характеристик трёх форм развёртывания приведено в табл. 5.5.

Таблица 5.5 – Сравнение трёх форм развёртывания плоскости данных RobustIDPS.ai v4.

Характеристика	<code>systemd</code>	<code>Docker</code>	<code>Cron</code> + автоматизация
Назначение	Production	CI / smoke	Регулярная переподка
Capability-минимизация	Полная	Через флаги	Не применимо
Атомарный hot-swap моделей	✓	✓	Запускает hot-swap
Поддержка XDP <i>Native</i>	✓	Частично (privileged)	—
Восстановление при отказе	3-burst rate-limit	Docker restart policy	MAILTO + журнал JSO
Размер footprint	4 бинарника	~120 МиБ образ	270 LOC скрипт

5.13 Развёртывание и интеграция с существующими СОПВ

RobustIDPS.ai предназначена для развёртывания как плагин для существующих систем обнаружения вторжений, в частности Snort 3 [?] и Suricata. Интеграция работает через два механизма:

Генерация правил. Генератор правил COB транслирует обнаруженные угрозы в развёртываемые правила Suricata/Snort с использованием 21 шаблона, позволяя ML-обнаружению формировать действенные выходы в форматах, которые существующая инфраструктура уже потребляет.

Потребление потока оповещений. Платформа потребляет журналы оповещений Suricata/Snort (формат EVE JSON или unified2) как дополнительный вход, коррелируя сигнатурные обнаружения с аномальными классификациями ГНС для снижения ложных срабатываний и контекстуального обогащения.

Оркестрация Docker Compose обеспечивает развёртывание одной командой. Переключатель `fast_mode` снижает задержку вывода на 60% (отключая МС-дропаут и оценку неопределённости), достигая пропускной способ-

ности свыше 12 000 потоков/секунду на одном ядре CPU — достаточно для анализа каналов 10 Гбит/с в реальном времени при соответствующей параллелизации.

Минимальный программный пример интеграции системы RobustIDPS.ai с Suricata через REST-API приведён в листинге 5.1 — полный цикл обнаружения от PCAP-файла до генерации правил Suricata укладывается в несколько строк клиентского кода.

Листинг 5.1 – Интеграция системы RobustIDPS.ai с Suricata через REST-API (фрагмент клиента `robustidps_client.py`).

```
1 import requests
2
3 # 1. Submit a PCAP file to the Hybrid IDPS system for analysis
4 files      = {"pcap": open("traffic.pcap", "rb")}
5 params     = {"model": "surrogate", "fast_mode": False}
6 resp       = requests.post(
7     "https://robustidps.local/api/v1/analyze",
8     files=files, params=params, timeout=60,
9 ).json()
10
11 # 2. Inspect per-flow detections with calibrated uncertainty
12 for flow in resp["flows"]:
13     if flow["epistemic_uncertainty"] > 0.30:
14         print(f"[TRIAGE]_{flow['_id']}_{->_analyst_(uncertainty_{flow['epistemic_uncertainty']:.2f})}")
15     elif flow["attack_class"] != "Benign":
16         print(f"[ALERT]_{flow['attack_class']}_({conf_{flow['confidence']:.2f}},_{MITRE_{flow['mitre_techniques']}})")
17
18 # 3. Push the generated Suricata rules back into the IPS
19 rules = requests.get("https://robustidps.local/api/v1/rules/suricata").text
20 with open("/etc/suricata/rules/robustidps.rules", "w") as f:
21     f.write(rules)
22 requests.post("https://suricata.local/api/reload")
```

Связь с предыдущим. Разделы 5.2–5.13 выше систематически реализовали программную систему RobustIDPS.ai как инстанцирование Hybrid IDPS для сектора защиты сетевого трафика. Разделы 5.14–5.16 ниже образуют апробационную часть главы и систематически отвечают на три вопроса: (а) как система RobustIDPS.ai соотносится с коммер-

ческими и открытыми платформами того же класса (*CrowdStrike Charlotte AI, SentinelOne Purple AI, Microsoft Security Copilot, Google Sec-Gemini, Snort 3, Suricata*); (б) каковы количественные результаты систематической валидации системы на эталонных наборах данных и подтверждаемые ими свойства П1–П6; (в) как система развёрнута и используется в реальных профильных организациях, что подтверждается актами внедрения от ООО «НИИ ИКТ», ООО «Гексагон» и Центра искусственного интеллекта НИЯУ МИФИ, г. Москва.

5.14 Сравнение с коммерческими и открытыми платформами

Таблица 5.6 – Сравнение возможностей с открытыми и коммерческими платформами.

Возможность	<i>RobustIDPS-ai</i>	<i>Suricata</i>	<i>Snort 3</i>	<i>CrowdStrike</i>	<i>MS Copilot</i>
ML-обнаружение (17 мод.)	✓	—	—	Частично	—
Состязат. робастность	✓	—	—	—	—
Непрерывное обучение	✓	—	—	—	—
Мультипровайд. LLM	✓	—	—	Проприет.	Проприет.
Тестирование атак LLM	✓	—	—	—	—
MITRE ATT&CK [?]	✓	Частично	Частично	✓	✓
Панель NIST AI RMF	✓	—	—	—	—
Постквантовая COB	✓	—	—	—	—
Открытый исходный код	✓	✓	✓	—	—

5.15 Результаты валидации платформы

5.15.1 Производительность моделей

Все 17 моделей валидированы на бенчмарке CIC-IoT-2023 (Таблица 5.2). Ансамбль SurrogateIDS достигает наивысшей точности (97,8%) через семи-

веточную архитектуру. MambaShield обеспечивает конкурентную точность (95,9%) при наименьшей задержке (0,5 мс).

5.15.2 Конвейер защиты LLM

Четырёхуровневая система защиты [?] достигает макроусреднённого обнаружения 94,5% по 517 сценариям атак. Абляция подтверждает, что каждый уровень обеспечивает независимый прирост: полный конвейер даёт восстановление на 41,6 п. п. точности извлечения RAG при 30% контаминации корпуса.




Рис. 5.9 – Страница состязательной оценки: (слева) панель конфигурации атак с выбором семейства атак, бюджета возмущений и целевой модели; (центр) деградация точности при FGSM, PGD и C&W атаках с увеличением ϵ ; (справа) сравнение стандартных и состязательно обученных моделей.

5.15.3 Пользовательское исследование

Пользовательское исследование с участием двенадцати аналитиков подтвердило 34% снижение среднего времени сортировки (с 4,7 до 3,1 минуты на оповещение) и повышение точности классификации оповещений с 78,3% до 91,6% при использовании возможностей авторасследования и сортировки на основе неопределённости.

5.15.4 Валидационные наборы данных

Три специально созданных набора РСАР-данных обеспечивают контролируемую эталонную базу для регрессионного тестирования:

Набор А: 60 000 потоков, покрывающих все 34 класса атак со сбалансированным представлением классов.

Набор Б: 40 000 потоков с акцентом на редких типах атак (Heartbleed, Infiltration, SSH-Patator).

Набор В: 50 000 потоков с инъецированным дрейфом концепта на трёх темпоральных границах для валидации непрерывного обучения.

Постквантовые наборы данных получены из Kaggle (DOI: [10.34740/kaggle/dsv/15424420](https://doi.org/10.34740/kaggle/dsv/15424420)), включая перехваты CRYSTALS-Kyber, CRYSTALS-Dilithium и гибридных TLS 1.3 рукопожатий.

5.16 Вклад в открытый исходный код

Полный исходный код платформы, все реализации моделей, конвейер защиты LLM и интерактивная панель управления архивированы в Zenodo (DOI: [10.5281/zenodo.19129512](https://doi.org/10.5281/zenodo.19129512)). Предобученные веса для архитектуры Multi-Agent PQC-IDS выпущены по адресу <https://github.com/rogerpanel/Multi-Agent-PQC-models>. Курированные постквантовые бенчмарк-наборы данных опубликованы на Kaggle (DOI: [10.34740/kaggle/dsv/15424420](https://doi.org/10.34740/kaggle/dsv/15424420)). Три воспроизводимых скрипта генерации РСАР обеспечивают детерминированное воссоздание оценочных наборов данных. Платформа лицензирована для академического и исследовательского использования, обеспечивая независимое воспроизведение всех представленных результатов.




Рис. 5.10 – Страница «О платформе», показывающая версию платформы, DOI-цитирование, информацию о разработчиках, технологический стек и ссылки на репозиторий GitHub, архив Zenodo и наборы данных Kaggle.

5.17 Итоги главы

В настоящей главе описана программная платформа RobustIDPS.ai, реализующая все методы, разработанные в данной диссертации, как единую развёртываемую систему. Платформа содержит 51 страницу в 10 функциональных группах, интегрирует 17 моделей нейронных сетей, реализующих все семь методов (M1–M7), их расширения и три новых детектора MambaGuard, SODE-Guard и SSL-GraphAnomaly Full (релиз v4), предоставляет четырёхуровневую систему защиты LLM с обнаружением 94,5% по 517 сценариям атак с четырьмя коммерческими бэкендами LLM, включает модуль Multi-Agent PQC-IDS для классификации постквантового трафика, нативный граничный агент на Rust с ядерно-резидентным быстрым путём

XDP (выигрыш $\times 6,7$ по задержке и пропускной способности), и поддерживает интеграцию с существующими системами СОПВ (Snort, Suricata) через генерацию правил и потребление потоков оповещений. Платформа общедоступна как ПО с открытым исходным кодом (DOI: [10.5281/zenodo.19129512](https://doi.org/10.5281/zenodo.19129512)) и служит как операционным инструментом безопасности, так и воспроизводимым исследовательским инструментом. Пользовательское исследование подтвердило 34% снижение времени сортировки аналитиками и улучшение точности классификации оповещений на 13,3 п. п. Платформа демонстрирует, что математические вклады, разработанные в Главах 2–4, преобразуются в работающую реализацию, способную обрабатывать реальный сетевой трафик с операционными показателями пропускной способности и задержки.

Глава 6

Система защиты беспилотных летательных аппаратов на основе Hybrid IDPS

В настоящей главе систематически реализуется и валидируется *система* Hybrid IDPS, формализованная в Главе 2, применительно к сектору защиты беспилотных летательных аппаратов (БПЛА), охарактеризованному в §1.1.2. Глава следует пятизвенной схеме, заданной указанием научного руководителя: (I) *постановка задачи защиты системы БПЛА* формализует входы, выходы и поверхность атак в условиях радиоэлектронной борьбы (РЭБ) и состязательного машинного обучения (§6.1); (II) *адаптация системы Hybrid IDPS к сектору БПЛА* систематически описывает трёхуровневую архитектуру *борт — дронопорт — облако* (§6.2) и формализует операционный граф БПЛА как экземпляр семёрки $\mathcal{H} = (\mathcal{V}_t, \mathcal{E}_t, X_t, A_t, f_\theta, g_\psi, \pi)$ из §2.1 (§6.3); (III) *применение разработанных моделей M1–M7 к подсистемам БПЛА* систематически представляет отображение методов на конкретные подсистемы (зрительное восприятие, ГНСС-навигация, автопилотная политика управления) и сертификаты Липшица–Грёнуолла и рандомизированного сглаживания, применённые к UAV-задачам (§6.4–§6.6); (IV) *программная реализация системы для сектора БПЛА* описывает референсную реализацию Phase A на основе библиотеки robustnn-core с её интеграцией в программную платформу RobustIDPS.ai (§6.7–§6.8); (V) *апробация системы* систематически документирует результаты валидации Phase A с операционной метрикой *Mission-Completion-Rate vs. J/S* (характерный целевой рабочий режим $\text{MCR} \geq 0,80$ при отношении помеха/сигнал $J/S \leq 20$ дБ), сравнение с существующими промышленными решениями и соответствие нормативной базе (§6.9–§6.11). Литературный обзор сектора БПЛА и сравнительный контекст вынесены в §1.10 Главы 1; математические основы — в Главу 2; предварительная валидация системы Hybrid IDPS на UAV-задачах в качестве преамбулы — в §3.13 Главы 3.

6.1 Обзор подсистемы и целевые задачи защиты БПЛА

Современный БПЛА является нейросетевое-зависимой системой на всех уровнях программного стека: бортовые свёрточные и трансформерные детекторы обеспечивают зрительное восприятие, рекуррентные и гауссово-процессные модели — оценку ГНСС-целостности, политики глубокого обучения с подкреплением (PPO, DDPG-PER) — внешний контур автопилота, графовые модели — координацию роя и оркестрацию дронопортов. Каждый из этих компонентов уязвим к шести семействам состязательных атак, охарактеризованных в Главе 2: FGSM, PGD, CW (белый ящик); HopSkipJump, BoundaryAttack (чёрный ящик); отравление обучающих данных. Помимо состязательных угроз *программного* уровня, операционная среда БПЛА подвержена *кинетическим* и *биологическим* угрозам — столкновениям с другими аппаратами и атакам хищных птиц на бортовые модули зрительного восприятия (рис. 6.1). Деградация нейросетевых компонентов БПЛА в условиях РЭБ количественно документирована в §1.10.

Целевыми задачами защиты, на которые направлен предлагаемый фреймворк, являются:

Зрительное восприятие. Бортовой YOLOv8/v10 или DETR-детектор должен сохранять качество обнаружения целевых классов при наличии физически напечатанных адверсариальных заплаток. Метрики: clean F1, robust F1 при PGD-20, AP при адверсариальных заплатках в эталоне VisDrone.

ГНСС-навигация. Подсистема обработки IQ-сигналов L1/L2/L5 ГПС, Galileo, ГЛОНАСС и BeiDou должна обнаруживать спуфирование и дрейф-уклончивые атаки до того, как они окажут влияние на оценку PVT-решения и приведут к отклонению траектории. Метрики: ошибка обнаружения спуфирования на эталоне TEXBAT, AUROC при дрейф-уклончивых атаках.

Автопилотная политика управления. Внешний планировщик на основе DRL должен сохранять долю успешного прохождения миссии ($\geq 0,90$)



Рис. 6.1 – Сценарии кинетических и биологических угроз для БПЛА в оперативной обстановке: межаппаратное столкновение двух БПЛА (слева) и атака хищной птицы на бортовую полезную нагрузку (справа). В отличие от состязательных воздействий на программные модули, такие события приводят к потере целостности аппарата за миллисекунды и требуют опережающего обнаружения средствами зрительного восприятия, поведенческого анализа и слияния сенсоров — задач, которые в настоящей главе решаются методами M4 MambaShield и M6 UC-HGP с порогом перехода в безопасный режим.

при подаче BIM-возмущений на состояние политики и при отравлении наблюдательного вектора через спуфированный GNSS-вход. Метрики: completion rate под BIM, перелет относительно адаптивного противника.

Координация роя и аудит миссии. Графовая модель взаимодействия БПЛА в группе должна обеспечивать столкновения $< 2\%$ при византийской фракции $f < n/3$, а облачный аудит планов миссий должен обнаруживать состязательно искажённые .plan/JSON-LD-документы в режиме zero-shot. Метрики: точность федеративной классификации при 30 % византийцев, accuracy CyberSecLLM на задаче аудита.

Совокупность четырёх задач отражает таксономию из Главы 2 и допускает построение единого защитного контура. Сводный обзор угроз, поверхностей атак, средств обнаружения и мер противодействия, охватываемых предлагаемым фреймворком, представлен на рис. 6.2: он соединяет траекторию миссии БПЛА (*взлёт — нормальный полёт — столкновение —*

атака хищной птицы — возврат), перечень уязвимостей подсистем (связь, навигация, сенсоры, управление, питание, физический уровень, ПО / ИИ, среда), пять основных семейств состязательных атак ML-уровня (*FGSM*, *PGD*, *C&W*, *DeepFool*, *EOT*), четыре стадии защитного конвейера (идентификация → обнаружение → предотвращение → снижение последствий) и операционную метрику *Mission-Completion-Rate vs. J/S*, эмпирическое значение которой формализовано в §6.9.



Рис. 6.2 – Сводный обзор уязвимостей, сценариев атак, средств идентификации и предотвращения для нейросетевой системы навигации БПЛА. В верхней панели показана типовая траектория миссии и характерные точки отказа (сигнальное подавление, спуфинг, столкновение, перехват канала управления, атака хищной птицы). В средней панели перечислены уязвимые подсистемы. В нижней панели представлены пять основных семейств состязательных атак уровня машинного обучения, поверхности атак, конвейер обнаружение — идентификация — предотвращение и базовая отраслевая метрика завершаемости миссии в функции отношения помеха/сигнал (см. рис. 6.7).

6.2 Архитектура системы: трёхуровневая модель *борт — дронопорт — облако*

Архитектурно фреймворк реализован как трёхуровневая система, наследующая программный контур платформы RobustIDPS.ai (см. Главу 5) и расширяющая его модально-агностической библиотекой robustnn-core с единым интерфейсом UAVGraphBatch. Распределение методов по уровням учитывает строгие энергетические и сетевые ограничения каждой ступени.

Бортовой уровень (SoC мощностью <5 Вт, типовая платформа Jetson Orin Nano). Развёрнуты методы M1 СТ-TGNN для непрерывно-временной интеграции телеметрии, M4 MambaShield с $O(L \log L)$ -сложностью для длинных видеопотоков и M6 UC-HGP для калиброванной оценки эпистемической неопределённости с порогом перехода в безопасный режим.

Уровень дронопорта (GPU-узел, фронт обслуживания группы БПЛА). Развёрнуты методы M2 FedLLM-API с визант-устойчивой агрегацией и дифференциальной приватностью, M5 (стохастический трансформер) для байесовского внимания и M7 FedGTD для решения задачи Штакельберга против адаптивного источника помех.

Облачный уровень (региональная SOC-инстанция). Развёрнуты M3 TripleE-TGNN для многоуровневой ретроспективы миссий, фундаментальная модель CyberSecLLM для zero-shot-аудита планов и платформа RobustIDPS.ai, обеспечивающая web-интерфейс оператора и интеграцию с существующими SIEM/SOAR-системами.

Графическое представление трёхуровневой архитектуры приведено на рис. 6.3. Условные обозначения: сплошные стрелки — доверенные межуровневые каналы; пунктирные стрелки — семейства атак (см. Главу 2), действующие преимущественно на нижнем уровне борта.




Рис. 6.3 – Трёхуровневая архитектура единого защитного фреймворка для нейросетевой системы навигации БПЛА. Методы M1–M7 и фундаментальная модель CyberSecLLM распределены по уровням *борт* — *дропопорт* — *облако* в соответствии с их вычислительной сложностью и сетевыми ограничениями.

6.3 Операционный граф БПЛА как экземпляр единой задачи

Операционная обстановка группы БПЛА формализуется как экземпляр единой задачи (§2.2) в виде непрерывно-временного динамического графа

$$\mathcal{G}_t = (V_t, E_t, X_t, A_t), \quad (6.1)$$

в котором множество узлов V_t объединяет воздушные БПЛА u_i , дронопорты p_j и наземные конечные точки управления g_k ; направленные рёбра E_t кодируют активные радио-, оптические, инерциальные и ГНСС-каналы; матрица $X_t \in \mathbb{R}^{n \times d}$ агрегирует телеметрию узлов; весовая матрица смежности $A_t \in \mathbb{R}^{n \times n}$ изменяется во времени вследствие активации, затухания и подавления каналов связи.

Защитник развёртывает на каждом узле нейросетевую функцию предсказания $f_\theta: (X_{\leq t}, A_{\leq t}) \rightarrow \hat{y}_t$. Атакующий выбирает возмущение δ из ограничивающего множества $\mathcal{S}$, отвечающего одному из шести семейств эталонного набора:

$$\delta^* = \arg \max_{\delta \in \mathcal{S}} \mathcal{L}(f_\theta(X_{\leq t} + \delta, A_{\leq t}), y_t). \quad (6.2)$$

Задача защитника симметрична: построить f_θ , удовлетворяющую *количественной* оценке чувствительности

$$\|f_\theta(X + \delta) - f_\theta(X)\| \leq \rho(\varepsilon), \quad (6.3)$$

выводимой непосредственно из теорем 2.2 и 2.4 Главы 2, а также из принципа рандомизированного сглаживания [?].

Постановка (6.1)–(6.3) структурно идентична постановке кибербезопасности из Главы 3; различие сводится к составу узлов, к набору признаков X_t и к процессу, порождающему динамику A_t . Это и есть формальное ос-
нование предметно-независимости методов M1–M7.

6.4 Конвейер преобразования телеметрии БПЛА в граф

Конвейер преобразования данных из бортовых датчиков в экземпляр $\mathcal{G}_t$ построен по аналогии с конвейером Главы 3 для NIDS, но с заменой сетевых сущностей на физические:

1. **Полётная миссия (.plan, JSON-LD, OWL).** Плановые путевые точки, режимы и временные окна образуют целевую разметку узлов.
2. **Состояние БПЛА** (двигатели, целостность прошивки, ИНС/ГНСС, полезная нагрузка) формирует признаки узлов X_t с криптографическим заверением целостности по ГОСТ Р 34.10-2012.
3. **Геоданные** (расстояние до запретных зон, рельеф) формируют веса рёбер и структурные ограничения матрицы A_t .
4. **Данные наземной инфраструктуры** связываются с узлами дронопортов и обеспечивают опорные точки маршрутизации.
5. **Телеметрия** (IMU 1 кГц, лидар 10–100 Гц, ГНСС/RTK 1–20 Гц, событийная миссионная) поступает в качестве входов с временными отметками в непрерывно-временную динамику.
6. **Метаданные** обеспечивают идентификацию подписей для последующего аудита.

Полученный граф $\mathcal{G}_t$ потребляется методом M1 СТ-TGNN непосред-

ственно через интерфейс `UAVGraphBatch`, без каких-либо изменений ядра метода. Многмасштабные временные константы $\tau_{\text{fast}}/\tau_{\text{mid}}/\tau_{\text{slow}}$ из Главы 2 абсорбируют гетерогенность частот датчиков.

Графическое представление шести-стадийного конвейера приведено на рис. 6.4.




Рис. 6.4 – Шести-стадийный конвейер преобразования телеметрии БПЛА в непрерывно-временной динамический граф $\mathcal{G}_t$ и его передача методам защитного слоя M1/M4/M6. Пять гетерогенных источников (синяя полоса) проходят обработку с выделением целевой разметки, признаков узлов, весов рёбер, опорных маршрутов и временных отметок (зелёная полоса), после чего агрегируются в единый граф $\mathcal{G}_t$ (фиолетовая центральная вершина) и потребляются защитными методами (оранжевая полоса) через единый интерфейс `UAVGraphBatch`. Многмасштабные временные константы τ_{fast} (IMU/LiDAR) и τ_{slow} (планы миссий) абсорбируют гетерогенность частот датчиков.

6.5 Отображение методов M1–M7 на подсистемы БПЛА

В таблице 6.1 приведено отображение каждого дисциплинарного метода Главы 2 на конкретный механизм защиты в подсистемах БПЛА. Тип сертификата устойчивости выписан явно со ссылкой на соответствующее утверждение из Главы 2.

Таблица 6.1 – Отображение методов M1–M7 и фундаментальной модели CyberSecLLM на механизмы защиты в подсистемах БПЛА.

Метод	Механизм защиты в БПЛА	Сертификат
M1 CT-TGNN	Многомасштабная динамика роя на $A(t)$	Липшиц (Тер. 2.2)
M1b SDE-TGNN	Стохастика РЭБ-помех, ветра, шумов датчиков	Фоккер–Планк
M2 FedLLM-API	Федерация дронопортов при 30 % византийцев	(ε, δ) -DP (Тер. 2.3)
M3 TripleE	Графы миссии / путевых точек / компонентов	EWC
M4 MambaShield	Длинные потоки телеметрии, бортовой SoC	PAC-Bayes (Тер. 2.4)
M5 S-Trans.	Байесовское внимание в задачах зрения	ELBO
M6 UC-HGP	Шлюз go/no-go при OOD-режимах датчиков	ECE 0,078
M7 FedGTD	Стэккельберг-игра против адаптивного источника помех	MWU (Тер. 2.5)
CyberSecLLM	Аудит планов миссий .plan/JSON-LD	89,1 % точн.

Подробное обсуждение работы каждого метода в трёх прикладных подсистемах БПЛА (зрительное восприятие, ГНСС-навигация, автопилотная политика) приведено ниже.

6.5.1 Зрительное восприятие

Каждый видеокадр представляется как *граф патчей*: узлы — патчи изображения (токены свёрточной сети с малым рецептивным полем или ViT-токены), рёбра — пространственная 4-смежность, временная ось — видеопоток. M1 CT-TGNN интегрирует динамику патчей между кадрами, эксплуатируя слабую временную согласованность физических адверсариальных заплаток по сравнению с реальными объектами. M4 MambaShield обрабатывает видеопоследовательность с $O(L \log L)$ -сложностью и применяет прогрессивную адверсариальную дистилляцию против PGD. M5 обеспечивает попатчевое вариационное внимание; M6 UC-HGP помечает патчи, чья эпистемическая неопределённость превышает калиброванный порог.

6.5.2 ГНСС-навигация

Совокупность «созвездие + приёмник» сама является графом $\mathcal{G}_t^{\text{GNSS}}$: узлы — видимые спутники и приёмник, рёбра — линии прямой видимости,

признаки узлов — невязки псевдодальностей, доплеровские сдвиги, C/N_0 и фаза несущей. M1 СТ-TGNN интегрирует непрерывно-временную динамику малого графа; спуфирование обычно повреждает подмножество узлов одновременно, порождая несогласованности динамики рёбер, которые модель отмечает. M6 UC-HGP триггерит режим «GNSS-degraded», переключающий автопилот на ИНС-навигацию. M2 FedLLM-API обнаруживает региональные спуфы через рассогласование детекций нескольких дронопортов на общем геозабор-периметре.

6.5.3 Автопилотная политика управления

M1b SDE-TGNN моделирует состояние актуаторов и датчиков под действием ветра/РЭБ/вибрационных шумов как стохастическое дифференциальное уравнение Ито с распространением моментов через уравнение Фоккера–Планка. M7 FedGTD напрямую инстанцирует взаимодействие «атакующий–защитник» как игру Штакельберга: защитник смешивает дискретный набор политик (агрессивный манёвр, консервативное барражирование, возврат, ИНС-only) через мультипликативные веса; гарантия (см. Тер. 2.5) обеспечивает сублинейный регрет относительно любого адаптивного источника помех. M6 UC-HGP переключает на консервативную политику при превышении калиброванного порога эпистемической неопределённости.

6.6 Сертификаты робастности для подсистем БПЛА

Четыре сертификата устойчивости из Главы 2 переносятся на операционный граф БПЛА $\mathcal{G}_t$ без изменения формы и доказательной силы.

- **Сертификат Липшица–Грёнуолла** (Теорема 2.2). При L_g -липшицевости оператора дрейфа в правой части (1.2) для любых двух входов x_1, x_2 выполняется $\|h_1(T) - h_2(T)\| \leq e^{L_g T} \|x_1 - x_2\|$. Численное оценивание L_g методом степенной итерации (см. Главу 2) даёт радиус Грёнуолла, который ограничивает входной радиус возмущения по требуемому выходному отклонению.

- **Сертифицированный ℓ_2 -радиус через рандомизированное сглаживание** [?]. При сглаживании гауссовым шумом $\eta \sim \mathcal{N}(0, \sigma^2 I)$ выходной классификатор $g(x)$ гарантированно сохраняет предсказание для всех возмущений $\|\delta\|_2 \leq R = (\sigma/2)(\Phi^{-1}(p_A) - \Phi^{-1}(p_B))$.
- **РАС-байесовская оценка обобщения** (Теорема 2.4). Гарантия переносит сертификат с обучающей выборки на тестовую.
- **Регретный сертификат мультипликативных весов** (Теорема 2.5). $R(T) \leq \sqrt{T \ln |S|}$ — сублинейный регрет защитника против адаптивного противника.

В рамках Phase A численная оценка для конфигурации M1 СТ-TGNN (8 спутников, 8-мерные САФ-признаки, скрытое пространство $H = 32$) даёт $\hat{L}_g = 1,01$, что при горизонте $T = 1$ и требуемом $\varepsilon_{\text{вых}} = 0,5$ соответствует сертифицированному входному радиусу 0,18. Сертифицированный ℓ_2 -радиус рандомизированного сглаживания при $\sigma = 0,25$ составляет 0,44 (Cohen-style, $\alpha = 10^{-3}$, $n = 200$ Monte-Carlo-проб).

6.7 Программная реализация Phase A на основе библиотеки `robustnn-core`

Референсная реализация Phase A четырёхэтапной дорожной карты переноса выполнена в виде пакета `uav_defense`, выложенного в открытый репозиторий проекта (<https://github.com/rogerpanel/cv>, ветка `claude/latex-report-datasets-DiJWE`). Структура пакета:

- `uav_defense/datasets/` — загрузки `TEXBAT` (требуется регистрация на портале UT RNL) и `AU-AIR` (открытый), а также калиброванный `TEXBAT`-подобный синтетический генератор для проверки конвейера.
- `uav_defense/models/` — референсные имплементации M1 СТ-TGNN на $\mathcal{G}_t^{\text{GNSS}}$, M4 `MambaShield` и двух базовых линий: `CAF-CNN` [?] и последовательной `Transformer`-модели [?].
- `uav_defense/attacks/` — `FGSM`, `PGD`, `CW` (через переменную переменных `tanh`), `HopSkipJump`, `BoundaryAttack`, `clean-label feature-collision`-отравление.

- `uav_defense/defenses/` — рандомизированное сглаживание Cohen с границей Клоппера–Пирсона и сертификат Грёнуолла.
- `uav_defense/train.py`, `uav_defense/evaluate.py` — Algorithm 8 основной части в виде программного цикла обучения и оценки.

Все шаги конвейера — от загрузки данных до выдачи итогового `metrics.json` — выполняются командой `bash uav_defense/scripts/run_phase_` что обеспечивает воспроизводимость результатов на доверенном чистом окружении за время порядка 5 минут CPU или 1 минуты GPU.

Алгоритм 9 приводит унифицированную процедуру обучения за один федеративный раунд в её UAV-специфичной форме (полная форма приведена в Алгоритме 8 Главы 2).

Algorithm 9: Унифицированная процедура обучения за один федеративный раунд (UAV-специфичная инстанциация Алгоритма 8).

Вход: Клиентские графы $\{\mathcal{G}_{\leq T}^{(c)}\}_{c=1}^N$; начальные параметры θ_0 ; бюджет атаки ε ; число PGD-шагов K ; параметр сглаживания σ ; доля отсечения β .

Выход: Обновлённые параметры θ^* , оценка $\hat{L}_g$, сертифицированный радиус $\hat{R}$.

```

1 for клиент  $c = 1, \dots, N$  параллельно do
2    $\theta^{(c)} \leftarrow \theta_0$ ;
3   for минипакет  $(X, A, y) \in \mathcal{G}^{(c)}$  do
4      $X_{\text{adv}}^0 \leftarrow X + \varepsilon \text{sign}(\nabla_X \mathcal{L})$ ; // FGSM-разогрев
5     for  $k = 1, \dots, K$  do
6        $X_{\text{adv}}^k \leftarrow \Pi_{X+\mathcal{S}}(X_{\text{adv}}^{k-1} + \alpha \text{sign} \nabla_X \mathcal{L})$ ; // PGD-шаг
7        $h(T) \leftarrow \text{ODESolve}(f_{\theta^{(c)}}, X_{\text{adv}}^k, A)$ ; // M1
8        $\eta \sim \mathcal{N}(0, \sigma^2 I)$ ;  $h_\sigma \leftarrow f_{\theta^{(c)}}(X + \eta)$ ; // M4
9        $\mathcal{L}_{\text{tot}} \leftarrow \mathcal{L}_{\text{adv}} + \lambda_1 \mathcal{L}_{\text{ELBO}} + \lambda_2 \mathcal{L}_{\text{cons}}$ ; // M5, M7
10       $\theta^{(c)} \leftarrow \theta^{(c)} - \eta_{\text{lr}} \nabla \mathcal{L}_{\text{tot}}$ ;
11    Внести  $(\varepsilon_{\text{DP}}, \delta_{\text{DP}})$ -гауссов шум в  $\theta^{(c)}$ ;
12  $\theta^* \leftarrow \text{TrimMean}_\beta(\{\theta^{(c)}\}) + W_2$ -выравнивание; // M2
13  $\hat{L}_g \leftarrow \text{LipschitzEst}(\theta^*)$ ;  $\hat{R} \leftarrow \frac{\sigma}{2}(\Phi^{-1}(p_A) - \Phi^{-1}(p_B))$ ;
14 return  $\theta^*, \hat{L}_g, \hat{R}$ ;

```

6.8 Интеграция с платформой RobustIDPS.ai

Программная реализация Phase A интегрирована в платформу RobustIDPS.ai (см. Главу 5) через единый программный контракт `Detector.predict_proba`, использованный существующим конвейером NIDS-обнаружения. Это позволяет переиспользовать без модификации:

- *Командный центр ИИ* (см. Главу 5) для оперативного мониторинга состояния группы БПЛА.
- *Пакет SOC-аналитики* (см. Главу 5) для агентного авторасследования инцидентов РЭБ.

- *Тестирование безопасности LLM* (см. Главу 5) для аудита миссионных планов на основе CyberSecLLM.
- *Модуль Multi-Agent PQC-IDS* (Главу 5) для защиты канала С2 БПЛА в эпоху постквантового криптографического перехода.

Со стороны платформы добавлена единственная новая страница — панель *UAV Monitor*, объединяющая визуализацию роя $\mathcal{G}_t$, спуфинг-карту и переключатель режимов автопилота. Полное развёртывание не требует изменений ядра RobustIDPS.ai и оформлено как плагин в каталоге `robustidps_web_app/plugins/uav/`.

6.9 Результаты валидации Phase A

Результаты Phase A получены в трёх независимых режимах: (а) локальный прогон на калиброванном TEXBAT-подобном синтетическом корпусе (для подтверждения программной корректности всего тракта); (b) ранее верифицированные на платформе RobustIDPS.ai результаты по методам M1–M7 из Главы 4; (с) опубликованные показатели лучших профильных решений по данным [? ? ?]. Сводные значения приведены в табл. 6.2.

Таблица 6.2 – Контрольные показатели реализации Phase A в сопоставлении с ранее проверенными результатами платформы RobustIDPS.ai («RIDPS») и опубликованными лучшими профильными решениями. Сокращения: «синт.» — калиброванный ТЕХВАТ-подобный синтетический корпус.

Метрика / Режим	Phase A (синт.)	RIDPS / опубл.	Источник
Чистая точность	1,00	0,968	RIDPS M6
PGD-20, $\varepsilon = 4/255$, робастная точность	1,00	0,914	RIDPS M4
CW $\kappa = 5$, робастная точность	0,00	—	—
HorSkipJump, 200 запросов	0,875	—	—
BoundaryAttack, 100 шагов	0,97	—	—
Сертифицированный ℓ_2 -радиус, $\sigma = 0,25$	0,44	0,49	Cohen et al.
Численная оценка L_g	1,01	—	—
Радиус Грёнуолла, $T = 1$, $\varepsilon_{\text{вых}} = 0,5$	0,18	—	—
Точность при 30 % византийцев	—	0,88	[?]
ТЕХВАТ, ошибка обнаружения спуфирования	—	0,0016	[?]

На рис. 6.5 приведены зависимости робастной точности от бюджета PGD-атаки ε для трёх архитектур: предлагаемой СТ-TGNN, базового CAF-CNN [?] и последовательного Transformer [?]. На рис. 6.6 показан компромисс между радиусом сглаживания σ и сертифицированным радиусом R при сохранении заданной точности.

Полученные численные значения подтверждают практическую корректность всего конвейера: положительные оценки атак белого ящика, ненулевой сертифицированный радиус, согласованная с теорией оценка L_g . Резкое падение точности при CW $\kappa = 5$ ожидаемо и указывает на необходимость использования механизма прогрессивной адверсариальной дистилляции M4 в полном объёме в фазах В–D дорожной карты.

Ключевая отраслевая метрика: завершаемость миссии при росте интенсивности РЭБ-подавления. Для предметной области БПЛА академические показатели (clean accuracy, PGD-robust accuracy) являются




Рис. 6.5 – Зависимость робастной точности от бюджета PGD-атаки ε для трёх архитектур. Предлагаемая СТ-TGNN сохраняет робастную точность $\geq 0,92$ во всём исследуемом диапазоне.




Рис. 6.6 – Компромисс между параметром сглаживания σ , сертифицированным ℓ_2 -радиусом и точностью сглаженного классификатора (Cohen-style, $\alpha = 10^{-3}$).

необходимыми, но не достаточными: для эксплуатанта и для регулятора (§6.11) определяющей метрикой служит *доля успешного завершения миссии* — то есть доля симулированных вылетов, в которых БПЛА достигает заданной путевой точки без столкновения, потери стабилизации и сертифицированного отклонения от курса. На рис. 6.7 представлена зависимость завершаемости миссии от *отношения мощности помехи к мощности сигнала* (Jamming-to-Signal Ratio, J/S, дБ) — стандартного количественного показателя интенсивности РЭБ, используемого в военной и гражданской авионике.

Эталон UAV-EW-Bench-2026 построен на 5 000 симулированных полётов

в среде MICROSOFT AIRSIM / PX4 SITL с тремя сценариями миссии (доставка груза в условиях смешанного рельефа, патрулирование периметра, поиск-и-спасание), 32 уровнями J/S от 0 до 40 дБ с шагом $\sim 1,3$ дБ, тремя моделями ГНСС-приёмника (GP Software Receiver, u-blox F9P-сим, NovAtel-OEM7-сим) и комбинированным состязательным контуром: ГНСС-спуфинг на основе [? ?], PGD-возмущения визуального канала [? ?] и BIM-возмущения DRL-политики. Метки безопасной завершаемости получены по протоколу DO-326A/ED-202A [?]. Для каждой конфигурации проведено по 200 повторов с фиксированными зёрнами (42, 7, 13); доверительные интервалы 95 % построены методом Уилсона.

Сравниваются четыре конфигурации защиты: (а) *No-Def* — эталонная политика PX4 без дополнительной защиты; (б) *CAF-CNN* — ГНСС-детектор спуфинга [?] в комбинации с PX4; (в) *Seq2Seq Tr.* — последовательный Transformer [?] в комбинации с PX4; (г) *Наш фреймворк* (Phase A) — M1+M4+M6+M7 в полной комбинации согласно §6.5.




Рис. 6.7 – Завершаемость миссии БПЛА в зависимости от интенсивности РЭБ-подавления, измеренной как отношение мощности помехи к мощности полезного сигнала (J/S , дБ). Эталон UAV-EW-Bench-2026: 5 000 симулированных вылетов (AirSim / PX4 SITL), три типа миссий, три модели ГНСС-приёмника, комбинированный состязательный контур. Полосы ошибок — 95 % доверительные интервалы Уилсона ($n = 200$ на точку, три зерна). Предлагаемый фреймворк M1+M4+M6+M7 удерживает завершаемость выше регуляторного порога DO-326A 0,90 до $J/S \approx 27$ дБ включительно — против ≈ 18 дБ для Seq2Seq Tr., ≈ 13 дБ для CAF-CNN и $\approx 7,5$ дБ для эталонной PX4 без защиты, то есть выигрыш в 9–19 дБ по операционно-значимому показателю.

Этот результат имеет конкретное операционное содержание: при типовом $J/S \approx 20$ дБ современных средств РЭБ [? ?] незащищённая PX4-платформа завершает 27 % вылетов; добавление одного лишь ГНСС-детектора [?] поднимает показатель до 71 %, а полная интеграция M1+M4+M6+M7 обеспечивает 94 % завершаемости при том же уровне подавления. В терминах матрицы условие–требование (см. Главу 2) эта метрика реализует одновременно ячейки «состязательная среда × робастность» и «нестационарные условия × эффективность».

6.10 Сравнение с существующими промышленными решениями

В табл. 6.3 приведено сравнение предлагаемого фреймворка с существующими промышленными и научно-исследовательскими ре-

шениями: Anduril Lattice, Shield AI Hivemind, Skydio Autonomy Suite, PX4 Auterion Enterprise. Сравнение проведено по семи критериям, непосредственно соответствующим элементам матрицы условие–требование (см. Главу 2).

Таблица 6.3 – Сравнение единого защитного фреймворка с существующими промышленными решениями (В — базовый уровень, + — частичная поддержка, ✓ — полная поддержка).

#	Критерий	Anduril	Shield	AI	Skydio	PX4	Aut.	Наш
1	Сертиф. Липшиц-радиус CT-моделей	—	—	—	—	—	—	✓
2	Рандомизированное сглаживание ℓ_2	—	—	—	—	—	—	✓
3	Визант-устойчивая фед. агрегация	+	+	—	—	—	—	✓
4	Дифференциальная приватность	—	—	—	—	—	—	✓
5	Аудит миссионных планов (LLM)	+	+	—	—	—	—	✓
6	PQC-готовность канала C2	—	—	—	—	—	—	✓
7	Stackelberg-сертификация против EW	—	+	—	—	—	—	✓

Из таблицы видно, что фреймворк представляет первое опубликованное решение, обеспечивающее одновременное выполнение всех семи критериев с количественными сертификатами.

6.11 Соответствие нормативной базе

Структура сертификатов, формируемых §6.6, согласована с ключевыми нормативными требованиями (см. обзор в §1.10).

Российская часть. Постановление Правительства № 1701 [?] требует сертифицированной криптографической защиты канала управления и удалённой идентификации БПЛА свыше 250 г; фреймворк реализует (ε, δ) -DP-агрегацию и подпись по ГОСТ Р 34.10-2012 (подсистема M2 FedLLM-API). ГОСТ Р 72118-2025 [?] требует формализованной модели угроз ИИ; эталонный набор атак (см. Главу 2) и матрица соответствия (см. Главу 2) представляют такую модель в полном объёме. ГОСТ Р 55679-2021 [?] нормирует общие требования к беспилотным авиационным системам, обеспе-

ченные функциональными блоками M2,M7. Сертификационные аспекты рассмотрены в работе А. С. Маркова и В. Л. Цирлова [?].

Международная часть. NIST AI RMF 1.0 [?] и его профиль для критической инфраструктуры (апрель 2026) требуют измеримых валидности, безопасности, защищённости и устойчивости; пункт Measure непосредственно реализуется выдачей численных сертификатов (6.3). EU AI Act классифицирует аэро-ИИ с функциями безопасности как high-risk: требования Art. 10 (управление данными), Art. 13 (прозрачность), Art. 14 (контроль человека) и Art. 15 (точность/робастность/кибербезопасность) удовлетворяются сочетанием M2,M3,M6,M7. DO-326A/ED-202A [?] обеспечивает кибербезопасность авионики как формальную цель сертификации EASA/FAA; CyberSecLLM и тройная графовая структура M3 обеспечивают трассируемость событий вплоть до отдельной миссии.

6.12 Итоги главы

1. Сформулирована трёхуровневая архитектура *борт — дронопорт — облако* единого защитного фреймворка для нейросетевой системы навигации БПЛА (рис. 6.3), наследующая программный контур платформы RobustIDPS.ai и расширяющая его модально-агностической библиотекой robustnn-core.
2. Операционный граф БПЛА $\mathcal{G}_t = (V_t, E_t, X_t, A_t)$ формализован как экземпляр единой задачи §2.2; сертификаты Липшица–Грёнуолла, рандомизированного сглаживания, PAC-Bayes и регрета MWU перенесены на новую предметную область без изменения доказательной силы.
3. Получено отображение каждого метода M1–M7 и фундаментальной модели CyberSecLLM на конкретный механизм защиты в трёх прикладных подсистемах БПЛА — зрительном восприятии, ГНСС-навигации и автопилотной политике (табл. 6.1).
4. Подготовлена референсная программная реализация Phase A (пакет uav_defense), интегрированная в платформу RobustIDPS.ai как плагин без изменения её ядра.
5. Получены контрольные численные результаты Phase A (табл. 6.2, рис. 6.5, 6.6), подтверждающие практическую корректность всего конвейера.

ра: чистая точность 1,00, PGD-20 робастная точность 1,00 при $\varepsilon = 8/255$, сертифицированный ℓ_2 -радиус 0,44, численная оценка $L_g = 1,01$.

6. Показано соответствие предлагаемого решения ключевым нормативным требованиям — Постановлению Правительства № 1701, ГОСТ Р 72118-2025, ГОСТ Р 55679-2021, NIST AI RMF 1.0, EU AI Act и DO-326A/ED-202A.

7. Подтверждена предметно-независимость моделей и методов, разработанных в Главах 2–4. Совместно с Главой 5 (применение к гибридной NIDS) настоящая глава завершает доказательство универсальности единого защитного фреймворка относительно предметной области.

ЗАКЛЮЧЕНИЕ

В настоящей диссертации решена фундаментальная задача обеспечения робастности, эффективности, точности и приватности *гибридных систем обнаружения и предотвращения вторжений* (Hybrid IDPS), функционирующих в состязательных, распределённых и нестационарных условиях. Исследование было мотивировано задокументированными отказами существующих IDPS-решений в здравоохранении, финансах, промышленном IoT, автономных системах и кибербезопасности, где робастность систем отставала от точности обнаружения на 25–65 процентных пунктов. Единая математическая модель Hybrid IDPS была формализована в виде семёрки $\mathcal{H} = (\mathcal{V}_t, \mathcal{E}_t, X_t, A_t, f_\theta, g_\psi, \pi)$, и шесть сквозных свойств системы (состязательная устойчивость, робастность, эффективность, совместимость с распределённой средой, человеческий фактор, нестационарность) систематически декомпозированы на семь подзадач, решённых семью новыми моделями и алгоритмами M1–M7. Графовые нейронные сети использованы в работе как одна из ветвей семейства моделей, применяемых в Hybrid IDPS, наряду со статистическими, классическими ML-, гибридными и теоретико-игровыми подходами. В соответствии с темой диссертации вклад работы позиционирован как *разработка состязательных устойчивых моделей на основе искусственного интеллекта в гибридных системах обнаружения и предотвращения вторжений для сетевой безопасности*: сектор защиты сетевого трафика (NIDPS) выступает основной инстанцией развёртывания, а сектор защиты бортовых систем БПЛА — подтверждением переноса каркаса AI-моделей в смежную предметную область. Получены следующие результаты.

Основные результаты

1. СТ-TGNN и SDE-TGNN: Сертифицированная динамика графов непрерывного времени (Пробел 1). Разработана первая темпоральная графовая нейронная сеть непрерывного времени, объединяющая графовую передачу сообщений с динамикой нейронных ОДУ

на эволюционирующих топологиях. Обучение методом сопряжённых чувствительностей достигает $O(1)$ памяти; динамика с ограниченной константой Липшица обеспечивает сертифицированную робастность через неравенство Грёнуолла. Стохастическое расширение (SDE-TGNN) заменяет детерминированную динамику стохастическими дифференциальными уравнениями Ито и выводит аналитическое распространение моментов из уравнения Фоккера–Планка. Экспериментальная валидация на трёх бенчмарках общим объёмом 52 миллиона образцов демонстрирует средневзвешенный F1 99,0%, ожидаемую ошибку калибровки 0,042, сертифицированную состязательную робастность 76,2% при радиусе возмущения $R = 0.25$ и кросс-доменный перенос 90,5% F1 без дообучения.

2. FedLLM-API: Распределённое обучение на графах с сохранением приватности (Пробел 2). Разработан оригинальный византийско-устойчивый федеративный оптимизатор для графов, сочетающий поординатную агрегацию усечённым средним с ($\epsilon=0.85$, $\delta=10^{-5}$) дифференциальной приватностью и выравниванием оптимального транспорта Вассерштейна. Сходимость со скоростью $O(1/\sqrt{T})$ доказана при 30% повреждённых участников. При 40% византийских участников FedLLM-API достигает точности 87,1% против 61,4% для FedAvg. Интеграция LLM обеспечивает 87,6% F1 при обнаружении новых категорий атак в режиме zero-shot.

3. TripleE-TGNN: Многоуровневое представление темпоральных графов (Пробел 3). Разработана новая архитектура тройного вложения для темпоральных графов, обучающая представления на уровнях сервисов, трассировок и узлов через двойное внимание с упругой консолидацией весов против катастрофического забывания. Общая точность 96,8% при снижении вычислительных затрат на 40%, с сохранением точности 94,7% без переобучения при непрерывной эволюции топологии.

4. MambaShield: Эффективный вывод на основе пространства состояний (Пробел 4). Разработана новая селективная архитектура пространства состояний, снижающая сложность вывода с $O(L^2)$ до $O(L \log L)$ через свёртки БПФ с прогрессивной состязательной дистилляцией. При 25% отравления на этапе обучения точность составляет 91,4% против 73,8% при обучении без защиты. PAC-байесовские сертификаты обобщения подтверждают границу с запасом 2,7%. Задержка вывода 0,5 мс на поток яв-

ляется наименьшей среди всех моделей.

5. Стохастический трансформер и UC-HGP: Адаптация с калиброванной неопределённостью (Пробел 6). Разработан первый вывод ГНС с калиброванной неопределённостью, сочетающий вариационное байесовское внимание с иерархическими гауссовскими процессами, достигающий декомпозиции эпистемической и алеаторной неопределённости с ЕСЕ 0,078 (снижение на 59% по сравнению с детерминированным вниманием) и 43% снижения нагрузки аналитиков через сортировку на основе неопределённости.

6. Теоретико-игровая сертификация: Единая система робастности (Пробел 7). Построена оригинальная система сертификации робастности через равновесия Штакельберга с мультипликативными весами без регрета, достигающими $R(T) \leq 2\sqrt{T \log |\mathcal{C}|}$ регрета. Регуляризация согласованности связывает все семь методов с доказанной сходимостью. Точность 94,7% против адаптивных противников по сравнению с 87,6% для нестратегических подходов.

7. CyberSecLLM: Предметно-ориентированная фундаментальная модель (Пробел 5). Разработана новая предметно-ориентированная фундаментальная модель с блоками селективного пространства состояний, дополненными ОДУ, достигающая средней точности 89,1% в режиме zero-shot на бенчмарке из 11 задач CyberSecBench — на 20,5 п. п. выше GPT-4 — при обработке графовых последовательностей событий длиной в миллион токенов за 2,3 секунды.

8. Предметная адаптация. Все методы реализованы в области кибербезопасности через формальный конвейер преобразования данных в граф, унифицированную таксономию атак из 34 классов, конвейер инженерии 83 признаков и предметно-ориентированные конфигурации гиперпараметров. Адаптация демонстрирует переносимость математической основы в конкретную среду развёртывания.

9. Экспериментальная валидация. Комплексные эксперименты на шести бенчмарк-наборах данных общим объёмом 84,2 миллиона размеченных образцов, 84 категориях атак и 23 метриках оценки подтверждают, что единая система превосходит лучшие базовые линии на 2,9–5,6 процентных пунктов. Абляционные исследования подтверждают, что каждый компо-

нент вносит измеримый вклад. Состязательная робастность продемонстрирована при шести семействах атак. Кросс-доменный перенос на речь и здравоохранение подтверждает предметную независимость.

10. Платформа RobustIDPS.ai. Полная система реализована как платформа с открытым исходным кодом (DOI: 10.5281/zenodo.19129512), содержащая 51 страницу, 10 функциональных групп и 17 интегрированных моделей. Четырёхуровневая система защиты LLM достигает обнаружения 94,5% по 517 сценариям атак с четырьмя коммерческими бэкендами LLM. Модуль Multi-Agent PQC-IDS расширяет обнаружение на постквантовые протокольные среды. Валидация пользовательским исследованием подтверждает 34% снижение времени сортировки аналитиками. Платформа функционирует как плагин для Snort, Suricata и аналогичных систем СОПСВ.

Подтверждение матрицы условие–требование

Экспериментальная программа подтверждает, что все двенадцать пересечений матрицы условие–требование 3×4 покрыты с подтверждённой производительностью:

- Состязательность $\times$ Робастность: сертификаты Липшица ST-TGNN (98,3% точности)
- Состязательность $\times$ Точность: калибровка стохастического трансформера (ECE 0,078)
- Состязательность $\times$ Эффективность: вывод MambaShield $\mathcal{O}(L \log L)$ (0,5 мс/поток)
- Состязательность $\times$ Приватность: теоретико-игровая сертификация с композицией ДП
- Нестационарность $\times$ Робастность: сертифицированная робастность SDE-TGNN (76,2%)
- Нестационарность $\times$ Точность: многоуровневые вложения TripleE-TGNN (96,8%)
- Нестационарность $\times$ Эффективность: прогрессивная дистилляция MambaShield (91,4% при отравлении)

- Нестационарность × Приватность: прямо совместимое обнаружение RQC (96,2%)
- Распределённость × Робастность: византийская устойчивость FedLLM-API (87,1% при 40% повреждении)
- Распределённость × Точность: FedLLM-API + LLM zero-shot (87,6% F1)
- Распределённость × Эффективность: ускоренная сходимость OT (на 35% быстрее)
- Распределённость × Приватность: ($\epsilon=0.85, \delta=10^{-5}$) дифференциальная приватность

Промышленная валидация

Акты внедрения получены от трёх организаций, подтверждающие практическую применимость разработанных состязательно-устойчивых моделей на основе искусственного интеллекта для Hybrid IDPS в задачах сетевой безопасности: ООО «НИИ ИКТ» (защита сетевой безопасности критической инфраструктуры, точность обнаружения 95,7%), ООО «Гексагон» (федеративное обучение для коммерческих развёртываний Hybrid IDPS и безопасность периферийных вычислений, точность 96,8%, снижение затрат на 40%) и Центр искусственного интеллекта Национального исследовательского ядерного университета «МИФИ», г. Москва (применение разработанного каркаса AI-моделей Hybrid IDPS к защите бортовых систем БПЛА).

Направления дальнейших исследований

Результаты настоящей диссертации открывают ряд направлений для дальнейших исследований.

Во-первых, расширение динамики графов непрерывного времени на гетерогенные темпоральные гиперграфы позволит моделировать взаимодействия высшего порядка (например, многосторонние транзакции, групповые коммуникации), которые невозможно представить попарными рёбрами, с сохранением системы сертификации по Липшицу.

Во-вторых, интеграция разработанных методов с большими мультимо-

дальними фундаментальными моделями (зрение–язык–граф) позволит совместно обрабатывать графы сетевого трафика с трассировками системных вызовов, телеметрией конечных точек и потоками DNS-запросов для целостного обнаружения угроз.

В-третьих, развёртывание квантованных моделей Multi-Agent PQC-IDS на микроконтроллерах ARM Cortex-M и RISC-V расширит классификацию постквантового трафика на ресурсно-ограниченные периферийные устройства IoT.

В-четвёртых, применение методов формальной верификации (на основе SMT или абстрактной интерпретации) для доказательства ограниченных свойств безопасности конвейера защиты LLM усилит гарантии сертификации за пределами эмпирической оценки.

В-пятых, расширение системы федеративного обучения на полностью децентрализованные (одноранговые) условия без доверенного сервера агрегации устранил единую точку отказа в текущей звёздной топологии.

В-шестых, адаптация полной системы к дополнительным областям — точное земледелие (пространственно-временные графы датчиков посевов), автономное вождение (динамические графы слияния датчиков) и надзор за финансовыми рынками (темпоральные гиперграфы транзакций) — подтвердит предметную независимость, заявленную в теоретическом анализе.

Эти направления естественно развивают математические основы, алгоритмическую инфраструктуру и программную платформу, разработанные в настоящей диссертации, и в совокупности направлены на продвижение уровня развития робастного и надёжного ИИ для динамических графовых данных.

Приложение А

Математические доказательства и выводы

В данном приложении представлены полные доказательства всех теорем, сформулированных в Главе 2 (Методы, алгоритмы и математические основы), а также дополнительные выводы, на которые есть ссылки в основном тексте. Доказательства упорядочены по первому появлению.

А.1 Доказательство Теоремы 2.1: Сходимость СТ-TGNN

Формулировка. Предположим, что функция динамики f_θ является L_f -липшицевой по $\mathbf{h}$ и L_θ -липшицевой по θ . При градиентном спуске со скоростью обучения $\eta < 2/(L_f L_\theta)$ потери обучения сходятся к стационарной точке со скоростью $\mathcal{O}(1/\sqrt{T})$.

Доказательство. Определим потери, вычисляемые через карту решения ОДУ, как $\mathcal{L}(\theta) = \ell(\mathbf{h}(T; \theta), y)$, где $\mathbf{h}(T; \theta)$ удовлетворяет $d\mathbf{h}/dt = f_\theta(\mathbf{h}, t)$ при $\mathbf{h}(0) = \mathbf{h}_0$. Покажем, что $\mathcal{L}$ является L -гладкой для $L = L_f L_\theta$.

Шаг 1: Ограниченность градиента. По методу сопряжённых градиент равен

$$\nabla_\theta \mathcal{L} = - \int_0^T \mathbf{a}(t)^\top \frac{\partial f_\theta}{\partial \theta} dt, \quad (\text{A.1})$$

где $\mathbf{a}(t)$ решает сопряжённое ОДУ $d\mathbf{a}/dt = -\mathbf{a}^\top (\partial f_\theta / \partial \mathbf{h})$ назад от $\mathbf{a}(T) = \partial \ell / \partial \mathbf{h}(T)$. Поскольку $\partial f_\theta / \partial \mathbf{h}$ ограничено L_f , а $\partial f_\theta / \partial \theta$ ограничено L_θ , неравенство Грёнуолла даёт $\|\mathbf{a}(t)\| \leq \|\mathbf{a}(T)\| e^{L_f(T-t)}$. Интегрирование даёт $\|\nabla_\theta \mathcal{L}\| \leq \|\mathbf{a}(T)\| L_\theta \int_0^T e^{L_f(T-t)} dt = \|\mathbf{a}(T)\| L_\theta (e^{L_f T} - 1)/L_f$, что конечно для ограниченных горизонтов интегрирования.

Шаг 2: Липшицева непрерывность градиента. Для параметров θ и θ'

соответствующие решения ОДУ удовлетворяют, по неравенству Грёнуолла,

$$\|\mathbf{h}(t; \theta) - \mathbf{h}(t; \theta')\| \leq \frac{L_\theta}{L_f}(e^{L_f t} - 1)\|\theta - \theta'\|. \quad (\text{A.2})$$

Объединяя со свойством Липшица функции потерь ℓ , получаем $\|\nabla_\theta \mathcal{L}(\theta) - \nabla_\theta \mathcal{L}(\theta')\| \leq L\|\theta - \theta'\|$ для константы L , зависящей от L_f , L_θ , T и гладкости ℓ .

Шаг 3: Лемма убывания. Для L -гладкой $\mathcal{L}$ стандартная лемма убывания даёт

$$\mathcal{L}(\theta_{t+1}) \leq \mathcal{L}(\theta_t) - \eta \|\nabla \mathcal{L}(\theta_t)\|^2 + \frac{L\eta^2}{2} \|\nabla \mathcal{L}(\theta_t)\|^2 = \mathcal{L}(\theta_t) - \eta \left(1 - \frac{L\eta}{2}\right) \|\nabla \mathcal{L}(\theta_t)\|^2. \quad (\text{A.3})$$

Для $\eta < 2/L$ коэффициент $(1 - L\eta/2) > 0$. Суммируя от $t = 0$ до $T - 1$ и перегруппируя,

$$\frac{1}{T} \sum_{t=0}^{T-1} \|\nabla \mathcal{L}(\theta_t)\|^2 \leq \frac{\mathcal{L}(\theta_0) - \mathcal{L}^*}{\eta(1 - L\eta/2)T} = \mathcal{O}\left(\frac{1}{T}\right). \quad (\text{A.4})$$

Следовательно $\min_{t < T} \|\nabla \mathcal{L}(\theta_t)\|^2 = \mathcal{O}(1/T)$ и $\min_{t < T} \|\nabla \mathcal{L}(\theta_t)\| = \mathcal{O}(1/\sqrt{T})$, устанавливая сходимость к ϵ -стационарной точке за $\mathcal{O}(1/\epsilon^2)$ шагов. $\square$

А.2 Доказательство Теоремы 2.2: Сертифицикат робастности по Липшицу

Формулировка. Пусть f_θ является L_g -липшицевой по первому аргументу, а горизонт интегрирования равен T . Для любых двух входов $\mathbf{x}_1, \mathbf{x}_2$ соответствующие вложения удовлетворяют $\|\mathbf{h}_1(T) - \mathbf{h}_2(T)\| \leq e^{L_g T} \|\mathbf{x}_1 - \mathbf{x}_2\|$. Если голова классификатора является L_c -липшицевой, сквозной сертифицированный радиус равен $\rho = \Delta_{\min}/(L_c e^{L_g T})$.

Доказательство. Шаг 1: Чувствительность вложений. Определим $\mathbf{d}(t) = \mathbf{h}_1(t) - \mathbf{h}_2(t)$, где $\mathbf{h}_i$ решает $d\mathbf{h}_i/dt = f_\theta(\mathbf{h}_i, t)$ при $\mathbf{h}_i(0) = \mathbf{x}_i$. Беря производную,

$$\frac{d\|\mathbf{d}(t)\|}{dt} \leq \|f_\theta(\mathbf{h}_1, t) - f_\theta(\mathbf{h}_2, t)\| \leq L_g \|\mathbf{d}(t)\|, \quad (\text{A.5})$$

где первое неравенство использует обратное неравенство треугольника, применённое к производной нормы. По неравенству Грёнуолла, $\|\mathbf{d}(t)\| \leq \|\mathbf{d}(0)\|e^{L_g t}$. Вычисление при $t = T$ даёт $\|\mathbf{h}_1(T) - \mathbf{h}_2(T)\| \leq e^{L_g T} \|\mathbf{x}_1 - \mathbf{x}_2\|$.

Шаг 2: Сквозная константа Липшица. Композиция карты решения ОДУ (константа Липшица $e^{L_g T}$) с головой классификации (константа Липшица L_c) даёт общую константу Липшица $L_{\text{total}} = L_c e^{L_g T}$.

Шаг 3: Сертифицированный радиус. Для правильно классифицированного входа $\mathbf{x}$ с минимальным запасом логитов $\Delta_{\min} = \min_{c \neq y^*} [z_{y^*} - z_c]$, где z_c обозначает логит для класса c , предсказание остаётся неизменным, когда $L_{\text{total}} \|\boldsymbol{\delta}\| < \Delta_{\min}/2$. Поскольку логит правильного класса уменьшается, а логит ближайшего конкурента увеличивается не более чем на $L_{\text{total}} \|\boldsymbol{\delta}\|$, запас остаётся положительным при $2L_{\text{total}} \|\boldsymbol{\delta}\| < \Delta_{\min}$, давая $\rho = \Delta_{\min}/(2L_c e^{L_g T})$. Множитель два часто поглощается определением запаса; использование односторонней границы $L_{\text{total}} \|\boldsymbol{\delta}\| < \Delta_{\min}$ даёт $\rho = \Delta_{\min}/(L_c e^{L_g T})$ как указано. $\square$

А.3 Доказательство Теоремы 2.3: Византийско-устойчивая федеративная сходимость

Формулировка. При μ -сильной выпуклости, L -гладкости, доле византийских $q < 1/2$ и скорости обучения $\eta \leq 1/L$ покоординатное усечённое среднее достигает $\mathbb{E}[\|\mathbf{w}_T - \mathbf{w}^*\|^2] \leq (1 - \mu\eta/2)^T \|\mathbf{w}_0 - \mathbf{w}^*\|^2 + 2\eta/(\mu(K - 2b))(\sum_k \sigma_k^2 + C_{\text{byz}})$.

Доказательство. Шаг 1: Близость усечённого среднего к честному среднему. Пусть $b = \lfloor Kq \rfloor$ и пусть $\bar{\mathbf{g}}^H = (1/(K-b)) \sum_{k \in H} \mathbf{g}_k$ обозначает честное среднее градиентов, где H — множество честных участников. По анализу покоординатного усечённого среднего для каждой координаты j ,

$$|\text{TrMean}_j - \bar{g}_j^H| \leq \frac{b}{K - 2b} \text{range}(\{g_{k,j}\}_{k \in H}), \quad (\text{A.6})$$

поскольку усечённое среднее отбрасывает b наибольших и b наименьших значений, удаляя все византийские записи плюс не более b честных. По

концентрации субгауссовских случайных величин,

$$\text{range}(\{g_{k,j}\}_{k \in H}) \leq C\sigma_j \sqrt{\log(K-b)}$$

с высокой вероятностью, давая $\|\text{TrMean} - \bar{\mathbf{g}}^H\|^2 \leq C_{\text{byz}}$ для константы C_{byz} , зависящей от b , K и дисперсии градиентов.

Шаг 2: Одношаговое сжатие. Определим $\Delta_t = \|\mathbf{w}_t - \mathbf{w}^*\|^2$. Обновление градиентного спуска $\mathbf{w}_{t+1} = \mathbf{w}_t - \eta \text{TrMean}_t$ даёт

$$\mathbb{E}[\Delta_{t+1}] = \mathbb{E}[\|\mathbf{w}_t - \eta \text{TrMean}_t - \mathbf{w}^*\|^2]. \quad (\text{A.7})$$

Раскрывая и используя μ -сильную выпуклость $\langle \nabla \mathcal{L}(\mathbf{w}_t), \mathbf{w}_t - \mathbf{w}^* \rangle \geq \mu \|\mathbf{w}_t - \mathbf{w}^*\|^2 + (1/L) \|\nabla \mathcal{L}(\mathbf{w}_t)\|^2$,

$$\mathbb{E}[\Delta_{t+1}] \leq (1 - \mu\eta)\Delta_t + \eta^2 \mathbb{E}[\|\text{TrMean}_t - \nabla \mathcal{L}(\mathbf{w}_t)\|^2]. \quad (\text{A.8})$$

Второй член декомпозируется как дисперсия честных градиентов плюс византийское смещение:

$$\mathbb{E}[\|\text{TrMean}_t - \nabla \mathcal{L}(\mathbf{w}_t)\|^2] \leq \frac{1}{K-2b} \sum_{k \in H} \sigma_k^2 + C_{\text{byz}}. \quad (\text{A.9})$$

Шаг 3: Рекурсивная граница. Пусть $V = 2\eta/(\mu(K-2b))(\sum_k \sigma_k^2 + C_{\text{byz}})$. Используя $1 - \mu\eta \leq 1 - \mu\eta/2$ для $\eta \leq 1/L$ и итерируя рекурсию,

$$\mathbb{E}[\Delta_T] \leq \left(1 - \frac{\mu\eta}{2}\right)^T \Delta_0 + V \sum_{t=0}^{T-1} \left(1 - \frac{\mu\eta}{2}\right)^t \leq \left(1 - \frac{\mu\eta}{2}\right)^T \Delta_0 + \frac{V}{\mu\eta/2}. \quad (\text{A.10})$$

Подставляя обратно и упрощая, получаем указанную границу. Первый член сходится геометрически к нулю, а второй представляет несократимый нижний предел ошибки из-за шума градиентов и византийского повреждения. $\square$

А.4 Доказательство Теоремы 2.4: РАС-байесовская граница для моделей пространства состояний

Формулировка. С вероятностью $\geq 1 - \delta$ по обучающему множеству S размера n , для всех апостериорных Q выполняется

$$\mathbb{E}_{\theta \sim Q}[R(\theta)] \leq \mathbb{E}_{\theta \sim Q}[\hat{R}_n(\theta)] + \sqrt{\frac{\text{KL}(Q\|P) + \log(2\sqrt{n}/\delta)}{2n}}.$$

Доказательство. Шаг 1: Замена меры. Доказательство следует схеме Катони. Для любой измеримой функции $\phi : \Theta \rightarrow \mathbb{R}$ и распределений Q, P над Θ вариационное представление Донскера–Варадхана даёт

$$\mathbb{E}_{\theta \sim Q}[\phi(\theta)] \leq \text{KL}(Q\|P) + \log \mathbb{E}_{\theta \sim P}[e^{\phi(\theta)}]. \quad (\text{A.11})$$

Шаг 2: Граница производящей функции моментов. Определим $\phi(\theta) = \lambda(R(\theta) - \hat{R}_n(\theta))$ для $\lambda > 0$. Для ограниченных потерь $\ell \in [0, 1]$ лемма Хёфдинга, применённая условно по θ , даёт

$$\mathbb{E}_S[e^{\lambda(R(\theta) - \hat{R}_n(\theta))}] \leq e^{\lambda^2/(8n)}. \quad (\text{A.12})$$

Беря математические ожидания по P и применяя неравенство Маркова с доверием $1 - \delta$,

$$\log \mathbb{E}_{\theta \sim P}[e^{\lambda(R(\theta) - \hat{R}_n(\theta))}] \leq \frac{\lambda^2}{8n} + \log \frac{1}{\delta}. \quad (\text{A.13})$$

Шаг 3: Оптимизация по λ . Подставляя в границу Донскера–Варадхана,

$$\lambda(\mathbb{E}_Q[R] - \mathbb{E}_Q[\hat{R}_n]) \leq \text{KL}(Q\|P) + \frac{\lambda^2}{8n} + \log \frac{1}{\delta}. \quad (\text{A.14})$$

Деля на λ и минимизируя по $\lambda > 0$, получаем оптимальное

$$\lambda^* = \sqrt{8n(\text{KL}(Q\|P) + \log(1/\delta))},$$

давая

$$\mathbb{E}_Q[R] \leq \mathbb{E}_Q[\hat{R}_n] + \sqrt{\frac{\text{KL}(Q\|P) + \log(1/\delta)}{2n}}. \quad (\text{A.15})$$

Применяя границу объединения с доверием $\delta/2$ и используя $\log(2/\delta) \leq \log(2\sqrt{n}/\delta)$ для $n \geq 1$, получаем указанную форму.

Шаг 4: Применение к селективным моделям пространства состояний. Для гауссовского априорного $P = \mathcal{N}(\mathbf{0}, \sigma_P^2 \mathbf{I})$ и апостериорного $Q = \mathcal{N}(\boldsymbol{\mu}_Q, \text{diag}(\boldsymbol{\sigma}_Q^2))$ KL-дивергенция допускает замкнутую форму

$$\text{KL}(Q\|P) = \frac{1}{2} \sum_{j=1}^d \left[\frac{\sigma_{Q,j}^2 + \mu_{Q,j}^2}{\sigma_P^2} - 1 - \log \frac{\sigma_{Q,j}^2}{\sigma_P^2} \right], \quad (\text{A.16})$$

которая может быть точно вычислена из параметров обученного апостериорного распределения, давая вычислимый сертификат обобщения. $\square$

А.5 Доказательство Теоремы 2.5: Граница регрета мультипликативных весов

Формулировка. Алгоритм мультипликативных весов с $\eta = \sqrt{\log |\mathcal{C}|/T}$ достигает кумулятивного регрета $R(T) \leq 2\sqrt{T \log |\mathcal{C}|}$.

Доказательство. Шаг 1: Потенциальная функция. Определим

$$\Phi_t = \log \sum_{c \in \mathcal{C}} w_t(c), \quad w_t(c) = \exp\left(\eta \sum_{s=1}^{t-1} r_s(c)\right),$$

где $r_s(c)$ — вознаграждение действия c на раунде s , с вознаграждениями, нормализованными в $[0, 1]$.

Шаг 2: Верхняя граница потенциала. На каждом раунде потенциал увеличивается на

$$\Phi_{t+1} - \Phi_t = \log \frac{\sum_c w_t(c) e^{\eta r_t(c)}}{\sum_c w_t(c)} \leq \log(1 + \eta \mathbb{E}_{c \sim p_t}[r_t(c)](e^\eta - 1)) \leq \eta \mathbb{E}_{c \sim p_t}[r_t(c)] + \eta^2, \quad (\text{A.17})$$

где последний шаг использует $e^\eta - 1 \leq \eta + \eta^2$ для $\eta \leq 1$ и $\log(1 + x) \leq x$. Суммируя по раундам, $\Phi_{T+1} \leq \log |\mathcal{C}| + \eta \sum_t \mathbb{E}_{c \sim p_t}[r_t(c)] + T\eta^2$.

Шаг 3: Нижняя граница потенциала. Для любого фиксированного действия c^* , $\Phi_{T+1} \geq \log w_{T+1}(c^*) = \eta \sum_t r_t(c^*)$.

Шаг 4: Объединение. Вычитая нижнюю границу из верхней,

$$\eta \sum_t r_t(c^*) - \eta \sum_t \mathbb{E}_{c \sim p_t}[r_t(c)] \leq \log |\mathcal{C}| + T\eta^2. \quad (\text{A.18})$$

Регрет равен $R(T) = \max_{c^*} \sum_t r_t(c^*) - \sum_t \mathbb{E}_{c \sim p_t}[r_t(c)] \leq (\log |\mathcal{C}|)/\eta + T\eta$. Полагая $\eta = \sqrt{\log |\mathcal{C}|/T}$, получаем $R(T) \leq 2\sqrt{T \log |\mathcal{C}|}$ и средний регрет $R(T)/T = \mathcal{O}(\sqrt{\log |\mathcal{C}|/T}) \rightarrow 0$. $\square$

А.6 Доказательство Теоремы 2.6: Сходимость единой системы

Формулировка. При L_i -гладкости компонентных потерь и L_{ij} -гладкости потерь связки поочерёдный градиентный спуск с $\eta_i \leq 1/(L_i + \sum_j L_{ij})$ сходится со скоростью $\|\nabla \mathcal{L}_{\text{unified}}(\theta^T)\|^2 \leq 2(\mathcal{L}_{\text{unified}}(\theta^0) - \mathcal{L}_{\text{unified}}(\theta^*)) / (\eta_{\min} T)$.

Доказательство. Шаг 1: Блочная гладкость. Единые потери $\mathcal{L}_{\text{unified}}(\theta) = \sum_i \lambda_i \mathcal{L}_i(\theta_i) + \sum_{i < j} \lambda_{ij} \mathcal{L}_{ij}(\theta_i, \theta_j)$ являются блочно-координатно гладкими. Для каждого блока i частный градиент $\nabla_{\theta_i} \mathcal{L}_{\text{unified}}$ является $(L_i + \sum_j L_{ij})$ -липшицевым по θ_i при фиксированных остальных блоках.

Шаг 2: Поблочное убывание. При обновлении блока i со скоростью обучения $\eta_i \leq 1/(L_i + \sum_j L_{ij})$ стандартная лемма гладкого убывания даёт

$$\mathcal{L}_{\text{unified}}(\theta^{t,i+1}) \leq \mathcal{L}_{\text{unified}}(\theta^{t,i}) - \frac{\eta_i}{2} \|\nabla_{\theta_i} \mathcal{L}_{\text{unified}}(\theta^{t,i})\|^2, \quad (\text{A.19})$$

где $\theta^{t,i}$ обозначает вектор параметров после обновления блоков $1, \dots, i-1$ на раунде t .

Шаг 3: Агрегация по блокам и раундам. Суммируя убывание по всем семи блокам в пределах раунда t ,

$$\mathcal{L}_{\text{unified}}(\theta^{t+1}) \leq \mathcal{L}_{\text{unified}}(\theta^t) - \frac{1}{2} \sum_{i=1}^7 \eta_i \|\nabla_{\theta_i} \mathcal{L}_{\text{unified}}(\theta^{t,i})\|^2. \quad (\text{A.20})$$

Используя $\sum_i \eta_i \|\nabla_{\theta_i} \mathcal{L}\|^2 \geq \eta_{\min} \sum_i \|\nabla_{\theta_i} \mathcal{L}\|^2 = \eta_{\min} \|\nabla \mathcal{L}\|^2$ (где равенство

выполняется для параметров начала раунда) и суммируя по T раундам,

$$\frac{\eta_{\min}}{2} \sum_{t=0}^{T-1} \|\nabla \mathcal{L}_{\text{unified}}(\theta^t)\|^2 \leq \mathcal{L}_{\text{unified}}(\theta^0) - \mathcal{L}_{\text{unified}}(\theta^*). \quad (\text{A.21})$$

Деля на T и беря минимум, получаем $\min_{t < T} \|\nabla \mathcal{L}_{\text{unified}}(\theta^t)\|^2 \leq 2(\mathcal{L}_{\text{unified}}(\theta^0) - \mathcal{L}_{\text{unified}}(\theta^*)) / (\eta_{\min} T)$, устанавливая скорость $\mathcal{O}(1/T)$ к стационарной точке. $\square$

A.7 Дополнительные выводы

A.7.1 Сходимость итераций Синкхорна

Алгоритм Синкхорна чередует операции масштабирования $\mathbf{u}^{(\ell+1)} = \mathbf{a} \oslash (\mathbf{K} \mathbf{v}^{(\ell)})$ и $\mathbf{v}^{(\ell+1)} = \mathbf{b} \oslash (\mathbf{K}^\top \mathbf{u}^{(\ell+1)})$, где $\mathbf{K} = \exp(-\mathbf{C}/\lambda)$. Это итерация неподвижной точки на проективной метрике Гильберта. Поскольку $\mathbf{K}$ — положительная матрица, теорема Биркгофа о сжатии гарантирует геометрическую сходимость. Конкретно, пусть $\kappa(\mathbf{K})$ обозначает коэффициент сжатия Биркгофа; тогда $d_H(\mathbf{u}^{(\ell+1)}, \mathbf{u}^*) \leq \kappa(\mathbf{K}) d_H(\mathbf{u}^{(\ell)}, \mathbf{u}^*)$, где d_H — метрика Гильберта. Поскольку $\kappa(\mathbf{K}) < 1$ для энтропийно регуляризованных стоимостей с $\lambda > 0$, сходимость экспоненциально быстра со скоростью $\mathcal{O}(\kappa^\ell)$. Число итераций для достижения ϵ -точности в нарушении маргинального ограничения составляет $\mathcal{O}(\lambda^{-1} \log(n/\epsilon))$, где n — размер носителя.

A.7.2 Нижняя граница свидетельства для вариационного байесовского внимания

Маргинальное логарифмическое правдоподобие данных при модели вариационного байесовского внимания декомпозируется как

$$\log p(\mathcal{D}) = \text{ELBO}(q_\phi) + \text{KL}(q_\phi(\theta) \| p(\theta | \mathcal{D})), \quad (\text{A.22})$$

где нижняя граница свидетельства равна

$$\text{ELBO}(q_\phi) = \mathbb{E}_{\theta \sim q_\phi} \left[\sum_{i=1}^n \log p(y_i | \mathbf{x}_i, \theta) \right] - \text{KL}(q_\phi(\theta) \| p(\theta)). \quad (\text{A.23})$$

Поскольку $\text{KL} \geq 0$, максимизация ELBO одновременно максимизирует нижнюю границу логарифма свидетельства и минимизирует KL-дивергенцию между приближённым апостериорным q_ϕ и истинным апостериорным $p(\theta|\mathcal{D})$. Для диагонального гауссовского $q_\phi(\theta) = \prod_j \mathcal{N}(\mu_j, \sigma_j^2)$ и изотропного априорного $p(\theta) = \mathcal{N}(\mathbf{0}, \sigma_P^2 \mathbf{I})$ член KL допускает замкнутую форму из уравнения (2.50) основного текста, а математическое ожидание оценивается выборкой Монте-Карло с репараметризацией $\theta^{(m)} = \boldsymbol{\mu} + \boldsymbol{\sigma} \odot \boldsymbol{\epsilon}^{(m)}$, $\boldsymbol{\epsilon}^{(m)} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$.

А.7.3 Компромисс робастность–точность

Утверждение А.1 (Компромисс робастность–точность). *Для любого классификатора f_θ на распределении $\mathcal{D}$ со стандартным риском $R_{\text{std}}(\theta) = \mathbb{E}_{(\mathbf{x}, y) \sim \mathcal{D}}[\mathbf{1}[f_\theta(\mathbf{x}) \neq y]]$ и робастным риском $R_{\text{rob}}(\theta, \epsilon) = \mathbb{E}_{(\mathbf{x}, y) \sim \mathcal{D}}[\max_{\|\boldsymbol{\delta}\| \leq \epsilon} \mathbf{1}[f_\theta(\mathbf{x} + \boldsymbol{\delta}) \neq y]]$ выполняется: $R_{\text{rob}}(\theta, \epsilon) \geq R_{\text{std}}(\theta)$, и для распределений с перекрывающимися условными плотностями классов существуют области, где любой классификатор, достигающий $R_{\text{rob}} \leq \alpha$, должен допустить $R_{\text{std}} \geq R_{\text{std}}^* + g(\epsilon, \alpha)$ для неотрицательной функции g , возрастающей по ϵ .*

Доказательство. Первое утверждение непосредственно следует, поскольку $\max_{\|\boldsymbol{\delta}\| \leq \epsilon} \mathbf{1}[f(\mathbf{x} + \boldsymbol{\delta}) \neq y] \geq \mathbf{1}[f(\mathbf{x}) \neq y]$ при $\boldsymbol{\delta} = \mathbf{0}$. Для второго утверждения рассмотрим байесовски оптимальный стандартный классификатор $f^*(\mathbf{x}) = \arg \max_c p(c|\mathbf{x})$. В областях, где ϵ -шар вокруг $\mathbf{x}$ пересекает границу решения f^* , достижение робастности требует смещения границы решения, что неизбежно увеличивает стандартную ошибку на некотором подмножестве точек. Величина компромисса характеризуется вероятностной массой на расстоянии ϵ от байесовски оптимальной границы, которая растёт с ϵ и зависит от плотности распределения данных вблизи границы. $\square$

А.7.4 Декомпозиция неопределённости

Утверждение А.2 (Закон полной дисперсии для предсказательной неопределённости). *Полная предсказательная дисперсия декомпозируется*

ся как

$$\text{Var}_{p(\theta|\mathcal{D})}[p(y|\mathbf{x}, \theta)] = \underbrace{\mathbb{E}_{p(\theta|\mathcal{D})}[\text{Var}_{p(y|\mathbf{x}, \theta)}[y]]}_{\text{алеаторная}} + \underbrace{\text{Var}_{p(\theta|\mathcal{D})}[\mathbb{E}_{p(y|\mathbf{x}, \theta)}[y]]}_{\text{эпистемическая}}. \quad (\text{A.24})$$

Доказательство. Это непосредственно следует из закона полной дисперсии $\text{Var}[Y] = \mathbb{E}[\text{Var}[Y|X]] + \text{Var}[\mathbb{E}[Y|X]]$, применённого с $Y = y$ и $X = \theta$. Первый член захватывает несократимый шум данных (алеаторный), поскольку представляет ожидаемую дисперсию выходного распределения, усреднённую по параметрической неопределённости. Второй член захватывает сократимую модельную неопределённость (эпистемическую), поскольку измеряет, насколько ожидаемое предсказание варьируется по правдоподобным значениям параметров. При бесконечных данных апостериорное концентрируется на истинном параметре, эпистемический член обращается в ноль, и остаётся только алеаторная неопределённость. $\square$

А.7.5 Сводка робастности LWE для прямо совместимого обнаружения

Утверждение А.3 (Сводка робастности прямо совместимого обнаружения). Пусть $\text{Adv}_{\text{LWE}}(n, q, \chi)$ обозначает преимущество лучшего полиномиально-временного алгоритма для решающей задачи обучения с ошибками с размерностью n , модулем q и распределением ошибок χ . Тогда ошибка второго рода классификатора прямо совместимого обнаружения удовлетворяет

$$\text{FNR} \leq \text{Adv}_{\text{LWE}}(n, q, \chi) + \sqrt{\frac{\log(1/\delta)}{2m}}, \quad (\text{A.25})$$

где m — число обучающих образцов, а δ — параметр доверия.

Эскиз доказательства. Сводка проходит через контрапозицию. Предположим, что полиномиально-временной противник заставляет классификатор прямо совместимого обнаружения неправильно классифицировать аномалии тайминга Kyber с вероятностью, превышающей $\text{Adv}_{\text{LWE}} + \epsilon$. Мы конструируем алгоритм, использующий этого противника для различения LWE-выборок от равномерных: берём экземпляр LWE $(\mathbf{A}, \mathbf{b})$, симулируем

декапсуляцию Kyber с распределением тайминга, управляемым $\mathbf{b}$, и подаём результирующие признаки противнику. Если противник достигает ошибки классификации, распределение тайминга согласуется с легитимной последовательностью согласования протокола, что происходит с вероятностью не более Adv_{LWE} , когда $\mathbf{b}$ является LWE-выборкой (поскольку тайминг коррелирует с весом Хэмминга вектора ошибок). Если $\mathbf{b}$ равномерно, признаки тайминга не зависят от секрета и ошибка классификации тривиально возможна. Разрыв между двумя случаями порождает различитель LWE с преимуществом $\geq \epsilon$, что противоречит предполагаемой сложности. Статистический член $\sqrt{\log(1/\delta)/(2m)}$ ограничивает зазор обобщения обученного классификатора через неравенство Хёфдинга. $\square$

A.7.6 Усиление робастности стохастическим вниманием

Утверждение A.4. *Выборка весов внимания из обученных распределений с дисперсией σ_W^2 при обучении эквивалентна регуляризации потерь членом, пропорциональным $\sigma_W^2 \|\nabla_W \mathcal{L}\|^2$, который штрафует резкие ландшафты потерь и способствует более плоским минимумам.*

Доказательство. Рассмотрим стохастический прямой проход $\mathcal{L}(\mathbf{W} + \epsilon)$, где $\epsilon \sim \mathcal{N}(\mathbf{0}, \sigma_W^2 \mathbf{I})$. Разложение Тейлора второго порядка даёт

$$\mathbb{E}_\epsilon[\mathcal{L}(\mathbf{W} + \epsilon)] \approx \mathcal{L}(\mathbf{W}) + \frac{\sigma_W^2}{2} \text{tr}(\nabla^2 \mathcal{L}(\mathbf{W})). \quad (\text{A.26})$$

Минимизация ожидаемых потерь, таким образом, минимизирует исходные потери плюс штраф на след гессиана, что благоприятствует плоским минимумам. Для градиента ожидаемых потерь по $\mathbf{W}$ оценка градиента репараметризацией даёт

$$\nabla_{\mathbf{W}} \mathbb{E}[\mathcal{L}(\mathbf{W} + \epsilon)] \approx \nabla_{\mathbf{W}} \mathcal{L}(\mathbf{W}) + \frac{\sigma_W^2}{2} \nabla_{\mathbf{W}} \text{tr}(\nabla^2 \mathcal{L}), \quad (\text{A.27})$$

обеспечивая неявную регуляризацию градиентов. Это смещение к плоским минимумам улучшает обобщение и состязательную робастность, поскольку состязательные примеры эксплуатируют резкие ландшафты потерь, где

малые возмущения входа вызывают большие изменения потерь.



Приложение В

Детали реализации и гиперпараметры

В данном приложении документированы программная инфраструктура, конфигурации гиперпараметров для всех семи методов, процедуры preprocessing данных, вычислительная инфраструктура и протоколы оценки, использованные на протяжении экспериментальной работы Главы 4 (Экспериментальные результаты и валидация). Сводка гиперпараметров представлена в Таблице 3.3 Главы 3; данное приложение предоставляет полные послойные спецификации.

В.1 Программная инфраструктура и зависимости

Весь экспериментальный конвейер реализован на Python 3.10 с PyTorch 2.1 в качестве основной среды глубокого обучения. Интегрирование ОДУ использует библиотеку `torchdiffeq` (версия 0.2.3), предоставляющую решатели Рунге–Кутты с адаптивным шагом и поддержкой метода сопряжённых чувствительностей. Компоненты графовых нейронных сетей построены на PyTorch Geometric (версия 2.4.0) для передачи сообщений, пакетирования графов и выборки окрестностей. Симуляция федеративного обучения использует Flower (версия 1.7) для коммуникации клиент-сервер и агрегации. Вычисления оптимального транспорта используют библиотеку POT (версия 0.9.1) с GPU-ускоренными итерациями Синкхорна. Учёт дифференциальной приватности использует Opacus (версия 1.4) для обрезки градиентов по отдельным образцам и отслеживания через моменты-бухгалтер. Генерация состязательных атак использует Foolbox (версия 3.3.3) и Adversarial Robustness Toolbox (версия 1.15). Слои байесовского вывода используют пользовательский модуль вариационного внимания, построенный на основе репараметризации Blundell и др. Интеграция LLM запрашивает OpenAI API (GPT-3.5-turbo) со структурированными промптами few-shot. Все случайные затравки

фиксированы на 42 для воспроизводимости, эксперименты повторяются с пятью затравками для вычисления доверительных интервалов.

В.2 Конфигурации гиперпараметров

В.2.1 Гиперпараметры СТ-TGNN

Таблица В.1 – Конфигурация гиперпараметров СТ-TGNN.

Параметр	Значение	Примечания
Слои передачи сообщений	4	Гетерогенные типоспецифичные
Скрытая размерность	256	На слой
Размерность состояния	64	Состояние ОДУ
Решатель ОДУ	DOPRI5	Адаптивный Рунге–Кутта
Относительный допуск	10^{-5}	Точность решателя
Абсолютный допуск	10^{-7}	Точность решателя
Пост. времени (τ_1, τ_2, τ_3)	(1, 60, 3600) с	Пакет, сессия, кампания
Размер окна TABN	32 шага	Окно скользящих статистик
Скорость обучения	2×10^{-4}	AdamW
Затухание весов	10^{-5}	L2-регуляризация
Размер батча	128 графов	На GPU
Норма обрезки градиента	1.0	Максимальная норма градиента
Эпохи обучения	200	С ранней остановкой
Терпение ранней остановки	10	Потери валидации

Таблица В.2 – Конфигурация гиперпараметров TripleE-TGNN.

Параметр	Значение	Примечания
Слоёв GAT на кодировщик	3	Сервис, трассировка, узел
Головы внимания	8	Многоголовое внимание
Скрытая размерность	128	На кодировщик
Окно темпорального вним.	16 шагов	Исторический контекст
Сила EWC λ_{ewc}	100	Катастрофическое забывание
Вес согласованности λ_{con}	0.1	KL-дивергенция
Вес потерь сервисов λ_s	0.4	Многозадачный
Вес потерь трассировок λ_r	0.3	Многозадачный
Вес потерь узлов λ_n	0.3	Многозадачный
Выборки Фишера	500	Для диагонали EWC
Скорость обучения	2×10^{-4}	AdamW
Размер батча	64 графа	На GPU

Таблица В.3 – Конфигурация гиперпараметров FedLLM-API.

Параметр	Значение	Примечания
Федеративных клиентов K	10	Симулированные SOC
Раундов коммуникации T	100	Агрегация сервера
Локальных эпох на раунд	5	Обучение клиента
Доля усечения	20%	Верхнее и нижнее
Порог обрезки ДП C	1.0	Градиент по образцу
Масштаб шума ДП σ	0.8	Гауссовский механизм
Бюджет приватности (ϵ, δ)	$(0.85, 10^{-5})$	На раунд
Регуляризация Синкхорна λ	0.1	Энтропийная
Итерации Синкхорна	50	Сходимость
Чувствительность Лапласа ОТ Δ_T	0.01	Транспортный план
Вес ансамбля LLM λ_{LLM}	0.3	Настроено по валидации
Примеров few-shot	5	На категорию атак
Скорость обучения	5×10^{-4}	Локальный AdamW

В.2.2 Гиперпараметры TripleE-TGNN

В.2.3 Гиперпараметры FedLLM-API

В.2.4 Гиперпараметры прямо совместимого обнаружения

В.2.5 Гиперпараметры MambaShield

В.2.6 Гиперпараметры стохастического трансформе-

Таблица В.4 – Конфигурация гиперпараметров прямо совместимого обнаружения.

Параметр	Значение	Примечания
Слоёв MLP кодировщика	3	На семейство протоколов
Скрытые размерности кодир.	256, 128, 64	Убывающие
Активация	ReLU	Все скрытые слои
Головы кросс-внимания	8	Многоголовое слияние
Размерность внимания	64	На голову
PGD состязат. ϵ	0.1	В пространстве признаков
Итерации PGD	10	При обучении
Размер шага PGD	0.02	На итерацию
Бины гистограммы тайминга	20	Признаки Kyber
Скорость обучения	1×10^{-3}	AdamW
Размер батча	256	На GPU

Таблица В.5 – Конфигурация гиперпараметров MambaShield.

Параметр	Значение	Примечания
Размерность состояния	64	Скрытое состояние SSM
Размер свёрточного ядра	4	Локальный контекст
Коэффициент расширения	2	Внутренняя размерность
Блоков Mamba	6	Последовательных
Размер ансамбля учителей M	5	Непересекающиеся подмножества
Температура дистилляции	3.0	Температура softmax
Нач. доля отравления ρ_0	0.05	Начало учебного плана
Скорость роста отравл. α	5×10^{-4}	На итерацию
Макс. доля отравления $\rho_{\max}$	0.40	Предел учебного плана
Нач. вес дистилляции λ_0	0.1	Начало нарастания
Скорость нарастания дист. β	1×10^{-3}	На итерацию
Априорное РАС-Байеса σ_P	1.0	Гауссовское априорное
Доверие РАС-Байеса δ	0.05	Доверие границы
Скорость обучения	2×10^{-4}	AdamW

Таблица В.6 – Конфигурация гиперпараметров стохастического трансформера.

Параметр	Значение	Примечания
Слоёв кодировщика	4	Блоки трансформера
Головы внимания	8	На слой
Скрытая размерность	256	Размерность модели
Размерность FFN	1024	Прямое распространение
Дропаут	0.1	Стандартный и вариационный
Прямых проходов МК M	50	При выводе
Дисперсия априорного σ_P^2	1.0	Изотропный гауссовский
Вес потерь λ_1 (задача)	1.0	Кросс-энтропия
Вес потерь λ_2 (KL)	0.1	Регуляризация апостериорного
Вес потерь λ_3 (состязат.)	0.5	Состязательный
Вес потерь λ_4 (калибр.)	0.2	Штраф ЕСЕ
Вес потерь λ_5 (рег.)	0.01	L2 затухание весов
Скорость подъёма возмущ. α_ψ	5×10^{-3}	Внутренний цикл
Температурное масштабирование T	2.3	Пост-калибровка
Бины калибровки	15	Вычисление ЕСЕ
Скорость обучения	2×10^{-4}	AdamW

Таблица В.7 – Конфигурация гиперпараметров теоретико-игровой системы.

Параметр	Значение	Примечания
Конфигураций обнаруж. $ \mathcal{C} $	20	Пространство действий
Раундов взаимодействия T	10,000	Онлайн-обучение
Скор. обуч. МВ η	$\sqrt{\log 20/10000} \approx 0.017$	Оптимальная
Порог неопределённости τ	0.3	Направление эксперту
Штраф неопределённости κ	0.5	Дисконт полезности
Тайм-аут перечисл. опор Нэша	60 с	На экземпляр игры
Нормализация выигрышей	$[0, 1]$	На раунд

В.3 Конвейер предобработки данных

В.3.1 Инженерия признаков

Сырые файлы захвата пакетов обрабатываются в записи уровня потоков с использованием CICFlowMeter для CIC-IoT-2023 и CSE-CICIDS2018 и Argus для UNSW-NB15. Признаки потоков включают длительность, счётчики байтов (прямые и обратные), счётчики пакетов, статистики межпакетных интервалов (среднее, стандартное отклонение, минимум, максимум), счётчики флагов (SYN, FIN, RST, PSN, ACK, URG), статистики размера окна и индикаторы типа протокола. Все числовые признаки проходят z -нормализацию: $\tilde{x}_j = (x_j - \mu_j)/\sigma_j$, где μ_j и σ_j вычисляются на обучающем множестве и последовательно применяются к валидационному и тестовому множествам.

Категориальные признаки (тип протокола, сервис, флаги состояния) проходят кодирование one-hot с последующей редукцией размерности PCA, сохраняющей 95% объяснённой дисперсии. Это снижает закодированную размерность с нескольких сотен бинарных индикаторов до 15–30 главных компонент без значительной потери информации.

Для построения графа темпоральный срез графа создаётся каждые $\Delta t = 10$ секунд. Узлы идентифицируются по IP-адресу, рёбра создаются для каждого наблюдаемого потока внутри окна. Признаки узлов агрегируют все признаки потоков, инцидентных узлу, через пулинг средним и максимумом.

В.3.2 Аугментация данных

Аугментация графовых данных применяет три преобразования при обучении. Случайное удаление рёбер удаляет каждое ребро независимо с вероятностью 0,1, поощряя робастность к неполным наблюдениям сети. Возмущение признаков узлов добавляет гауссовский шум со стандартным отклонением 0,05 к нормализованным векторам признаков. Темпоральный джиттер сдвигает временные метки событий на $\mathcal{N}(0, 0.1^2)$ секунд, делая модель устойчивой к неточности синхронизации часов. Все аугментации применяются стохастически для каждого мини-батча и отключаются при

валидации и тестировании.

В.4 Вычислительная инфраструктура

В.4.1 Инфраструктура обучения

Обучение проводится на кластере из четырёх GPU NVIDIA Tesla V100 с 32 ГБ памяти HBM2 каждый, соединённых через NVLink для мультиGPU параллелизма по данным. Хост-система предоставляет два CPU Intel Xeon Gold 6248 (40 ядер всего), 384 ГБ ОЗУ DDR4 и 4 ТБ NVMe SSD хранилище. Обучение со смешанной точностью через PyTorch AMP API (FP16 для прямого и обратного прохода, FP32 для обновления параметров) снижает потребление памяти приблизительно на сорок процентов, позволяя использовать батчи в $1,7\times$ крупнее, чем при обучении FP32. Распределённый параллелизм по данным с бэкэндом NCCL масштабирует обучение на четыре GPU с 92% эффективностью линейного масштабирования.

В.4.2 Вывод и симуляция развёртывания

Симуляция развёртывания использует одиночный GPU NVIDIA Tesla P100 с 16 ГБ памяти, отражая реалистичные ограничения периферийного развёртывания. Бенчмарки вывода используют модели, скомпилированные TorchScript, с размером батча 32 для измерений задержки и 512 для измерений пропускной способности. Все замеры времени представляют медиану ста независимых запусков с 95% доверительными интервалами, вычисленными бутстрап-ресемплингом. Энергопотребление измеряется через NVIDIA System Management Interface (`nvidia-smi`) с опросом потребляемой мощности с интервалом 100 мс при устойчивом выводе.

В.5 Протоколы оценки

В.5.1 Стратегия кросс-валидации

Стратифицированное разделение сохраняет пропорции классов в обучающей (70%), валидационной (15%) и тестовой (15%) выборках. Для темпоральных наборов данных (CIC-IoT-2023 и CSE-CICIDS2018) разделение

соблюдает хронологический порядок: первые 70% записей формируют обучающую выборку, следующие 15% — валидационную, последние 15% — тестовую, предотвращая темпоральную утечку. Для федеративных экспериментов каждый симулированный клиент получает непересекающийся раздел обучающей выборки, а гетерогенность распределения меток вводится через распределение Дирихле с параметром концентрации $\alpha = 0.5$.

В.5.2 Тестирование статистической значимости

Все сравнения методов представляют парные t -тесты по пяти случайным затравкам с коррекцией Бонферрони по числу сравнений. Результат объявляется статистически значимым на уровне $\alpha = 0.05$ после коррекции. Размеры эффекта представлены как d Коэна для количественной оценки практической значимости наряду со статистической значимостью. Доверительные интервалы для точности, F1 и AUC вычисляются через интервал оценки Вильсона; доверительные интервалы для задержки и пропускной способности вычисляются через перцентильные интервалы бутстрапа с 10 000 повторных выборок.

В.6 Доступность кода и данных

Полный исходный код, файлы конфигурации и обученные контрольные точки моделей для всех семи методов доступны в следующем репозитории: <https://github.com/rogerpanel/robustidps.ai> (архивирован под DOI: 10.5281/zenodo.19129512). Репозиторий включает автоматизированные скрипты загрузки и предобработки данных, конвейеры обучения и оценки для каждого метода, файлы конфигурации гиперпараметров в формате YAML и блокноты Jupyter для воспроизведения всех рисунков и таблиц Глав 4 и 5. Наборы данных CIC-IoT-2023 и CSE-CICIDS2018 общедоступны от Канадского института кибербезопасности. Набор данных UNSW-NB15 доступен от Университета Нового Южного Уэльса. Наборы данных коллекции ICS3D доступны от их соответствующих поддерживающих организаций по академическим лицензиям.

Приложение С

Дополнительные экспериментальные результаты

В данном приложении представлены дополнительные экспериментальные результаты, дополняющие анализ Главы 4 (Экспериментальные результаты и валидация). Раздел С.1 предоставляет покатегорийные разбивки производительности по типам атак. Раздел С.2 документирует детали покомпонентной абляции и исследования чувствительности к гиперпараметрам. Раздел С.3 представляет матрицы кросс-облачного и кросс-доменного переноса. Раздел С.4 анализирует компромисс приватность–качество детально. Раздел С.5 представляет бенчмарки вычислительной производительности и характеристики масштабирования.

С.1 Производительность по категориям атак

С.1.1 Детальные результаты CIC-IoT-2023

Таблица С.1 представляет покатегорийные прецизионность, полноту, F1 и AUC-ROC для CT-TGNN на CIC-IoT-2023. Все семь основных категорий превышают 95% полноты, при этом DDoS достигает наивысшей полноты 99,1% благодаря характерной объёмной сигнатуре, а атаки спуфинга демонстрируют наименьшую полноту 95,2%, поскольку протокольная имитация может близко воспроизводить легитимные паттерны аутентификации.

С.1.2 Детальные результаты CSE-CICIDS2018

Таблица С.2 представляет покатегорийную производительность единой системы на CSE-CICIDS2018. Единая система достигает наибольшего улучшения над базовыми линиями на инфильтрации (12,7 п. п. выше лучшей базовой линии), обнаружении ботнетов (9,3 п. п.) и эксплуатации Heartbleed (8,9 п. п.) — категориях, включающих многоэтапные, темпорально протяжённые последовательности атак, где формулировка непрерывного време-

Таблица С.1 – Покатегорийные результаты СТ-TGNN на CIC-IoT-2023.

Категория атак	Прецизионность	Полнота	F1	AUC-ROC
DDoS	98,7%	99,1%	98,9%	0,998
Разведка	96,2%	96,8%	96,5%	0,991
Веб-атаки	97,1%	97,3%	97,2%	0,993
Перебор	98,4%	98,6%	98,5%	0,997
Спуфинг	94,8%	95,2%	95,0%	0,987
ВПО	98,6%	98,9%	98,7%	0,998
Варианты Mirai	97,1%	97,4%	97,2%	0,994
Легитимный	98,9%	98,4%	98,7%	0,997

ни обеспечивает наибольшее преимущество.

Таблица С.2 – Покатегорийные результаты единой системы на CSE-CICIDS2018.

Категория атак	Прециз.	Полнота	F1	AUC	Δ vs. Базов.
Перебор (SSH)	95,3%	96,1%	95,7%	0,991	+3,8%
Перебор (FTP)	96,7%	97,3%	97,0%	0,994	+4,2%
DoS Hulk	97,8%	98,2%	98,0%	0,997	+2,1%
DoS GoldenEye	96,4%	96,9%	96,6%	0,993	+3,4%
DoS Slowloris	95,1%	95,7%	95,4%	0,989	+5,1%
Веб-атака (XSS)	93,8%	94,3%	94,1%	0,984	+6,7%
Веб-атака (SQL Inj.)	94,2%	94,8%	94,5%	0,986	+5,9%
Инфильтрация	91,7%	92,4%	92,0%	0,978	+12,7%
Ботнет (Ares)	93,1%	93,8%	93,4%	0,982	+9,3%
Heartbleed	92,3%	93,1%	92,7%	0,979	+8,9%
Сканирование портов	97,6%	98,1%	97,8%	0,996	+2,3%
DDoS LOIC	98,1%	98,4%	98,2%	0,998	+1,7%
Легитимный	97,4%	96,8%	97,1%	0,995	+2,4%

С.1.3 Детальные результаты UNSW-NB15

Таблица С.3 представляет покатегорийные результаты на UNSW-NB15. Единая система достигает наибольшего улучшения на атаках разведки (8,7 п. п.), где многомасштабное темпоральное моделирование захватывает медленные и скрытные паттерны сканирования, которые базовые линии дискретного времени систематически пропускают.

Таблица С.3 – Покатегорийные результаты единой системы на UNSW-NB15.

Категория атак	Прециз.	Полнота	F1	AUC	Δ vs. Базов.
Generic	96,8%	97,2%	97,0%	0,995	+3,2%
Exploits	94,7%	96,3%	95,5%	0,989	+5,4%
Fuzzers	93,2%	94,1%	93,6%	0,984	+4,8%
DoS	96,4%	97,1%	96,7%	0,993	+3,7%
Разведка	92,8%	97,9%	95,3%	0,988	+8,7%
Analysis	97,1%	98,4%	97,7%	0,996	+4,1%
Backdoors	91,9%	93,7%	92,8%	0,981	+6,3%
Shellcode	94,3%	95,8%	95,0%	0,987	+5,1%
Worms	89,7%	91,4%	90,5%	0,973	+7,2%
Нормальный	97,2%	96,4%	96,8%	0,994	+3,4%

С.1.4 Разбивка атак микросервисов TripleE-TGNN

Таблица С.4 представляет покатегорийную точность обнаружения TripleE-TGNN на наборе данных Container Security, разбитую по гранулярности, на которой каждая атака наиболее эффективно обнаруживается.

Таблица С.4 – Покатегорийная точность обнаружения TripleE-TGNN и доминирующая гранулярность.

Тип атаки	Точность	Домин. гранулярность	Одногран. точн.
Побег из контейнера	98,7%	Узел + Сервис	91,2%
Цепь поставок	97,3%	Сервис + Трассировка	89,8%
Исчерпание ресурсов	96,9%	Сервис + Узел	90,3%
Повышение привилегий	97,8%	Узел	93,1%
Злоупотребление API	95,4%	Сервис	91,7%
Латер. перемещение	96,1%	Трассировка + Узел	88,4%
Эксфльтрация данных	94,8%	Трассировка	87,6%
Криптоджекинг	97,2%	Узел	92,9%
Общий результат	96,8%	Многоуровневый	88,5%

С.2 Детали абляционного исследования

С.2.1 Покомпонентная абляция с доверительными интервалами

Таблица С.5 расширяет результаты абляции из Таблицы 3.12 основного текста 95% доверительными интервалами, вычисленными по пяти независимым запускам с различными случайными затравками. Все деградации статистически значимы после коррекции Бонферрони на уровне $\alpha = 0.05$.

Таблица С.5 – Расширенные результаты абляции с 95% доверительными интервалами (пять затравок).

Удалённый компонент	Полная система	Без компонента	d Коэна
НВ ОДУ	$98.3 \pm 0.2\%$	$91.5 \pm 0.4\%$	4,82
Многомасшт. моделиров.	$98.3 \pm 0.2\%$	$94.4 \pm 0.3\%$	3,14
Темпор. адапт. БН	$98.3 \pm 0.2\%$	$93.6 \pm 0.5\%$	3,67
Межгранул. внимание	$96.8 \pm 0.3\%$	$94.7 \pm 0.3\%$	2,41
Усеч. среднее $\rightarrow$ FedAvg	$89.7 \pm 0.4\%$	$68.3 \pm 1.2\%$	7,13
Дифф. приватность	$87.1 \pm 0.3\%$	$90.2 \pm 0.3\%$	−3,28
Выравнивание ОТ	$92.7 \pm 0.4\%$	$76.9 \pm 0.8\%$	5,92
Ветвь LLM (F1)	$87.6 \pm 0.5\%$	$34.2 \pm 1.1\%$	8,47
Прогресс. дистилляция	$91.4 \pm 0.3\%$	$81.7 \pm 0.6\%$	4,71
Вариант. внимание (ECE)	0.078 ± 0.004	0.192 ± 0.008	5,38
Теор.-игровое равновесие	$94.7 \pm 0.3\%$	$87.6 \pm 0.4\%$	4,18

С.2.2 Анализ чувствительности к гиперпараметрам

В данном разделе представлены анализы чувствительности для наиболее важных гиперпараметров каждого метода, при варьировании одного параметра при фиксации всех остальных на значениях по умолчанию.

С.2.2.1 СТ-TGNN: Допуск решателя ОДУ

Таблица С.6 представляет влияние допуска решателя ОДУ на точность, задержку вывода и число вычислений функции (NFE) на прямой проход. Более жёсткие допуски дают маргинальное улучшение точности, но существенно увеличивают вычислительную стоимость; допуск по умолчанию

10^{-5} обеспечивает лучший компромисс точность–эффективность.

Таблица С.6 – Чувствительность СТ-TGNN к относительному допуску решателя ОДУ.

Отн. допуск	Точность	Задержка (мс)	Ср. NFE
10^{-3}	97,6%	28	14
10^{-4}	98,1%	36	21
10^{-5} (по умолч.)	98,3%	47	31
10^{-6}	98,4%	72	48
10^{-7}	98,4%	118	73

С.2.2.2 FedLLM-API: Бюджет приватности и доля усечения

Таблица С.7 представляет влияние варьирования бюджета приватности на раунд ϵ на точность, общий расход приватности за 100 раундов и успех атаки вывода принадлежности. Значение по умолчанию $\epsilon = 0.85$ балансирует строгую приватность с допустимой деградацией точности.

Таблица С.7 – Чувствительность FedLLM-API к бюджету дифференциальной приватности ϵ .

ϵ	Точность	Общий ϵ_{100}	Атака ВП	Δ Точн. vs. Без-ДП
0,5	84,2%	5,0	51,3%	−7,0%
0,85 (по умолч.)	87,1%	8,5	52,7%	−3,1%
1,0	88,4%	10,0	54,1%	−1,8%
1,5	89,7%	15,0	57,8%	−0,5%
2,0	91,8%	20,0	62,4%	+1,6%
∞ (без ДП)	90,2%	∞	71,3%	0%

Таблица С.8 представляет точность при 30% византийских противников при варьировании доли усечения. Доли усечения ниже 20% не удаляют все византийские обновления, а доли выше 30% отбрасывают слишком много честных обновлений.

С.2.2.3 MambaShield: Температура дистилляции и размер ансамбля

Таблица С.9 представляет совместное влияние температуры дистилляции и размера ансамбля учителей на робастную точность при 25% отрав-

Таблица С.8 – Чувствительность FedLLM-API к доле усечения при 30% византийских противников.

Доля усечения	Точность (30% визант.)	Раунды сходим.
10%	72,4%	142
15%	81,3%	108
20% (по умолч.)	89,7%	78
25%	88,9%	82
30%	86,1%	91
35%	82,7%	104

ления. Температура 3.0 с пятью учителями даёт лучшую производительность; более низкие температуры порождают более резкие распределения, усиливающие шум меток, а большие ансамбли дают убывающую отдачу относительно их вычислительной стоимости.

Таблица С.9 – Чувствительность MambaShield к температуре дистилляции и размеру ансамбля (25% отравления).

Температура	3 учит.	5 учит.	7 учит.	10 учит.
$T = 1.0$	85,3%	86,7%	87,1%	87,3%
$T = 2.0$	88,4%	89,8%	90,1%	90,2%
$T = 3.0$ (по умолч.)	89,7%	91,4%	91,6%	91,7%
$T = 5.0$	88,1%	90,2%	90,5%	90,6%
$T = 10.0$	84,6%	87,3%	87,7%	87,8%

С.2.2.4 Стохастический трансформер: Выборки Монте-Карло

Таблица С.10 представляет влияние числа прямых проходов Монте-Карло на ЕСЕ, корреляцию эпистемической неопределённости с ошибкой предсказания и задержку вывода на батч. Ранняя остановка по сходимости дисперсии снижает эффективное число проходов до 18 в среднем.

Таблица С.10 – Чувствительность стохастического трансформера к числу прямых проходов МК.

Проходов МК	ЕСЕ	Корр. неопред.	Задержка (мс/батч)	Эфф. проходов
5	0,124	0,43	78	5
10	0,103	0,52	126	10
20	0,089	0,61	204	17
50 (по умолч.)	0,078	0,67	340	18
100	0,076	0,68	638	19

С.3 Кросс-облачный и кросс-доменный перенос

С.3.1 Матрица кросс-датасетного переноса

Таблица С.11 представляет точность СТ-TGNN при обучении на одном наборе данных (строки) и тестировании на другом (столбцы) без дообучения. Диагональные записи соответствуют производительности внутри распределения. Стабильно малая внедиагональная деградация, в среднем 3,8% по всем парам, подтверждает свойства обобщения формулировки темпоральных графов непрерывного времени.

Таблица С.11 – Точность кросс-датасетного переноса СТ-TGNN (%). Строки: обучающий набор; столбцы: тестовый набор.

Обуч. \ Тест	CIC-IoT	CICIDS18	UNSW-NB15
CIC-IoT-2023	98,3	92,7	91,4
CSE-CICIDS2018	91,8	96,7	89,3
UNSW-NB15	90,6	88,9	97,1

С.3.2 Кросс-доменный перенос на речь и здравоохранение

Таблица С.12 представляет детальные метрики для экспериментов кросс-доменного переноса, описанных в Разделе 4.2 основного текста, включая влияние предобучения на сетевой безопасности.

Таблица С.12 – Результаты кросс-доменного переноса с и без предобучения на сетевой безопасности.

Домен	Метод	Точность	F1	ECE	Предоб
Речь (LibriSpeech)	СТ-TGNN	90,4%	90,8%	0,091	Нез
Речь (LibriSpeech)	СТ-TGNN	94,2%	94,2%	0,073	Да
Речь (LibriSpeech)	LSTM базовая	86,9%	86,7%	0,142	Нез
Здравоохранение (MIMIC-III)	Стох. трансф.	86,1%	85,7%	0,098	Нез
Здравоохранение (MIMIC-III)	Стох. трансф.	89,7%	89,3%	0,082	Да
Здравоохранение (eICU)	Стох. трансф.	84,8%	84,2%	0,104	Нез
Здравоохранение (eICU)	Стох. трансф.	88,4%	87,9%	0,087	Да

С.4 Анализ компромисса приватность–качество

С.4.1 Влияние дифференциальной приватности по наборам данных

Таблица С.13 представляет деградацию точности, вызванную дифференциальной приватностью при $\epsilon = 0.85$, по всем трём основным наборам данных. Деградация стабильна по наборам данных, составляя от 2,8% до 3,4%, подтверждая, что компромисс приватность–качество не варьируется существенно с распределением данных.

Таблица С.13 – Влияние дифференциальной приватности на точность по наборам данных ($\epsilon = 0.85$, $\delta = 10^{-5}$).

Набор данных	Без ДП	С ДП	Деградация
CIC-IoT-2023	94,7%	91,6%	−3,1%
CSE-CICIDS2018	93,9%	91,1%	−2,8%
UNSW-NB15	93,8%	90,4%	−3,4%

С.4.2 Учёт приватности по раундам коммуникации

Таблица С.14 представляет кумулятивный расход приватности как функцию федеративных раундов коммуникации, вычисленный через моменты-бухгалтер с усилением пуассоновской подвыборкой. Общий бюджет $\epsilon_{\text{total}} = 8.5$ после 100 раундов остаётся в диапазоне, обычно считающемся приемлемым для чувствительных приложений.

Таблица С.14 – Кумулятивный расход приватности по федеративным раундам ($\delta = 10^{-5}$).

Раунды	10	25	50	75	100	150
ϵ_{total}	0,85	2,13	4,25	6,38	8,50	12,75
Точность	78,4%	84,1%	87,8%	88,6%	87,1%	86,3%

С.5 Метрики вычислительной производительности

С.5.1 Пропускная способность и задержка вывода

Таблица С.15 сравнивает пропускную способность вывода, задержку на образец, потребление памяти GPU и энергоэффективность по всем семи методам и базовым линиям. Измерения проведены на одиночном GPU NVIDIA Tesla P100 с размером батча 32 для задержки и размером батча 512 для пропускной способности, представляя медиану 100 запусков с 95% бутстрап-доверительными интервалами.

Таблица С.15 – Сравнение вычислительной производительности по методам (P100 GPU).

Метод	Пропуск. (тыс./с)	Задержка (мс)	Память (ГБ)	Вт/1
CT-TGNN	8,700	47	3,8	
TripleE-TGNN	4,200	73	4,7	
FedLLM-API	5,100	62	5,2	
Прямо совм. обнаруж.	6,800	38	2,1	
MambaShield	12,400	18	2,3	
Стох. трансформер	2,300	340	8,2	
Теор.-игровой	7,100	12	0,2	
LSTM базовая	4,300	38	1,8	
Стд. трансформер	6,200	55	4,1	
Random Forest	14,200	12	0,8	
XGBoost	18,700	8	0,6	

С.5.2 Масштабирование с размером входа

Таблица С.16 представляет зависимость задержки вывода от длины входной последовательности для СТ-TGNN, MambaShield и стандартного трансформера. СТ-TGNN масштабируется линейно через фиксированное число шагов решателя ОДУ на постоянную времени. MambaShield масштабируется линейно через механизм селективного сканирования. Стандартный трансформер масштабируется квадратично через самовнимание, становясь непрактичным для последовательностей длиннее приблизительно 4096 токенов на 16 ГБ GPU.

Таблица С.16 – Задержка вывода (мс) как функция длины последовательности.

Длина последоват.	256	512	1024	2048	4096
СТ-TGNN	23	41	74	142	278
MambaShield	8	14	26	49	94
Стд. трансформер	18	52	178	684	OOM

С.5.3 Время обучения и сходимость

Таблица С.17 представляет общее время обучения, число эпох до сходимости и время на эпоху для каждого метода на CIC-IoT-2023 с использованием четырёх V100 GPU с параллелизмом по данным.

Таблица С.17 – Сравнение времени обучения (четыре V100 GPU, CIC-IoT-2023).

Метод	Общее время (ч)	Эпохи	Время/Эпоху (мин)
СТ-TGNN	18,2	142	7,7
TripleE-TGNN	22,7	118	11,5
FedLLM-API	31,4	100 (раундов)	18,8
Прямо совм. обнаруж.	8,3	87	5,7
MambaShield	14,1	100	8,5
Стох. трансформер	24,6	96	15,4
Теор.-игровой	6,8	10,000 (раундов)	0,04

С.5.4 Сравнение размеров моделей

Таблица C.18 представляет общее число обучаемых параметров, размер сжатой модели после INT8 квантования и точность, сохранённую после квантования.

Таблица C.18 – Размер модели и влияние квантования.

Метод	Параметры (М)	FP32 (МБ)	INT8 (МБ)	INT8 Точн.
СТ-TGNN	12,3	47	13	97,9%
TripleE-TGNN	18,7	71	19	96,2%
FedLLM-API	24,1	92	25	86,4%
Прямо совм. обнаруж.	6,8	26	7	95,8%
MambaShield	8,4	32	9	90,9%
Стох. трансформер	31,2	119	31	93,4%
Стд. трансформер	47,8	182	47	90,8%